列表

批注

模型评估与选择

内容分析	**模型评估与选择是机器学习中至关重要的一步。我们首先介绍了经验误差和过拟合的概念，了解了模型在训练数据上的误差和在新数据上的泛化能力之间的关系。然后，我们探讨了几种常用的评估方法，包括留出法交叉验证法和自助法，它们能够帮助我们评估模型的性能并选择最佳模型。我们还介绍了多种性能度量指标，如错误率、精查准率、查全率、P-R曲线、F1、ROC曲线和AUC，以帮助我们全面评估模型的性能。此外，我们学习了比较检验方法，如交叉验证t检验和McNemar检验，用于比较不同模型之间的性能差异。最后，我们讨论了偏差和方差的权衡，以及如何在两者之间找到平衡点，以提高模型的泛化能力。通过这些内容，我们能够全面了解模型评估与选择的关键概念和为后续学习和实践打下坚实基础。**
教学目的及要求	了解经验误差与过拟合；了解模型评估的基本方法；了解模型性能度量和比较检验；了解泛化误差的分解。
重点	教学重点：评估方法、性能度量、比较检验。
难点	教学难点：评估方法、性能度量、比较检验
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

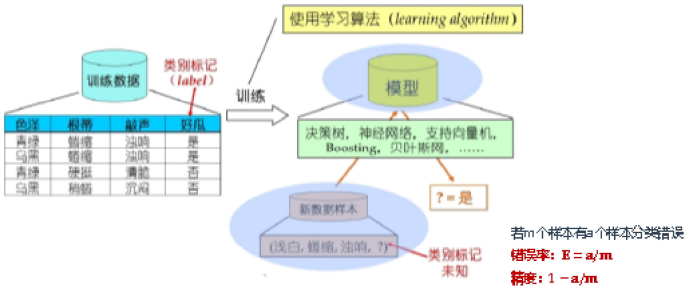
课程知识点

模型评估与选择

1. 经验误差与过拟合

本知识点主要教学目的：让学生了解泛化误差、经验误差、欠拟合和过拟合。

1.1 典型的机器学习过程



1.2 泛化误差 vs. 经验误差

泛化误差（Generalization Error）：泛化误差是指模型在新的、未见过的数据上的误差。它是衡量模型在实际应用中的性能表现。泛化误差可以型的泛化能力，即模型对未知数据的适应能力。泛化误差是我们真正关心的指标，因为我们希望模型能够在新数据上表现良好。

经验误差（Empirical Error）：经验误差是指模型在训练数据上的误差，也称为训练误差。它是通过将模型应用于已知标签的训练数据来计算得差可以衡量模型在训练数据上的拟合程度，但并不能直接反映模型在新数据上的表现。

我们希望得到泛化误差小的学习器。然而，我们事先并不知道新样本是什么样，实际能做的是努力使经验误差最小化，在很多情况下，我们可以学差很小，在训练集上表现很好的学习器，例如甚至对所有训练样本都分类正确，即分类错误率为零，分类精度为100%，但这是不是我们想要的学的是，这样的学习器在多数情况下都不好。

我们实际希望的，是在新样本上能表现得很好的学习器。为了达到这个目的，应该从训练样本中尽可能学出适用于所有潜在样本的“普通规律”，到新样本时做出正确的判别。然后，当学习器把训练样本学的“太好”了的时候，很可能已经把训练样本自身的一些特点当作了所有潜在样本都会质，这样就会导致泛化性能下降。这种现象在机器学习中称为“过拟合”。

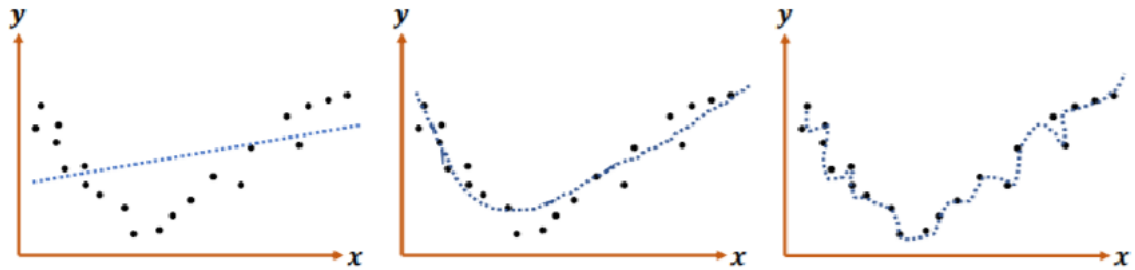
1.3 过拟合(overfitting) vs. 欠拟合(underfitting)



图 2.1 过拟合、欠拟合的直观类比

过拟合：模型在训练数据上表现得过于好，但在新数据上的表现较差。过拟合通常发生在模型过于复杂或训练数据过少的情况下。当模型过度拟合噪声或细节时，它可能会捕捉到训练数据中的特定模式和关联，而无法泛化到新数据。过拟合的特点是模型在训练数据上的误差较低，但在测试数高。

欠拟合：模型无法很好地拟合训练数据，无法捕捉到数据中的关键模式和关联。欠拟合通常发生在模型过于简单或训练数据不足的情况下。当模型足以捕捉到数据的复杂性时，它可能会产生较大的训练误差和测试误差。欠拟合的特点是模型在训练数据和测试数据上的误差都较高。



有多种因素可能导致过拟合，其中最常见的情况是由于学习能力过于强大，以至于把训练样本所包含的不太一般的特性都学到了，而欠拟合则通常力低下造成的。欠拟合比较容易克服，而过拟合则很麻烦。过拟合是机器学习面临的关键障碍，各类学习算法都必然带有一些针对过拟合的措施；到，过拟合是无法彻底避免的，我们所能做的只是“缓解”，或者说减小其风险。

2. 评估方法

本知识点主要教学目的：让学生了解三种常用的模型评估方法。

2.1 模型选择

模型选择，三个关键问题：

1.如何获得测试结果？评估方法：在模型选择中，我们需要对不同的模型进行评估，以获得它们在未见过的测试数据上的性能结果。

2.如何评估性能优劣？性能度量：为了评估模型的性能优劣，需要选择合适的性能度量指标。

3.如何判断实质差别？比较检验：在模型选择过程中，我们需要判断不同模型之间的实质差别，即它们在性能上是否有显著差异。

2.2 评估方法

我们可以通过试验测试对学习器的泛化误差进行评估并进而做出选择，以测试集上的“测试误差”作为泛化误差的近似。

通常我们假设测试样本也是从样本真实分布中独立同分布采样而得。但需注意的是，测试集应该尽可能与训练集互斥，即测试样本尽量不在训练集训练过程中使用过。

1.留出法

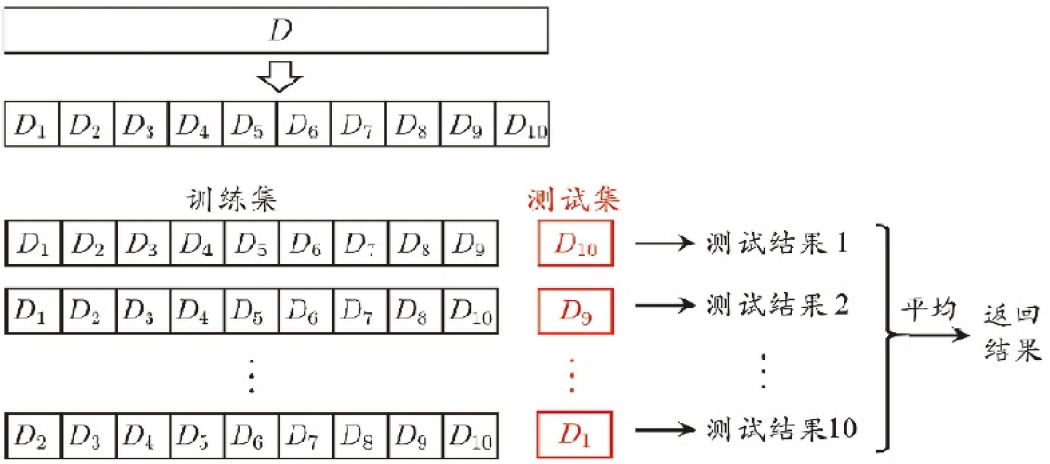
“留出法”直接将数据集D划分为两个互斥的集合S和T，即$D = S \cup T, S \cap T = \phi$。在S上训练出模型后，用T来评估其测试误差，作为泛化误差的估计

需要注意的是，训练/测试集的划分要尽可能保持数据分布的一致性，避免因数据划分过程引入额外的偏差而对最终结果产生影响。

另一个需注意的问题是，即便在给定训练/测试集的样本比例后，仍存在多种划分方式对初始数据集D进行分割，这些不同的划分将导致不同的训练应的，模型评估的结果也会有差别。因此单次使用留出法得到的估计结果往往不够稳定可靠，在使用留出法时，一般要采用若干次随机划分、重复后取平均值作为留出法的评估结果。

2.交叉验证法

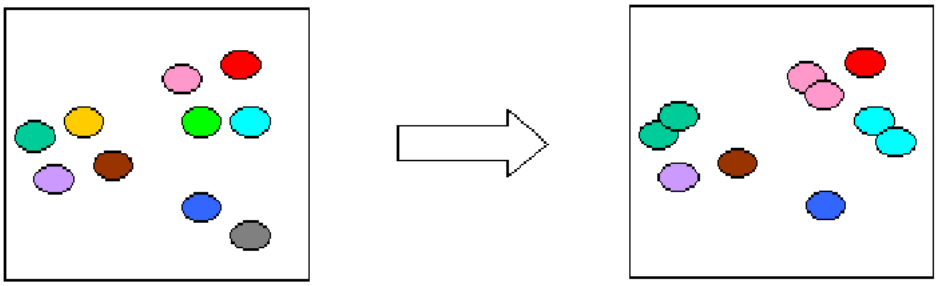
将数据集D划分为k个大小相似的互斥子集，即



每个子集 D_i 都尽可能保持数据分布的一致性，即从D中通过分层采样得到。然后每次用k-1个子集的并集作为训练集，余下的那个子集作为测试集得k组训练/测试集，从而可进行k次训练和测试，最终返回的是这k个测试结果的均值。

3.自助法

直接以自助采样法(Bootstrap Sampling)为基础的“有放回采样”、“可重复采样”。



给定m个样本的数据集D，问对它进行采样产生数据集D'：每次随机从D中挑选一个样本，将其拷贝放入D'，然后再将该样本放回初始数据集D中本在下次采样时仍有可能被采到；这个过程重复执行m次后，我们就得到了包含m个样本的数据集D'，这就是自助采样的结果。显然D中有一部分D'中多次出现，而另一部分样本不出现，初始数据集D中约有36.8%的样本未出现在采样数据集D'中。

2.3调参与最终模型

调参是指在机器学习中通过调整模型的超参数来优化模型性能的过程。超参数是在模型训练之前设置的参数，不会通过训练数据自动学习得到，而定的。调参的目标是找到最佳的超参数组合，以达到性能最优的模型。

给定包含m个样本的数据集D，在模型评估与选择过程中由于需要留出一部分数据进行评估测试，事实上我们只使用了一部分数据训练模型。因此完成后，学习算法和参数配置已选定，此时应该用数据集D重新训练模型。这个模型在训练过程中使用了所有m个样本，这才是我们最终提交给用

3. 性能度量

本知识点主要教学目的：让学生掌握模型的性能度量。

性能度量(Performance Measure)是衡量模型泛化能力的评价标准，反映了任务需求，在对比不同模型的能力时，使用不同的性能度量往往会导致结果；这意味着模型的“好坏”是相对的，什么样的模型是好的，不仅取决于算法和数据，还决定于任务需求。

回归(Regression) 任务最常用的性能度量是均方误差：

$$E(f;D) = \frac{1}{m}\sum_{i=1}^{m}(f(x_i)-y_i)^2$$

3.1 错误率 vs. 精度

错误率：分类问题中，错误预测的样本数占总样本数的比例。

精度：分类问题中，正确预测的样本数占总样本数的比例。

错误率：

$$\sum_{i=1}^{m}$$

精度：

$$acc(f;D) = \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}(f(x_i)=y_i) = 1-E(f;D)$$

3.2 查准率 vs. 查全率

表 2.1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP（真正例）	FN（假反例）
反例	FP（假正例）	TN（真反例）

对于二分类问题，可将样例根据其真实类别与学习器预测类别的组合划分为真正例（TP）、假正例（FP）、真反例（TN）、假反例（FN）四种情
P+FP+TN+FN=样例总数。

查准率：

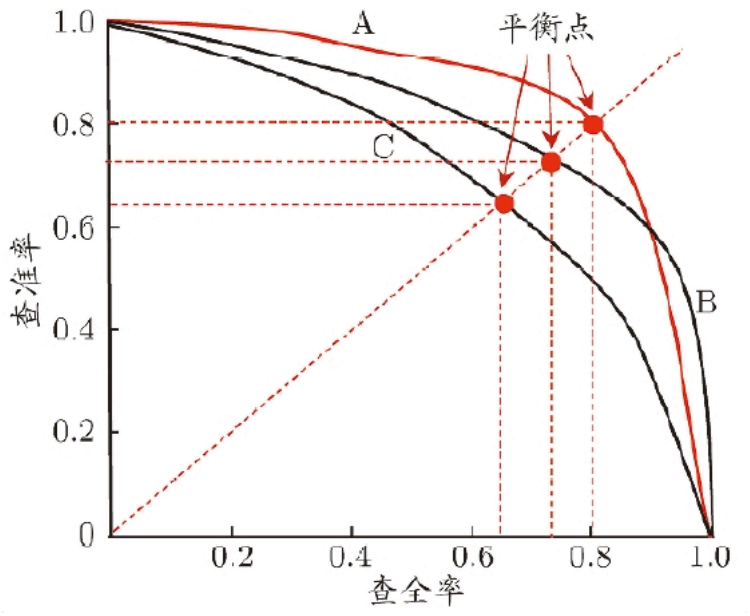
$$P = \frac{TP}{TP+FP}$$

查全率：

$$R = \frac{TP}{TP+FN}$$

查准率和查全率是一对矛盾的度量，一般来说查准率高时，查全率往往偏低；而查全率高时，查准率往往偏低。

3.3 P-R曲线



很多情形下，我们可根据学习器的预测结果对样例进行排序，排在前面的是学习器认为“最可能”是正例的样本，排在最后的则是学习器认为“最
例的样本。按此顺序逐个把样本作为正例进行预测，则每次可以计算出当前的查全率、查准率。以查准率为纵轴、查全率为横轴作图，就得到了查
曲线，简称“P-R曲线”。

情形下，人们往往仍希望把学习器A与B比出个高低。这时一个比较合理的判据是比较P-R曲线下面积的大小，但是这个值不太容易估算。

平衡点（BEP）是“查准率=查全率”时的取值。基于平衡点的比较，可认为学习器A优于学习器B。

3.4 F1度量

比 BEP 更常用的 F1 度量：

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{样例总数 + TP - TN}$$

在一些应用中，对查准率和查全率的重视程度有所不同。F1度量的一般形式——F_β，能让我们表达出对查准率/查全率的不同偏好。

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

其中β>0度量了查全率对查准率的相对重要性。β=1时退化为标准的F1；β>1时查全率有更大影响；β<1时查准率有更大影响。

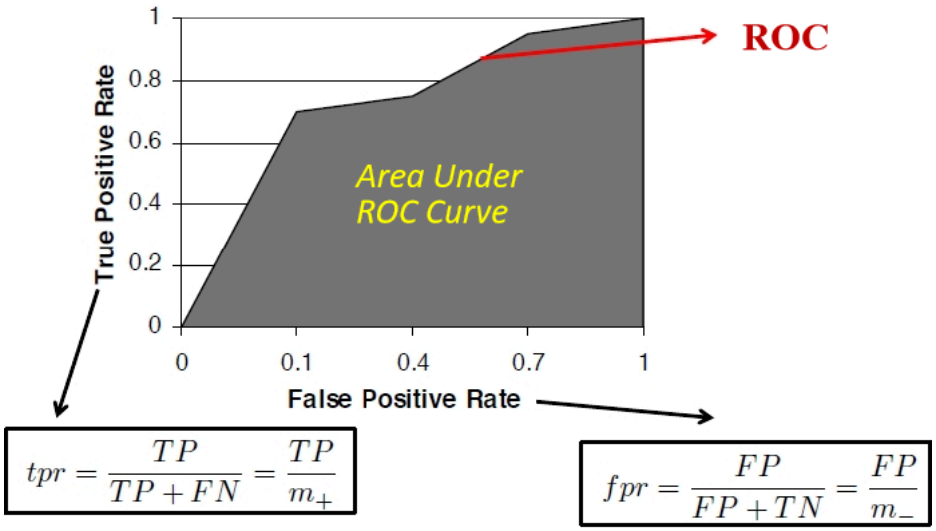
3.5 宏xx vs. 微xx

很多时候我们有多个二分类混淆矩阵，例如进行多次训练/测试，每次得到一个混淆矩阵；或是在多个数据集上进行训练/测试，希望估计算法的‘
亦或是执行多分类任务，每两两类别的组合都对应一个混淆矩阵...总之，我们希望在n个二分类混淆矩阵上综合考察查准率和查全率。

一种直接的做法是先在各混淆矩阵上分别计算出查准率和查全率，再计算平均值，这样就得到“宏查准率”、“宏查全率”，以及相应的“宏F1”

还可先将各混淆矩阵的对应元素进行平均，再基于这些平均值计算出“微查准率”、“微查全率”和“微F1”。

3.6 ROC&AUC



$$tpr = \frac{TP}{TP + FN} = \frac{TP}{m_+}$$

$$fpr = \frac{FP}{FP + TN} = \frac{FP}{m_-}$$

与P-R曲线相似，我们根据学习器的预测结果对样例进行排序，按此排序逐个把样本作为正例进行预测，每次计算出两个重要量的值（真正例率TP
FPR），分别以它们为横、纵坐标作图，接到了“ROC曲线”。

若两个学习器ROC曲线发生交叉，比较ROC曲线下的面积，即AUC。

$$\mathrm{AUC} - 1 - \frac{1}{m^+ m^-} \sum_{x^+ \in D^+} \sum_{x^- \in D^-} \left(\mathbb{I}\left(f(x^+) < f(x^-)\right) + \frac{1}{2} \mathbb{I}\left(f(x^+) = f(x^-)\right) \right)$$

3.7 非均等代价

犯不同的错误往往会造成不同的损失。为权衡不同类型错误所造成的不同损失，可为错误赋予“非均等代价”(unequal cost)。

真实类别	预测类别	
	第 0 类	第 1 类
第 0 类	0	$cost_{01}$
第 1 类	$cost_{10}$	0

以二分类任务为例，我们可根据任务领域知识设定一个“代价矩阵”，如上表所示，其中$cost_{ij}$表示将第i类样本预测为第j类样本的代价。一般来说，将第0类别判别为第1类所造成的损失更大，则$cost_{01} > cost_{10}$；损失程度相差越大，$cost_{01}$与$cost_{10}$值的差别越大。

在非均等代价下，我们所希望的不再是简单地最小化错误次数，而是希望最小化“总体代价”。若将上表中第0类作为正类，第1类作为反类，令D表样例集D的正例子集和反例子集，则代价敏感错误率为：

$$E(f;D;cost) = \frac{1}{m}\left(\sum_{x_i \in D^+} \mathbb{I}(f(x_i) \neq y_i) \times cost_{01} + \sum_{x_i \in D^-} \mathbb{I}(f(x_i) \neq y_i) \times cost_{10}\right)$$

4. 比较检验

本知识点主要教学目的：让学生了解常用的机器学习性能比较方法。

在某种度量下取得评估结果后，是否可以直接比较用以评判优劣？

NO！因为：

① 我们希望比较的是泛化性能，然而通过试验评估方法我们获得的是测试上的性能，两者的对比结果可能未必相同。

② 测试集上的性能与测试集本身的选择有很大关系，且不论使用不同大小的测试集会得到不同的结果，即便使用相同大小的测试集，若包含的测试测试结果也会不同。

③ 很多机器学习算法本身有一定的随机性，即便用相同的参数设置在同一个测试集上多次运行，其结果也会有不同。

统计假设检验为我们进行学习器性能比较提供了重要依据。基于假设检验结果问题可推断出，若在测试集上观察到学习器A比B好，则A的泛化性能意义上优于B，以及这个结论的把握有多大。

4.1 假设检验

假设检验中的“假设”是对学习器泛化错误率 $\epsilon\epsilon$ 分布的某种判断或猜想。

包含m个样本的测试集上，泛化错误率为 $\epsilon\epsilon$ 的学习器被测得测试错误率为 $\hat{\epsilon}\epsilon$

的概率：

$$P(\hat{\epsilon};\epsilon) = \binom{m}{\hat{\epsilon} \times m} \epsilon^{\hat{\epsilon} \times m}(1-\epsilon)^{m-\hat{\epsilon} \times m}$$

$P\left(\hat{\epsilon};\epsilon\right)$P(ϵ

;ϵ) 在$\epsilon\epsilon=\hat{\epsilon}\epsilon$

时最大，若$\hat{\epsilon}\epsilon$

=0.3，如下图所示：

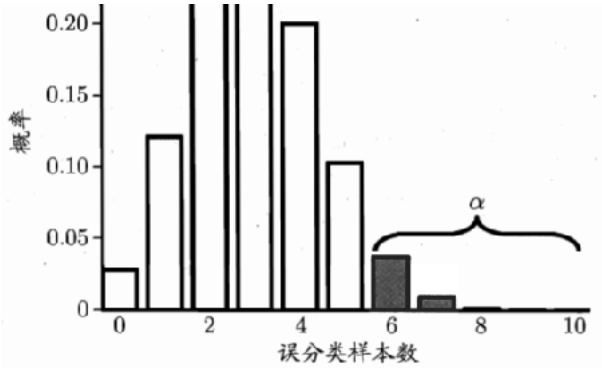


图 2.6 二项分布示意图($m = 10, \epsilon = 0.3$)

根据二项检验：在α的显著度下可认为学习器的泛化错误大于0.3。

4.2 两学习器比较

交叉验证 t 检验 (基于成对 t 检验)结合了交叉验证和t检验的思想，用于判断两个学习器的性能差异是否显著。

通过交叉验证t检验，可以对两个学习器在给定任务上的性能差异进行统计判断。这样可以更客观地评估不同学习器之间的性能差异，并选择性能更
器。需要注意的是，交叉验证t检验的结果仅适用于给定的数据集和评估指标，对于其他数据集和指标可能不适用。此外，还需要确保数据的独立性
的满足性，以保证检验结果的可靠性。

McNemar 检验 (基于列联表，卡方检验)是一种用于比较两个分类器在二分类问题上性能差异的统计检验方法。它基于分类器在交叉表中的错误分
计算卡方统计量来判断两个分类器之间的显著差异。

4.3 多学习器比较

比较多个学习器在多个任务上性能差异的统计检验方法：

Friedman检验：基于学习器在不同任务上的排名，通过计算卡方统计量来判断性能差异的显著性。Friedman检验的零假设是多个学习器的性能没
异。

如果Friedman检验的结果显示多个学习器存在显著差异，那么可以使用Nemenyi后续检验来进行多个学习器之间两两比较。Nemenyi后续检验基
间的平均排名差异，通过计算临界值来判断两个学习器之间的显著差异。如果两个学习器的平均排名差异大于临界值，则可以认为它们的性能差异

Friedman 检验图：横轴为平均序值，每个算法圆点为其平均序值，线段为临界阈值的大小。

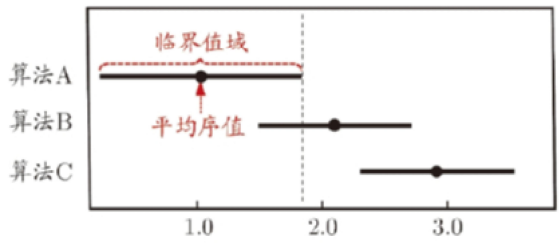


图 2.8 Friedman 检验图

若两个算法有交叠 (A 和 B)，则说明没有显著差别；

否则有显著差别 (A 和 C)，算法 A 显著优于算法 C。

5. 偏差与方差

本知识点主要教学目的：让学生了解机器学习的具体应用场景。

测试样本x，y_D为x的在数据集中的标记，y为x的真实标记，f(x;D)为训练集D上学得模型f在x上的预测输出，学习算法期望预测为：

$$\bar{f}(x) = \mathbb{E}_D[f(x; D)]$$

偏差：偏差是指学习算法在不同训练集上的预测结果与真实结果之间的差异。它衡量了学习算法对问题的简化程度和对训练数据的拟合能力。高偏
对问题的拟合不足，可能会导致欠拟合。

方差：方差是指学习算法在不同训练集上的预测结果之间的差异。它衡量了学习算法对训练数据的敏感程度和对噪声的拟合能力。高方差意味着算过于敏感，可能会导致过拟合。

$$var(x) = \mathbb{E}_D[(f(x;D) - \bar{f}(x))^2]$$

列表

噪声：噪声是指问题本身的随机性和不确定性所引入的误差。它是无法通过学习算法来消除的部分，因为噪声是问题固有的属性。

批注

$$\varepsilon^2 = \mathbb{E}_D[(y_D - y])^2]$$

5.1 偏差-方差分解

对回归任务，泛化误差可通过“偏差-方差分解”拆解为：

$$E(f;D) = bias^2(\boldsymbol{x}) + var(\boldsymbol{x}) + \varepsilon^2$$

期望输出与真实输出的差别

$$bias^2(\boldsymbol{x}) = \left(\bar{f}(\boldsymbol{x}) - y\right)^2$$

同样大小的训练集的变动，所导致的性能变化

$$var(\boldsymbol{x}) = \mathbb{E}_D\left[\left(f(\boldsymbol{x};D) - \bar{f}(\boldsymbol{x})\right)^2\right]$$

表达了当前任务上任何学习算法所能达到的期望泛化误差下界

$$\varepsilon^2 = \mathbb{E}_D\left[(y_D - y)^2\right]$$

偏差-方差分解说明，泛化性能是由学习算法的能力、数据的充分性以及学习任务本身的难度共同决定。给定学习任务，为了取得好的泛化性能，小，即使得数据扰动产生的影响较小。

5.2 偏差-方差窘境

一般来说偏差与方差是有冲突的，这称为偏差-方差窘境(bias-variance dillema)。

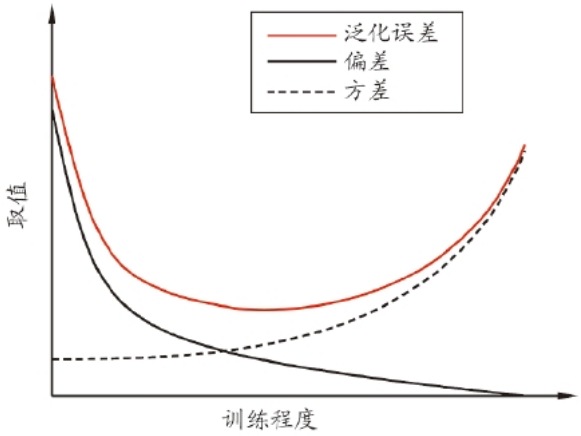


图 2.9 泛化误差与偏差、方差的关系示意图

给定学习任务，假定我们能控制学习算法的训练程度，则在训练不足时，学习器的拟合能力不够强，训练数据的扰动不足以使学习器产生显著变化导了泛化错误率；随着训练程度的加深，学习器的拟合能力逐渐增强，训练数据发生的扰动渐渐能被学习器学习到，方差逐渐主导了泛化错误率；足后，学习器的拟合能力已非常强，训练数据发生的轻微扰动都会导致学习器发生显著变化，若训练数据自身的，非全局的特性被学习器学到了，合。