列表

批注

线性模型

备课材料

OracleWDP•华育兴业

内容分析	线性模型是机器学习中常用的方法之一。线性回归通过参数估计建立输入与输出的线性关系，多元线性回归适用于多个特征而对数线性回归用于二元分类问题。对数几率回归是一种常用的分类算法，通过参数求解估计类别概率。 线性判别分析通过求解最佳投影方向w将样本投影到低维空间，可用于数据降维和分类。多分类学习可采用拆分策略、一对一对其余或多对多方法。类别不平衡问题常见于样本数量不平衡的情况，可通过再缩放、过采样、欠采样和阈值移动等方法这些方法为线性模型的应用和评估提供了基础。
教学目的及要求	了解线性回归分析；了解对数几率回归分析；了解线性判别分析原理；了解多分类学习如何拆解；了解类别不平衡问题处理
重点	教学重点：线性回归、线性判别分析、类别不平衡。
难点	教学难点：线性回归、线性判别分析
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

课程知识点

线性模型

线性回归

本知识点主要教学目的：让学生了解线性回归模型、参数拟合和广义线性模型。

线性模型

线性模型(linear model)试图学得一个通过属性的线性组合来进行预测的函数，即：

$$f(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + \ldots + w_d x_d + b$$

向量形式：$f(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} + b$

线性模型形式简单、易于建模，但却蕴含着机器学习中一些重要的基本思想。许多功能更为强大的非线性模型可在线性模型的基础上通过引入层级射而得。此外，由于w直观表达了各属性在与测中的重要性，因此线性模型有很好的可解释性。

线性回归

线性回归(linear regression)试图学得一个线性模型以尽可能准确地预测实值输出标记。

$$f(x_i) = wx_i + b，\ 使得 f(x_i) \simeq y_i$$

如何确定w和b呢?

均方误差是回归任务中最常用的性能度量，因此我们可视图让均方误差最小化。

$$\begin{aligned}(w^*, x^*) &= \arg\min_{(w,b)} \sum_{i=1}^{m} (f(x_i) - y_i)^2 \\ &= \arg\min_{(w,b)} \sum_{i=1}^{m} (y_i - wx_i - b)^2\end{aligned}$$

使$E_{(w,b)} = \sum_{i=1}^{m} (y_i - wx_i - b)^2$最小化的过程，称为线性回归模型的最小二乘参数估计。

$$\frac{\partial E_{(w,b)}}{\partial w} = 2\left(w\sum_{i=1}^{m} x_i^2 - \sum_{i=1}^{m}(y_i - b)x_i\right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2\left(mb - \sum_{i=1}^{m}(y_i - wx_i)\right)$$

令导数为 0, 得到闭式(closed-form)解：

$$w = \frac{\sum_{i=1}^{m} y_i(x_i - \bar{x})}{\sum_{i=1}^{m} x_i^2 - \frac{1}{m}\left(\sum_{i=1}^{m} x_i\right)^2}, b = \frac{1}{m}\sum_{i=1}^{m}(y_i - wx_i)$$

其中$\bar{x} = \frac{1}{m}\sum_{i=1}^{m} x_i$为$x$的均值

多元线性回归

对于给定(x\ = (x_{1};x_{2};...x_{d}))，其中(x_{i})是在第i个属性上的取值，此时我们试图学得：

$$f(x_i) = wx_i + b，使得 f(x_i) \simeq y_i$$

这称为“多元线性回归“（multivariate linear regression）。

把w和b吸收入向量形式$\hat{w} = (w, b)$

$$\boldsymbol{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^T & 1 \\ \boldsymbol{x}_2^T & 1 \\ \vdots & \vdots \\ \boldsymbol{x}_m^T & 1 \end{pmatrix}, \boldsymbol{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

同样采用最小二乘法求解，有

$$\hat{\boldsymbol{w}}^* = \arg\min_{\hat{\boldsymbol{w}}} (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})^T(\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})$$

令$E_{\hat{w}} = (\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})^T(\boldsymbol{y} - \boldsymbol{X}\hat{\boldsymbol{w}})$,对$\hat{\boldsymbol{w}}$求导：

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\boldsymbol{X}^T(\boldsymbol{X}\hat{\boldsymbol{w}} - \boldsymbol{y})$$

- 若$\boldsymbol{X}^T\boldsymbol{X}$满秩或正定，则$\hat{\boldsymbol{w}}^* = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{y}$
- 若$\boldsymbol{X}^T\boldsymbol{X}$不满秩，则可解出多个$\hat{\boldsymbol{w}}^*$
  - 此时需求助于归纳偏好，或引入正则化

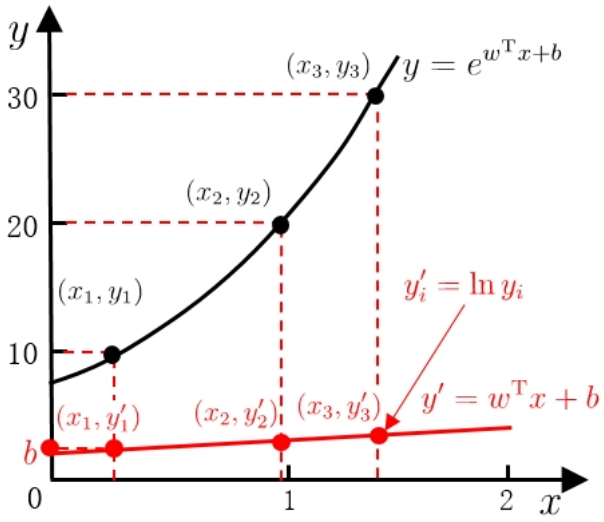
对数线性回归

对于样例((x,y),y \in {\mathbb{R}})若希望线性模型的预测值逼近真实标记，则得到线性回归模型(y\ = \ w^{T}x + b)

可否令模型预测值逼近y的衍生物呢？譬如说，假设我们认为示例所对应的输出标记是指在指数尺度上变化，那就可将输出标记的对数作为模型逼
即：

得到对数线性回归(log-linear regression)

实际是在用$e^{w^T x+b}$逼近y



广义线性模型

一般形式：

$$y = g^{-1}(w^T x + b)$$

g(·)：单调可微的联系函数

得到的模型称为广义线性模型(generalized linear model)

对数线性回归是广义线性模型在g(·) = ln(·)时的特例。

对于样例((x,y),y \in {\mathbb{R}})若希望线性模型的预测值逼近真实标记，则得到线性回归模型(y\ = \ w^{T}x + b)

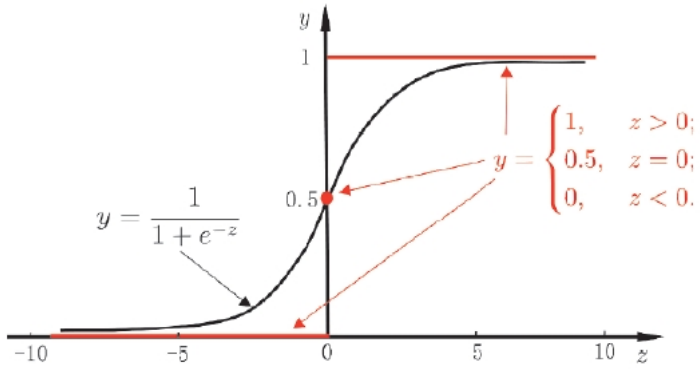
对数几率回归

本知识点主要教学目的：让学生了解对数几率回归模型和参数求解。

二分类任务

考虑二分类任务，其输出标记y∈{0,1}，而线性回归模型产生的预测值(z = \ w^{T}x + b)是实值。于是，我们需将实值z转换为0/1值。最理想的是“单位阶跃函数”：

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$



$$y = \frac{1}{1+e^{-z}}$$

对数几率回归

对数几率函数作为(g^{- 1}(\bullet))代入y = (g^{- 1})((w^{T}x + b))得：

$$y = \frac{1}{1 + e^{-(\boldsymbol{w}^T\boldsymbol{x}+b)}}$$

若将y视为样本x作为正例的可能性，则1-y是其反例可能性，两者的比值(\frac{y}{1 - y})称为“几率”，反映了x作为正例的相对可能性。

对几率取对数则得到“对数几率”

[\ln\frac{y}{1 - y}]

对应的模型称为“对数几率回归”。特别需注意到，虽然它的名字是“回归”，但实际确实一种分类学习方法。

这种方法有很多优点，例如它是直接对分类可能性进行建模，无需事先假设数据分布，这样就避免了假设分布不准确所带来的问题；它不是仅预测而是可得到近似概率预测，这对许多需利用概率辅助决策的任务很有用；此外，对率回归求解的目标函数是任意阶可导的凸函数，有很好的数学性多数值优化算法都可直接用于求取最优解

对数几率回归-参数求解

如何确定w和b?

将 y 看作类后验概率估计p(y=1 | x)

$$\ln\frac{y}{1-y} = \boldsymbol{w}^T\boldsymbol{x} + b \Longrightarrow \ln\frac{p(y=1\mid x)}{p(y=0\mid x)} = \boldsymbol{w}^T\boldsymbol{x} + b$$

于是，我们可以通过“极大似然法”来估计w和b，给定数据集$\{(\boldsymbol{x}_i, y_i)\}_{i=1}^m$，对率回归模型最大化“对数似然”。

$$\ell(\boldsymbol{w}, b) = \sum_{i=1}^{m} \ln p(y_i|\boldsymbol{x}_i; \boldsymbol{w}, b)$$

令β = (w,b),(\widehat{x} = \ (x;1))，则(w^{T}x)+b可简写为(\beta^{T}x)^

再令$p_1(\hat{\boldsymbol{x}}; \boldsymbol{\beta}) = p(y=1\mid \hat{\boldsymbol{x}}; \boldsymbol{\beta}); p_0(\hat{\boldsymbol{x}}; \boldsymbol{\beta}) = p(y=0\mid \hat{\boldsymbol{x}}; \boldsymbol{\beta}) = 1 - p_1(\hat{\boldsymbol{x}}; \boldsymbol{\beta})$

$$\ell(\boldsymbol{w}, b) = \sum_{i=1}^{m} \ln p(y_i|\boldsymbol{x}_i; \boldsymbol{w}, b)$$

$$= \sum_{i=1}^{m} \ln(y_i p_1(\hat{\boldsymbol{x}}; \boldsymbol{\beta}) + (1 - y_i) p_0(\hat{\boldsymbol{x}}; \boldsymbol{\beta}))$$

最大化似然函数ℓ(w,b)就等价于等价为最小化ℓ(β)

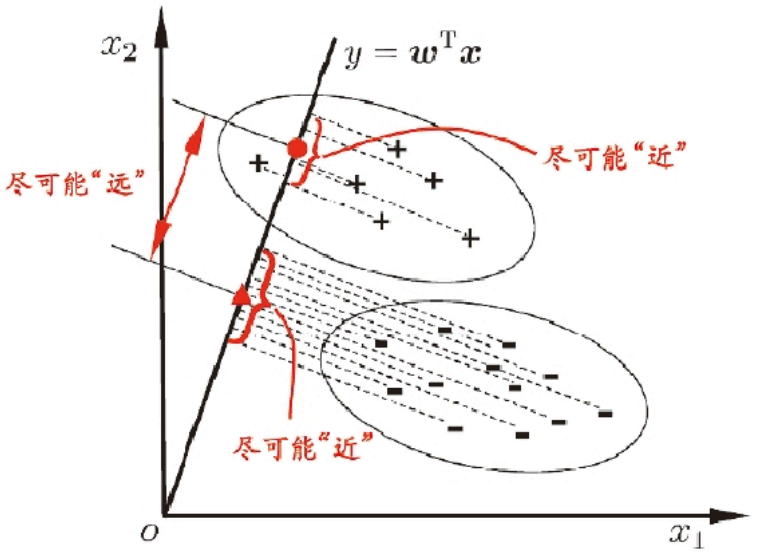
$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{m} \left(- y_i \boldsymbol{\beta}^T \hat{\boldsymbol{x}}_i + \ln(1 + e^{\boldsymbol{\beta}^T \hat{x}_i}) \right)$$

线性判别分析

本知识点主要教学目的：让学生了解线性判别分析原理和求解最佳投影方向。

线性判别分析(LDA)

其投影到同样的这条直线上，再根据投影点的位置来确定新样本的类别。



求解最佳投影方向w

针对二分类数据，求解最佳投影方向$\boldsymbol{w}^*$的一般步骤为：

1.把来自两类的训练样本集D $= \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{m}$ 划分为2个子集X_0和X_1

2.计算各类的均值向量μ_i, $i = 0,1$; $\mu_i = \frac{1}{N_i}\sum_{x \in X_i} x$;

3.计算各类的类内离散矩阵S_{wi}, $i = 0,1$; $S_{wi} = \sum_{x \in X_i}(x - \mu_i)(x - \mu_i)^T$;

4.计算类内总离散矩阵$S_w = S_{w0} + S_{w1}$;

5.计算矩阵S_w的逆矩阵S_w^{-1}

6.求出向量$\boldsymbol{w}^* = S_w^{-1}(\mu_1 - \mu_0)$ **(拉格朗日乘子法求解出)** ;

7.判别函数为y $= \boldsymbol{w}^{*T}x$;

8.判别函数的阈值w_0可采用以下两种方法确定：

- $w_0 = \frac{w^{*T}\mu_0 + w^{*T}\mu_1}{2}$;
- $w_0 = \frac{N_0 w^{*T}\mu_0 + N_1 w^{*T}\mu_1}{N_0 + N_1}$;

9.分类规则；比较y值与阈值w_0的大小，得出其分类。

推广到多类（N类）

- 全局散度矩阵

$$S_t = \sum_{i=1}^{m} (x_i - \mu)(x_i - \mu)^T$$

- 类内散度矩阵

$$S_w = \sum_{i=1}^{N} \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^T$$

- 类间散度矩阵

$$S_b = \sum_{i=1}^{N} m_i(\mu_i - \mu)(\mu_i - \mu)^T$$

多分类LDA有多种实现方法：使用S_b，S_w，S_t三者中的任何两个即可。

常见的一种实现是采用优化目标：

$$\max_{\mathbf{W}} \frac{\mathrm{tr}(\mathbf{W}^{\mathrm{T}} S_b \mathbf{W})}{\mathrm{tr}(\mathbf{W}^{\mathrm{T}} S_w \mathbf{W})} \quad \Longrightarrow \quad S_b \mathbf{W} = \lambda S_w \mathbf{W}$$

$\mathrm{tr}(\cdot)$表示矩阵的迹。

W的闭式解是$S_w^{-1} S_b$的 N-1 个最大广义特征值所对应的特征向量组成的矩阵。

多分类学习

本知识点主要教学目的：让学生了解多分类任务的基本思路和拆分策略。

多分类学习

多分类学习的思路：“拆解法”。

将多分类任务拆分为若干个二分类任务求解。具体来说，先对问题进行拆分，然后为拆出的每个二分类任务训练一个分类器；在测试时，对这些分
果进行集成以获得最终的多分类结果。

经典的拆分策略：

一对一（One vs. One ,OvO）

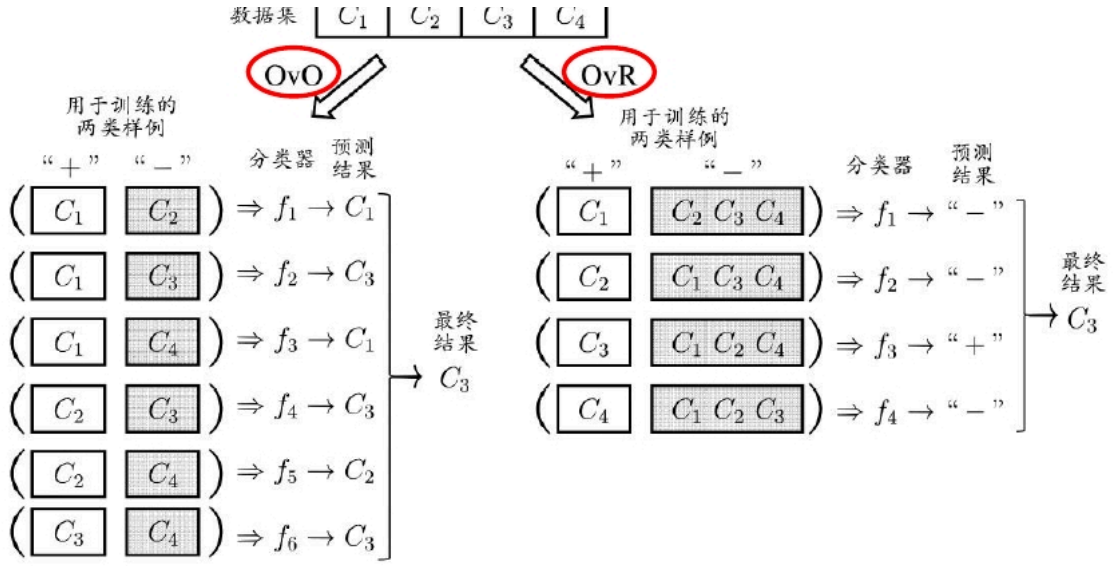
一对其余（One vs. Rest ,OvR）

多对多（Many vs. Many,MvM）

OvO & OvR

OvO：多个二分类器，每个对两个类别进行分类，最终通过投票或集成方法确定类别。

OvR：多个二分类器，每个对一个类别与其他类别进行分类，选择最高分类概率的类别作为预测结果。



OvO需训练N(N-1)/2个分类器，而OvR只需训练N个分类器，因此，OvO的存储开销和测试时间通常比OvR更大，但在训练时，OvR的每个分类器
训练样例，而OvO的每个分类器仅用到两个类别的样例，因此，在类别很多时，OvO的训练时间通常比OvR更小。

选择使用OvO还是OvR方法取决于具体的问题和数据特点。有些算法（如支持向量机）对于二分类问题更有效，可以使用OvO方法。而有些算法
归）可以直接处理多类分类问题，不需要使用OvO或OvR方法。

MvM-纠错输出码

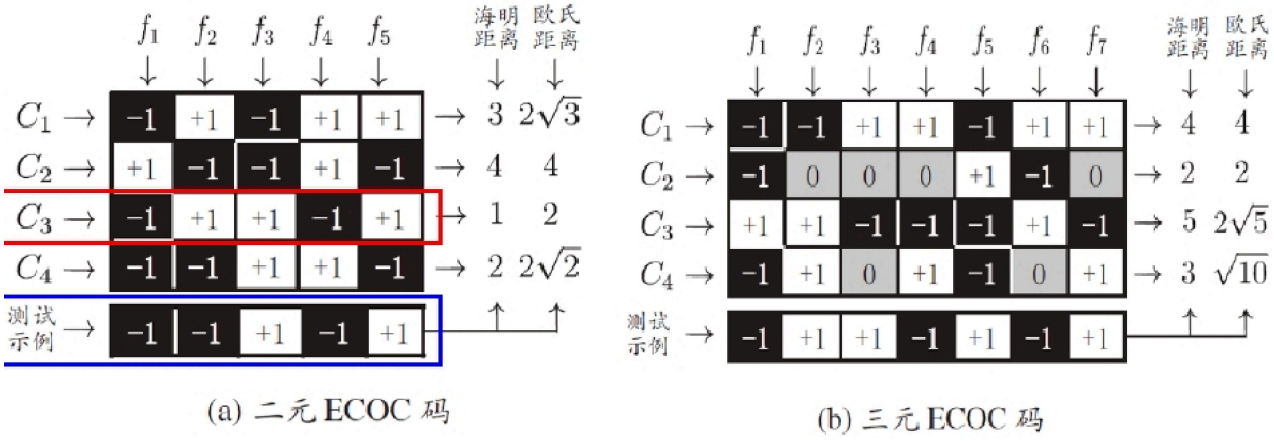
多对多(MvM): 将若干类作为正类，若干类作为反类。

MvM的正、反类构造必须有特殊的设计，最常用的技术：纠错输出码（ECOC）

ECOC的工作过程主要分为两步：

编码：对N个类别做M次划分，每次划分将一部分类别划为正类，一部分划分为反类，从而形成一个二分类训练集；这样一共产生M个训练集，可
类器。

解码：M个分类器分别对测试样本进行预测，这些预测标记组成一个编码，将这个预测编码与每个类别各自的编码进行比较，返回其中距离最小的
预测结果。



欧氏距离：计算两个点之间的直线距离，通过计算各个维度上对应特征值的差的平方和再开根号。

海明距离：计算两个等长字符串之间的差异，通过计算对应位置上不同字符的数量来衡量差异。

类别不平衡问题

本知识点主要教学目的：让学生了解如何处理类别不平衡问题。

分类学习方法共同的基本假设：不同类别的训练样例数目相当。

类别不平衡（class-imbalance）：分类任务中不同类别的训练样例数目差别很大。



不同类别的样本比例相差很大；“小类”往往更重要

类别不平衡问题可能导致以下情况：

学习器对多数类别的学习效果更好，而对少数类别的学习效果较差。

由于样本不平衡，学习器可能倾向于将所有样本都归为多数类别，导致分类结果的偏倚。

再缩放

某一分类器决策规则变换：

$$若\frac{y}{1-y}>1，则预测为正例$$

$$若\frac{y}{1-y}>\frac{m^+}{m^-}，则预测为正例$$

(m^{+})：正例数目；(m^{-})：反例数目

对预测值调整：

$$\frac{y'}{1-y'}=\frac{y}{1-y}\times\frac{m^+}{m^-}$$

基本策略——“再缩放”(rescaling)

其他策略

常见类别不平衡学习方法：

过采样 (oversampling)：通过增加少数类别样本的数量来平衡不同类别的样本数量。

例如：SMOTE：合成样本生成的过采样方法通过在少数类别样本之间进行插值生成新的合成样本来增加少数类别的数量。

欠采样 (undersampling)：通过减少多数类别样本的数量来平衡不同类别的样本数量。

例如：EasyEnsemble：通通过对多个子训练集进行欠采样，使得每个子训练集都包含少数类别样本和随机选取的多数类别样本。然后，每个子训练一个基分类器，最后通过集成这些基分类器的预测结果来得到最终的分类结果。

阈值移动 (threshold-moving)：通过移动决策阈值，可以调整分类器的偏好，使其更倾向于将样本归为少数类别。