列表

批注

**决策树**

备课材料

**OracleWDP•华育兴业**

| | |
|---|---|
| **内容分析** | 决策树是一种常用的机器学习方法，它以树状结构进行分类或回归预测。决策树模型通过树形结构来表示决策过程，<br>每个内部节点表示一个特征属性的测试，每个叶子节点表示一个类别或决策结果。决策树简史介绍了决策树的发展历程和应<br>停止条件包括三种：所有样本属于同一类别、所有样本具有相同的属性值或没有属性可用于进一步划分。基本算法包括ID3、<br>C4.5和CART等。划分选择是决策树算法中的关键步骤，常用的划分选择指标有信息增益、增益率和基尼指数。<br>剪枝处理是为了防止决策树过拟合，包括预剪枝和后剪枝两种方法。连续与缺失值处理是处理决策树中的连续属性和缺失值<br>如二分法离散化和缺失值填充。多变量决策树是在传统决策树算法的基础上，引入多个特征属性进行划分，<br>提高模型的表达能力和预测准确率。决策树是一种直观、易于理解和解释的机器学习算法，广泛应用于分类和回归问题。 |
| **教学目的及要求** | 了解决策树模型的基本算法；了解决策树的划分选择；了解决策树的剪枝处理；了解决策树中连续值和缺失值的处理；<br>了解多变量决策树。 |
| **重点** | 教学重点：决策树算法、划分选择、剪枝处理。 |
| **难点** | 教学难点：划分选择、剪枝处理。 |
| **教学方式** | 教学采用教师一边使用ppt讲授，一边使用实验环境进行操作 |

**课程知识点**

# 决策树

## 基本流程

本知识点主要教学目的：让学生了解决策树模型的基本流程和算法。

### 决策树模型

决策树(DecisionTree）是在已知各种情况发生概率的基础上，通过构成决策树来求取净现值的期望值大于等于零的概率，评价项目风险，判断其可
分析方法，是直观运用概率分析的一种图解法。

决策树基于“树”结构进行决策的，这恰是人类在面临决策问题时一种很自然的处理机制。

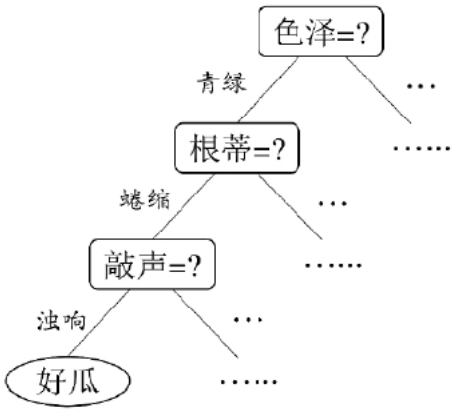



图 4.1 西瓜问题的一棵决策树

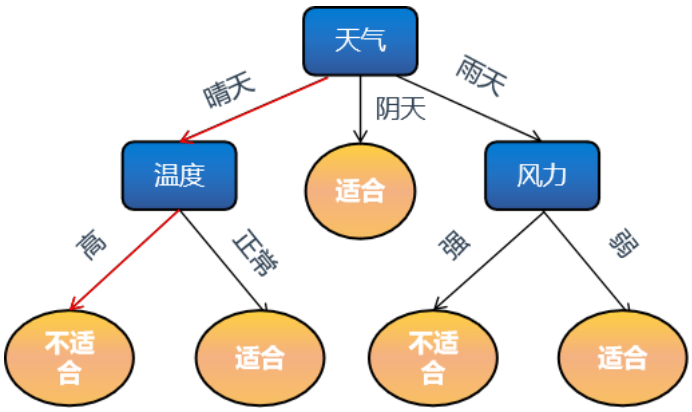
例如，我们要对“这是好瓜吗？”这样的问题进行决策时，通常会进行一系列的判断或“子决策”：我们先看“它是什么颜色？”，如果是“青绿
再看“它的根蒂是什么形态？”，如果是“蜷缩”，我们再判断“它敲起来是什么声音？”，最后，我们得出最终决策：这是个好瓜。这个决策过
示。

化能力强，即处理不见示例能力强的决策树。

## 一个例子

例如，我们根据天气状况来判断某天是否适合打网球。图中长方椭圆蓝色节点表示判断条件；橙色圆形节点表示决策结果；箭头表示在 断条件下的决策路径。

如果某一天情况是这样的：（天气：晴天；湿度：高，风力：强），那么按照这颗决策树，这一天不适合打网球？




## 决策树简史

1950年代末至1960年代初：决策树的雏形开始出现。Morgan和Sondak等人首先提出了使用树形结构进行决策推理的概念，并在机器学习领域中树的概念。

1960年代末至1970年代：决策树算法开始得到具体化和系统化的发展。Quinlan等人提出了ID3（Iterative Dichotomiser3）算法，这是第一个学习算法。

1980年代：决策树算法继续得到改进和推广。Quinlan提出了C4.5算法，该算法是ID3算法的扩展版本，引入了连续特征的处理和缺失值的处理等其他改进的决策树算法也开始出现，例如CART（Classification and Regression Trees）算法。

1990年代至2000年代：随着计算能力的提升和机器学习研究的深入，决策树算法得到了广泛应用和发展。此时，决策树算法不仅用于分类问题，题和特征选择等领域。此外，基于决策树的集成学习方法，如随机森林和梯度提升树等也逐渐兴起。

2010年代至今：决策树算法在大数据和人工智能的时代得到了更广泛的应用。随着深度学习的兴起，决策树算法与神经网络等方法的结合也成为研外，随着机器学习算法的自动化和自动调参技术的发展，决策树算法也变得更加易于使用和高效。

## 基本流程

策略：“分而治之”(divide-and-conquer)

决策树的生成是一个递归过程。在决策树基本算法中，有三种情形会导致递归返回：

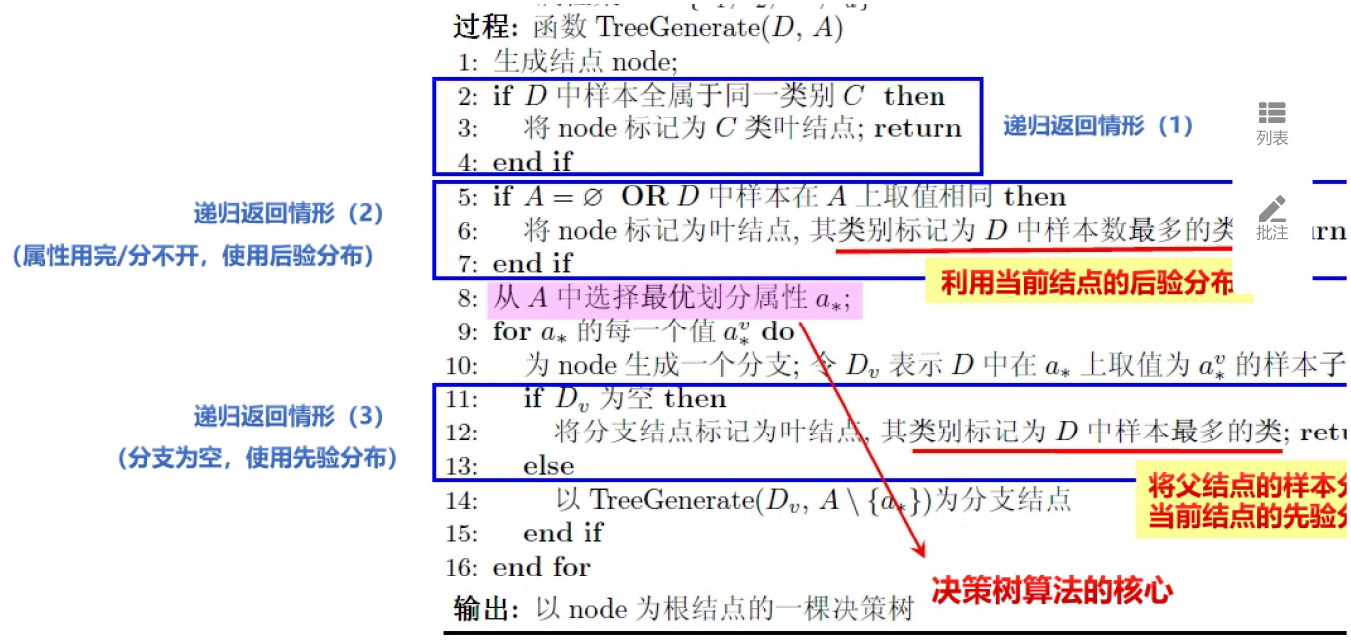
(1) 当前结点包含的样本全属于同一类别，无需划分;

(2) 当前属性集为空, 或是所有样本在所有属性上取值相同，无法划分;

(3) 当前结点包含的样本集合为空，不能划分。

在第（2）种情形下，我们把当前结点标记为叶结点，并将其类别设定为该结点所含样本最多的类别；在第（3）种情形下，同样把当前结点标记为将其类别设定为其父结点所含样本最多的类别。注意这两种情形的处理实质不用：情形（2）是在利用当前结点的后延分布，而情形（3）则是把父分布作为当前结点的先验分布。

## 基本算法




根据西瓜数据2.0来做例子。

根据 “纹理”属性划分后，发现“纹理”为模糊的三个样本都是坏瓜，即递归返回情形（1）：当前结点包含的样本全属于同一类别，无需划分。

| 色泽 | 根蒂 | 敲声 | 纹理 | 脐部 | 触感 | 好瓜 |
|---|---|---|---|---|---|---|
| 浅白 | 硬挺 | 清脆 | 模糊 | 平坦 | 硬滑 | 否 |
| 浅白 | 蜷缩 | 浊响 | 模糊 | 平坦 | 软粘 | 否 |
| 浅白 | 蜷缩 | 浊响 | 模糊 | 平坦 | 硬滑 | 否 |
| 青绿 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 乌黑 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 是 |
| 乌黑 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 青绿 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 是 |
| 浅白 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 青绿 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 是 |
| 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 硬滑 | 是 |
| 青绿 | 硬挺 | 清脆 | 清晰 | 平坦 | 软粘 | 否 |
| 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 否 |
| 乌黑 | 稍蜷 | 浊响 | 稍糊 | 稍凹 | 软粘 | 是 |
| 乌黑 | 稍蜷 | 沉闷 | 稍糊 | 稍凹 | 硬滑 | 否 |
| 青绿 | 稍蜷 | 浊响 | 稍糊 | 凹陷 | 硬滑 | 否 |
| 浅白 | 稍蜷 | 沉闷 | 稍糊 | 凹陷 | 硬滑 | 否 |
| 青绿 | 蜷缩 | 沉闷 | 稍糊 | 稍凹 | 硬滑 | 否 |

同理，接下来对“纹理”为清晰的样本，再次根据“根蒂”属性划分后，发现“根蒂”为蜷缩的样本都是好瓜。

| 色泽 | 根蒂 | 敲声 | 纹理 | 脐部 | 触感 | 好瓜 |
|---|---|---|---|---|---|---|
| 青绿 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 乌黑 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 是 |
| 乌黑 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 青绿 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 是 |
| 浅白 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 青绿 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 是 |
| 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 硬滑 | 是 |
| 青绿 | 硬挺 | 清脆 | 清晰 | 平坦 | 软粘 | 否 |
| 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 否 |

“根蒂”为硬挺的样本全部是坏瓜，即递归返回情形（1）：此时只有“根蒂”为稍蜷的样本同时含有好瓜和坏瓜，因此需要继续进行划分。

| 色泽 | 根蒂 | 敲声 | 纹理 | 脐部 | 触感 | 好瓜 |
|---|---|---|---|---|---|---|
| 青绿 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 是 |
| 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 硬滑 | 是 |
| 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 否 |

别，即好瓜。

## 划分选择

本知识点主要教学目的：让学生了解信息增益、增益率和基尼指数。

列表

批注

### 信息增益

信息熵 (entropy) 是度量样本集合“纯度”最常用的一种指标。

假定当前样本集合D中第k 类样本所占的比例为(p_{k})(k=1,2,...,|y|)，则 D 的信息熵定义为

$$\mathrm{Ent}(D) = -\sum_{K=1}^{|y|} p_k \log_2 p_k$$

Ent(D)的值越小，则D的纯度越高。

信息熵的值越大，表示随机变量的不确定性越高，即信息量越大。

反之，信息熵越小，表示随机变量的不确定性越低，即信息量越少。

假定离散属性a的取值：({ a^{1},a{2},...,a^{V}})。^{D}{v}: D 中在a上取值为(a^{v})的样本集合

以属性a对数据集 D 进行划分所获得的信息增益为：

$$\mathrm{Gain}(D,a) = \mathrm{Ent}(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v)$$

划分前的信息熵

划分后的信息熵

第 v 个分支的权重，样本越多越重要

一般而言，信息增益越大，则意味着使用属性a来进行划分所获得的“纯度提升”越大。因此，我们可用信息增益来进行决策树的划分属性选择。

著名的ID3决策树学习算法就是以信息增益为准则来选择划分属性。

| 编号 | 色泽 | 根蒂 | 敲声 | 纹理 | 脐部 | 触感 | 好瓜 |
|---|---|---|---|---|---|---|---|
| 1 | 青绿 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 2 | 乌黑 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 是 |
| 3 | 乌黑 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 4 | 青绿 | 蜷缩 | 沉闷 | 清晰 | 凹陷 | 硬滑 | 是 |
| 5 | 浅白 | 蜷缩 | 浊响 | 清晰 | 凹陷 | 硬滑 | 是 |
| 6 | 青绿 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 是 |
| 7 | 乌黑 | 稍蜷 | 浊响 | 稍糊 | 稍凹 | 软粘 | 是 |
| 8 | 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 硬滑 | 是 |
| 9 | 乌黑 | 稍蜷 | 沉闷 | 稍糊 | 稍凹 | 硬滑 | 否 |
| 10 | 青绿 | 硬挺 | 清脆 | 清晰 | 平坦 | 软粘 | 否 |
| 11 | 浅白 | 硬挺 | 清脆 | 模糊 | 平坦 | 硬滑 | 否 |
| 12 | 浅白 | 蜷缩 | 浊响 | 模糊 | 平坦 | 软粘 | 否 |
| 13 | 青绿 | 稍蜷 | 浊响 | 稍糊 | 凹陷 | 硬滑 | 否 |
| 14 | 浅白 | 稍蜷 | 沉闷 | 稍糊 | 凹陷 | 硬滑 | 否 |
| 15 | 乌黑 | 稍蜷 | 浊响 | 清晰 | 稍凹 | 软粘 | 否 |
| 16 | 浅白 | 蜷缩 | 浊响 | 模糊 | 平坦 | 硬滑 | 否 |
| 17 | 青绿 | 蜷缩 | 沉闷 | 稍糊 | 稍凹 | 硬滑 | 否 |

以上表中的西瓜数据集2.0为例，该数据集包含17个训练样例，用以学习一颗能预测没剖开的是不是好瓜的决策树，根结点的信息熵为

$$\text{Ent}(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6}+\frac{3}{6}\log_2\frac{3}{6}\right) = 1.000$$

$$\text{Ent}(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6}+\frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$\text{Ent}(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5}+\frac{4}{5}\log_2\frac{4}{5}\right) = 0.722$$

属性“色泽”的信息增益为：

$$\text{Gain}(D,\text{色泽}) = \text{Ent}(D) - \sum_{v=1}^{3}\frac{|D^v|}{|D|}\text{Ent}(D^v)$$

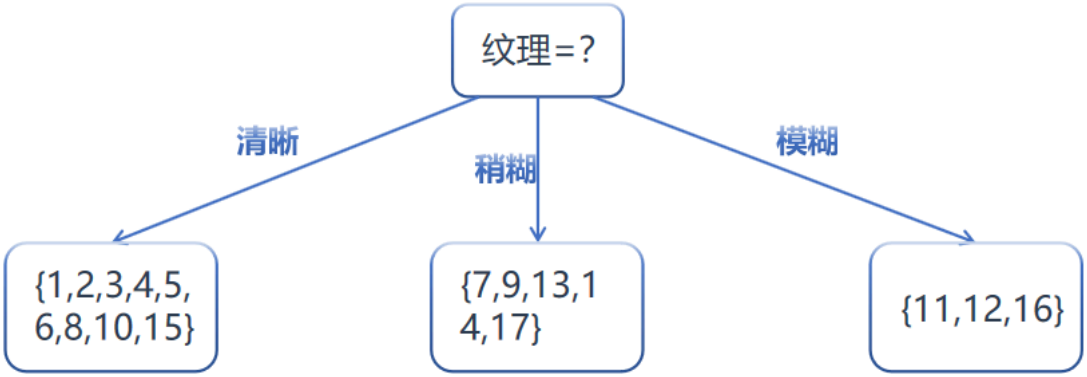
$$= 0.998 - \frac{6}{17}\times 1.000 + \frac{6}{17}\times 0.918 + \frac{5}{17}\times 0.722 = 0.109$$

类似的，其他属性的信息增益为：

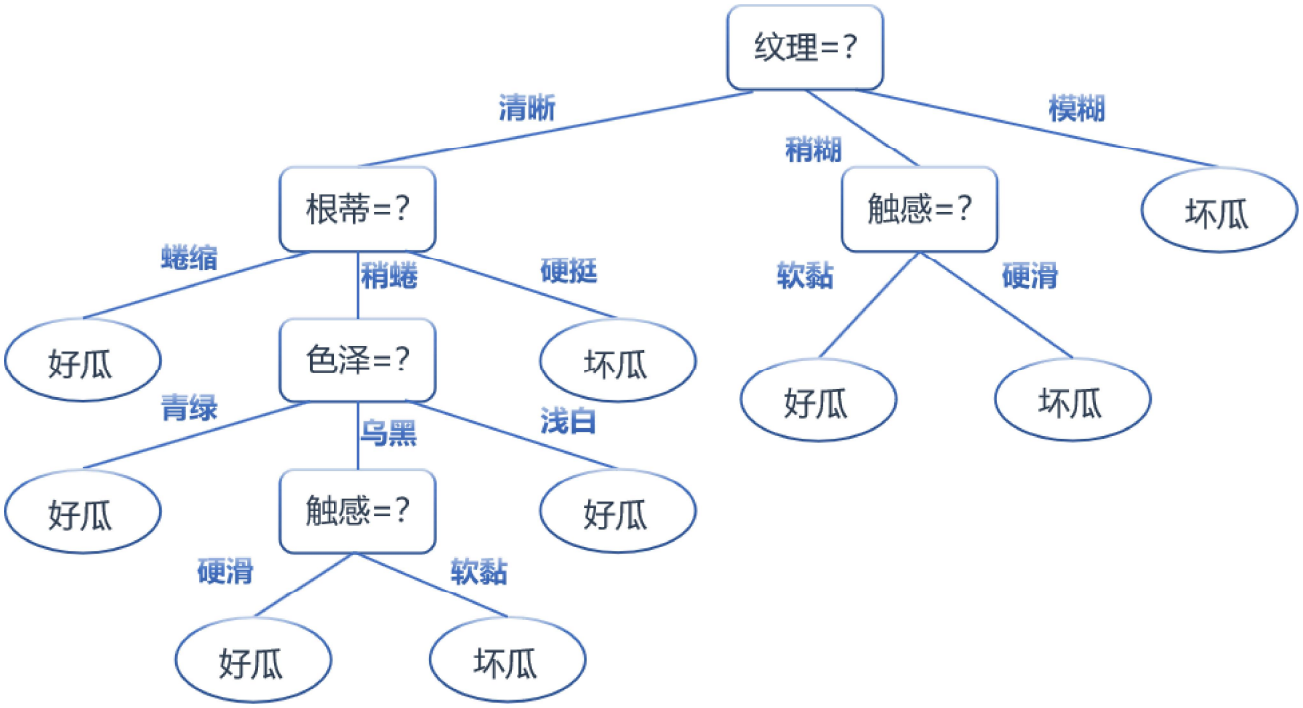
Gain(D,根蒂) = 0.143；Gain(D,敲声) = 0.141； Gain(D,纹理) = 0.381；

Gain(D,脐部) = 0.289； Gain(D,触感) = 0.006

显然，属性“纹理”的信息增益最大，其被选为划分属性。




对每个分支结点做进一步划分，最终得到决策树。



信息增益：对于可取值数目较多的属性有所偏好。

C4.5决策树算法不直接使用信息增益，而是使用“增益率”来选择最优划分属性。

C4.5决策树算法启发式：先从候选划分属性中找出信息增益高于平均水平的，再从中选取增益率最高的。



增益率：

$$\text{Gain_ratio}(D,a) = \frac{\text{Gain}(D,a)}{\text{IV}(a)}$$

其中：

$$\text{IV}(a) = -\sum_{v=1}^{V}\frac{|D^v|}{|D|}\log_2\frac{|D^v|}{|D|}$$

属性a的可能取值数目越多 (即 V 越大)，则 IV(a) 的值通常就越大。

缺点:对取值数目少的属性有偏好。

### 基尼指数

CART决策树算法使用基尼指数来选择划分属性。

$$\text{Gini}(D) = \sum_{k=1}^{|y|}\sum_{k'\neq k} p_k p_{k'} = 1-\sum_{k=1}^{|y|} p_k^2$$

属性a的基尼指数：

$$\text{Gini_index}(D,a) = \sum_{v=1}^{V}\frac{|D^v|}{|D|}\text{Gini}(D^v)$$

在候选属性集合中，选取那个使划分后基尼指数最小的属性。

## 剪枝处理

本知识点主要教学目的：让学生掌握两种常用剪枝：预剪枝和后剪枝。

### 划分选择 vs. 剪枝

研究表明: 划分选择的各种准则虽然对决策树的尺寸有较大影响，但对泛化性能的影响很有限。例如信息增益与基尼指数产生的结果，仅在约 2%

剪枝方法和程度对决策树泛化性能的影响更为显著。在数据带噪时甚至可能将泛化性能提升25%

划分选择虽然可以减少训练集上的错误率，但在过拟合的风险方面相对较高。剪枝可以作为一种正则化技术，有效控制模型的复杂度，从而降低过

剪枝(pruning)是决策树对付“过拟合”的主要手段!

### 剪枝

剪枝可通过主动去掉一些分支来降低过拟合的风险。

基本策略：

预剪枝 (pre-pruning): 提前终止某些分支的生长

后剪枝 (post-pruning): 生成一棵完全树，再“回头”剪枝

剪枝过程中需评估剪枝前后决策树的优劣

以西瓜数据集2.0为例。

- 验证集

列表

批注

## 预剪枝

基于信息增益准则，我们先选取“脐部”来对训练集进行划分，并产生三个分支，如下图所示。

是否应该进行这个划分?

预剪枝要对划分前后的泛化性能进行估计。

若不进行划分，该结点将被标记为叶结点，其类别标记为训练样例数最多的类别，假设我们将这个叶结点标记为“好瓜”，则编号为{4,5,8}的样例
验证精度为 3/7 = 42.9%。

若划分后，则编号为{4,5,8,11,12}的样例被分类正确，验证精度为 4/7 = 71.4%>42.9%。

于是，用“脐部”进行划分得以确定。

预剪枝的基本思想是在每次进行属性划分之前，先计算划分后的子集的评价指标值，然后根据停止划分条件来判断是否进行属性划分。如果满足停
则停止划分并将当前节点标记为叶节点，将样本集中的多数类别作为该叶节点的分类标记。

预剪枝缺点:

- 预剪枝是一种贪心算法，可能会导致决策树过度剪枝，从而使模型欠拟合。
- 预剪枝需要提前设置停止划分条件，这需要根据经验或交叉验证等方法来确定，可能会存在一定的主观性。

### i. 后剪枝

后剪枝是一种在决策树构建完成后对其进行修剪的剪枝方法。

以上决策树验证集精度为42.9%。

首先考虑结点⑥，若将其替换为叶结点，根据落在其上的训练样例{7,15}，将其标记为“好瓜”，测得验证集精度提高至 57.1%，于是决定剪枝。

然后考虑结点⑤若将其替换为叶结点，根据落在其上的训练样例{6,7,15}，将其标记为“好瓜”，测得验证集精度仍为 57.1%，可以不剪枝。

对结点②若将其替换为叶结点，根据落在其上的训练样例{1,2,3,14}，将其标记为“好瓜”，测得验证集精度仍为 71.4%，决定剪枝。

同理，对结点③和①，先后替换为叶结点，均未测得验证集精度提升，于是不剪枝。

最终，后剪枝得到的决策树:

后剪枝缺点:

可能导致决策树过度剪枝，使模型欠拟合。

可能需要遍历整个决策树的节点，计算复杂度较高，对于大规模数据集或复杂决策树的训练会消耗大量时间和计算资源。

## 预剪枝 vs. 后剪枝

时间开销:

过/欠拟合风险：

• 预剪枝：过拟合风险降低，欠拟合风险增加

• 后剪枝：过拟合风险降低，欠拟合风险基本不变

泛化性能：后剪枝通常优于预剪枝



## 连续与缺失值

本知识点主要教学目的：让学生了解决策树分类任务中对连续值和缺失值的处理。

### 连续值处理

如何在决策树学习中使用连续属性?

基本思路：连续属性离散化

常见做法：二分法（C4.5决策树）

• n 个属性值可形成 n-1 个候选划分

• 然后即可将它们当做 n-1 个离散属性值处理

通过二分法将连续属性的取值范围划分为多个区间，然后将每个区间作为一个离散属性值。具体步骤是找到连续属性的最大值和最小值，取中点作属性值小于等于分割点的归为一类，大于分割点的归为另一类。这样就将连续属性离散化为两个离散属性值。可以根据需求和属性的特性，选择适行离散化。

例如，对属性“密度”连续属性离散化。

候选划分点集合：

[T_{密度} = \ { 0.244,0.294,0.351,0.381,0.420,0.459,0.518,0.574,0.600,0.621,0.636,]

[0.648,0.661,0.681,0.708,0.746}]

计算出属性“密度”的信息增益最大化的划分点：0.381。

同理属性“含糖率”的划分点：0.126。

基于信息增益生成的决策树：

若当前结点划分属性为连续属性，该属性还可作为其后代结点的划分属性。

### 缺失值处理

仅使用无缺失的样例？这是对数据的极大浪费

使用带缺失值的样例，需解决：

1.如何进行划分属性选择?

2.给定划分属性，若样本在该属性上的值缺失，如何进行划分?

基本思路：样本赋权，权重划分

仅通过无缺失值的样例来判断划分属性的优劣

学习开始时，根结点包含样例集 D 中全部17个样例，权重均为 1。

以属性“色泽”为例，该属性上无缺失值的样例子集信息熵为：

$$\begin{aligned}\mathrm{Ent}(\tilde{D}) &= -\left(\frac{6}{14}\log_2\frac{6}{14}+\frac{8}{14}\log_2\frac{8}{14}\right)\\ &= 0.985\end{aligned}$$

$$\mathrm{Ent}(\tilde{D}^1) = -\left(\frac{2}{4}\log_2\frac{2}{4}+\frac{2}{4}\log_2\frac{2}{4}\right) = 1.000;\ \mathrm{Ent}(\tilde{D}^2) = -\left(\frac{4}{6}\log_2\frac{4}{6}+\frac{2}{6}\log_2\frac{2}{6}\right) = 0.91^{\circ}$$

$$\mathrm{Ent}(\tilde{D}^3) = -\left(\frac{0}{4}\log_2\frac{0}{4}+\frac{4}{4}\log_2\frac{4}{4}\right) = 0$$

列表

因此，样本子集(\widetilde{D})上属性“色泽”的信息增益为：

批注

于是，样本集 D 上属性“色泽”的信息增益为：

$$\mathrm{Gain}(D, 色泽) = \rho \times \mathrm{Gain}(\tilde{D}, 色泽) = \frac{14}{17} \times 0.306 = 0.252$$

区别： 无缺失值样例占比

类似地可计算出所有属性在数据集上的信息增益：

$$\mathrm{Gain}(D, 色泽) = 0.252;\ \mathrm{Gain}(D, 根蒂) = 0.171;$$
$$\mathrm{Gain}(D, 敲声) = 0.145;\ \mathrm{Gain}(D, 纹理) = 0.424;$$
$$\mathrm{Gain}(D, 脐部) = 0.289;\ \mathrm{Gain}(D, 触感) = 0.006$$

## 多变量决策树

本知识点主要教学目的：让学生了解多变量决策树。

### 轴平行划分

决策树的分类边界特点：轴平行，即它的分类边界又 若干个与坐标轴平行的分段组成。

如上图，显然，边界的每一段都是与坐标轴平行的。这样的分类边界使得学习结果有较好的可解释性，因为每一段划分都直接对应了某个属性取值

学习任务所对应的分类边界很复杂时，需要非常多段划分才能获得较好的近似

此时的决策树会相当复杂，由于要进行大量的属性测试，预测时间开销会很大。

### 多变量决策树

多变量决策树：每个非叶结点不仅考虑一个属性。

例如“斜决策树” (oblique decision tree) 不是为每个非叶结点寻找最优划分属性，而是建立一个线性分类器。

更复杂的“混合决策树”甚至可以在结点嵌入神经网络或其他非线性模型。