神经网络

备课材料

OracleWDP·华育兴业

列表

批注

内容分析	机器学习中的神经网络是一种受生物神经系统启发的模型，它由神经元模型和连接权重组成。本章将介绍神经网络的基本概 包括神经元模型和激活函数的作用。接着，我们将讨论感知机和多层前馈网络的结构，它们是神经网络的基本组成部分。此 我们将详细介绍BP算法，包括前向传播和反向传播的过程，以及如何使用它来训练神经网络并缓解过拟合问题。在进一步讨 我们将探讨全局最小和局部极小的概念，以及它们对神经网络训练的影响。最后， 我们将介绍其他常见的神经网络模型和深度学习的概念，以展示神经网络在机器学习中的广泛应用
教学目的及要求	了解神经网络相关的基本概念；了解感知机和多层网络；了解误差逆传播算法；了解常见神经网络模型。
重点	教学重点：感知机、误差逆传播算法、常见神经网络模型。
难点	教学难点：感知机、误差逆传播算法。
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

课程知识点

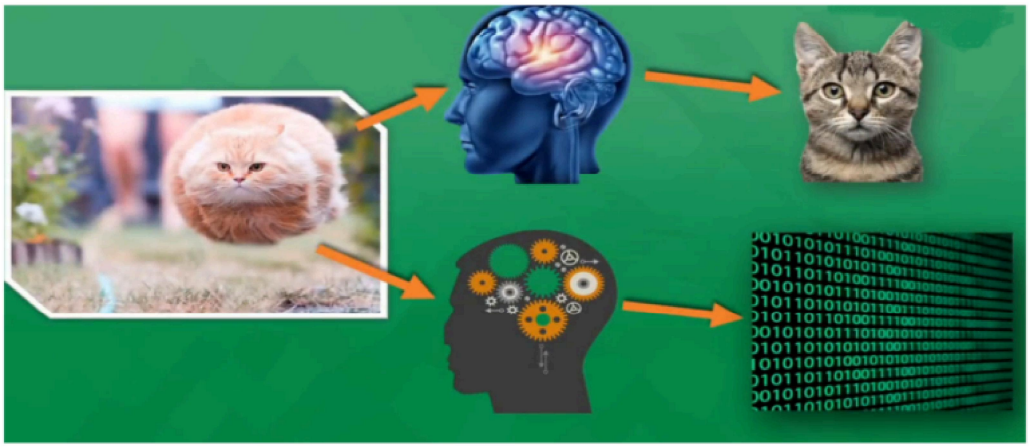
神经网络

神经网络与神经元模型

本知识点主要教学目的：让学生了解神经网络、神经元模型和激活函数。

神经网络

神经网络是一个具有适应性的简单单元组成的广泛并行互联的网络，它的组织能够模拟生物神经系统对真实世界物体所作出的交互反应。神经网络
神经元连接进行计算，大多情况下人工神经网络可以在外界信息的基础上改变内部结构，是一种自己适应的，逐渐的过程。



如果你看到张张图片，无论是跳跃，飞奔还是漫步的猫，你都可以知道它只是一只猫，因为，你已经被告知过圆眼睛，毛茸茸，尖耳朵的就是猫，
通过已经成熟的视觉神经系统，已经判定它就是一直猫。计算机也是一样，通过不断的训练，告诉哪些是猫，哪些是狗，哪些是牛，它们会用一种
括这些学习到的判断力，最终以数学的模式，也就是我们这里所看到的0或者1的形式判断其应该被分到哪一类。目前的百度图片搜索和google p
轻易的判断人物，地点，事物；这些都归功于计算机神经系统的突破发展。

神经元

由于神经网络的模拟对象是人的大脑。根据生物学的研究，人脑的计算单元是神经元（neuron）。它能根据环境变化做出反应，再将信息传递给其
元。在人脑中，大约有860亿个神经元，它们相互联结构成了极其复杂的神经系统，而后者正是人类智慧的物质基础。将上述的神经元结构抽象成
以得到如下图所示的神经元模型。

经元的树突，而输出可以类比为神经元的轴突，计算则可以类比为细胞核。

M-P 神经元模型中，神经元接收到来自n个其他神经元传递过来的输入信号，这些输入信号通过带权重的连接进行传递，神经元接收到 入值
阈值进行比较，然后通过“激活函数”处理以产生神经元的输出。

激活函数

理想中的激活函数是上图（a）所示的阶跃函数，他将输入值映射为输出值“0”或“1”，显然“1”对应于神经元兴奋，“0”对应于神经元抑制
函数具有不连续、不光滑等不太好的性质，因此实际常用sigmoid函数作为激活函数，它把可能在较大范围内变化的输入值挤压到(0,1)输出值范围
也称为“挤压函数”。

感知机与多层网络

本知识点主要教学目的：让学生了解感知机和多层前馈网络结构。

感知机

感知机由两层神经元组成。

输入层接收外界输入信号后传递给输出层，输出层是M-P神经元，亦称“阈值逻辑单元”。

感知机能容易地实现逻辑与、或、非运算。

感知机只有输出层神经元进行激活函数处理，即只有一层功能神经元，其学习能力非常有限。

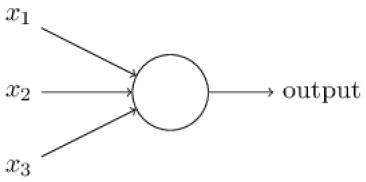
要解决非线性可分问题，需考虑使用多层功能神经元。

小明通过一定的算法决定自己明天是否去看新上映的电影。

a.是否下雨（是＝0，否＝1）

b.是否有女生愿意陪小明一起看（是＝1，否＝0）；c.是否有剧透狗告诉了小明结局（是＝0，否＝1）。

小明觉得，a和c两个因素对他的决定影响比较小，权重分别为1和2，而是否有女生同去占的权重比较大，为4。经过运算后，如果最终的答案≥2，
会去看电影。



小明的决策过程就可以用感知器来描述，如下图所示。①(x_{1}、x_{2}、x_{3})三个输入值，分别代表a、b、c三个因素。

②中间的圆圈就是感知器模型的计算过程。

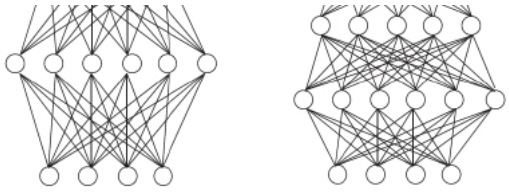
③左边三个箭头连线分别指代了三个权重(w_{1})＝1、(w_{2})＝4、(w_{3})＝2。如果(x_{1})∗(w_{1})+(x_{2})∗(w_{2})+(x_{3})∗(w_{3})≥2，那么就
小明明天会去看电影。

这里最终判断是否≥2中的数字2，被称为阈值（threshold），为了表达更方便，一般用它的相反数来表达：b=-threshold，这里的b被称为偏置

多层前馈网络结构

多层网络：包含隐层的网络

前馈网络：神经元之间不存在同层连接也不存在跨层连接，即网络中无环或者回路。



设计一个神经网络时，输入层与输出层的节点数往往是固定的，中间层则可以自由指定；

神经网络结构图中的拓扑与箭头代表着预测过程时数据的流向，跟训练时的数据流有一定的区别；

结构图里的关键不是圆圈（代表“神经元”），而是连接线（代表“神经元”之间的连接）。每个连接线对应一个不同的权重（其值称为权值），得到的。

多层前馈网络有强大的表示能力。

只需一个包含足够多神经元的隐层，多层前馈神经网络就能以任意精度逼近任意复杂度的连续函数。

设置隐层神经元数是深度学习模型中的一个重要参数，它会对模型的性能和计算效率产生影响。以下是一些常用的方法来设置隐层神经元数：

规则经验法：在没有先验知识的情况下，可以使用一些常用的经验法则来选择隐层神经元数。例如，可以设置隐层神经元数为输入层神经元数的两
样做的原因是增加隐层神经元数可以增加模型的学习能力和表达能力，但也会增加计算复杂度和过拟合的风险。

网络复杂度和模型性能平衡：在实际应用中，需要在模型性能和计算资源之间进行权衡。较少的隐层神经元数可以减少计算复杂度，但可能导致模
较多的隐层神经元数可以增加模型的拟合能力，但可能会导致过拟合和计算资源的浪费。因此，需要根据具体任务和数据集的复杂程度来选择适当
数。

调参和模型选择：可以通过交叉验证和参数调优的方法来选择最佳的隐层神经元数。在训练过程中，可以尝试不同的隐层神经元数，并评估模型在
能。选择性能最好的模型作为最终的模型。

自动调参算法：还可以使用一些自动调参的算法来选择最佳的隐层神经元数。例如，可以使用贝叶斯优化、遗传算法等方法进行参数搜索和优化，
隐层神经元数。

需要注意的是，隐层神经元数的选择并没有一种通用的准则，它依赖于具体的任务、数据集和计算资源。因此，需要根据实际情况进行选择和调整
以尝试不同的隐层神经元数，并通过实验来评估模型的性能和效果。

误差逆传播算法

本知识点主要教学目的：让学生掌握B算法的两个阶段：前向传播和反向传播。

BP算法

误差逆传播算法（error Backpropagation，简称BP）算法，也称为BP算法，是一种用于训练多层神经网络的反向传播算法。

BP算法的基本思想是通过反向传播误差信号来调整神经网络的权重和偏置，以最小化网络输出与期望输出之间的差异，从而实现网络的训练和学习

具体来说，BP算法分为两个阶段：前向传播和反向传播。

前向传播：通过输入样本，按照神经网络的权重和偏置，逐层计算神经元的输出值，直到输出层。计算的过程中，使用激活函数来引入非线性变换
络的拟合能力。

反向传播：计算输出层的误差，然后从输出层开始逐层向前传播误差，根据误差信号来调整网络的权重和偏置。这个过程中，使用梯度下降法来更
置，使得网络的输出逼近期望输出。

前向传播

前向传播是神经网络中的一种计算过程，通过将输入数据从输入层传递到输出层，得到网络的预测结果。

具体做法如下：

1.初始化权重和偏置：根据网络的结构，随机初始化权重和偏置值。

2.输入数据传递：将输入数据（例如一张图片）作为输入层的神经元的激活值。

3.前向计算：从输入层开始，通过每一层的权重和偏置，计算出下一层的神经元的激活值。

a. 对于隐藏层：将上一层的激活值与该层的权重相乘，再加上该层的偏置，然后通过激活函数进行非线性变换，得到该层的神经元的激活值。

4.输出结果：输出层的神经元的激活值代表了网络对输入数据的预测结果。

通过前向传播，我们可以得到神经网络对输入数据的预测结果。这一过程实际上是一种信息的正向流动，通过每一层的计算，逐渐将输 的信层，最终得到网络的预测结果。

列表

如果当时你想要问电脑：嘿，你看看这张图片是不是一只猫的时候，它能真正看到的全部是一堆数字。通过对这些数字的加工、处理 另外生成出来的数字也有了认知上的意义，通过一点点处理，我们就能得知计算机判断这张图片是猫还是狗。

批注

反向传播

反向传播是神经网络中的一种学习算法，通过计算输出结果与期望输出之间的差异，将这个差异反向传播回网络，调整网络的权重和偏置，以减小望输出之间的差异。具体做法如下：

1.初始化权重和偏置：根据网络的结构，随机初始化权重和偏置值。

2.前向传播：通过前向传播计算出网络的预测结果。

3.计算损失函数：根据预测结果和期望输出，计算出损失函数的值，衡量预测结果与期望输出之间的差异。

4.反向传播：从输出层开始，计算每一层的误差梯度，将这个梯度反向传播回每一层，以调整权重和偏置。

a. 对于输出层：计算输出层的误差梯度，即损失函数对输出层激活值的导数。根据链式法则，将这个梯度与输出层的激活函数的导数相乘，得到输梯度。

b. 对于隐藏层：计算隐藏层的误差梯度，即上一层的误差梯度与上一层的权重的转置矩阵相乘，再与隐藏层的激活函数的导数相乘，得到隐藏层的

5.更新权重和偏置：根据误差梯度和学习率，更新每一层的权重和偏置。

6.重复步骤2到步骤5，直到达到指定的训练次数或达到预设的收敛条件。

你给计算机看图片是一只飞奔的猫，但是计算机却觉得它是一只狗狗。显然是区分错误，但是这一次错误的经验却是非常有价值的，我们可以从中训。

那么，计算机是如何学习经验的呢？这就是通过对比预测的答案和真实答案的差别，然后再把这种差别再反向的传递过去。对于每一个神经元，像改动一点点，这样到了下一次识别的时候呢，通过所有改进的神经网络，计算机被识别的正确率又可以被提高一点点，这样每一次的一点点累加上练，那就是往正确的方向上迈出了一大步。

我们可以再进一步看看神经网络是怎样被训练的：在计算机里每一个神经元都有属于它的刺激函数，我们可以用这些函数给计算机一个刺激行为，给这些计算机看一只飞奔的猫时，神经网络里只有部分的神经元被激励或者被激活，被激活的神经元被传递下去的信息是计算机最为重视的信息，结果最有价值的信息。如果预测的结果是一只狗，所有神经元的参数都会被调整，使得有一些容易被激活的神经元变的迟钝，另外一些却变得敏感明了所有神经元的参数正在被改变，变得对图片里真正重要的信息敏感。这样，被改变的参数就可以渐渐预测出正确的答案，也就是它是一只猫！

原来，在计算机里每一个神经元都有属于它的刺激函数，我们可以用这些函数给计算机一个刺激行为，当我们第一次给这些计算机看一只飞奔的猫里只有部分的神经元被激励或者被激活，被激活的神经元被传递下去的信息是计算机最为重视的信息，也就是对输出结果最有价值的信息。如果预只狗，所有神经元的参数都会被调整，使得有一些容易被激活的神经元变的迟钝，另外一些却变得敏感起来，这就说明了所有神经元的参数正在被图片里真正重要的信息敏感。这样，被改变的参数就可以渐渐预测出正确的答案，也就是它是一直猫！

缓解过拟合

BP算法常常导致过拟合。

常用两种策略缓解BP网络的过拟合：

早停 (early stopping)：一种简单而有效的防止过拟合的方法。

若训练误差连续 a 轮的变化小于 b, 则停止训练

使用验证集：若训练误差降低、验证误差升高 , 则停止训练

正则化 (regularization)：通过限制模型的参数，避免模型过度拟合训练数据，提高模型的泛化能力。

在误差目标函数中增加一项描述网络复杂度

本知识点主要教学目的：让学生了解决策树分类任务中对连续值和缺失值的处理。

在神经网络训练中，我们通常使用损失函数来度量模型的训练误差。训练误差是指模型在训练数据上的预测结果与真实标签之间的差异

在神经网络的训练过程中，我们希望通过调整模型的权重和偏置参数，使得损失函数的值尽可能小。这个过程可以看作是在参数空间中 优解

全局最小和局部极小是优化问题中的两个概念，用于描述损失函数的最小值。

全局最小：全局最小点是整个参数空间中的最低点，是损失函数的最小值。

局部极小：局部极小点是损失函数曲线上某个局部区域内的最低点，但不一定是整个函数的最小值。

在神经网络训练中，我们希望找到损失函数的全局最小点，即找到能够使得训练误差最小化的模型参数。然而，由于神经网络模型的复杂性和非凸往往存在多个局部极小点，同时也可能存在鞍点等其他非最小点。因此，寻找全局最小点是一个非常具有挑战性的问题。

“跳出”局部极小的常见策略：

不同的初始参数：以多组不同参数值初始化多个神经网络，按标准方法训练后，取其中误差最小的解作为最终参数。

模拟退火：模拟退火在每一步都以一定的概率接受比当前解更差的结果，从而有助于“跳出”局部极小。

随机梯度下降：随机梯度下降在计算梯度时加入了随机因素，有机会跳出局部极小继续搜索。

遗传算法

……

深度学习

本知识点主要教学目的：让学生了解常见神经网络模型和深度学习模型。

其他常见神经网络模型

RBF（径向基）网络： 分类任务中除BP之外最常用

ART网络： “竞争学习”的代表

SOM（自组织映射）网络：最常用的聚类方法之一

级联相关网络： “构造性”神经网络的代表

Elman网络：递归神经网络的代表

Boltzmann机： “基于能量的模型”的代表

……

RBF（径向基） 神经网络

RBF神经网络的核心思想是使用径向基函数来进行模型的建模和预测。

RBF神经网络的结构包括输入层、隐藏层和输出层。具体来说，RBF神经网络的结构如下：

- 输入层：接受输入数据的特征向量。
- 隐藏层：由一组径向基函数组成，每个径向基函数都有一个中心和一个半径。隐藏层的作用是将输入数据映射到一个高维空间中。
- 输出层：根据隐藏层的输出，进行线性组合和激活函数计算，得到最终的输出结果。

RBF神经网络的训练过程包括以下几个步骤：

- 初始化隐藏层的中心和半径：通常使用聚类算法（如K-means）来选择合适的中心点，并根据中心点计算半径。
- 计算隐藏层的输出：根据输入数据和隐藏层的中心点，使用径向基函数计算隐藏层的输出。
- 计算输出层的权重：使用最小二乘法或其他优化算法，根据隐藏层的输出和目标值，计算输出层的权重。
- 预测和误差计算：使用训练好的模型进行预测，并计算预测结果与真实值之间的误差。
- 参数更新：根据误差，使用梯度下降等优化算法，更新隐藏层的中心和半径，以及输出层的权重。

i. SOM 神经网络

1.初始化神经元的权重向量：通常使用随机初始化的方式，为每个神经元分配一个权重向量。

2.计算神经元与输入样本之间的距离：使用欧几里得距离或其他相似度度量方法计算神经元的权重向量与输入样本之间的距离。

3.选择获胜神经元：选择距离输入样本最近的神经元作为获胜神经元。

4.更新邻域神经元：将获胜神经元周围一定范围内的神经元的权重向量调整，使其更接近输入样本。

适应阶段：

1.缩小邻域范围：随着训练的进行，逐渐减小获胜神经元周围的邻域范围。

2.进一步更新邻域神经元：在缩小的邻域范围内，继续调整神经元的权重向量，使其更接近输入样本。

级联相关网络

构造性神经网络： 将网络的结构也当做学习的目标之一，希望在训练过程中找到适合数据的网络结构。

训练：

开始时只有输入层和输出层

级联 - 新的隐层结点逐渐加入，从而创建起层级结构

相关 - 最大化新结点的输出与网络误差之间的相关性

Elman 网络

递归神经网络：

网络中可以有环形结构, 可让使一些神经元的输出反馈回来作为输入

t 时刻网络的输出状态：由 t 时刻的输入状态和 t-1 时刻的网络状态共同决定

Elman 网络是最常用的递归神经网络之一

结构与前馈神经网络很相似，但隐层神经元的输出被反馈回来

使用推广的BP算法训练

目前在自然语言处理等领域常用的 LSTM 网络，是一种复杂得多的递归神经网络。

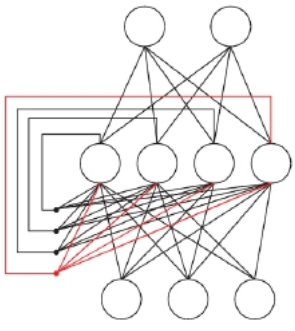


图 5.13 Elman 网络结构

深度学习的兴起

2006年，Hinton发表了深度学习的 Nature 文章

2012年，Hinton 组参加 ImageNet 竞赛，使用 CNN 模型以超过第二名 10个百分点的成绩夺得当年竞赛的冠军

伴随云计算、大数据时代的到来，计算能力的大幅提升，使得深度学习模型在计算机视觉、自然语言处理、语音识别等众多领域都取得了较大的成

典型的深度学习模型就是很深层的神经网络

（例如微软研究院2015年在ImageNet竞赛获胜使用 152层网络）

典型的深度学习模型就是很深层的神经网络。显然，对神经网络模型，提高容量的一个简单方法是增加隐层的数目。隐层多了，相应的连接数就会更多，模型复杂度也可通过单纯增加隐层神经元的数目来实现。单隐层的多层前馈网络已具有很强大的学习能力；但从增加模型的隐层的数目显然比增加隐层神经元的数目更有效，因为增加因层数不仅增加了拥有激活函数的神经元数目，还增加了激活函数嵌套的而，络难以直接用经典算法进行训练，因为误差在多隐层内逆传播时，往往会“发散”而不能收敛到稳定状态。

列表

批注

深度学习模型：卷积神经网络CNN

卷积神经网络（Convolutional Neural Network，简称CNN）是一种在计算机视觉和图像识别领域广泛应用的深度学习模型。CNN的设计灵感来觉系统，它通过模拟人类视觉处理方式来实现图像的特征提取和分类。

CNN中的两个重要概念是参数共享和局部相关性。

参数共享指的是在CNN的卷积层中，使用相同的权重参数（卷积核）对输入数据进行卷积操作。这意味着卷积核的权重在整个输入图像上是共享的每个位置都有不同的权重。这种参数共享的方式大大减少了需要学习的参数数量，从而降低了模型的复杂度，并且能够更好地处理输入图像的平移

局部相关性指的是在卷积操作中，卷积核只与输入数据的局部区域进行卷积运算。这是因为图像中的像素之间通常存在一定的空间相关性，即相邻在某种程度上是相似的。通过利用这种局部相关性，CNN可以有效地提取图像中的局部特征，并且通过卷积核的滑动操作将这些特征组合成更高级

参数共享和局部相关性的结合使得CNN在处理图像数据时具有很强的表达能力和高效的计算性能。它能够自动学习图像中的特征，并且对输入图像放和旋转等变换具有一定的鲁棒性。因此，CNN在图像分类、目标检测、图像分割等任务中取得了显著的成果，并成为计算机视觉领域的重要工具