列表

批注

支持向量机

备课材料

OracleWDP•华育兴业

内容分析	支持向量机（SVM）是一种强大的机器学习方法，用于分类和回归。本章将介绍SVM的关键概念和技术。 SVM通过最大化类别间的间隔来构建分类器，基于支持向量的概念。支持向量机从线性模型发展而来， 通过引入间隔和支持向量的概念，将线性模型扩展到非线性情况。为了处理线性不可分的问题，引入了核函数的概念。常用 如线性核函数、多项式核函数和高斯核函数。为了处理噪声和复杂数据，支持向量机引入了软间隔和正则化的概念。 软间隔允许在分类过程中存在一定程度的错误分类，替代损失函数和松弛变量用于平衡间隔和错误分类的权衡。 正则化则用于控制模型的复杂度，防止过拟合。本章还介绍了支持向量回归和核方法，包括表示定理、 核化线性模型和核线性判别模型。
教学目的及要求	了解支持向量机基本原理；了解软间隔与正则化；了解支持向量机回归基本原理；了解核函数和核方法。
重点	教学重点：支持向量机、软间隔、支持向量机回归、核函数。
难点	教学难点：支持向量机、核函数。
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

课程知识点

支持向量机

间隔与支持向量机

本知识点主要教学目的：让学生了解支持向量机原理以及如何求解。

引子

线性模型是机器学习中常用的一类模型，它通过线性函数对输入特征进行加权组合来进行预测或分类。

线性模型：在样本空间中寻找一个超平面, 将不同类别的样本分开。

分类学习最基本的想法就是基于训练集在样本空间中找到一个划分超平面。将不同类别的样本分开。但能将训练样本分类的划分超平面可能有很多
示，我们应该努力去找到哪一个呢?

直观上看，应该取找位于两类训练样本“正中间”的划分超平面，如上图中红色的线，因为该划分超平面对训练样本局部扰动的“容忍”性最好。

例如，由于训练集的局限性或噪声的因素，训练集外的样本可能比上图中的训练雅本更接近两个类的分隔界，这将使许多划分超平面出现错误，而
受影响最小。换言之，这个划分超平面所产生的分类结果是最鲁棒的，对未见示例的泛化能力最强。

应选择”正中间”, 容忍性好, 鲁棒性高, 泛化能力最强。

间隔与支持向量

在支持向量机（Support Vector Machine，SVM）中，支持向量（Support Vectors）是离决策边界最近的训练样本点。这些样本点对于确定决
关键作用。

支持向量机的目标是找到一个最优的决策边界，使得两个类别的样本之间的间隔最大化。

SVM方法是用一个有宽度的区域，替代一条直线来分隔数据。能够分隔所有数据的最宽的区域的中线，定为决策边界（boundary）。

间隔是指从决策边界到最近的训练样本点的距离的两倍。支持向量机通过最大化这个间隔来寻找最优的决策边界，从而使得分类器对未见过的样本
化能力。

$$\begin{aligned} \arg\max_{\boldsymbol{w},b} \quad & \frac{2}{\|\boldsymbol{w}\|} \\ \text{s.t.} \quad & y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \ldots, m. \end{aligned}$$

显然，为了最大化间隔，仅需最大化(\left| w \right|^{- 1})，这等价于最小化(\left| w \right|^{2})，于是，上式可重写为：

$$\begin{aligned} \arg\min_{\boldsymbol{w},b} \quad & \frac{1}{2}\|\boldsymbol{w}\|^2 \\ \text{s.t.} \quad & y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \ldots, m. \end{aligned}$$

这就是支持向量机的基本型。

对偶问题

通过引入拉格朗日函数将上述最优化问题转化为其对偶问题，则可以得到：

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^{\mathrm{T}} \boldsymbol{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^{m} \alpha_i y_i = 0 \ , \quad \alpha_i \geqslant 0 \ , \quad i = 1, 2, \ldots, m \end{aligned}$$

KKT条件

最终模型：

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top \boldsymbol{x} + b = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i^\top \boldsymbol{x} + b$$

KKT条件是用于非线性规划问题和支持向量机优化问题的一组约束最优化条件。

从对偶问题解出的(\alpha_{i})是朗格朗日乘子，它恰对应着训练样本((x_{i},y_{i}))。所以以上问题需满足KKT条件，即要求：

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\boldsymbol{x}_i) \geq 1, \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1) = 0. \end{cases}$$

支持向量机解的稀疏性：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关。

在SVM中，支持向量是训练样本中与决策边界最靠近的样本点。这些支持向量在训练完成后对模型的决策起关键作用。而大部分的训练样本并不会型产生影响。

重要性质：模型训练完后，大部分的训练样本都不需要保留，最终模型仅仅与支持向量有关

支持向量机具有稀疏性的性质，即训练完成后，大部分的训练样本都不需要保留，最终模型仅与支持向量有关。这种稀疏性带来了内存和计算效率也增强了模型的鲁棒性。然而，稀疏性的程度取决于数据集和参数设置。

本知识点主要教学目的：让学生了解处理线性不可分支持向量机的引入核函数来处理。

线性可分性（linear separability）

根据数据的线性可分性，可以将SVM分为线性可分和线性不可分两种情况。

列表

线性可分：

在线性可分的情况下，存在一个超平面（决策边界），可以将正例和负例完全分开。SVM的目标是找到一个最优的超平面，使得超平 批注 的正间的距离最大化。这些最近的样本点被称为支持向量。通过最大化间隔，SVM能够获得较好的分类性能。

线性不可分

在线性不可分的情况下，正例和负例之间无法通过一个超平面完全分开。

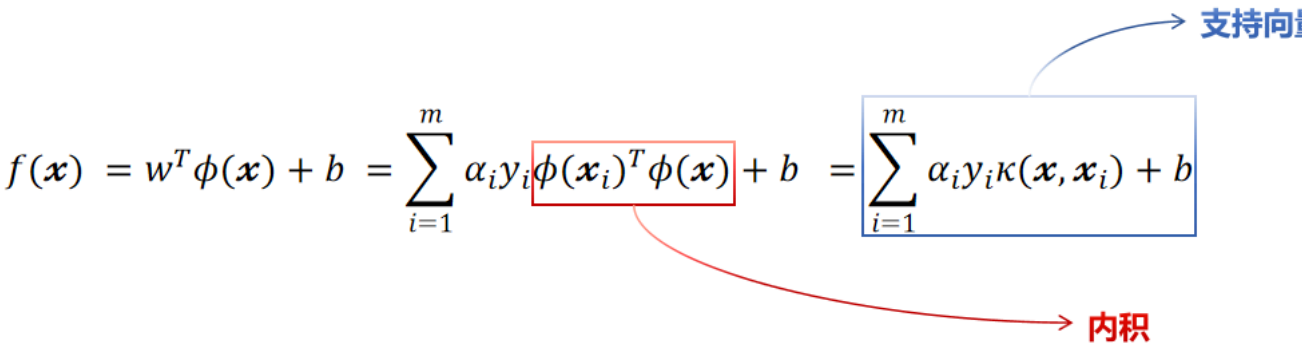
将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分。

为了处理线性不可分问题，SVM引入了松弛变量（Slack Variables）和软间隔（Soft Margin）的概念。松弛变量允许一些样本点位于错误的一侧部，从而允许一定的分类错误。软间隔允许决策边界在一定程度上偏离支持向量，以提高模型的泛化能力。

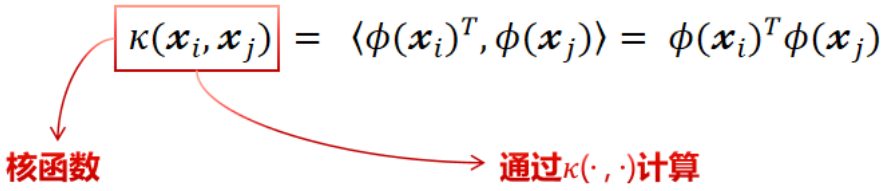
核支持向量机

设样本x映射后的向量为ϕ(x)，划分超平面为$f(x)\ = w^{T}\phi(x) + b$。

求解支持向量机的对偶问题，得到：



由于特征空间维数可能很高，直接计算内积比较困难。为了避开这个障碍，可以设想这样一个函数



即(x_{i})与(x_{j})在特征空间的内积等于它们在原始样本空间中通过函数κ(·,·)计算的结果，有了这样的函数，我们就不必直接去计算高维甚至无穷维的内积。

核函数

Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵半正定, 则它就能作为核函数来使用。

常用的核函数如下表：

核函数的注意事项

核函数选择成为svm的最大变数

核函数的选择是SVM中最重要的决策之一，它对模型的性能和表现具有重大影响。选择合适的核函数是使用SVM进行非线性分类或回归任务时需要权衡的关键因素。

本数据，如果特征经过适当的处理（如词袋模型、TF-IDF等），在某些情况下可能会呈现出线性可分的特性。这时，使用线性核函数可以得到较好
果。

然而，对于情况不明的文本数据（即无法确定是否线性可分），使用高斯核函数是一个常见的选择。高斯核函数通过将文本样本映射到 维特
算在该空间中的内积，从而能够处理非线性可分的情况。高斯核函数具有较强的拟合能力，可以更好地适应复杂的文本分类问题。

核函数的性质：

1 核函数的线性组合仍为核函数

2 核函数的直积仍为核函数

3 设κ((x_{1}),(x_{2}))为核函数，则对于任意函数(g)，(g(x_{1})\kappa(x_{1},x_{2})g(x_{2}))仍为核函数。

软间隔与正则化

本知识点主要教学目的：让学生掌握软间隔和正则化。

软间隔

Q：现实中, 很难确定合适的核函数使得训练样本在特征空间中线性可分; 同时一个线性可分的结果也很难断定是否是有过拟合造成的。

A：引入”软间隔”的概念, 允许支持向量机在一些样本上不满足约束。

在标准的支持向量机中，假设训练数据是线性可分的，即存在一个超平面可以完全将正例和负例分开。这种情况下，我们可以使用硬间隔（Hard
构建支持向量机，即要求所有的训练样本都位于正确的一侧，没有任何样本落在超平面或者错误的一侧。

然而，当数据集中存在噪声、异常样本或重叠的情况时，使用硬间隔可能会导致过拟合，即模型过于关注训练样本的准确分类，而对新样本的泛化
了解决这个问题，引入了软间隔的概念。

损失函数

基本想法：最大化间隔的同时, 让不满足约束的样本应尽可能少。

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m} l_{0/1}\left(y_i\left(\boldsymbol{w}^{\top}\phi(\boldsymbol{x}_i)+b\right)-1\right)$$

其中(l_{0/1})是”0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

正则化常数C>0，如果C→∞，则等价于要求所有的样本点都分类正确，否则就允许一部分极少的样本分类错误。

替代损失

(l_{0/1})非凸、非连续，数学性质不太好，不易求解。于是，人们通常用其他一些函数来代替(l_{0/1})，称为“替代损失”。替代损失函数一般具有
性质，如它们通常是凸的连续函数且是(l_{0/1})的上界。下图给出了三种常用的替代损失函数：

松弛变量

采用hinge损失的原始问题：

$$\min_{w,b} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \max(0, 1 - y_i(w^T\varphi(x_i) + b))$$

引入松弛变量(\xi_{i})≥0，可将上式重写为：

$$\min_{\mathbf{w},b,\xi_i} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}\xi_i$$

$$s.t. \quad y_i\left(\mathbf{w}^{\mathrm{T}}\mathbf{x}_i + b\right) \geq 1 - \xi_i$$

$$\xi_i \geq 0, i = 1, 2, \ldots, m$$

注：每一个样本都对应一个松弛变量(\xi_{i})，用以表征该样本不满足约束(y_{i}f(x_{i}) \geq 1)的程度。

正则化

支持向量机学习模型的更一般形式

(L_{p})范数是常用的正则化项，其中

(L_{2})范数倾向于w的分量取值尽量均衡，即非零分量个数尽量稠密

(L_{0})范数和(L_{1})范数则倾向于w的分量尽量稀疏，即非零分量个数尽量少

支持向量回归

本知识点主要教学目的：让学生了解支持向量回归的基本原理。

特点: 允许模型输出和实际输出间存在2ϵ的偏差。

对样本(x,y)，传统回归模型通常直接基于模型输出f(x)与真实输出y之间的差别来计算损失，当且仅当f(x)与y完全相同时，损失才为零。与此不同。归假设我们能容忍f(x)与y之间最多有ϵ的偏差，即仅当f(x)与y之间的差别绝对值大于ϵ时，才计算损失。这相当于以f(x)为中心，构建了一个宽度为若训练样本落入此间隔带，则认为是被预测正确的。

损失函数

落入中间2ϵ间隔带的样本不计算损失, 从而使得模型获得稀疏性。

在支持向量回归（Support Vector Regression，SVR）中，与传统的最小二乘回归不同，SVR使用了不同的损失函数来进行模型的训练和优化。

最小二乘回归使用的是最小二乘损失函数，即将预测值与真实值之间的差异平方作为损失，然后通过最小化总体损失来拟合模型。最小二乘回归的测值与真实值的平方差最小化。

而在SVR中，使用的是不同的损失函数，常见的是ε-insensitive损失函数。该损失函数在一个ε范围内对预测值和真实值之间的差异不敏感，而对于差异则进行惩罚。具体来说，SVR的目标是找到一个边界带（margin），使得大部分样本都落在边界带内，而超出边界带的样本则受到惩罚。

与最小二乘回归相比，SVR的损失函数可以更好地处理离群值和噪声样本，因为它对于差异在ε范围内的样本不敏感，而对于超出ε范围的样本进行得SVR在面对具有噪声和离群值的数据时具有更好的鲁棒性。

深度学习

本知识点主要教学目的：让学生了解常见神经网络模型和深度学习模型。

表示定理

给定训练样本，若不考虑偏移项b，则无论SVM还是SVR，学得的模型总能表示成核函数(\kappa(x,x_{i}))的线性组合。

更一般的结论(表示定理): 对于任意单调增函数Ω和任意非负损失函数l, 优化问题：

$h(\boldsymbol{x}_i)$

的解总可以写为

$$h^* = \sum_{i=1}^{m} \alpha_i \kappa(\cdot, \boldsymbol{x}_i)$$

列表

批注

核化线性模型

核化线性模型的基本思想是将数据通过核函数映射到一个高维特征空间中，然后在该特征空间中应用线性模型。这样，在原始特征空间中线性不可
在高维特征空间中变得线性可分。

通过表示定理可以得到很多线性模型的”核化”版本

- 核SVM
- 核LDA
- 核PCA
- ……

核方法通过引入核函数将数据映射到高维特征空间，从而在原始特征空间中线性不可分的问题可以在高维特征空间中变得线性可分。核方法可以处
题，并且避免了计算高维特征空间的复杂性。

核线性判别模型

核线性判别分析（Kernel Linear Discriminant Analysis，KLDA）是一种基于核方法的线性判别分析方法。它是对传统的线性判别分析（Linear D
Analysis，LDA）在非线性情况下的扩展。

LDA是一种经典的监督学习方法，用于降低数据维度并进行分类。它的目标是找到一个投影方向，使得同一类别的样本尽可能地接近，不同类别的
分开。传统的LDA是在原始特征空间中进行线性投影的，但当数据在原始特征空间中无法被线性分割时，LDA的性能会受到限制。

KLDA通过引入核函数，将数据映射到一个高维特征空间中，然后在该特征空间中进行线性判别分析。具体来说，KLDA首先计算样本之间的核矩阵
表示样本在高维特征空间中的相似度。然后，对核矩阵进行中心化和标准化处理，以便进行后续的特征分析。最后，KLDA通过求解广义特征值问
的投影方向，使得同一类别的样本尽可能地接近，不同类别的样本尽可能地分开。

KLDA的优点在于可以处理非线性问题，并且通过核技巧避免了计算高维特征空间的复杂性。它能够更好地拟合非线性数据，并提高分类的准确性