列表

批注

贝叶斯分类器

备课材料

OracleWDP•华育兴业

内容分析	本章介绍机器学习中的贝叶斯分类器及其相关概念。首先，讨论概率决策与参数估计，包括贝叶斯决策论、生成式模型和参数估计方法，其中频率主义学派的极大似然估计是重点。然后，详细介绍朴素贝叶斯分类器的原理、具体例子和拉普拉斯修正，它基于特征条件独立性假设，适用于文本分类等任务。接下来，介绍半朴素贝叶斯分类器，包括SPODE和TAN算法，它们在考虑特征相关性时具有一定优势。然后，探讨贝叶斯网的结构、学习和推断方法，它是一种图模型用于表示变量之间的依赖关系。最后，介绍EM算法，一种迭代优化算法，用于在概率模型中进行参数估计。
教学目的及要求	了解极大似然估计；了解朴素贝叶斯分类器；了解半朴素贝叶斯分类器；了解贝叶斯网和EM算法。
重点	教学重点：极大似然估计、朴素贝叶斯分类器、贝叶斯网、EM算法。
难点	教学难点：朴素贝叶斯分类器、贝叶斯网、EM算法。
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

课程知识点

贝叶斯分类器

概率决策与参数估计

本知识点主要教学目的：让学生了解贝叶斯决策论和极大似然估计。

贝叶斯决策论

贝叶斯决策论（Bayesian decision theory）是在概率框架下实施决策的基本方法。

在分类问题情况下，在所有相关概率都已知的理想情形下，贝叶斯决策考虑如何基于这些概率和误判损失来选择最优的类别标记。

假设有N种可能的类别标记，即(y\ = \ { c_{1},c_{2},...,c_{N}} ，\lambda_{\text{ij}})是将一个真实标记为(c_{j})的样本误分类为(c_{i})所产生的损失率(P(c_{i}┃\ x))可获得将样本x分类为(c_{i})所产生的期望损失（expected loss），即在样本x上的“条件风险”（conditional risk）

我们的任务是寻找一个判定准则(h:\ X \longmapsto Y)以最小化总体风险

贝叶斯判定准则（Bayes decision rule）： 为最小化总体风险，只需在每个样本上选择那个能使条件风险R(c ┃ x)最小的类别标记，即

$$h^*(x) = \underset{c \in y}{\operatorname{argmin}} R(c \mid x)$$

此时，(h^{\ast})被称为贝叶斯最优分类器(Bayes optimal classifier)，与之对应的总体风险R((h^{\ast}))称为贝叶斯风险 (Bayes risk)

1−R((h^{\ast}))反映了分类起所能达到的最好性能，即通过机器学习所能产生的模型精度的理论上限。

最小化分类错误率的贝叶斯最优分类器为：

$$h^*(x) = \underset{c \in y}{\operatorname{argmax}} P(c \mid x)$$

即对每个样本x，选择能使后验概率P(c ┃ x)最大的类别标记。

欲使用贝叶斯判定准则来最小化决策风险，首先要获取后延概率P(c ┃ x)。然而，在现实任务中这通常难以直接获取。

机器学习所要实现的是基于有限的训练样本尽可能准确地估计出后验概率P(c ┃ x)。

生成式模型（generative models）：先对联合概率分布P(x ,c)建模，再由此获得P(c ┃ x)。

生成式模型

列表
批注

生成式模型通过建立联合概率分布对数据进行建模，包括估计类别的先验概率和每个类别下的条件概率分布。求解后验概率时，可以(斯定
率和条件概率来计算后验概率。

参数估计

估计类条件概率的常用策略：先假定其具有某种确定的概率分布形式，再基于训练样本对概率分布参数估计。

记关于类别c的类条件概率为P(c ┃ x)，假设P(c ┃ x)具有确定的形式被参数θ_c唯一确定，我们的任务就是利用训练集D估计参数θ_c。

概率模型的训练过程就是参数估计过程，统计学界的两个学派提供了不同的方案：

频率主义学派 (frequentist)认为参数虽然未知，但却存在客观值，因此可通过优化似然函数等准则来确定参数值

贝叶斯学派 (Bayesian)认为参数是未观察到的随机变量、其本身也可由分布，因此可假定参数服从一个先验分布，然后基于观测到的数据计算参数
布。

频率主义学派-极大似然估计

令(D_{c})表示训练集中第c类样本的组合的集合，假设这些样本是独立的，则参数(\theta_{c})对于数据集(D_{c})的似然是：

上式的连乘操作易造成下溢，通常使用对数似然(log-likelihood)：

此时参数(\theta_{c})的极大似然估计({\widehat{\theta}}_{c})为

在连续属性情形下，假设概率密度函数(p(x\ |\ c)\ \sim\ N(\mu_{c}\ ,\sigma_{c}^{2}))，则参数(\mu_{c})和(\sigma_{c}^{2})的极大似然估计为

也就是说，通过极大似然法得到的正态分布均值就是样本均值，方差就是的均值，这显然是一个符合直觉的结果。

需注意的是，这种参数化的方法虽能使类条件概率估计变得相对简单，但估计结果的准确性严重依赖于所假设的概率分布形式是否符合潜在的真实

朴素贝叶斯分类器

本知识点主要教学目的：让学生了解朴素贝叶斯分类器。

朴素贝叶斯分类器采用了“属性条件独立性假设”：每个属性独立地对分类结果发生影响。

其中d为属性数目，(x_{i})为x在第i个属性上的取值。

由于对所有类别来说P(x)相同，因此基于

$$h^*(x) = \underset{c \in y}{\operatorname{argmin}} R(c \mid x)$$

的贝叶斯判定准则有：

这就是朴素贝叶斯分类器的表达式。

朴素贝叶斯分类器的训练器的训练过程就是基于训练集D估计类先验概率P©并为每个属性估计条件概率P((x_{i})┃ c)。

令(D_{c})表示训练集D中第c类样本组合的集合，若有充足的独立同分布样本，则可容易地估计出类先验概率

对离散属性而言，令(D_{c}),(x_{i})表示(D_{c})中在第i个属性上取值为(x_{i})的样本组成的集合，则条件概率P((x_{i}) ┃ c)可估计为

对连续属性而言可考虑概率密度函数，假定P((x_{i}) ┃ c)~ N((\mu_{c,i}\ ,\sigma_{c,i}^{2}))，其中(\mu_{c,i})和(\sigma_{c,i}^{2})分别是第c类样本在第i个
均值和方差，则有

具体例子

1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.46	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.36	0.37	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测 1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	?

首先估计类先验概率P©：

[P(好瓜 = 是)\ = \ 8/17 \approx 0.471；]

[P(好瓜 = 否)\ = \ 9/17 \approx 0.529；]

然后计算每个属性估计条件概率P((x_{i}) | c)：

[P_{青绿|是}_ = \ P(色泽 = 青绿|好瓜 = 是)\ \ = 3/8 = 0.375\ ；]

[\text{...}]

[p_{含糖：0.460|否} = \ p(含糖率 = 0.460|好瓜 = 否)\ \ = \frac{1}{\sqrt{2\pi} \bullet 0.108}\exp^{- \frac{{(0.460 - 0.154)}^{2}}{2 \bullet {0.
pprox 0.066\ ]

[P(好瓜 = 是) \times P_{青绿|是} \times P_{蜷缩|是} \times P_{浊响|是} \times P_{清晰|是}P \times P_{凹陷|是} \times P_{硬滑|是} \times P_{
是} \times P_{含糖：0.460|是}]

[\ \approx 0.052]

[P(好瓜 = 否) \times P_{青绿|否} \times P_{蜷缩|否} \times P_{浊响|否} \times P_{清晰|否}P \times P_{凹陷|否} \times P_{硬滑|否} \times P_{
否} \times P_{含糖：0.460|否}\ \approx 6.8 \times 10\hat{} - 5]

由于0.052>6.8×10^−5，因此，朴素贝叶斯分类器将测试样本“测1”判别为”好瓜“。

拉普拉斯修正

在概率估计中，如果某个事件在训练数据中没有出现过，那么在频率派的观点下，其概率将被估计为0，这会导致后续计算中出现问题。

为了避免其他属性携带的信息被训练集中未出现的属性值“抹去”，在估计概率值时通常要进行“拉普拉斯修正”（Laplacian correction）

N表示训练集D中可能的类别数，(N_{i})表示第i个属性可能的取值数。

半朴素贝叶斯分类器

本知识点主要教学目的：让学生了解半朴素贝叶斯分类器。

软间隔

为了降低贝叶斯公式中估计后验概率的困难，朴素贝叶斯分类器采用的属性条件独立性假设；对属性条件独立假设记性一定程度的放松，由此产生
“半朴素贝叶斯分类器” (semi-naïve Bayes classifiers)

半朴素贝叶斯分类器最常用的一种策略： “独依赖估计”(One-Dependent Estimator,简称ODE)，假设每个属性在类别之外最多仅依赖一个其他

其中(\text{pa}{i})为属性(x{i})所依赖的属性，称为(x_{i})的父属性.。

SPODE&TAN

最直接的做法是假设所有属性都依赖于同一属性，称为“超父” (super-parenet)，然后通过交叉验证等模型选择方法来确定超父属性，由此形成
per-Parent ODE)方法。

列表

TAN通过构建一个树状结构来表示特征之间的依赖关系，其中树的每个节点代表一个特征，节点之间的边表示特征之间的相关性。这个 构可
生成树算法（如Kruskal算法或Prim算法）来构建。

批注

贝叶斯网

本知识点主要教学目的：让学生了解贝叶斯网。

贝叶斯网 (Bayesian network)亦称“信念网”(brief network)，它借助有向无环图 (Directed Acyclic Graph, DAG)来刻画属性间的依赖关系，并
表 (Conditional Probability Table, CPT)来表述属性的联合概率分布。

网络图结构可以看出 -> “色泽”直接依赖于“好瓜”和“甜度”

从条件概率表可以得到 -> “根蒂”对“甜度”的量化依赖关系 P(根蒂 = 硬挺|甜度 = 高) = 0.1

结构

贝叶斯网有效地表达了属性间的条件独立性。给定父结集，贝叶斯网假设每个属性与他的非后裔属性独立。

将属性B = 〈G,Θ〉将属性(x_{1}),(x_{2}),...,(x_{d})的联合概率分布定义为：

下图的联合概率分布定义为：

显然，(x_{3})和(x_{4})在给定(x_{1})的取值时独立，(x_{4})和(x_{5})在给定(x_{2})的取值时独立，记为(x_{3})⊥(x_{4})|(x_{1})和(x_{4})⊥(x_{5})|(x_{

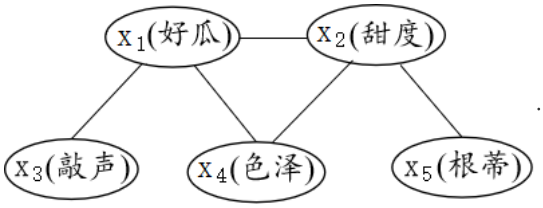
贝叶斯网中三个变量之间的典型依赖关系：

分析有向图中变量间的条件独立性，可使用“有向分离”(D-separation)

V型结构父结点相连

有向边变成无向边

由此产生的图称为道德图(moral graph)



学习

学习（Learning）：贝叶斯网络的学习任务是从给定的数据中学习网络的结构和参数。学习过程中，通常需要解决两个子任务：结构学习和参数学

结构学习：结构学习是确定贝叶斯网络中变量之间的依赖关系，即确定有向无环图的结构。常用的结构学习方法包括基于约束的搜索算法、贪婪搜
式搜索算法等。

参数学习：参数学习是估计贝叶斯网络中条件概率表的参数。参数学习可以通过最大似然估计、贝叶斯估计或其他统计方法来进行。

推断

推断（Inference）：贝叶斯网络的推断任务是根据给定的证据（观测到的变量）计算目标变量的后验概率分布。推断过程中，贝叶斯网络利用贝
件概率表进行计算。

常用的推断算法包括：

变量消除（Variable Elimination）

...

EM算法

本知识点主要教学目的：让学生了解EM算法。

问题：存在“未观测”变量的情形下，是否仍能对模型参数进行估计？

未观测的变量称为“隐变量”（latent variable）。令X表示已观测变量集，Z表示隐变量集，若预对模型参数Θ做极大似然估计，则应最 似

由于Z是隐变量，上式无法直接求解。此时我们可以通过对Z计算期望，来最大化已观测数据的对数“边际似然”（marginal likelihood）

EM算法的核心思想是通过迭代的方式，交替进行两个步骤：E步（Expectation Step）和M步（Maximization Step）。

在E步中，根据当前的参数估计，计算隐变量的后验概率（期望）；

在M步中，根据隐变量的后验概率，重新估计模型的参数（最大化似然函数）。通过交替进行E步和M步，不断更新参数，直到收敛为止。

当参数Θ已知 - > 根据训练数据推断出最优隐变量Z的值(E步)

当Z已知 - > 对Θ做极大似然估计(M步)