集成学习

备课材料

OracleWDP•华育兴业

内容分析	本章节将深入探讨集成学习，一种强大的机器学习策略，它通过结合多个个体学习器的预测来改善模型性能。 我们首先介绍集成学习的概念以及个体学习器的分类，并特别关注同质学习器。然后，我们将详细讲解Boosting， 一种重要的集成学习方法，包括其基本概念、算法步骤、权重调整，以及AdaBoost算法。接着，我们将讨论偏差与方差的 在此之后，我们将引入Bagging和随机森林，解释其概念、算法步骤、数据采样方法以及特点。然后，我们将探讨不同的结 包括平均法、投票法和学习法。最后，我们将讨论多样性的重要性，包括误差-分歧分解、多样性度量和多样性增强等内容。
教学目的及要求	了解集成学习基本原理；了解Boosting算法的一般流程；了解了解Bagging与随机森林；了解结合策略和多样性。
重点	教学重点：集成学习、Boosting、Bagging、随机森林。
难点	教学难点：Boosting、Bagging、随机森林。
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

课程知识点

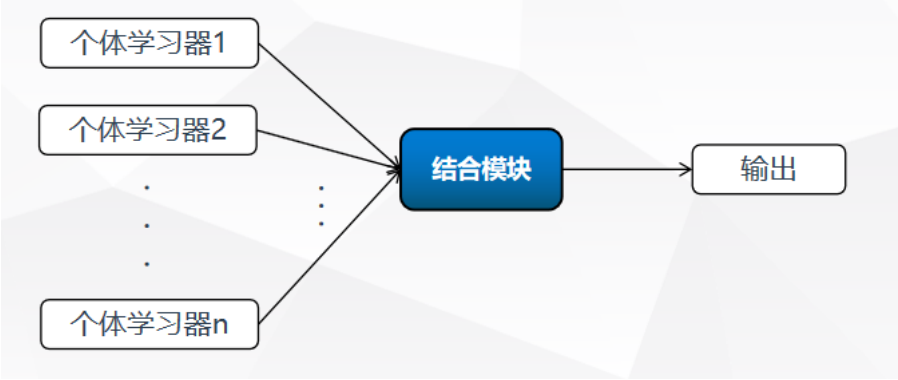
集成学习

个体与集成

本知识点主要教学目的：让学生了解集成学习和个体学习器种类。

集成学习（Ensemble Learning）

集成学习（Ensemble Learning）指通过构建并结合多个学习器来完成学习任务。和传统学习方法训练一个学习器不同，集成学习方法训练多个学
它们来解决一个问题。



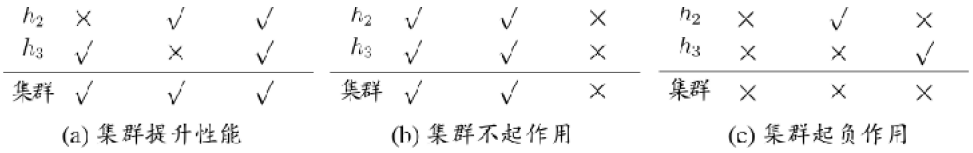
集成学习的一般结构如下：先产生一组“个体学习器”，再用某种策略将它们结合起来。个体学习器通常由一个现有的学习算法从训练数据产生。

同质集成中的个体学习器亦称“基学习器”，相应的学习算法称为“基学习算法”。

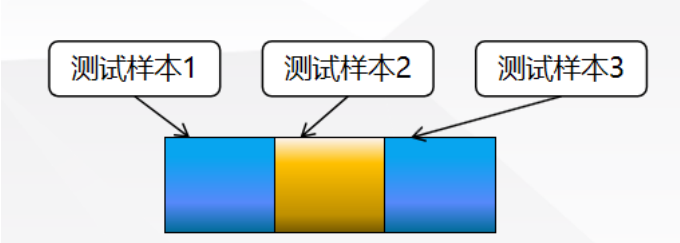
集成也可包括不同类型的个体学习器，这样的集成是“异质”的。异质集成中的个体学习器有不同的学习算法生成，此时，个体学习器一般称为
或直接成为个体学习器

上图给出了一个通用的集成学习框架，一个集成由多个基学习器构成，而及学习器由基学习算法在训练数据上训练获得，它们可以是决策树、神经
习算法。

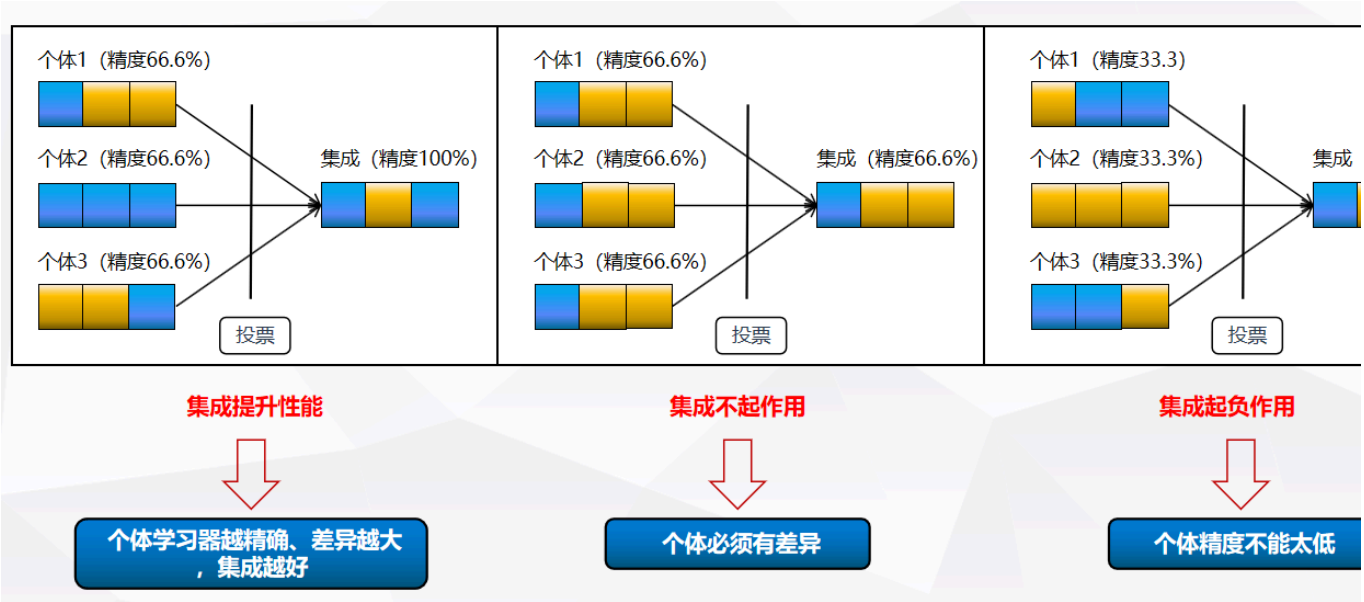
考虑一个简单的例子，在二分类问题中，假定3个分类器在三个样本中的表现如下图所示，其中√ 表示分类正确，X 号表示分类错误，集成的结果
生。



例如，这里有一个二分类问题，用于测试的样本数据正确分类如下图所示。



假设有三个机器学习分类器在样本中的表现如下图所示。



个体学习器应该“好而不同”，即个体学习器要有一定的“准确性”，即学习器不能太坏，并且要有“多样性”，即学习器间具有差异。

既然多个个体的集成比单个个体更好，那么是不是个体越多越好?

更多的个体意味着:

- 在预测时需要更大的计算开销，因为要计算更多的个体预测
- 更大的存储开销，因为有更多的个体需要保存

个体的增加将使得个体间的差异越来越难以获得。

个体学习器分类

针对好而不同的集成概念，集成学习需要解决的主要问题:

- 如何得到若干个个体学习器（生成方式）
- 如何选择结合策略（结合方式）

对于个体学习器可分为:

- 同质学习器（基学习器）：只包含同种类型的基学习器;
- 异质学习器（组件学习器）：同时包含不同种类型的基学习器;

例如：都是决策树算法得到的个体学习器（同质）；既有决策树算法得到的个体学习器，又有其他算法得到的学习器（异质）。

同质学习器

集成学习用的比较多的是同质学习器。同质学习器按照个体学习器之间是否存在依赖关系可以分为两类。

Boosting

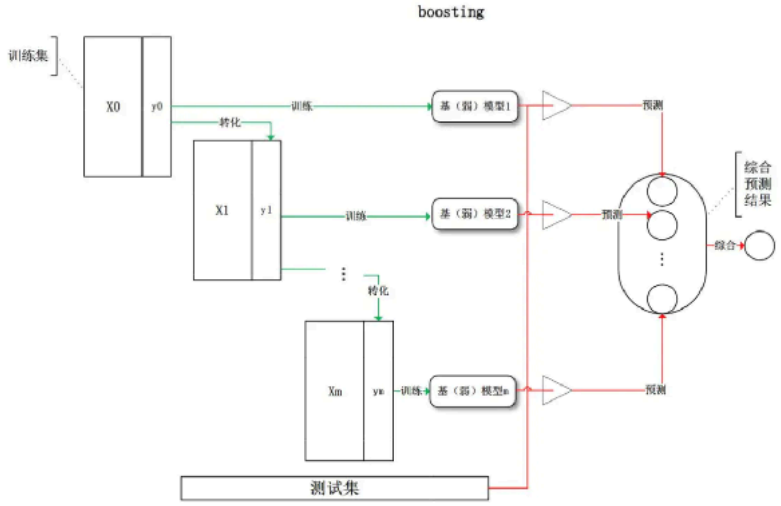
本知识点主要教学目的：让学生了解Boosting算法的一般步骤。

列表

批注

Boosting概述

Boosting集成学习的过程不能并行，它的计算过程会先从原始样本集中训练出一个个体学习器，然后对该学习器中做错的训练样本进 通过
本权重，依次学习多个分类器并进行一些线性组合，达到将原本较弱的个体学习器提升为强学习器的目的。最著名的就是Adaboost算



Boosting算法步骤

Boosting是一种可将弱学习器提升为强学习器的算法，算法的一般步骤为：

1.先从初始训练集训练出一个基学习器

2.再根据基学习器的表现对训练样本分布进行调整，使得先前基学习器做错的训练样本在后续受到更多关注。

1）对于训练集中的每个样本建立权重值wi，表示对每个样本的权重，假设有n个训练样本，那么每个训练样本初始权重值为wi = 1/n

2）训练过程中，如果某个训练样本点被弱分类器分类正确,那么在构造下一个训练集中,它对应的权值wi要减少。相反,如果某个训练样本点被错误
权值就应该增大,权值更性过的样本集被用于训练下一个分类其,整个训练过程如此迭代地进行下去。

3）最后,将各个训练得到的弱分类器组合成一个强分类器,各个弱分类器的训练过程结束后,加大分类误差率小的弱分类器的权重,使其在最终的分类
大的决定作用,而降低分类误差率的弱分类器的权重,使其在最终的分类函数中起着较小的决定作用。也就是说,误差率低的弱分类器在最终分类中占
之较小。

3.然后基于调整后的样本分布在训练下一个基学习器

如此重复进行直至基学习器数目达到事先指定的值T，最终将这T个基学习器进行加权结合

例如对于一个分类问题，首先给每一个训练样例赋予相同的权重，然后训练第一个基分类器并用它来对训练集进行测试，对于那些分类错误的测试
（实际算法中是降低分类正确的样例权重），然后用调整后的带权训练集训练第二个基分类器，然后重复这个过程直到最后得到一个足够好的学习

Boosting算法-权重

样本的权重

- 没有先验知识的情况下，初始的分布应为等概分布，也就是训练集如果有N个样本，每个样本的分布概率为1/N。

- 每次循环后，提高错误样本的分布概率，分错样本在训练集中所占权重增大，使得下一次循环的弱学习器能够集中力量对这些错误样本进行判断

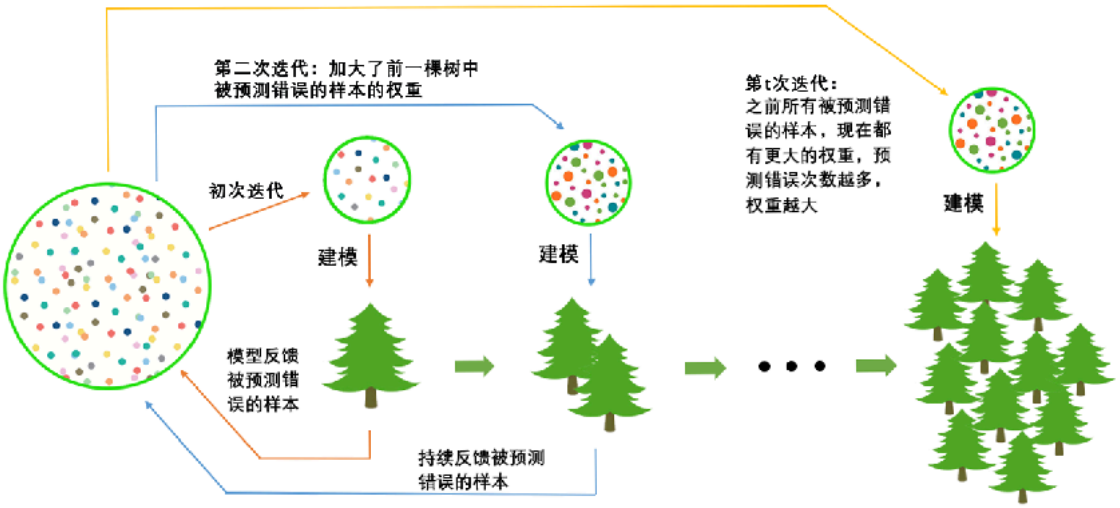
弱学习器的权重

在Boosting算法中，样本的权重起着重要的作用。初始时，所有样本的权重相等。在每一轮的训练过程中，根据前一个分类器的预测结果，样本的
调整。被错误分类的样本会被赋予更高的权重，以便在下一轮训练中更加关注这些难以分类的样本。而被正确分类的样本则会被赋予较低的权重，
轮训练中的影响。

通过不断调整样本权重，Boosting算法能够逐步改进模型的性能，提高对难以分类样本的分类能力。最终，通过将多个弱分类器进行加权组合，B
可以构建出一个强分类器，具有较高的分类准确率。

AdaBoost（自适应提升算法）

AdaBoost（Adaptive Boosting，自适应提升算法法）是当代Boosting领域的开山鼻祖，是首个成功将boosting思想发扬光大的算法



首先我们有一个巨大的数据集，在建第一棵树时，我们对数据进行初次有放回抽样，然后建模。

建模完毕后，我们对模型进行一个评估，然后将模型预测错误的样本反馈给我们的数据集，一次迭代就算完成。紧接着，我们要建立第二棵决策树
行第二次又放回抽样。 但这次有放回抽样，和初次的随机有放回抽样就不同了，在这次的抽样中，我们加大了被第一棵树判断错误的样本的权重。
被第一棵树判断错误的样本，更有可能被我们抽中。 基于这个有权重的训练集来建模，我们新建的决策树就会更加倾向于这些权重更大的，很容易
本。 建模完毕之后，我们又将判错的样本反馈给原始数据集。

下一次迭代的时候，被判错的样本的权重会更大，新的模型会更加倾向于很难被判断的这些样本。如此反复迭代，越后面建的树，越是之前的树们
专家，越专注于攻克那些之前的树们不擅长的数据。对于一个样本而言，它被预测错误的次数越多，被加大权重的次数也就越多。

我们相信，只要弱分类器足够强大，随着模型整体不断在被判错的样本上发力，这些样本会渐渐被判断正确。如此就一定程度上实现了我们每新建
效果都会提升的目标。

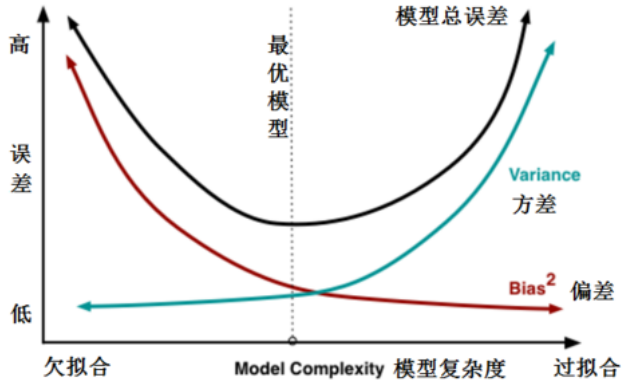
偏差 & 方差

一个集成模型((f))在未知数据集((D))上的泛化误差(E(f;D))，由方差((var))，偏差((bais))和噪声((\varepsilon))共同决定。

[E(f;D) = var(x) + bais\hat{}2(x) + \varepsilon\hat{}2]

偏差Bias：描述的是预测值和真实值之差。偏差越大，越偏离真实数据。要想偏差表现的好，就需要复杂化模型，容易过拟合。

方差Variance：描述的是预测值的离散程度，也就是离其期望值的距离。方差越大，数据的分布越分散。描述样本上训练出来的模型在测试集上的
方差表现的好，需要简化模型，容易欠拟合。

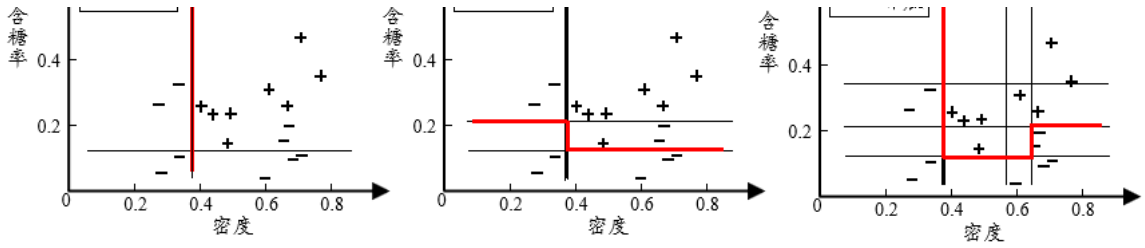


Boosting主要关注降低偏差

- 偏差刻画了学习算法本身的拟合能力

- Boosting思想，对判断错误的样本不停的加大权重，为了更好地拟合当前数据，所以降低了偏差，因此

Boosting能基于泛化性能相当弱的学习器构建出很强的集成。



我们以决策树桩为基学习器，在西瓜数据3.0α上运行AdaBoost算法，不同的规模的集成及基学习器所对应的分类边界如上图。

Bagging与随机森林

本知识点主要教学目的：让学生了解Bagging与随机森林的原理和一般步骤。

Bagging概述

Bagging全称是Bootstrap Aggregating，思想是从全体样本中随机取一部分进行模型训练，通过多次这样的训练，对模型结果取均值或投票作为
出。

形象的比喻来说，Bagging相当于并联电路 ，而Boosting相当于串联电路。

Bagging算法个体学习器之间不存在强依赖关系，,一系列个体学习器可以并行生成。

将多个个体学习模型，结合一定策略，将它们结合在一起，从而形成一个强学习器。

例如上图，我们选取三颗决策树模型作为个体学习模型，先将数据输入，经过Bootstrap采样得到三个子集数据，再经过三颗决策树模型训练得到
颗决策树的预测经过某种结合策略得到的预测效果可堪比一个强学习器。

Bagging算法步骤

1.数据采样（有放回的采样）：从原始样本集中使用Bootstraping方法随机抽取n个训练样本，共进行k轮抽取，得到k个训练集。（k个训练集之间
元素可以有重复）

2.数据训练：对于k个训练集，我们训练k个模型（这k个模型可以根据具体问题而定，比如决策树，knn等）

3.结合策略：

对于分类问题：由投票表决产生分类结果；

对于回归问题：由k个模型预测结果的均值作为最后预测结果。（所有模型的重要性相同）

数据采样-Bootstrap

想要得到泛化性能强的集成，集成中的歌学习器应该尽可能相互独立，虽然“独立”在现实中无法做到，但可以设法使基学习器尽可能具有较大的
们给定一个训练集，对训练样本进行采样，产生出若干不同的子集，再从每个数据子集中训练出一个基学习器，这里产生子集的方法就是Bootstr

Bootstrap方法是非常有用的一种统计学上的估计方法。Bootstrap是对观测信息进行再抽样，进而对总体的分布特性进行统计推断。Bootstrap是
的重复抽样方法，抽样策略就是简单的随机抽样。

这样，由于训练数据不同，我们获得基学习器可望具有比较大的差异，然而，我们同时还希望个体学习器不能太差。若每个子集完全不同，则每个
到一小部分训练数据，甚至不足以进行有效学习，无法保证产生好的学习器。所以，我们考虑使用相互有交叠的采样子集。

例如，对于一个包含m个样本的数据集，基学习器（Base Learner）有k个，进行m次有放回的随机采样，这样得到k个大小为m的采样集分别给k
进行训练。

因为是有放回的采样，所以采样到的样本有可能有重复样本。

假设一个样本被抽取到的概率是1/m，则抽样次数足够大时，一个样本不被抽到的概率为：(\lim_{m \rightarrow \infty}{\left(1 + \frac{1}{m} \
0.368})

所以Bootstrap方法，当抽样样本无限大时，抽样样本的最大覆盖率为63.2%。

Bagging算法特点

器的偏倚引起。

由于每个样本被选中的概率相同，因此bagging并不侧重于训练数据集中的任何特定实例

对于那些容易受样本影响的学习器，它们在不同的训练集上可能会产生差异较大的预测结果。这种差异可能是由于样本的随机性引起的。Bagging通过建多个子训练集，让每个基学习器在不同的训练集上进行训练，从而减少了样本的随机性对最终预测结果的影响。

对于不剪枝的决策树、神经网络等学习器，它们通常具有较高的方差，即对训练数据的变化较为敏感，容易出现过拟合的问题。而Bagging通过学习器并对它们的预测结果进行平均或投票，可以降低模型的方差，减少过拟合的风险。

随机森林概述

随机森林（Random Forest,RF）是Bagging的一个扩展变体，随机森林在以决策树为基学习器构建Bagging集成的基础上，进一步在决策树的训练了随机属性选择。

随机森林和Bagging的主要区别在于引入了随机特征选择。即：在每棵决策树选择分割点时，随机森林会先随机选择一个特征子集，然后再整个子集的分割点选择。

传统决策树在选择划分属性时，是在当前结点的属性集合（假定有d个属性）中选择一个最优属性；而在RF中，对基决策树的每个结点，先从该结点中随机选择一个包含k个属性的子集，然后再从这个子集中选择一个最优属性进行划分。这里的参数k控制了随机性的引入程度；若令k=d，则基决策与传统决策树相同；若令k=1，则是随机选择一个属性用于划分；一般情况下，推荐值(k = \log_{2}d)。

随机森林步骤

1.有放回随机采样：从原始训练数据中随机选取n个数据作为训练数据输入（通常n远小于全体训练数据N）。

2.随机特征选择：每一个结点从全体特征集M中选取m个特征进行构建决策树（通常m远小于M）。

3.在构造每棵决策树时，选取基尼指数最小的特征来分裂节点构建决策树。

4.重复第2步和第3步多次，每一次输入数据对应一颗决策树，这样就得到了一个随机森林，用于对预测数据进行决策。

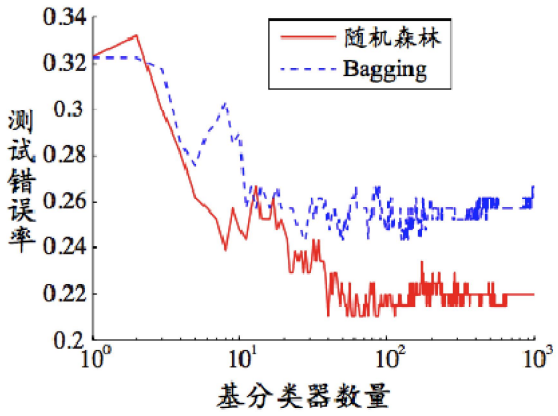
5.对待预测数据进行预测时，多棵决策树同时进行决策，采用多数投票的方式产生最终决策结果。

随机森林回归算法策略一般为求均值的方式

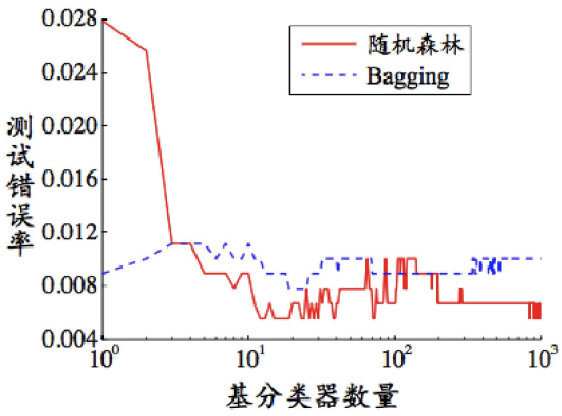
随机森林分类算法策略一般为少数服从多数的投票方式

Bagging与随机森林

随机森林的收敛性与Bagging相似，如下图所示，随机森林的起始性能往往相对较差，特别是在集成中只包含一个基学习器时。然而随着个体学习器数目的增加，随机森林通常会收敛到更低的泛化误差。值得一提的是，随机森林的训练效率常由于Bagging，因为在个体决策树的构建过程中，Bagging是使用“确定型”决策树，在选择划分属性时要对结点的所有属性进行考察，而随机森林使用的“随机型”决策树则只需考察一个属性子集。



(a) glass 数据集



(b) auto-mpg 数据集

结合策略

本知识点主要教学目的：让学生了解集成学习的结合策略。

合多个学习器则多减小这一风险；

2. 从计算的方面来看，学习算法往往会陷入局部极小，有的局部极小点所对应的泛化性能可能很糟糕，而通过多次运行之后进行结合 低降小点的风险；
3. 从表示方面来看，某些学习任务的真实假设可能不在当前学习算法所考虑的假设空间中，此时若使用单学习器则肯定无效，而通过 个学应的假设空间有所扩大，有可能学得更好的近似。

平均法

平均法：对于数值类的回归预测问题；

基本思想：对于若干个弱学习器的输出进行平均得到最终的预测输出。

常用的平均法有简单平均法和加权平均法。

简单平均法是加权平均法的特例

加权平均法在二十世纪五十年代被广泛使用

集成学习中的各种结合方法都可以看成是加权平均法的变种或特例

加权平均法可认为是集成学习研究的基本出发点

加权平均法未必一定优于简单平均法

简单平均法

$$H(\boldsymbol{x}) = \frac{1}{T}\sum_{i=1}^{T} h_i(\boldsymbol{x}).$$

加权平均法

$$H(\boldsymbol{x}) = \sum_{i=1}^{T} w_i h_i(\boldsymbol{x}) \,, \quad w_i \geq 0 \quad \text{and} \quad \sum_{i=1}^{T} w_i = 1 \,.$$

投票法

投票法：对于分类问题的预测；

基本思想：多个基分类器都进行分类预测，然后根据分类结果用某种投票的原则进行投票表决，按照投票原则使用不同投票法。

绝对多数投票法（majority voting）

$$H\left(\boldsymbol{x}\right) = \begin{cases} c_j & \text{if } \sum_{i=1}^{T} h_i^j\left(\boldsymbol{x}\right) > \frac{1}{2}\sum_{k=1}^{l}\sum_{i=1}^{T} h_i^k\left(\boldsymbol{x}\right) \\ \text{rejection} & \text{otherwise} \,. \end{cases}$$

相对多数投票法（plurality voting）

$$H(\boldsymbol{x}) = c_{\arg\max_j \sum_{i=1}^{T} h_i^j(\boldsymbol{x})}$$

加权投票法（weighted voting）

$$H(\boldsymbol{x}) = c_{\arg\max_j \sum_{i=1}^{T} w_i h_i^j(\boldsymbol{x})}$$

学习法

学习法：Stacking是典型代表；

基本思想：第一层用不同的算法形成T个弱分类器，同时产生一个与原数据集大小相同的新数据集，利用这个新数据集和一个新算法构成第二层的

Stacking的优势在于能够利用不同学习器的优点，提高整体模型的性能。通过组合多个学习器的预测结果，Stacking可以更好地适应不同的数据分
具有较强的泛化能力。

多样性

本知识点主要教学目的：让学生了解EM算法。

多样性 – 误差-分歧分解

定义学习器(h_{i})的分歧：

$$A(h_i \mid \boldsymbol{x}) = \big(h_i(\boldsymbol{x}) - H(\boldsymbol{x})\big)^2$$

集成的分歧：

$$\begin{aligned}\overline{A}(h \mid \boldsymbol{x}) &= \sum_{i=1}^{T} w_i A(h_i \mid \boldsymbol{x}) \\ &= \sum_{i=1}^{T} w_i \big(h_i\left(\boldsymbol{x}\right) - H\left(\boldsymbol{x}\right)\big)^2\end{aligned}$$

分歧项代表了个体学习器在样本x上的不一致性，即在一定程度上反映了个体学习器的多样性，个体学习器(h_{i})和集成H的平方误差分别为：

$$E(h_i \mid \boldsymbol{x}) = \big(f(\boldsymbol{x}) - h_i(\boldsymbol{x})\big)^2$$

$$E(H \mid \boldsymbol{x}) = \big(f(\boldsymbol{x}) - H(\boldsymbol{x})\big)^2$$

个体学习器(h_{i})在全样本上的泛化误差和分歧项分别为：

$$E_i = \int E(h_i \mid \boldsymbol{x}) p(\boldsymbol{x}) d\boldsymbol{x}$$

$$A_i = \int A(h_i \mid \boldsymbol{x}) p(\boldsymbol{x}) d\boldsymbol{x}$$

集成的泛化误差为：

$$E = \int E(H \mid \boldsymbol{x}) p(\boldsymbol{x}) d\boldsymbol{x}$$

令$\overline{E} = \sum_{i=1}^{T} w_i E_i$表示个体学习器泛化误差的加权均值，$\overline{A} = \sum_{i=1}^{T} w_i A_i$表示个体学习器的加权分歧值，有：

$$E = \overline{E} - \overline{A}$$

多样性 – 误差-分歧分解

多样性度量(diversity measure)用于度量集成中个体学习器的多样性

对于二分类问题，分类器(h_{i})与(h_{j})的预测结果联立表为：

$h_j = +1$	a	c
$h_j = -1$	b	d

$$a + b + c + d = m$$

不合度量(Disagreement Measure)

$$dis_{ij} = \frac{b + c}{m}$$

相关系数(Correlation Coefficient)

$$\rho_{ij} = \frac{ad - bc}{\sqrt{(a + b)(a + c)(c + d)(b + d)}}$$

Q-统计量(Q-Statistic)

$$Q_{ij} = \frac{ad - bc}{ad + bc} \qquad |Q_{ij}| \leq |\rho_{ij}|$$

K-统计量(Kappa-Statistic)

多样性增强

常见的增强个体学习器的多样性的方法

- 数据样本扰动
  - 基于采样法
- 输入属性扰动
  - 随机子空间算法
- 输出表示扰动
  - 翻转法(Flipping Output)、输出调剂法(Output Smearing)、ECOC法
- 算法参数扰动
  - 负相关法