聚类

备课材料

OracleWDP•华育兴业

内容分析	机器学习中的聚类是一种无监督学习方法，用于将数据集中的样本划分为不同的组或簇。本章节将介绍聚类的基本概念，包括分类任务与聚类任务的区别，常见的聚类算法以及性能度量与距离计算方法。我们将探讨原型聚类算法，包括经典的k均学习向量量化和高斯混合聚类，它们通过寻找样本的原型来进行聚类。此外，我们还将介绍密度聚类算法DBSCAN，它通过样本的密度来划分簇。最后，我们将讨论层次聚类算法AGNES，它通过逐步合并样本来构建聚类层次结构。
教学目的及要求	了解聚类的基本概念；了解常用性能度量指标与距离计算；了解常用的原型聚类；了解密度聚类的基本原理；了解层次聚类的基本原理。
重点	教学重点：性能度量、距离计算、原型聚类、密度聚类、层次聚类。
难点	教学难点：K-Means聚类、DBSCAN聚类、层次聚类。
教学方式	教学采用教师一边使用ppt讲授，一边使用实验环境进行操作

课程知识点

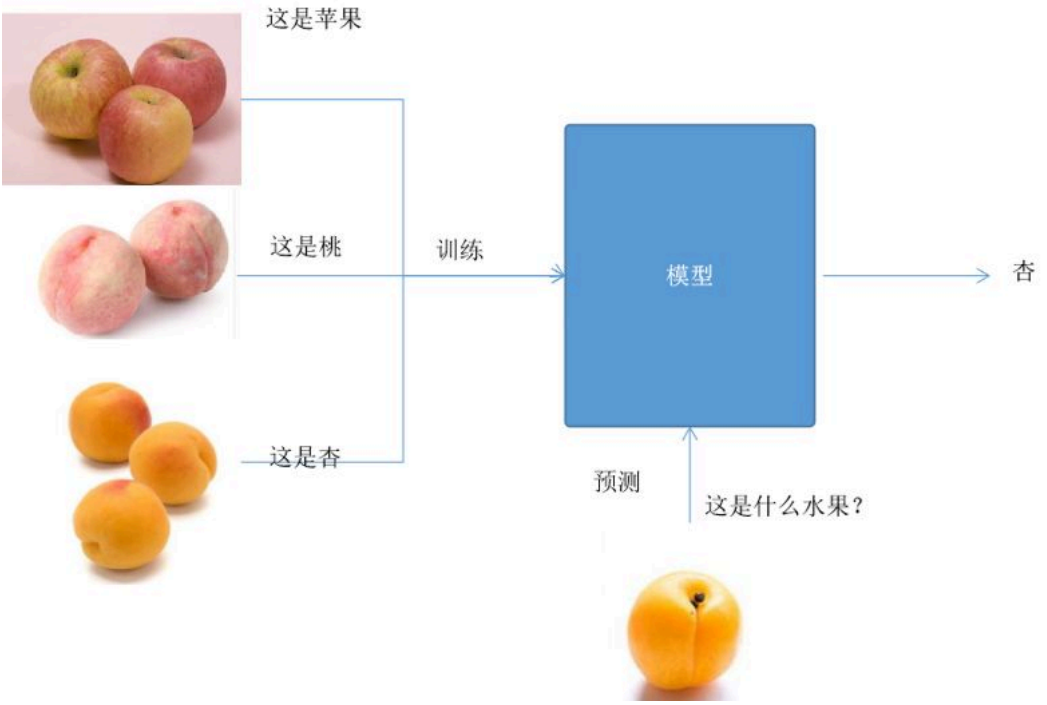
聚类

聚类概述

本知识点主要教学目的：让学生了解聚类的基本概念。

分类任务vs. 聚类任务

分类问题是机器学习中最常见的一类问题，它的目标是确定一个物体所属的类别。例如，我们要判定一个水果是苹果、杏，还是桃。解决这类问题一些各种类型的水果让算法学习，然后根据学习得到的经验对一个水果的类型做出判定。



这就像一个幼儿园的小朋友，老师先拿各种水果教他们，告诉每种水果是什么样子的，接下来这些孩子就会认这些类型的水果了。这种做法称为有有训练和预测两个过程，在训练阶段，我们用大量的样本进行学习，得到一个判定水果类型的模型。接下来，在预测阶段，给一个水果，就可以用出它的类别。



在这里，类型被称为“簇”（cluster）。以左面的图为例，这里有一堆水果，但我们事先没有告诉你有哪些水果，也没有一个训练好的判定各种水
聚类算法要自动将这堆水果进行归类。聚类算法没有训练过程，这是和分类算法最本质的区别，算法要根据自己定义的规则，将相似的样本划分在
的样本分成不同的类。

聚类任务

在“无监督学习”中，训练样本的标记信息是未知的，目标是通过对无标记训练样本的学习来揭示数据的内在性质及规律，为进一步的数据分析提
学习任务中研究最多、应用最广的是“聚类”。

聚类试图将数据集中的样本划分为若干个通常是不想交的子集，每个子集称为一个“簇”（cluster）。通过这样的划分，每个簇可能对应于不同的

常见聚类算法

常见的聚类算法包括：

K-means聚类算法：将数据点分为K个簇，通过最小化数据点与簇中心之间的平方距离来进行聚类。

层次聚类算法：基于数据点之间的相似性或距离构建层次结构，可以是自上而下的划分聚类（Divisive）或自下而上的凝聚聚类（Agglomerative

DBSCAN聚类算法：基于密度的聚类算法，通过确定核心对象和密度可达性来划分簇。

密度聚类算法：例如OPTICS和HDBSCAN，通过考虑数据点的密度分布来进行聚类。

高斯混合模型（GMM）聚类算法：假设数据点由多个高斯分布组成，通过最大化似然函数来进行聚类。

谱聚类算法：将数据点表示为图的拉普拉斯特征向量，通过对特征向量进行聚类来划分簇。

Mean-Shift聚类算法：通过寻找数据点密度最大的区域来进行聚类。

性能度量与距离计算

本知识点主要教学目的：让学生了解性能度量与距离计算。

性能度量

聚类性能度量，亦称为聚类“有效性指标”（validity index）。与监督学习中的性能度量作用相似，对聚类结果，我们需通过某种性能度量来评价
一方面，若明确了最终将要使用的性能度量，则可直接将其作为聚类过程的优化目标，从而更好地得到符合要求的聚类结果。

直观来讲：

我们希望“物以类聚”，即同一簇的样本尽可能彼此相似，不同簇的样本尽可能不同。换言之，聚类结果的“簇内相似度”（intra-cluster simila
“簇间相似度”（inter-cluster similarity）低，这样的聚类效果较好。

对数据集$D\ = \ \{ x_{1},x_{2},...,x_{m}\}$，假定通过聚类得到的簇划分为$C\ = \ \{ C_{1},C_{2},...,C_{k}\}$，参考模型给出的簇划分为$C^{\ast}\ = \ \{ C_{1}^{\ast},C_{2}^{\ast},...,C_{s}^{\ast}\}$。相应地，令λ与$\lambda^{\ast}$分别表示与C和$C^{\ast}$对应的簇标记向量。我们将样本两两配对考虑，定义：

$$b = |SD|, SD = \{(x_i, x_j)|\lambda_i = \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$$

$$c = |DS|, DS = \{(x_i, x_j)|\lambda_i \neq \lambda_j, \lambda_i^* = \lambda_j^*, i < j\}$$

$$d = |DD|, DD = \{(x_i, x_j)|\lambda_i \neq \lambda_j, \lambda_i^* \neq \lambda_j^*, i < j\}$$

性能度量 - 外部指标

accard系数（Jaccard Coefficient, JC）

FM指数（Fowlkes and Mallows Index, FMI）

Rand指数（Rand Index, RI）

性能度量 - 内部指标

考虑聚类结果的簇划分C =({ C_{1},C_{2},...,C_{k}})，定义

簇C内样本间的平均距离

簇C内样本间的最远距离

簇(C_{i})与簇(C_{j})最近样本间的距离

簇(C_{i})与簇(C_{j})中心点间的距离

DB指数（Davies-Bouldin Index, DBI）

Dunn指数（Dunn Index, DI）

性能度量 - 内部指标

距离度量函数：dist(·,·)

距离度量的性质：

非负性：dist((x_{i}),(x_{j}))≥0

同一性：dist((x_{i}),(x_{j}))=0当且仅当(x_{i})=(x_{j})

对称性：dist((x_{i}),(x_{j})) = dist(({x_{j},x}_{i}))

直递性：dist((x_{i}),(x_{j})) ≤dist((x_{i}),(x_{k})) +dist((x_{k}),(x_{j}))

闵可夫斯基距离（Minkowski distance）：

p=2: 欧氏距离（Euclidean distance）

p=1：曼哈顿距离（Manhattan distance）

属性介绍：

连续属性 (continuous attribute)：在定义域上有无穷多个可能的取值

离散属性 (categorical attribute)：在定义域上是有限个可能的取值

有序属性 (ordinal attribute)：例如定义域为{1,2,3}的离散属性，“1”与“2”比较接近、与“3”比较远，称为“有序属性”。

无序属性 (non-ordinal attribute)：例如定义域为{飞机，火车，轮船}这样的离散属性，不能直接在属性值上进行计算，称为“无序属性”。

原型聚类

本知识点主要教学目的：让学生了解常用的原型聚类的基本原理。

原型聚类也称为“基于原型的聚类” (prototype-based clustering)，此类算法假设聚类结构能通过一组原型刻画。

算法过程：

通常情况下，算法先对原型进行初始化，再对原型进行迭代更新求解。

常用的原型聚类算法：

高斯混合聚类算法

k均值算法

给定数据集(D\ = \ { x_{1},x_{2},...,x_{m}}) ， k均值算法针对聚类所得簇划分(C\ = \ { C_{1},C_{2},...,C_{k}})最小化平方误差：

其中，(\mu_{i})是簇(C_{i})的均值向量。

E值在一定程度上刻画了簇内样本围绕簇均值向量的紧密程度，E值越小，则簇内样本相似度越高。

K均值聚类算法流程

1.选择聚类的个数k

2.以随机或猜测的方式初始化聚类中心，生成k个中心

3.将每个数据点归并到离它距离最近的聚类中心所属的聚类

4.重新计算每个类的平均值，更新为新的聚类中心

5.重复2、3步骤直到聚类中心不再发生变化或者达到最大迭代次数

6.输出最终的聚类中心和k个类划分

k均值算法实例

接下来下表的西瓜数据集4.0为例，来演示k均值算法的学习过程。将编号为i的样本称为(x_{i})。

编号	密度	含糖率	编号	密度	含糖率	编号	密度	含糖率
1	0.697	0.460	11	0.245	0.057	21	0.748	0.232
2	0.774	0.376	12	0.343	0.099	22	0.714	0.346
3	0.634	0.264	13	0.639	0.161	23	0.483	0.312
4	0.608	0.318	14	0.657	0.198	24	0.478	0.437
5	0.556	0.215	15	0.360	0.370	25	0.525	0.369
6	0.403	0.237	16	0.593	0.042	26	0.751	0.489
7	0.481	0.149	17	0.719	0.103	27	0.532	0.472
8	0.437	0.211	18	0.359	0.188	28	0.473	0.376
9	0.666	0.091	19	0.339	0.241	29	0.725	0.445
10	0.243	0.267	20	0.282	0.257	30	0.446	0.459

假定聚类簇数k =3，算法开始时，随机选择3个样本(x_{6}),(x_{12}),(x_{27})作为初始均值向量，即(\mu_{1}) = (0.403;0.237),(\mu_{2}) = (0.343 {3})= (0.533;0.472)。

考察样本(x_{1}) = (0.697;0.460)，它与当前均值向量(\mu_{1}),(\mu_{2}),(\mu_{3})的距离分别为0.369，0.506，0.166，因此(x_{1})将被划入簇(似的，对数据集中的所有样本考察一遍后，可得当前簇划分为

于是，可以从分别求得新的均值向量(\mu_{1}^{' }) = (0.473;0.214),(\mu_{2}^{' }) = (0.394;0.066),(\mu_{3}^{' })= (0.623;0.388)不断重复上

聚类结果：

k均值算法（k=3）在各轮迭代后的结果，样本点由圆圈表示，均值向量由加号表示，红色虚线显示出簇划分

学习向量量化

学习向量量化（Learning Vector Quantization，简称LVQ）是一种聚类算法，它结合了监督学习和向量量化的思想。LVQ算法通过将输入数据样义的类别中，从而实现对数据的聚类。

LVQ算法的基本思想是通过学习一组原型向量（也称为代码矢量或聚类中心），将输入数据映射到这些原型向量所代表的类别中。在训练过程中，样本的特征和类别标签，不断调整原型向量的位置，以使得它们能够更好地表示各个类别。

□LVQ算法的训练过程可以概括为以下几个步骤：

3.计算距离：计算选择的样本与所有原型向量之间的距离。

4.确定最近原型向量：找到距离样本最近的原型向量。

5.更新原型向量：根据样本的类别标签和最近原型向量的类别标签，更新最近原型向量的位置，使其更好地代表该类别。

6.重复步骤2至步骤5，直到达到停止条件（例如达到最大迭代次数或收敛）。

LVQ算法的输出是一组原型向量，它们代表了不同的类别。对于新的未知样本，可以根据其与原型向量的距离来确定其所属的类别。

高斯混合聚类

高斯混合聚类（Gaussian Mixture Clustering）是一种聚类算法，它基于高斯混合模型对数据进行建模和聚类。该算法假设数据样本是由多个高斯
混合体，并通过估计模型参数来确定每个样本所属的聚类。

- GMM的参数包括每个高斯分布的均值、协方差矩阵和权重。
- 均值表示每个簇的中心位置，协方差矩阵表示簇内样本的分布情况，权重表示每个簇的重要性。
- EM算法
- 为了估计GMM的参数，通常使用期望最大化（Expectation-Maximization，EM）算法。
- EM算法通过迭代的方式，交替进行E步（计算后验概率）和M步（更新参数）。

高斯混合聚类的步骤

- 1：初始化模型参数，包括均值、协方差矩阵和权重。
- 2：E步，计算每个样本属于每个簇的后验概率。
- 3：M步，根据后验概率更新模型参数。
- 4：重复步骤2和步骤3，直到收敛或达到最大迭代次数。

聚类结果评估

- 可以使用内部指标（如紧密性和分离性）或外部指标（如兰德系数和互信息）评估聚类结果的质量。
- 内部指标用于评估聚类簇内的紧密性和簇间的分离性。
- 外部指标用于与已知的真实标签进行比较，评估聚类结果的一致性。

密度聚类

本知识点主要教学目的：让学生了解密度聚类的常用算法DBSCAN。

密度聚类也称为“基于密度的聚类”（density-based clustering）。

此类算法假设聚类结构能通过样本分布的紧密程度来确定。

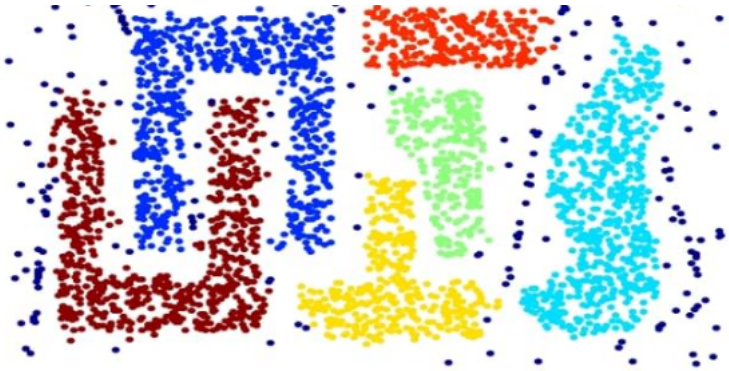
通常情况下，密度聚类算法从样本密度的角度来考察样本之间的可连接性，并基于可连接样本不断扩展聚类簇来获得最终的聚类结果。

这类算法能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，且对噪声数据不敏感。

代表算法有：DBSCAN、OPTICS、DENCLUE算法等。

DBSCAN聚类

DBSCAN一个比较有代表性的基于密度的聚类算法。与层次聚类方法不同，它将簇定义为密度相连的点的最大集合，能够把具有足够高密度的区域
并可在有“噪声”的空间数据库中发现任意形状的聚类。



ϵ邻域：对样本(x_{j})∈D ，其ϵ邻域包含样本集D中与(x_{j})的距离不大于ϵ的样本；

核心对象：若样本(x_{j})的ϵ邻域至少包含MinPts个样本，则该样本点为一个核心对象；

密度直达：若样本(x_{j})位于样本(x_{i})的ϵ邻域中，且(x_{i})是一个核心对象，则称样本(x_{j})由(x_{i})密度直达；

密度可达：对样本(x_{i})与(x_{j})，若存在样本序列(p_{1},p_{2},...,p_{n})，其中(p_{1}) = (x_{i});(p_{n}) = (x_{j})且(p_{i + 1})由(p_{i})密度直达，则(x_{j})由(x_{i})密度可达；

密度相连：对样本(x_{i})与(x_{j})，若存在样本(x_{k})使得两样本均由(x_{k})密度可达，则称该两样本密度相连。

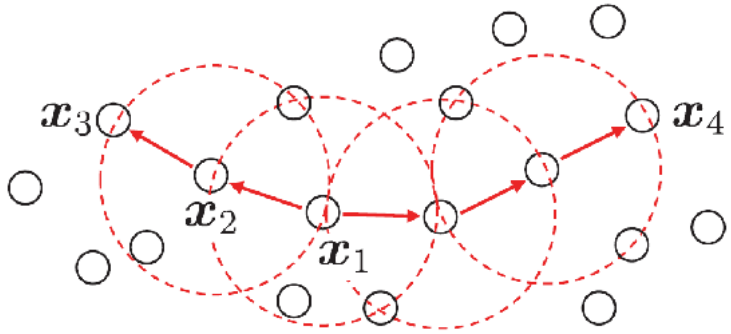
令MinPts = 3，则虚线显示出ϵ领域。

(x_{1})是核心对象

(x_{2})由(x_{1})密度直达

(x_{3})由(x_{1})密度可达

(x_{3})与(x_{4})密度相连



以西瓜数据集4.0为例，来演示DBSCAN算法的学习过程。

假定领域参数(ϵ,MinPts)，设置ϵ=0.11，MinPts=5。

核心对象集合：(\Omega\ = \ { x_{3},x_{5},x_{6},x_{8},x_{9},x_{13},x_{14},x_{18},x_{19},x_{24},x_{25},x_{28},x_{29}})

从中随机选取一个核心对象x_8作为种子，DBSCAN生成第一个聚类簇：

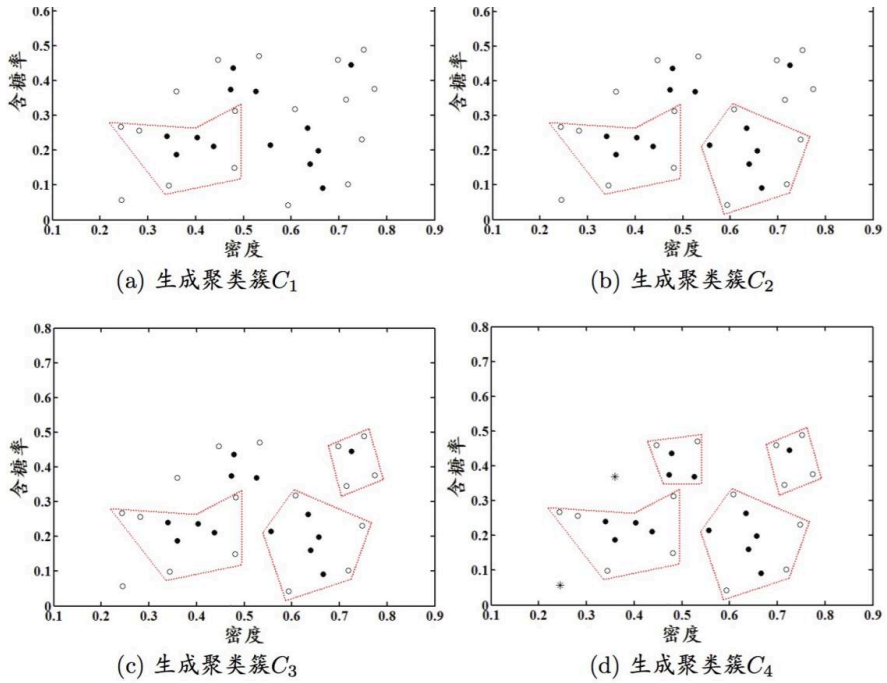
(C_{1}) = {(x_{6}),(x_{7}),(x_{8}),(x_{10}),(x_{12}),(x_{18}),(x_{20}),(x_{23})}

将(C_{1})中包含的核心对象从Ω中去除，再从更新后的集合中随机选取一个核心对象，不断重复，直至Ω为空。

$$C_2 = \{x_3, x_4, x_5, x_9, x_{13}, x_{14}, x_{16}, x_{17}, x_{21}\}$$

$$C_3 = \{x_1, x_2, x_{22}, x_{26}, x_{29}\}$$

$$C_4 = \{x_{24}, x_{25}, x_{27}, x_{28}, x_{30}\}$$



(a) 生成聚类簇C_1 (b) 生成聚类簇C_2

(c) 生成聚类簇C_3 (d) 生成聚类簇C_4

层次聚类

本知识点主要教学目的：让学生了解层次聚类算法。

层次聚类试图在不同层次对数据集进行划分，从而形成树形的聚类结构。数据集划分既可采用“自底向上”的聚合策略，也可采用“自顶向下”的

AGNES算法（自底向上的层次聚类算法）

首先，将样本中的每一个样本看做一个初始聚类簇，然后在算法运行的每一步中找出距离最近的两个聚类簇进行合并，该过程不断重复，直到达至的个数。

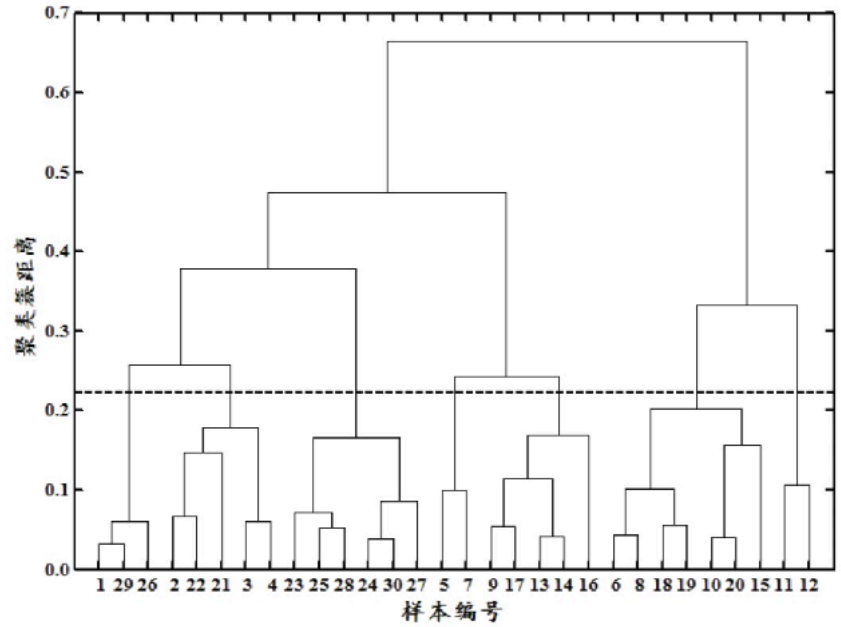
这里两个聚类簇(C_{i})和(C_{j})的距离，可以有3种度量方式。

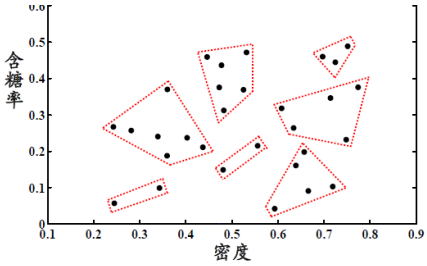
最小距离：

最大距离：

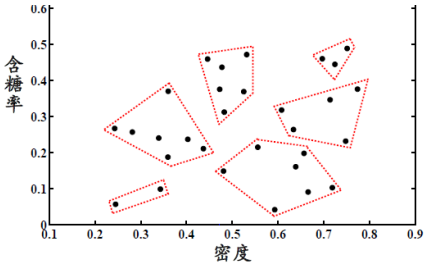
平均距离：

AGNES算法树状图

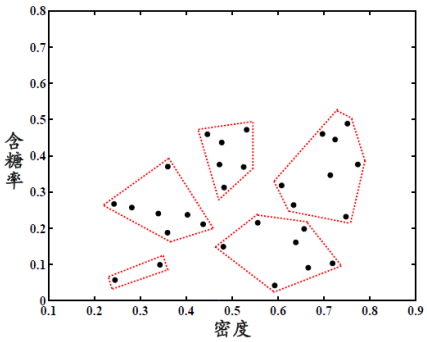




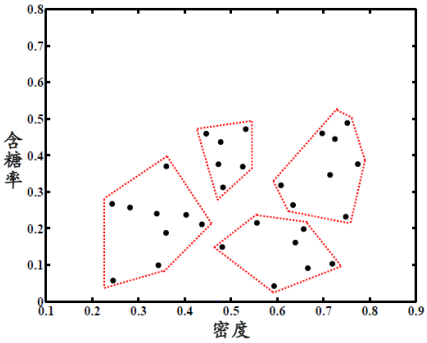
(a) 聚类簇数 $k = 7$



(b) 聚类簇数 $k = 6$



(c) 聚类簇数 $k = 5$



(d) 聚类簇数 $k = 4$

列表
批注