Adaboost算法

1.1.分配每个观测样本Xi，一个初始权重（W_i），$W_i=1/n$，其中n为样本总量数;

1.2.训练一个“弱模型;”（常用决策树）;

1.3.对于每个目标:

1.3.1.如果预测错误，W_i上涨;

1.3.2.如果预测正确，W_i下降;

1.4.训练一个新的”弱模型“，其中权重较大的观测样本相应分配较高的优先权;

1.5.重复步骤三和四，直到得到样本被完美预测，或是训练出当前规模的决策树。

ChrisAlbon

拟合度：调整R方

Adjusted R-Squared

直观的讲，校正决定系数考虑了变量的个数对决定系数的影响，

当新加入的变量没有统计意义的时候，校正决定系数会变小。

$$\bar{R}^2 = 1 - \frac{RSS/(n-d-1)}{TSS/(n-1)}$$

残差平方和 → RSS

特征值 → d

总平方和 → TSS

观测值 → n

*译者注：

ESS：回归平方和

当回归方程中含有截距项时：

TSS = RSS +ESS

否则上述公式不成立。

ChrisAlbon

Agglomerative聚类

Agglomerative Custering

所有的观测对象首先以自己群组，满足特定准则的对象会聚集在一起。重复这个过程，群组不断增大，直到某个端点饱和位置。

ChrisAlbon

AIC

“赤池信息量准则”

AkaikeInformation Criterion

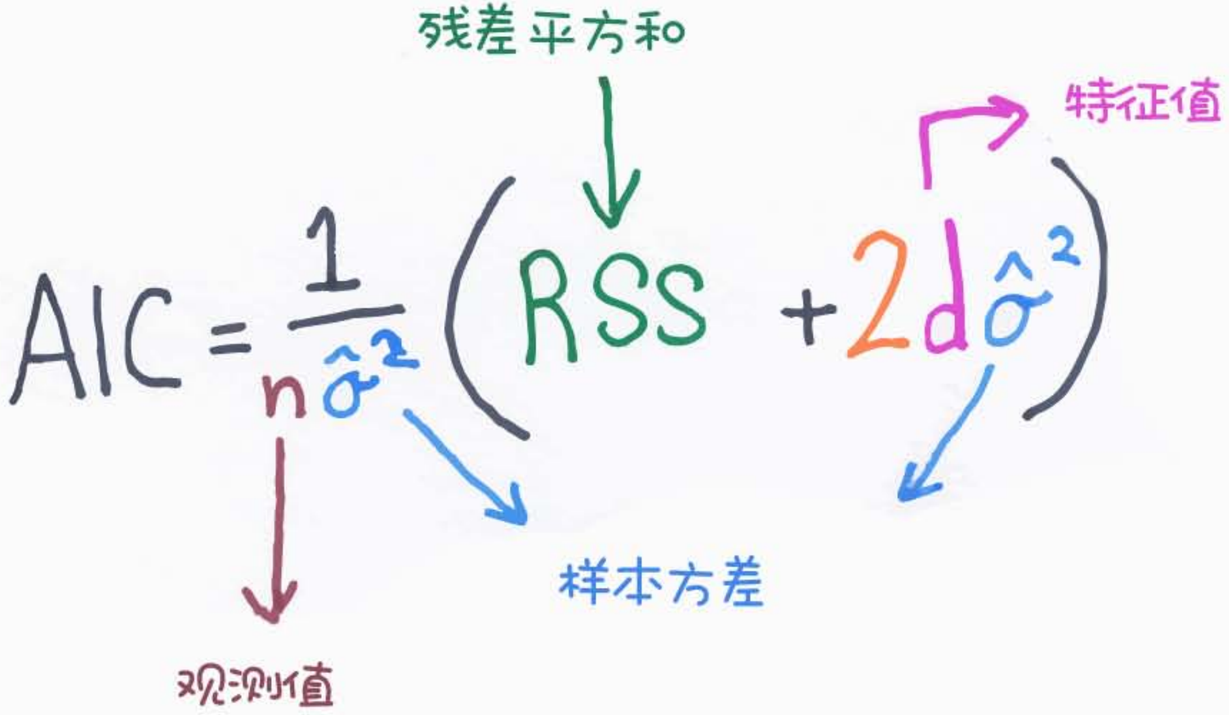

备注：AIC常用来比较模型优劣。例如特征选择阶段

BY CHRIS ALBON

神经网络的结构

architecture on the neural network

神经网络的结构指的是神经元，激活函数以及有多少层。

大多数神经网络的结构可以被理解成神经元组成的堆积的层。

对于一个问题来说最好的结构是通过验证集来验证的。

Chris Albon

AUC值

Area Under The Curve

对于一个问题来说最好的结构是通过验证集来验证的。

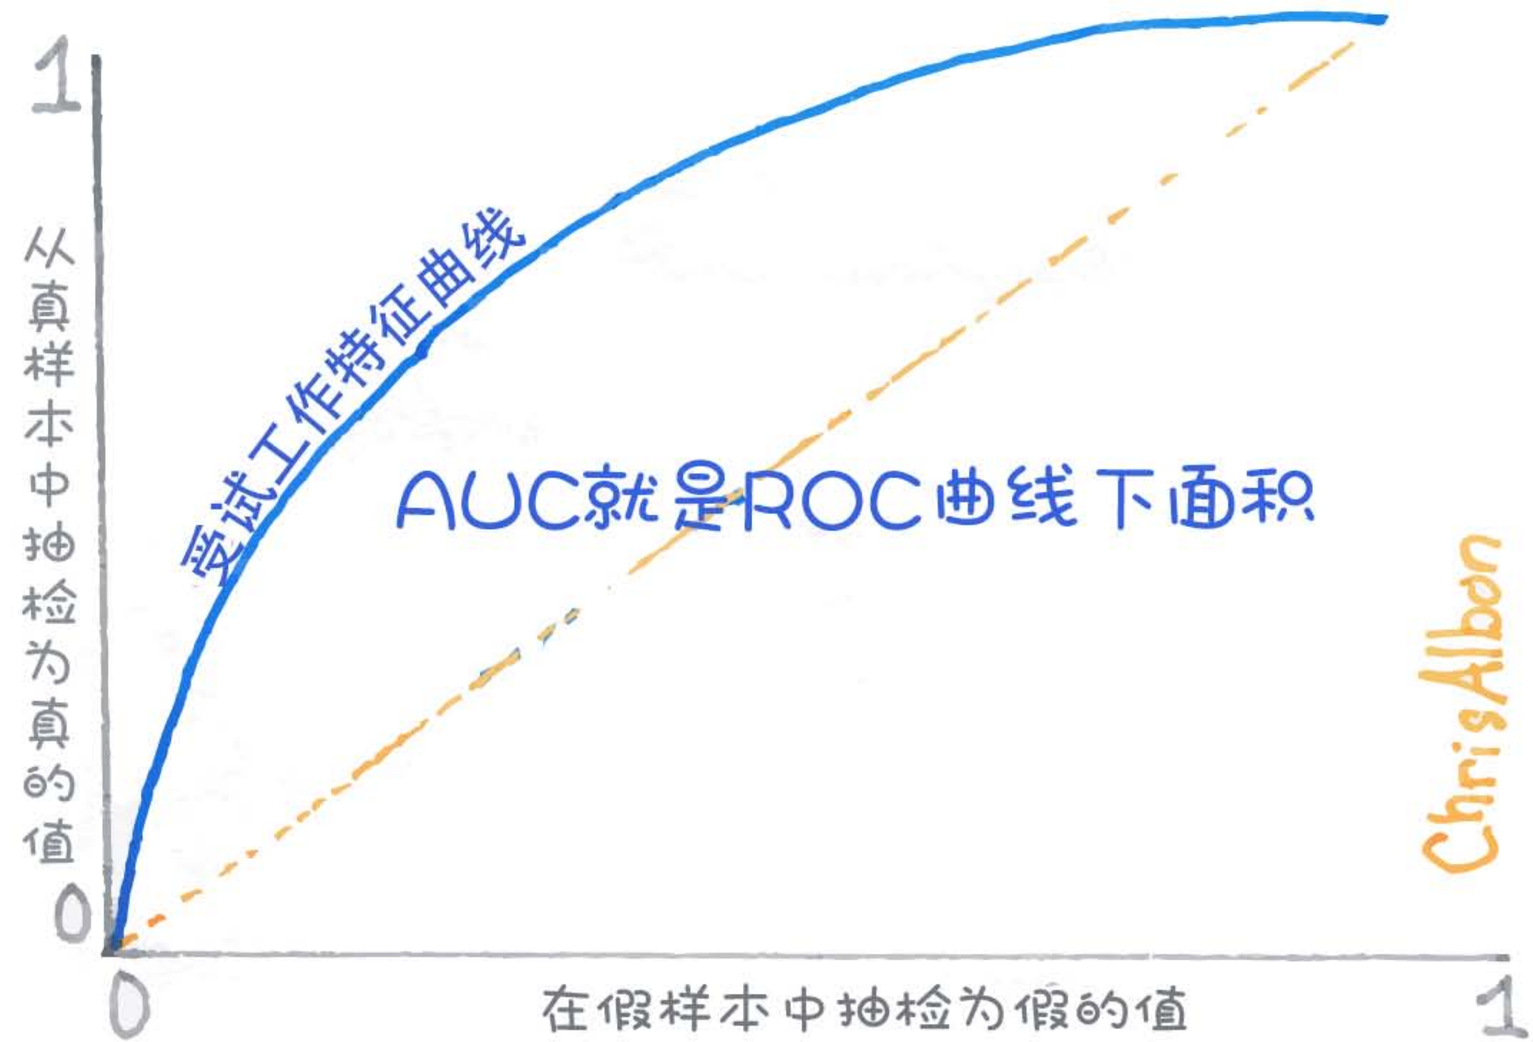

如何防止过拟合
avoid over-fitting

简易模型

交叉验证评估

正则化

获取更多数据

集成学习

BY CHRIS ALBON

反向传播算法
back propagation

通过神经网络反向发送信息的算法

计算损失函数相对于参数的梯度

不负责更新参数，更新参数可通过算法优化来完成

Chris Albon

词袋模型
bag of words

把文本转化成矩阵。矩阵的每一行都是一个样本，每一个特征都是一个单词。矩阵中的每一个元素都是一个标志这个单词有没有出现的二元分类器，或者是这个单词出现的次数。

Chris Albon

Bagging算法

Bootstrap aggregation

训练集　　自助采样后的数据集　　基模型　　投票　　结果

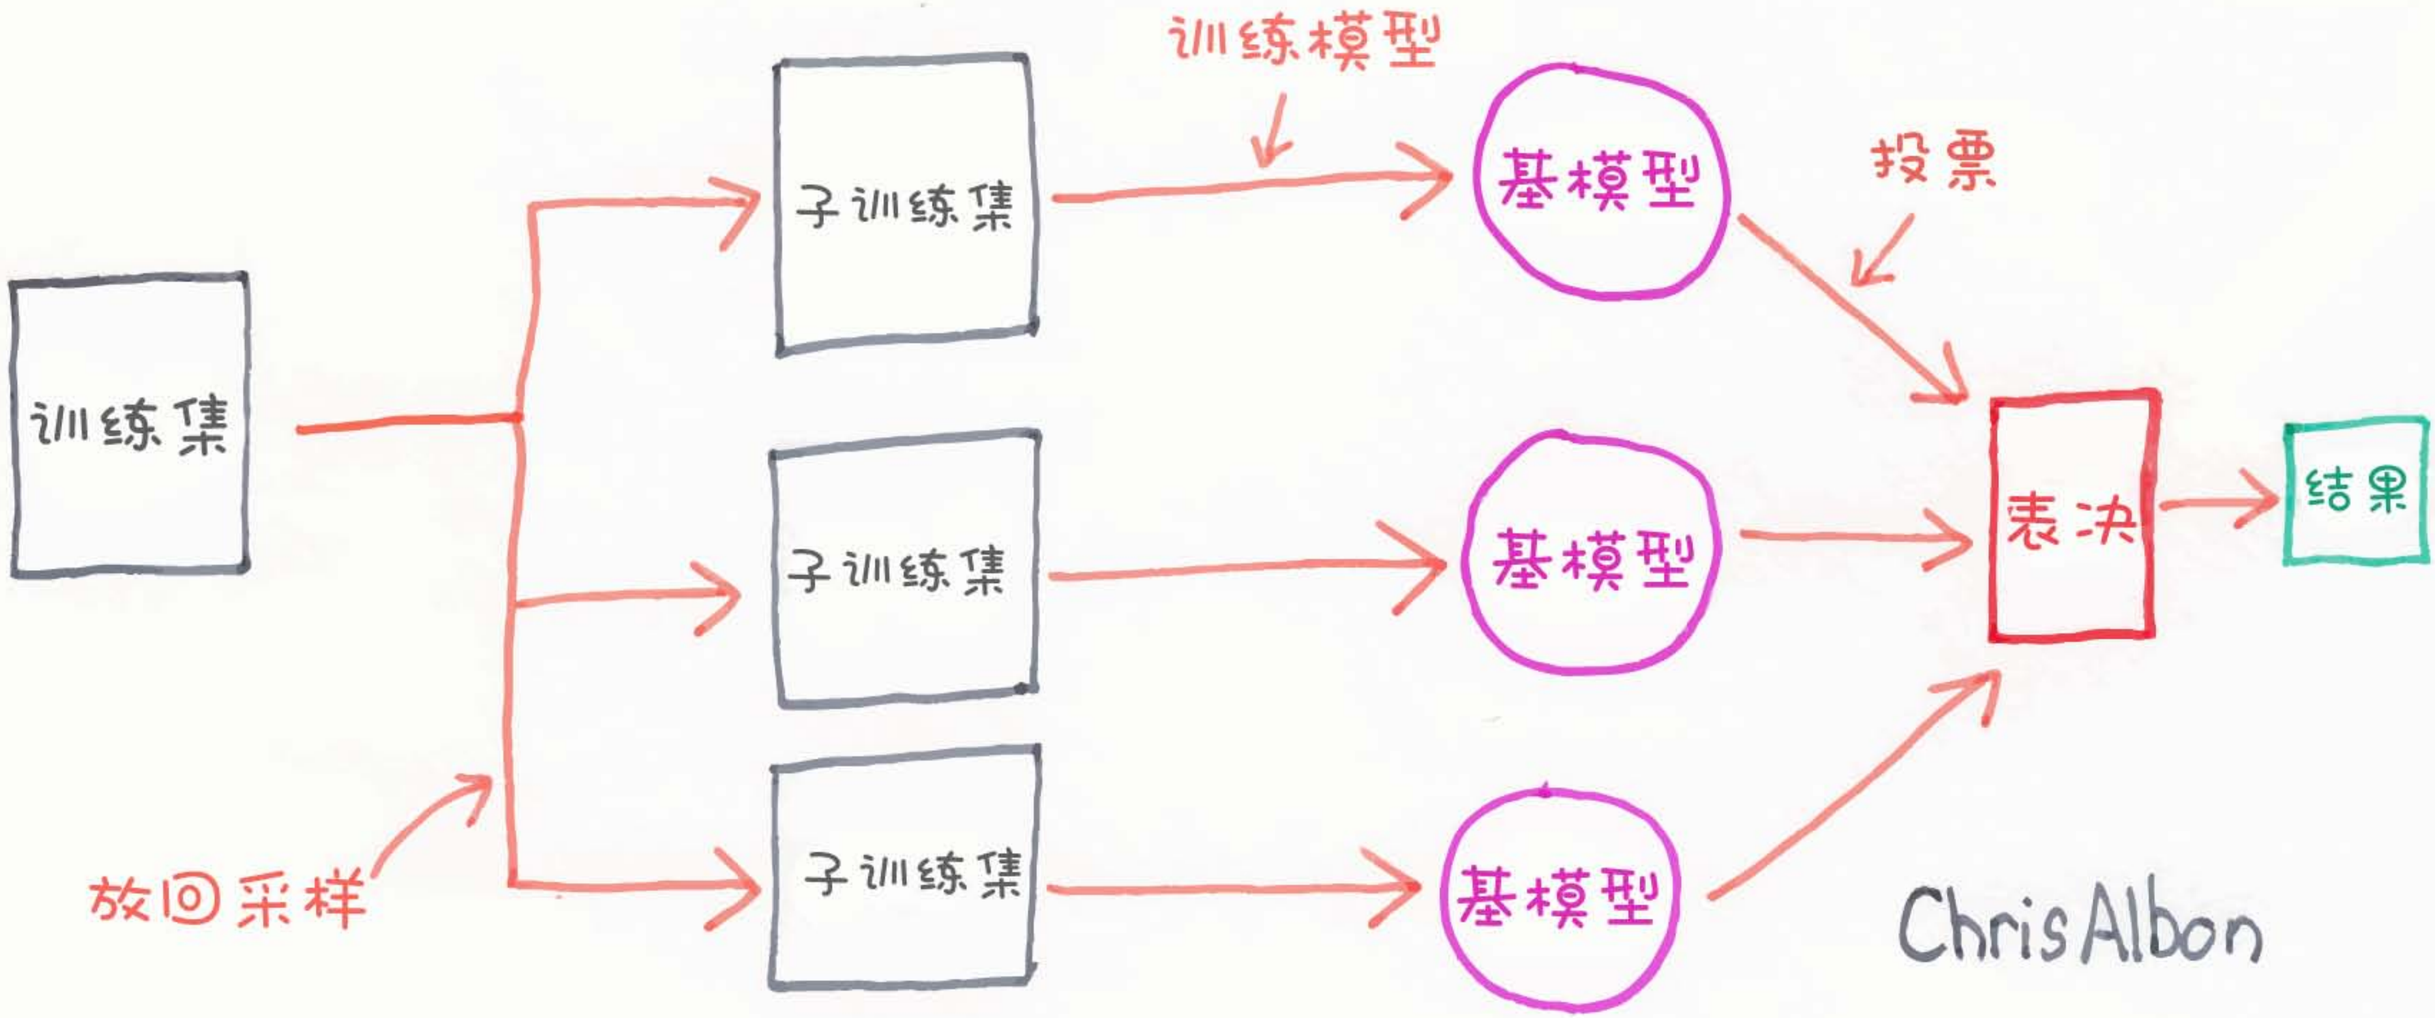

Bagging方法 VS. Dropout方法

模型： Bagging中，所有的模型是独立的。

Dropout中，子网络间分享参数。

训练： Bagging中，所有的模型都会被训练。

Dropout中，只有一部分子网络会被训练。

ChrisAlbon

深度学习（基础）

1. 数据
2. 损失函数，例如交叉熵
3. 优化算法，例如随机优化算法Adam
4. 网络架构，例如全链接层
5. 测试数据
6. 评价指标，例如准确性

Chris Albon

贝叶斯误差

Bayes Error

想象我们可以看到潜在的真实人口分布。甚至还有可能是由于宇宙中的固有噪声或者数据的限制引起的预测误差。

Chris Albon

贝叶斯法则

Bayes Theorem

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

后验概率 $P(A|B)$

似然度 $P(B|A)$

先验概率 $P(A)$

边际似然度 $P(B)$

*译者注：贝叶斯法则说明当不能准确知悉一个事物的本质时，可以依靠与事物特定本质相关的事件出现的多少去判断其本质属性的概率。 即支持某项属性的事件发生得愈多，则该属性成立的可能性就愈大。

BY CHAIS ALBON

贝叶斯方法的优点和缺点
Bayesian Methods Pros And Cons

优点：

数据量小的情况下也很好用，经常很直观。

缺点

大数据下计算消耗很大，必须选择一个先验。

Chris Albon

误差BIAS

误差是一种预期的由使用模型来逼近真实世界函数创建的误差。

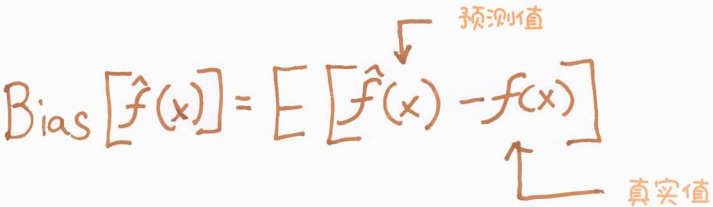

BY CHRIS ALBON

大O算法

表示算法的空间或时间会随着输入规模的增大而增大

译者注:

大O表示法用于根据输入大小的增长，运行时间或空间要求如何增长来对算法进行分类。参照微积分里“阶”的概念。

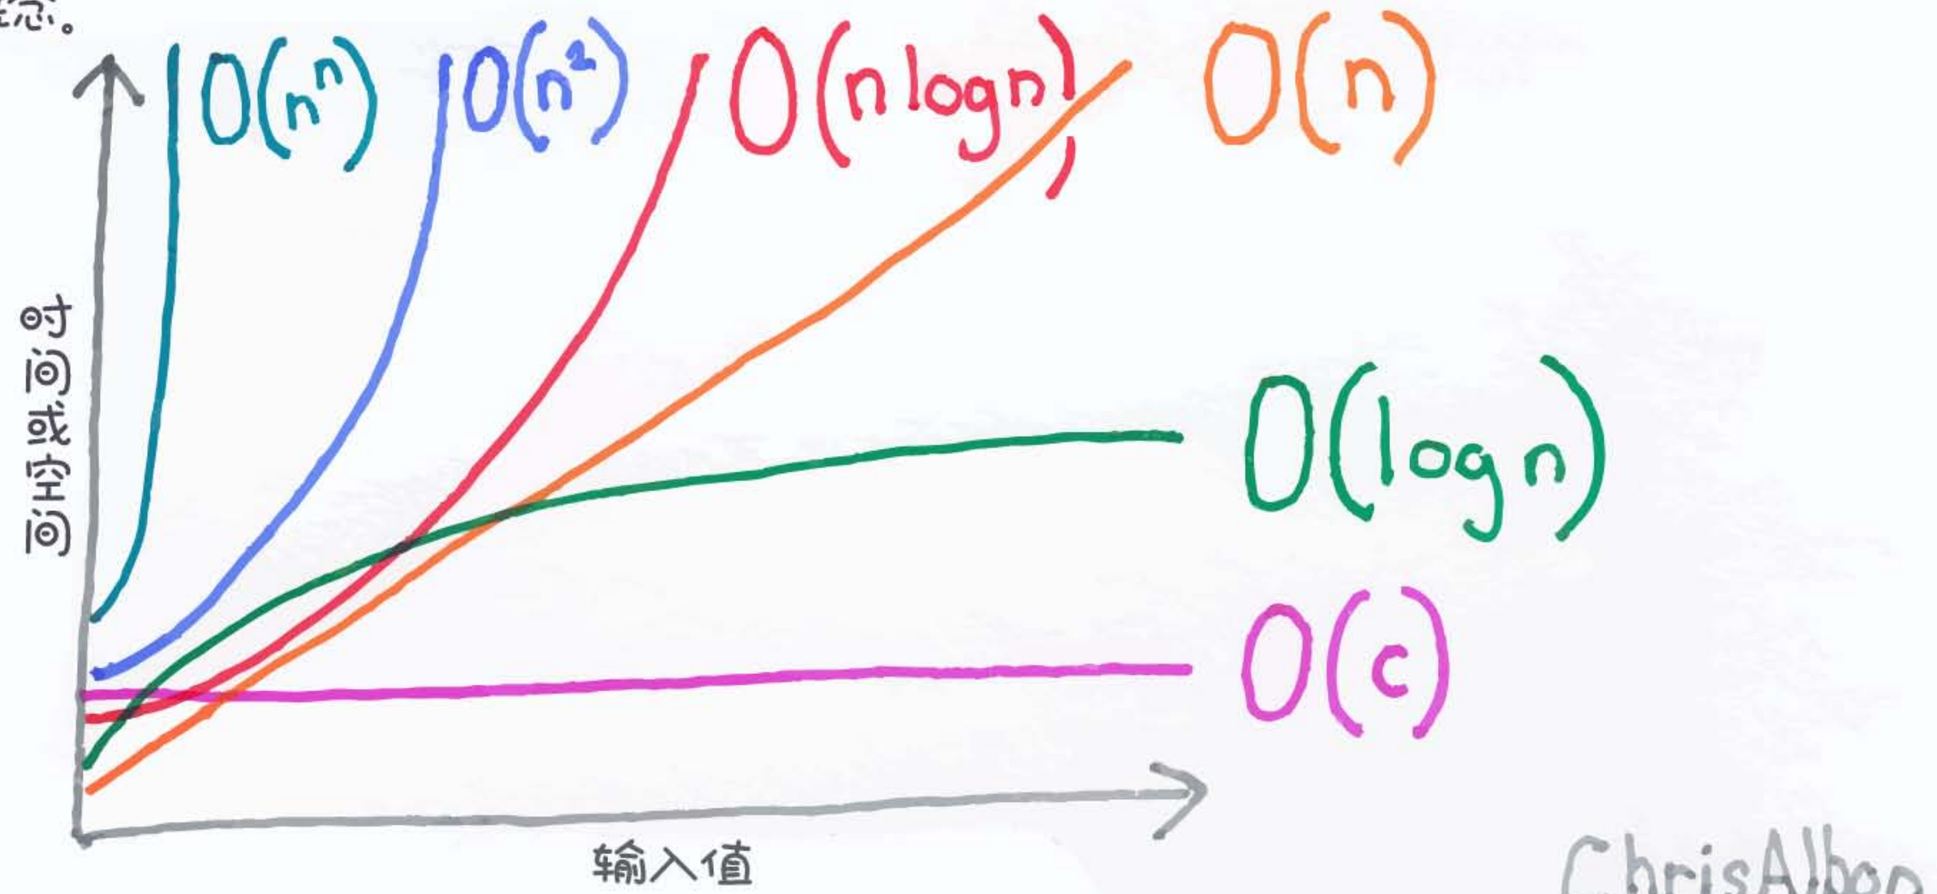

Boosting算法

这是一种集成学习的策略，通过训练一组较弱的模型，并使每一个模型去尝试正确预测上一个模型预测错误的样本，以取得更好的结果。

ChrisAlbon

布莱尔分数

Birer score

$$BS = \frac{1}{n} \sum_{t=1}^{n} \left(P_t - O_t \right)^2$$

n：样本数量

P_t：预测概率

O_t：实际结果

布莱尔分数表示了所有样本的预测概率值与它们实际结果的均方误差。这个分数范围为0到1，越低代表预测越准确。

*译者注：

举例说明，比如预测过去某一天会不会下雨，预测值为100%，真实情况为1（表示下雨），则布莱尔分数为0，最佳的布莱尔分数

如果预测值为30%，真实情况为0，则布莱尔分数为0.09，也是不错的预测值

Chris Albon

正则化强度的倒数C

inverse of regularization strength

读做：阿尔法

超参数α是用来控制正则化强度的。例如：

$\alpha \sum_{j=1}^{} |\hat{\theta}_j|$ ← L1范数

然而，我们通常见到的是超参数C，它是α的倒数 $C = \frac{1}{\alpha}$

Chris Albon

类别特征

Categorical Feature

无序类别：没有固定顺序的类别

举例：水果、性别与城市的分类

有序类别：有固定顺序的类别

举例：痛苦的级别，在学校的成绩

ChrisAlbon

微积分中的链式求导法则

Chain rule of Calculus

链法则用于有效计算反向传播算法中的梯度。

若：$y = g(x)$，$z = f(g(x))$，即 $f(y)$ 则：

$$\frac{dz}{dx} = \frac{dz}{dy}\frac{dy}{dx}$$

反向传播算法常常将链法则用于张量的计算，但概念本质上是一样的。

Chris Albon

特征选择中的卡方应用

Chi-Squared For Feature Selection

想要在特征选择时运用χ2，我们需要计算特征和目标之间的χ2，然后按所需数量选择那些χ2分数最高的特征。

从直观上来讲，如果特征和目标独立的话，那么这个特征对样本的分类没有什么作用。

第i类中样本的数量：

$$\chi^2 = \sum_{i=1}^{n} \frac{(O_i - E_i)^2}{E_i}$$

特征和目标没有关系的情况下，第i类中期望样本的数量。

卡方

Chi-Squared

$$\chi = \sum_{i=1}^{n} \left(\frac{O_i - E_i}{E_i} \right)^2$$

O_i = 观测值

E_i = 期待值

卡方用于检验分类数据是否出现与随机变量不同的比率值。

BY CHRIS ALBON

分类 Classification

分类问题出现在我们训练模型预测定性目标的时候。
比如，预测性别、水果种类等。

*译者注:
我们在训练模型进行定性预测之前，要先对其输出结果分类，比如人类的性别、水果的种类等。模型只需要输出在或不在这一类中即可。

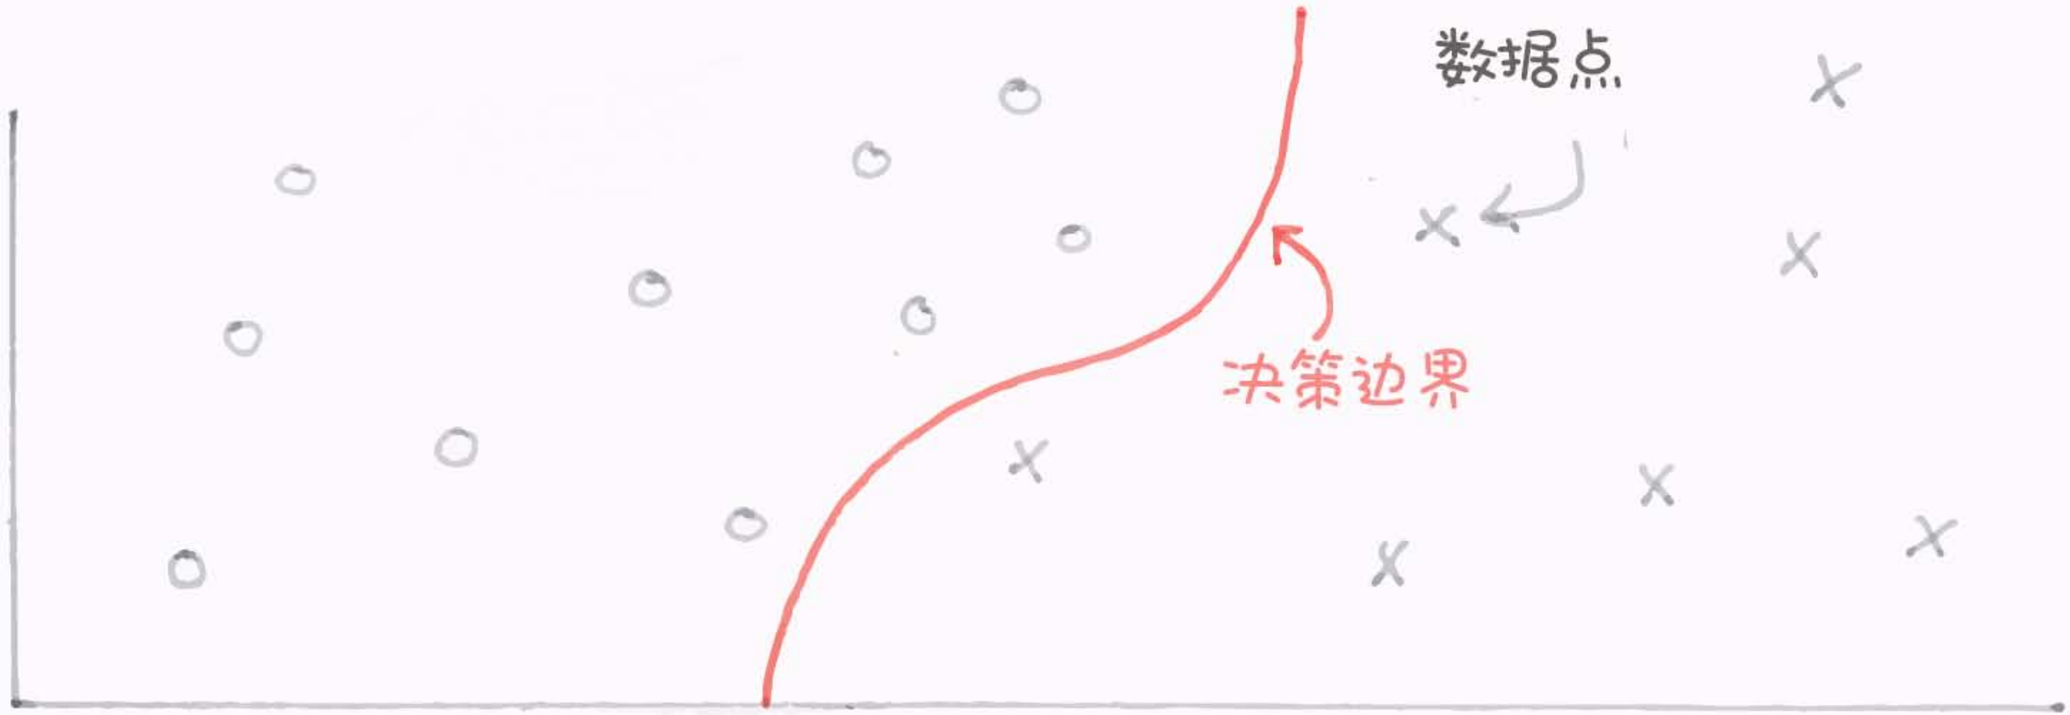

增加注释 定性目标是指非量化数据

ChrisAlbon

训练
conditioning

Conditioning is a measure of how much a function's outputs change when its inputs change. Poorly conditioned functions are highly sensitive to rounding errors that can happen in numerical computing.

条件作用是用于测量当一个方程的输入值变化时其输出值的变化量。不好的条件方程在数值计算中对于微小错误非常敏感。

*译者注:

数据可能存在（或预处理时存在）噪声，噪声很大程度影响了输出。

ChrisAlbon

混淆矩阵

confusion matrix

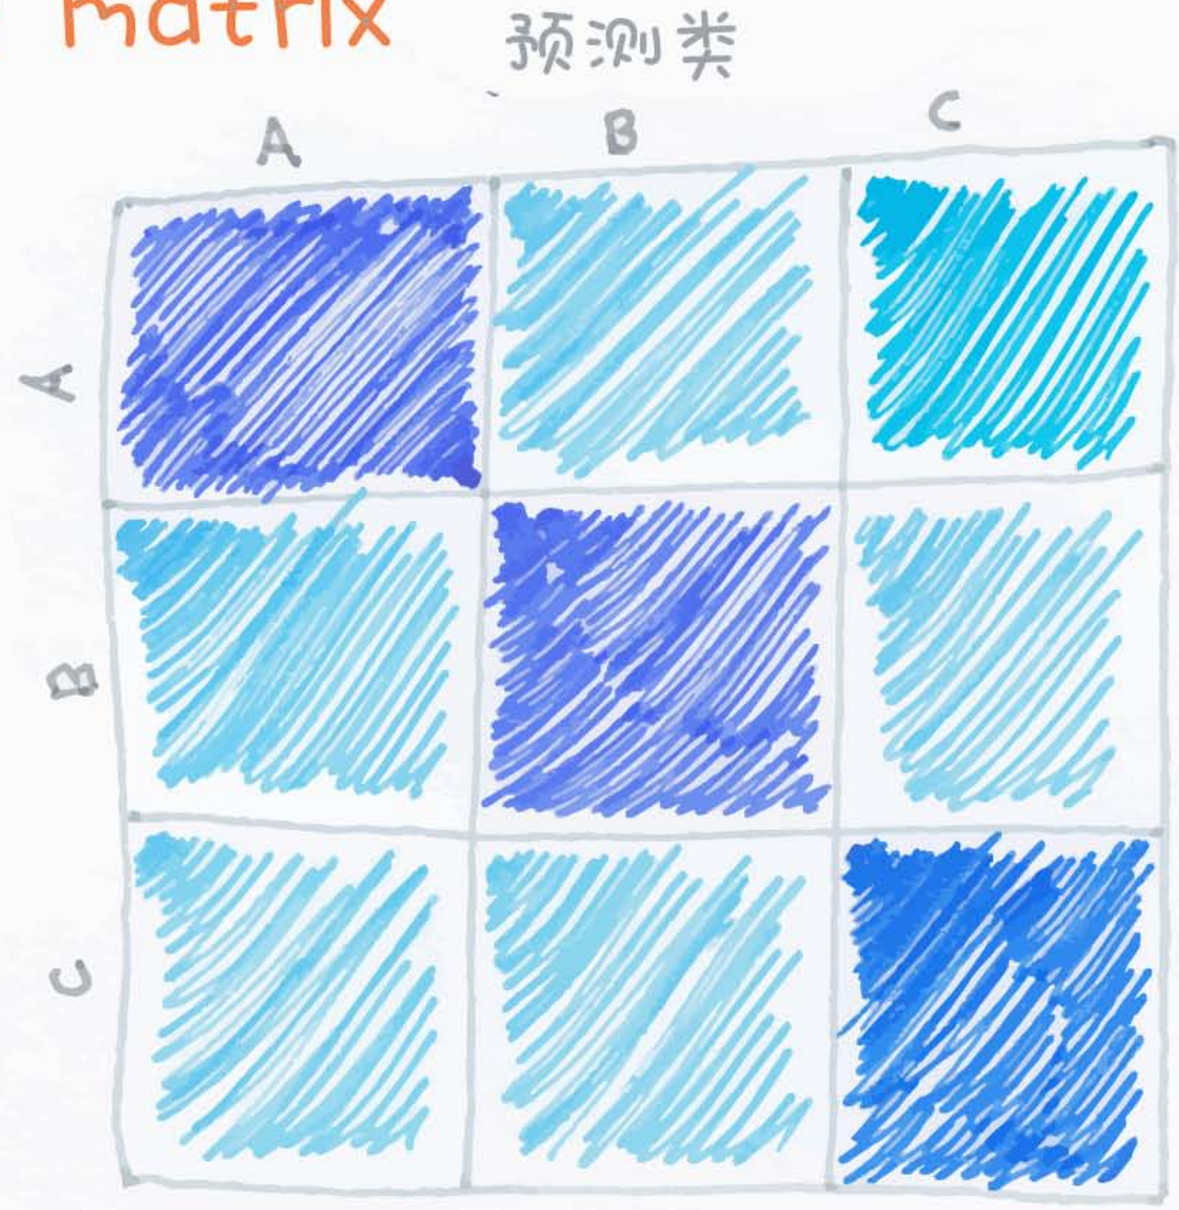

混淆矩阵通过比较分类结果与真实值，形象反映分类模型的准确度，即好坏。在左图，不在正方形对角线上的小正方形是错误的分类结果。

+注释在对角线上的数值是预测值与实际值相符的数值。

例如图所示第一行A预测正确，B，C预测错误。

Chris Albon

CP

用于模型选择中比较不同模型的性能值

$$C_p = \frac{1}{n}\left(RSS + 2d\hat{\sigma}^2\right)$$

调整实际中训练数据被低估而产生的测试误差的补偿点数

观测值数量

残差平方

特征值数量

估计误差方差

Chris Albon

累计分布函数
Cumulative Distribution Function

CDF告诉我们返回一个随机变量值低于一些特定值的概率。

它是随机值大于某些特定值的概率的累积

$$f(x) = Pr[X \leq y]$$

随机值

一些属于 X的值

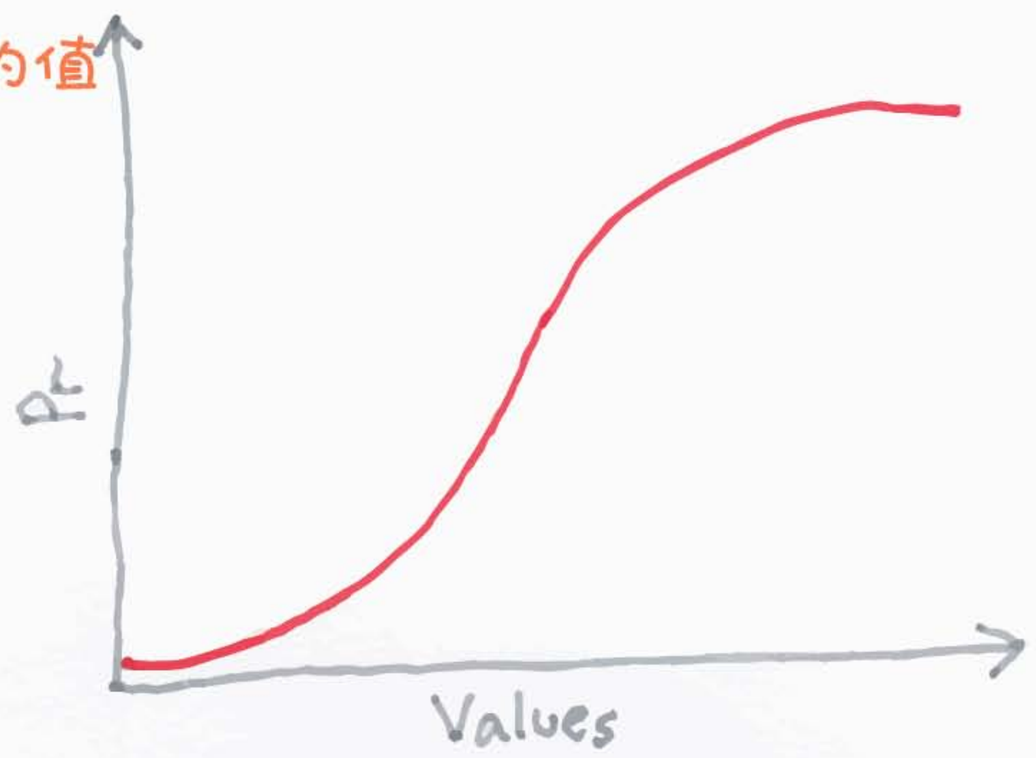

Chris Albon

维度之咒

Curse Of Dimen ionality

随着特征空间维度的增加，数字配置可以呈指数增长，因此被观测所覆盖的配置数量会减少。

Chris Albon

数据增强

Dateset augmentation

将计算机视觉问题中的图像中通过旋转、缩放、移动等方式注入噪音。其他一些注入噪音的方法用于其他问题当中。

—经常用于图像识别；

—能大幅度降低误差；

ChrisAlbon

代表点聚类算法

DBSCAN方法旨在寻求因密集度而被类聚的观测点，并对于聚类簇的数量和形状不作任何假设。

1.选择一个随机观察点x_i
2.如果x_i有一定数量（大于指定的最小数量）的近邻点，就认为x_i属于一个簇的一部分
3.对x_i的近邻点，近邻点的近邻点以及等等，重复步骤2，这些点称为核心对象
4.步骤3找不到近邻点后，在剩下的数据集随机选择一点
最后，不是核心对象的观察点被聚类到相邻近的簇或者被视为异常值。

ChrisAlbon

决策树回归

Decision Tree Regression

和决策树分类相似，然而使用了均方差或者其他相似的度量作为损失函数来决定划分，而不是交叉熵（cross entropy）或者是基尼不纯度。

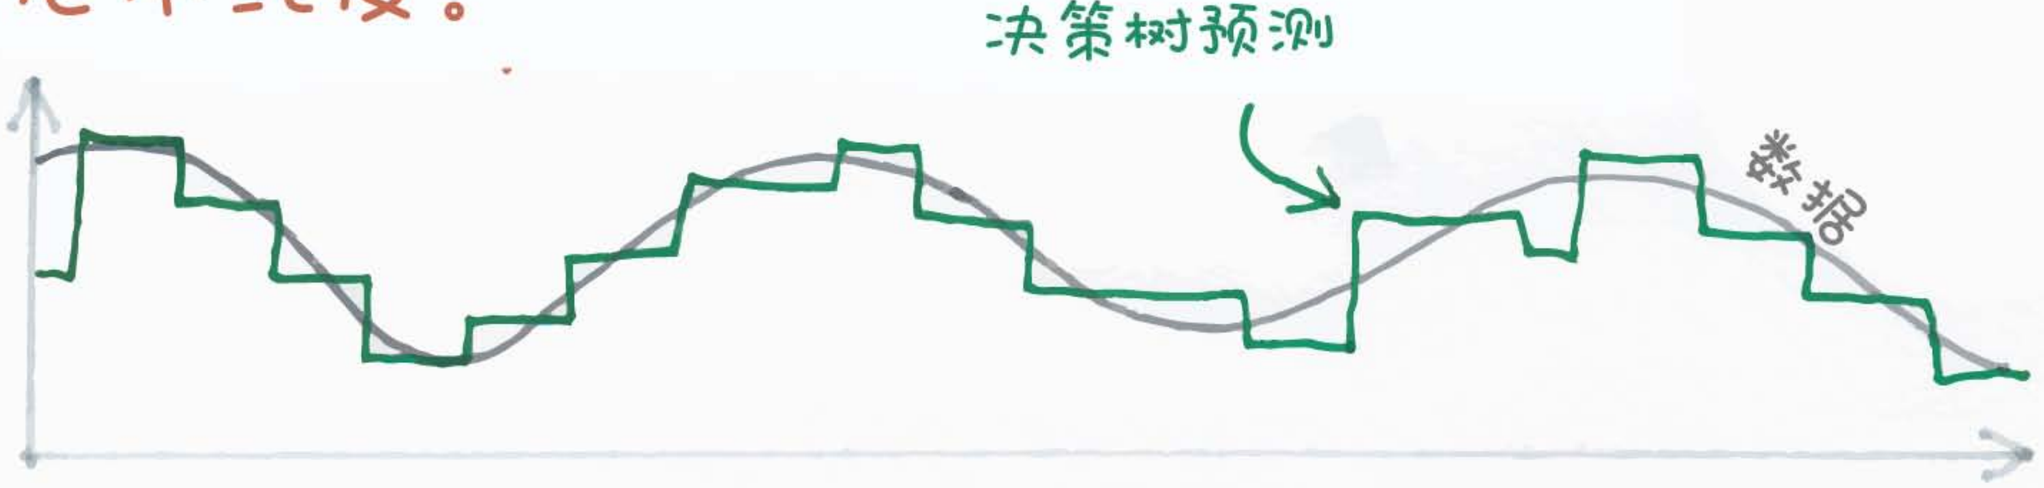

决策树

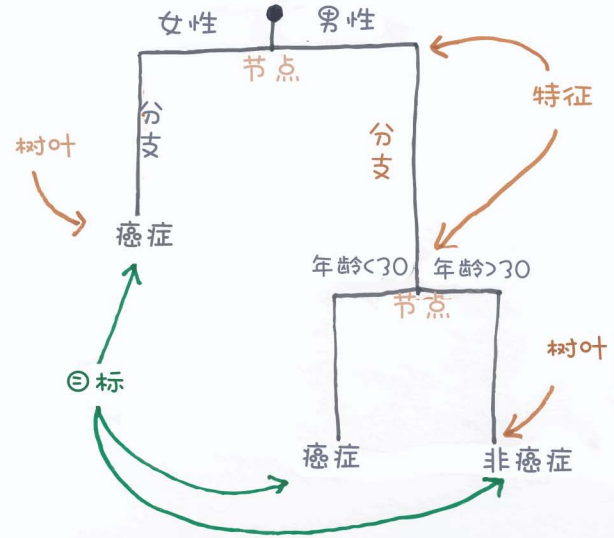

决策树易于解释。训练之后，你还可以原原本本的把它们画出来。

在提供最高信息增益的特征处将数据划分开。

BY CHRIS ALBON

导数

Derivative

一个函数的导数是它的变化率。直观上说，某点的一阶导是函数在那一点的斜率。

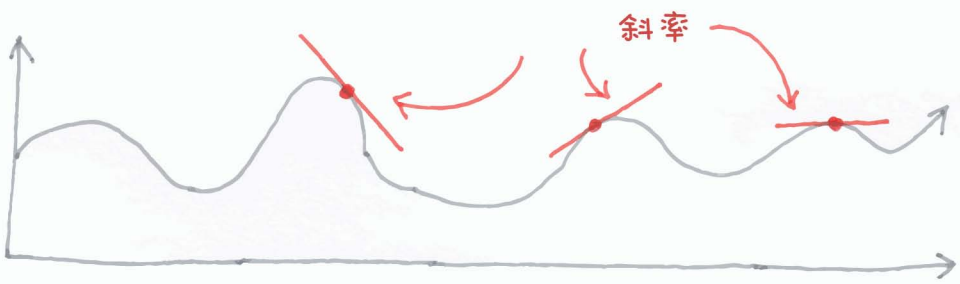

Chris Albon

矩阵设计（通称“特性矩阵”）

Design Matrix

一个矩阵的每一行都是一个观测值，每一列都是一种特性。

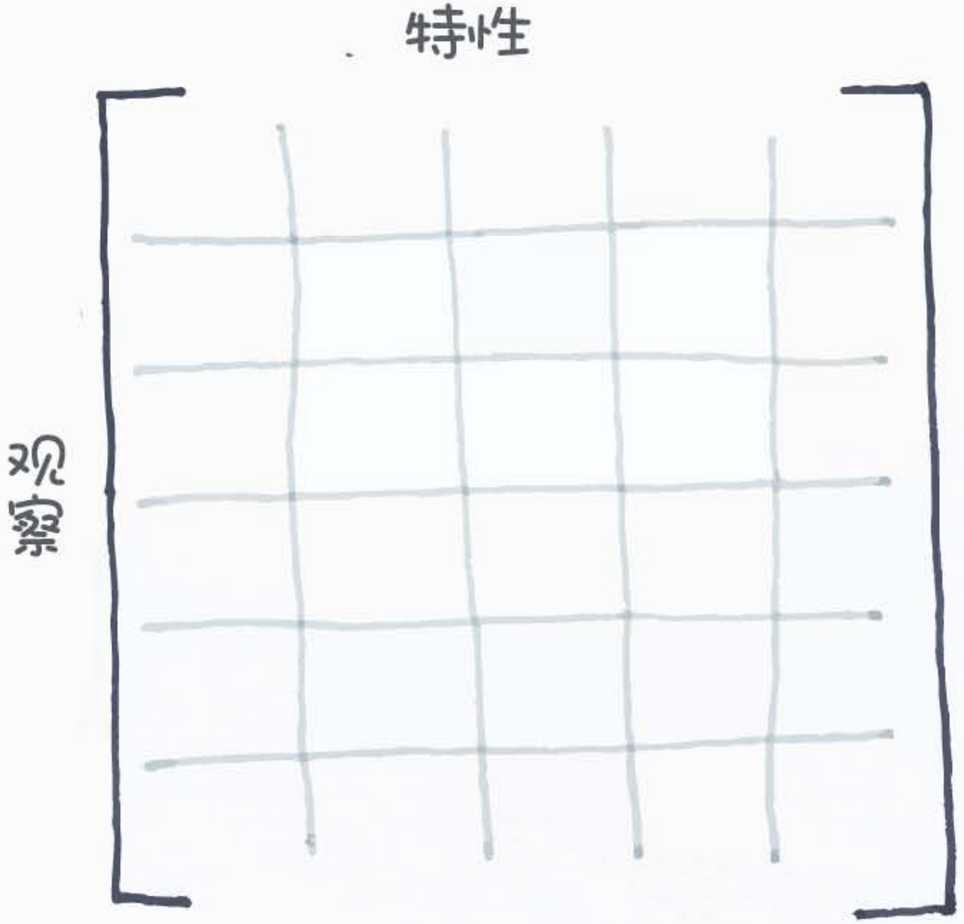

Chris Albon

行列式

Determinants

行列式可以看作是一个标量值，它是一个矩阵，形式上，矩阵的行列式是所有矩阵的乘积，它是所有矩阵特征值的乘积。

行列式的绝对值可以想象为矩阵膨胀或收缩空间的多少。

Chris Albon

KNN算法

Does K-NN Learn

KNN算法

样本A最接近的k个样本本身不训练，他是懒惰的，仅仅记住所有数据

*译者注：

KNN可理解为一种死记硬背式的分类器，记住所有的训练数据，对于新的数据则直接和训练数据匹配，如果存在相同属性的训练数据，则直接用它的分类来作为新数据的分类。

Chris Albon

点积
dot product

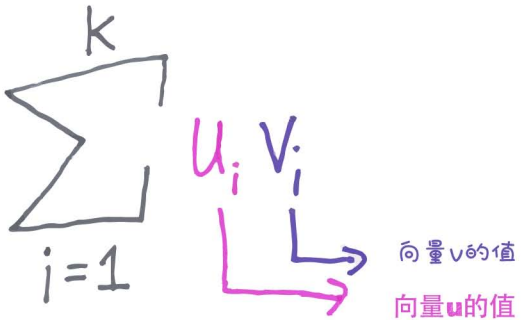

点积也称内积。当点积为零时，两个向量正交。

Chris Albon

降采样

downsampling

一种通过从大类中创建与小类数量相同的随机子集，从而处理类别不平衡问题的策略。

ChrisAlbon

信息丢失
dropout

训练一组有共享参数的子网络组合，组合包含了所有子网络，并由控制特定掩码概率的超参数约束。

*译者注：
简单来说，dropout以概率p来丢弃神经元，并且让别的神经元以概率q=1-p进行保留。每个神经元都有相同的概率被丢弃和保留。

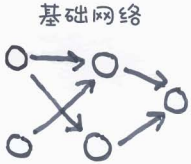

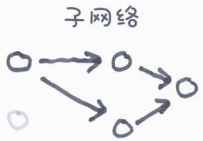

Chris Albon

提前停止训练的优势

Early Stopping Advantages

1.不需要去更改网络结构或者训练方法。

2.在最优点自动停止训练相比于超参数调节（例如权重衰减）要简单很多。

*译者注：最优点可以理解为验证集损失能够保持不断降低到达的最低点。

Chris Albon

提前停止训练

Early_Stopping

当验证集误差增大时，神经网络的训练就停止。

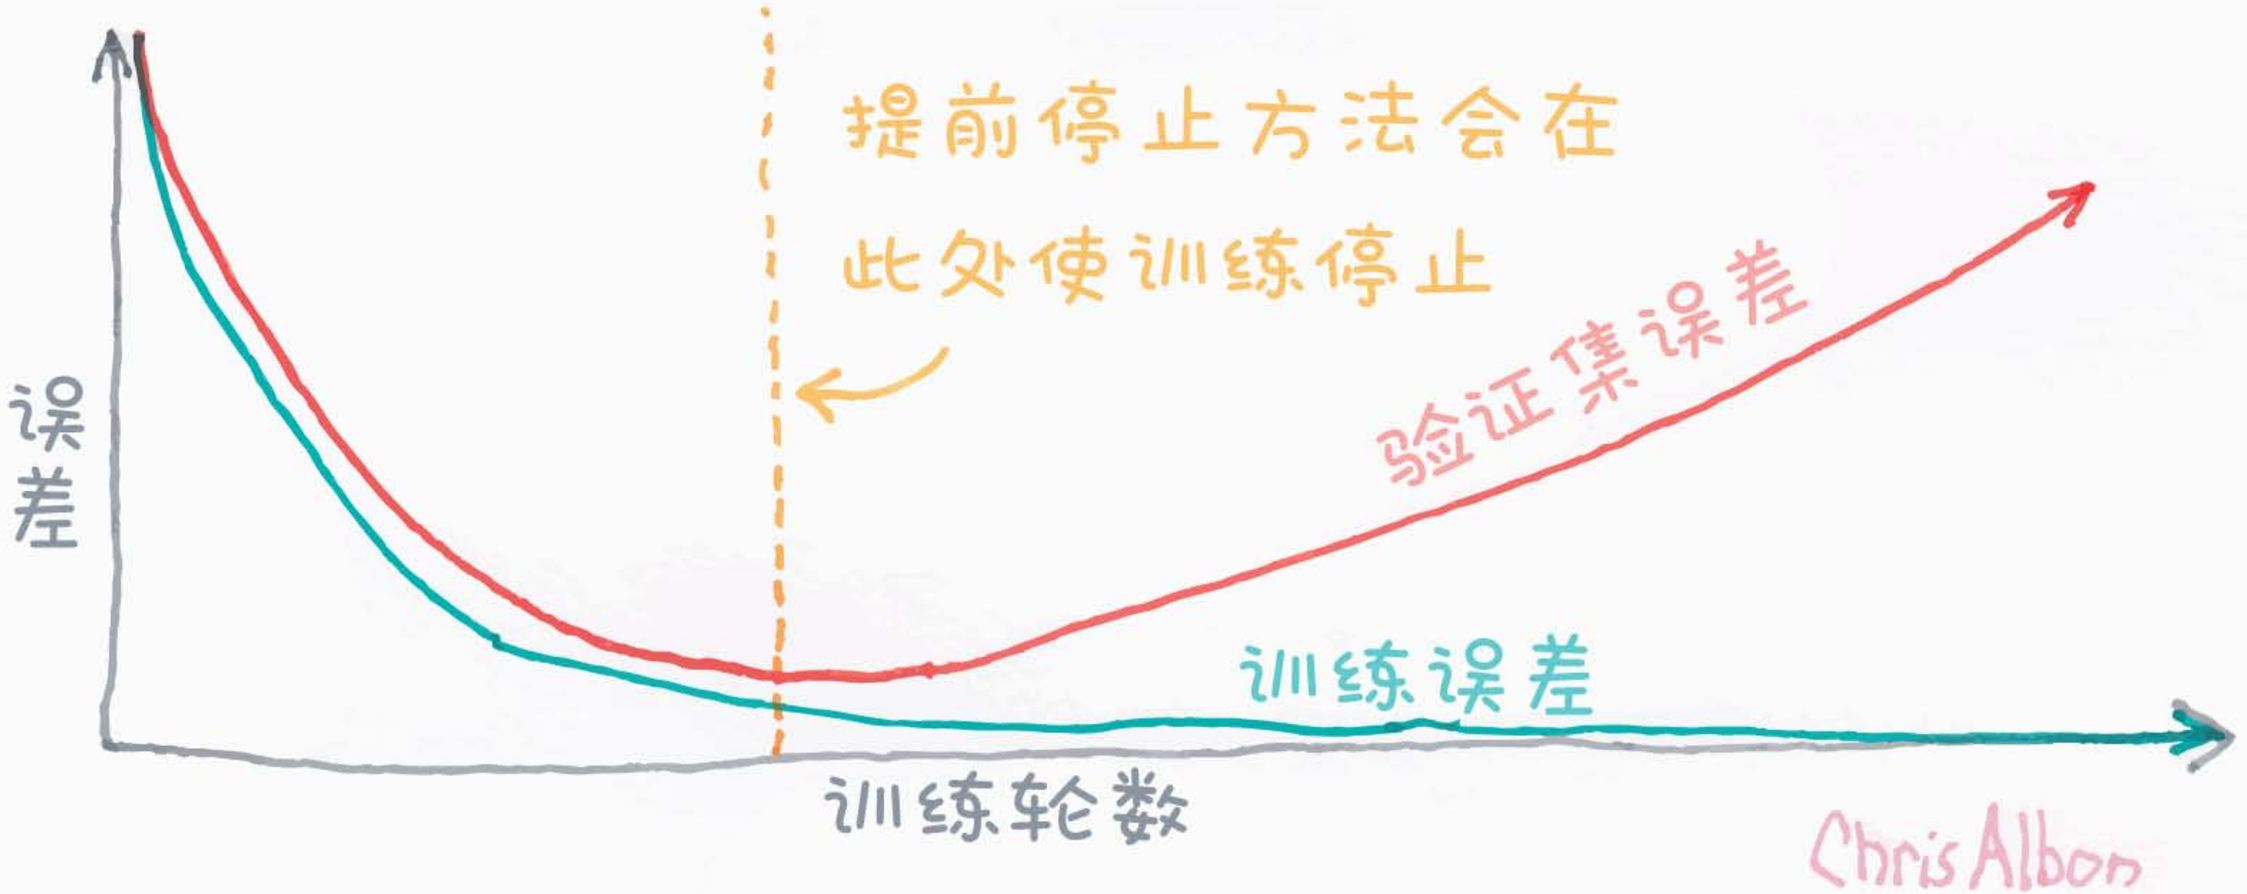

热点对特性的影响

Effect Of One Hot On Feature Importance

在随机森林中，我们能计算每个特征的重要性。然而，如果我们的特征是一个我们one-hotted的分类的名义特征，那这个特征的重要性会被分配到所有one-hotted特征上。

ChrisAlbon

特征向量

Eigenvector

n阶矩阵乘以它的特征向量等于它的特征向量乘以特征值。

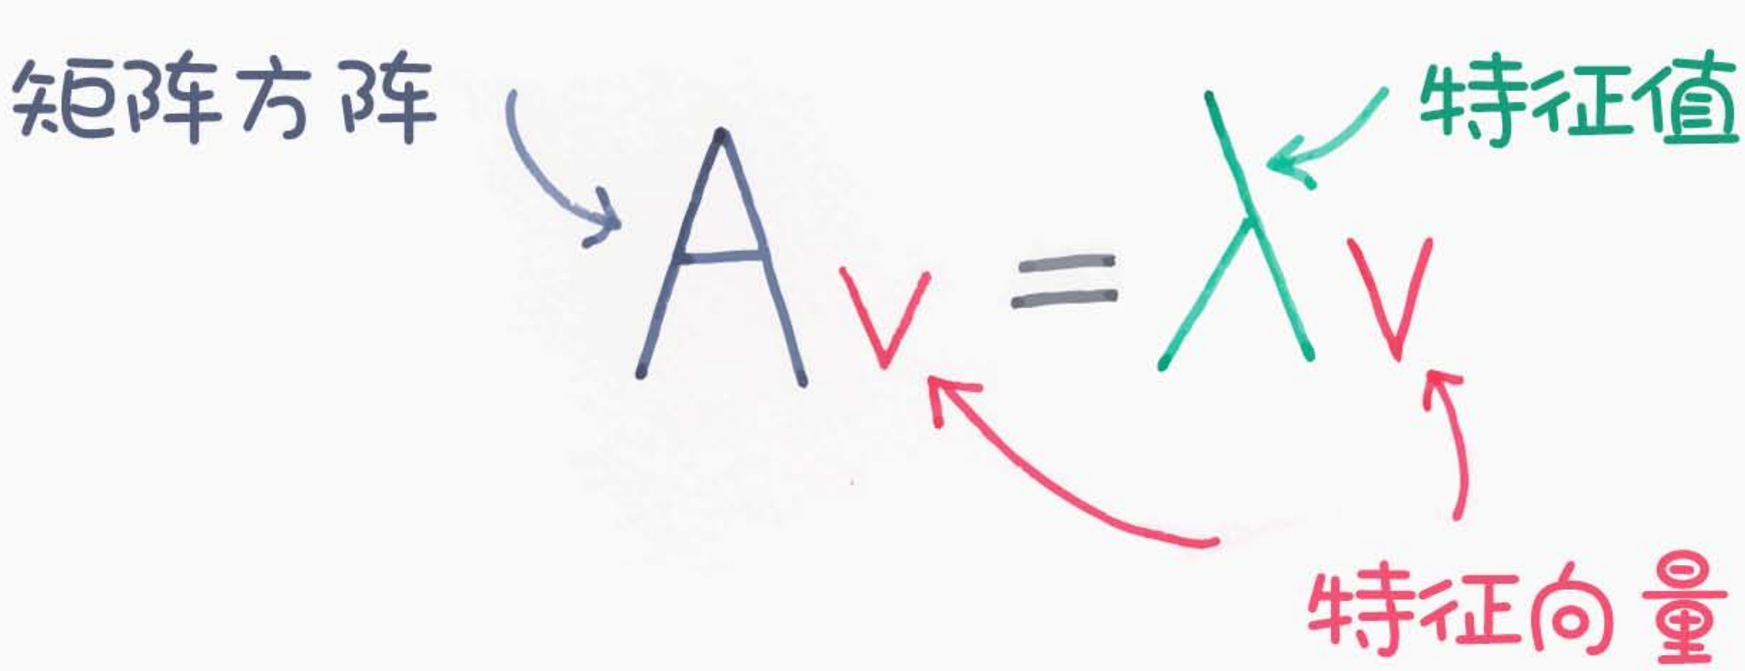

Chris Albon

弹性网络
elastic net

一种结合L1和L2正则项的线性回归模型

$$RSS + \alpha\rho\|w\|_1 + \frac{\alpha(1-\rho)}{2}\|w\|_2^2$$

Alpha ↓ α　Rho ↓ ρ

RSS ↑ 残差平方和

w ↑ 权重

alpha决定正则化的强度

Rho决定L1和L2的混合比例

ChrisAlbon

指数型线性单元
exponential linear units

$$\phi(z) = \begin{cases} z & \text{if } z >= 0 \\ a[\exp(z) - 1] & \text{否则} \end{cases}$$

↑
正向超参数

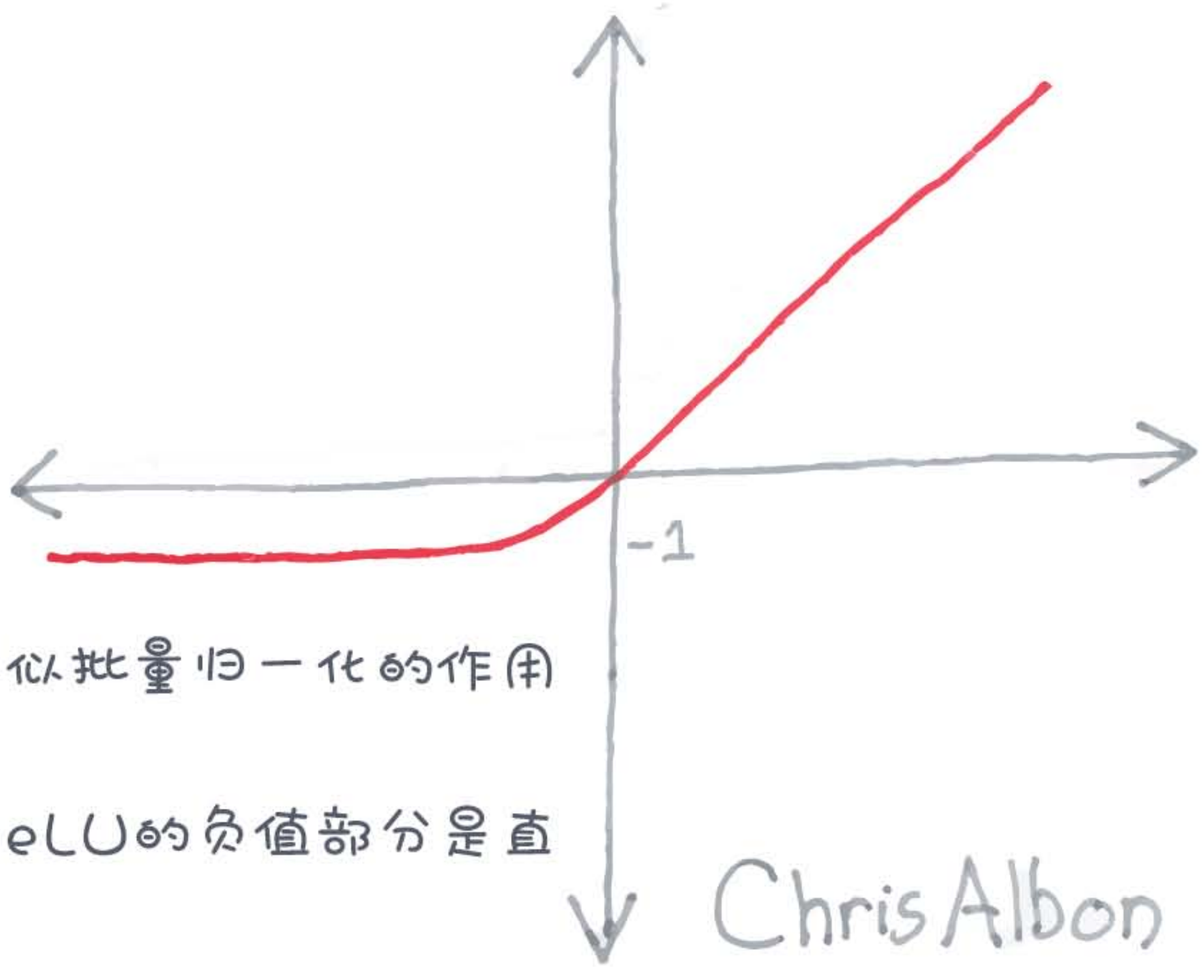

译者注：

ELU实现了两个优点：

1、将前面单元输入的激活值均值控制在0（类似批量归一化的作用）

2、让激活函数的负值部分也可以被使用了（ReLU的负值部分是直接被丢弃的）

编码有序类别特征

encoding oridnal categorical features

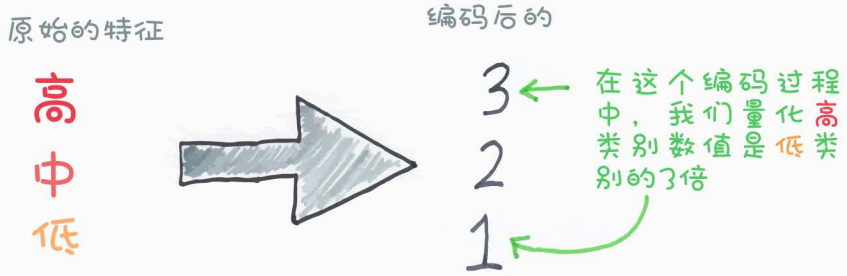

*译者注：
许多机器学习算法都需要数值型的特征。编码过程看上去很简单，但着重指出的是，我们编码的是有序类别间的间隔。

集成学习方法
Ensemble Methods

当几个模型分别训练完毕后，我们通过投票或平均结果的方式来得到预测值。例如，随机森林模型。

译者注：
集成学习应该还包括提升（典型的有GBDT模型），而不仅仅只是bagging这一种形式。

Chris Albon

迭代轮数
epoch

在人工神经网络中，每次所有的样本被送进网络中训练一次，称为一轮。训练神经网络通常需要多个轮次。

Chris Albon

错误类型
error type

第一类错误：假阳性

第二类错误：假阴性

*译者注：
举例说明，目标是判定病人是否怀孕。一个医生对一名男性说你怀孕了，这是第一类错误；医生又对一名孕妇说你没有怀孕，这是第二类错误。

BY CHRIS ALBON

解释平方和

EXPLAINED SUM OF SQUARES

ESS测量模型中的方差（信息）量

$$ESS = \sum_{i=1}^{n} \left(\hat{y}_i - \bar{y} \right)^2$$

$\hat{y}_i$：预测值

$\bar{y}$：平均值

ChrisAlbon

梯度爆炸

Exploding Gradient Problem

当带参数的损失函数前期层的梯度非常大时，会造成不稳定学习和低性能。一个可能修复的方式是梯度裁剪。

Chris Albon

极值 Extrema

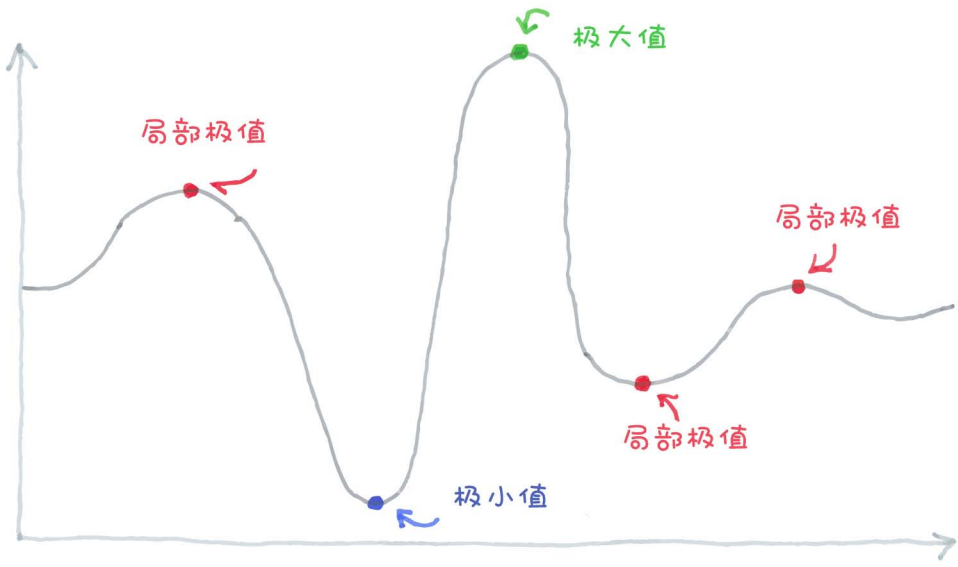

Chris Albon

F检验

F-STATISTIC

总平方和　　残差平方和

$$F = \frac{(TSS - RSS)/p}{RSS/(n-p-1)}$$

p ← 特征数量

n ← 样本数量

译者注

经F检验用于测试，如果群体特征具有共性，说明具有统计学上的意义。

方差齐性检验，从两研究总体中随机抽取样本，要对这两个样本进行比较的时候，首先要判断两总体方差是否相同，即方差齐性。

Chris Albon

F1值

F1 score

$$F_1 = 2 \times \frac{准确率 * 召回率}{准确率 + 召回率}$$

F1的值是精确率与召回率的调和平均数，F1的取值范围从0到1，数量越大，表明实验结果越理想。

*译者注：

Precision 精确率 TP/(TP+FP) 预测为真，实际也为真/预测为真的总数

Recall 召回率 TP/(TP+FN) 预测为真，实际也为真/实际为真的总数

Chris Albon

误报率

False Positive Rate

$$FPR = \frac{\text{False Positives}}{\text{False Positives} + \text{True Negatives}}$$

特征重要度

Feature Importance

决策树将最大化减少杂质，通过计算所有决策树中各特征的杂质的平均减少量，我们可以知道特征的重要性。

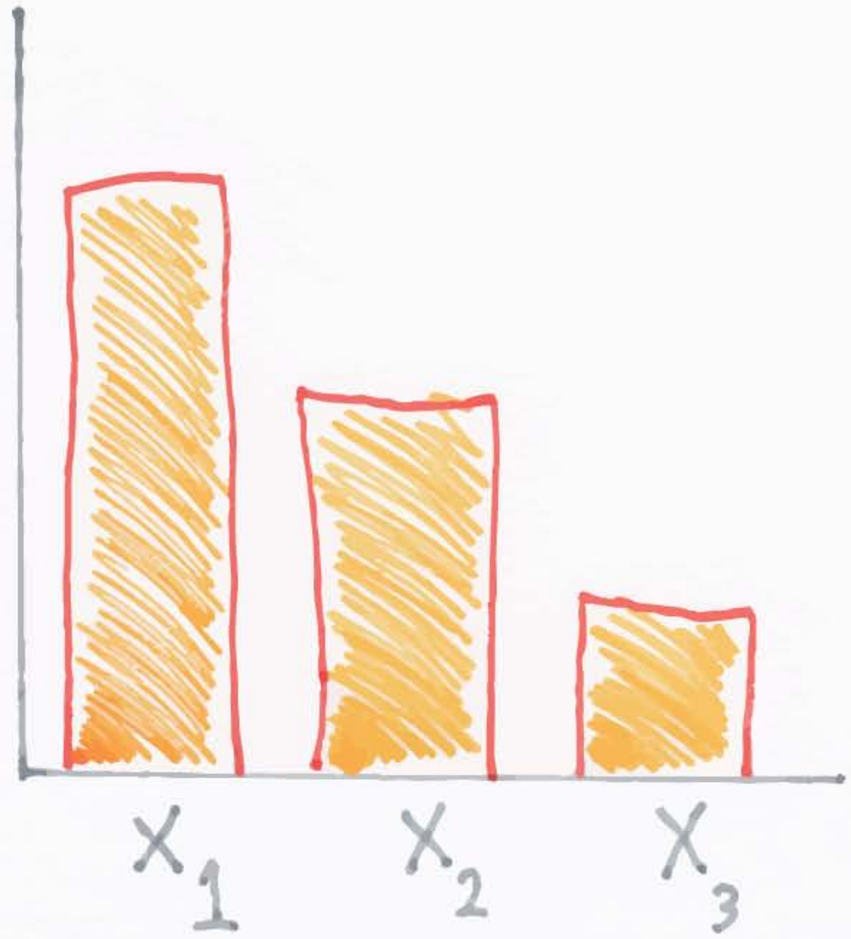

ChrisAlbon

特征选择策略

feature selection strategies

1. 移除高度相关的变量
2. 使用最小二乘法来选择高度显著的特征
3. 正向选择/反向选择/递归选择
4. 随机森林模型输出的特征重要性程度
5. Lasso回归（L1正则）

*译者注：
正向选择可以理解为每次加入一个新的特征，重新对模型进行评估，找出评估结果最佳的特征组合。反向选择是依次减少特征

BY CHRIS ALBON

前馈神经网络

feed forward neural networks

—也被称为多层感知机

—因为信息是从输入层前向传递给输出层的，所以被称为前馈网络

—网络结构示例：

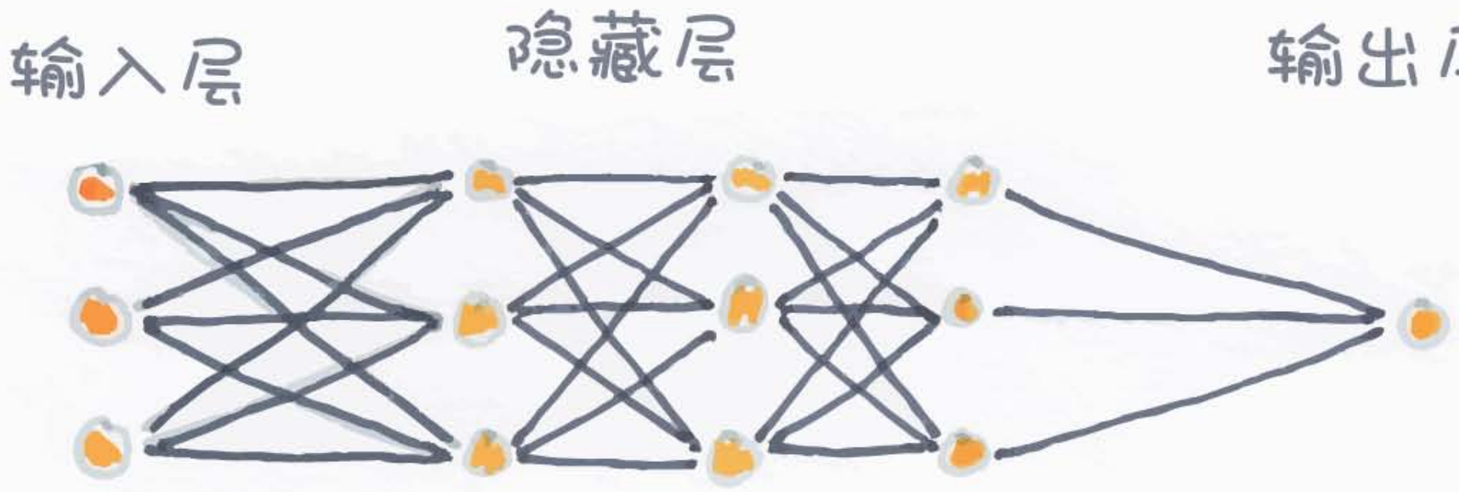

Chris Albon

线性回归参数计算

Finding Linear Regression Parameters

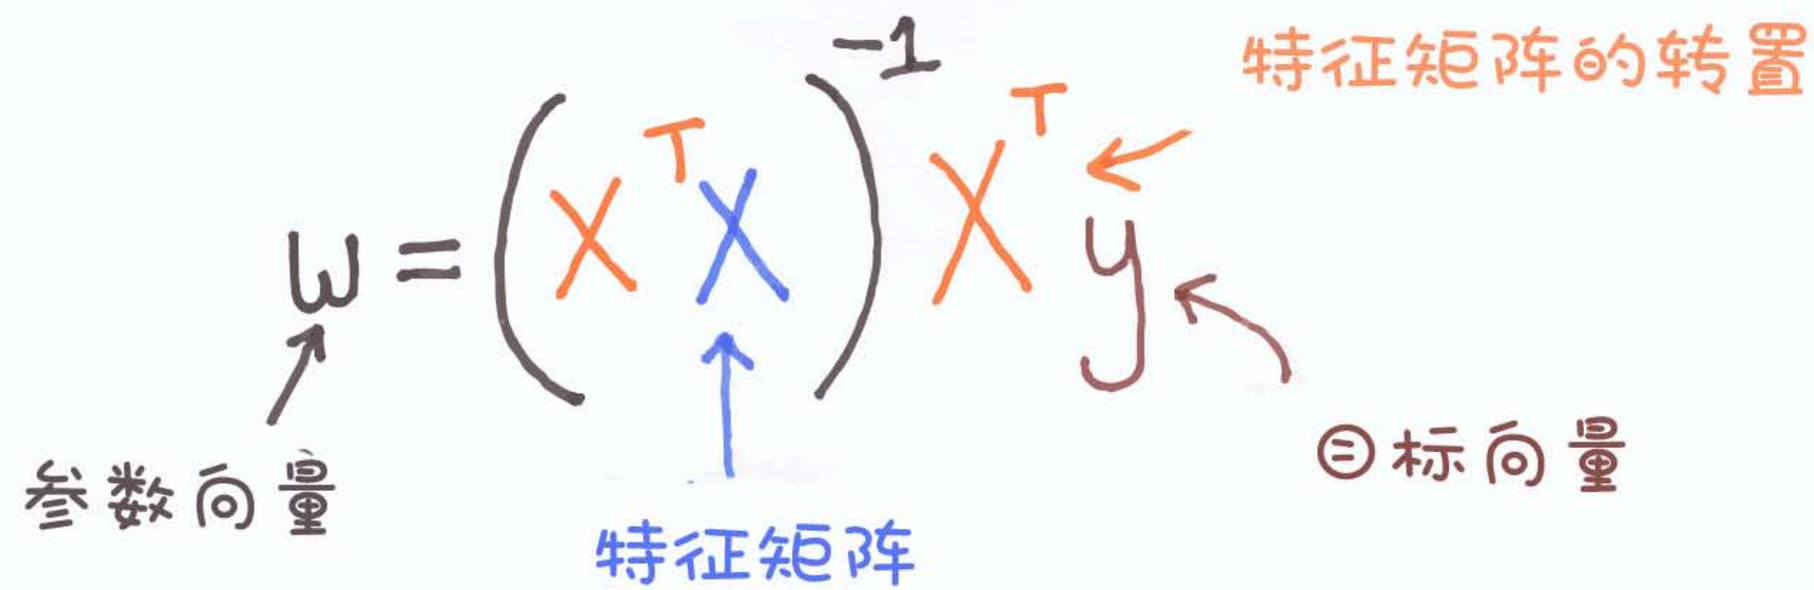

解析解是通常采取的方法。然而，如果有大量数据的话，为逆矩阵XTX的计算成本太高，梯度下降算法是更好的选择。

*译者注：解析解是通过最小二乘法求解的

ChrisAlbon

向前逐步选择法

Forward Stepwise Selection

1,创建一个模型,m0,没有特征,f

2,k = 0 ..... f - 1

a)创建一个模型,将一个功能添加到现有的模型

b)重复所有未使用的特性

c)选择模型与最好的评估度量,定义为"mk+1"

3,通过使用交叉验证、交叉模型评价指标,来

Chris Albon

梯度下降
Gradient Descent

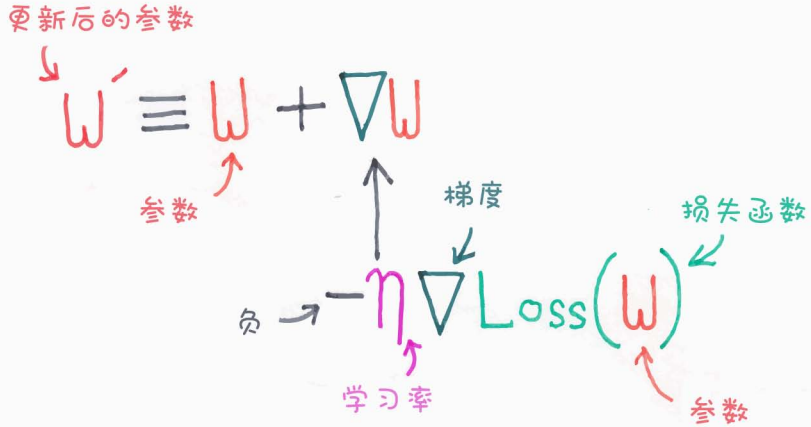

Chris Albon

梯度下降小口诀

Gradient Descent rule of thume

如果特征之间的数值范围较大，梯度下降会花更长时间。Andrew Ng的法则是如果特征值大小在-3到3之间，或者-1/3到1/3之间，那么就没啥问题。

Chris Albon

梯度
Gradient

一个函数f的梯度是一个包含了该函数在点x所有偏导的向量。

$$\nabla_x f(x)$$

Chris Albon

贪心算法

Greedy Algorithms

只优化最近的决策

一个策略的十心市宜去贪城便机个人最飞一某中坐。达市到法到城找方们下要的我剩们宜当去我便，实如市则总策例城略，机，最是。

ChrisAlbon

希腊字母 1

greek letters

A α alpha

Δ δ delta

B β beta

E ε epsilon

Γ γ gamma

Z ζ zeta

Chris Albon

希腊字母 2
greek letters

Η η eta
（读：伊塔）

Θ θ theta
（读：西塔）

Ι ι iota
（读：阿欧塔）

Κ κ Kappa
（读：喀帕）

Λ λ lambda
（读：拉姆达）

Μ μ mu
（读：缪）

Chris Albon

希腊字母3
greek letters

N ν nu
（读：拗）

Ξ ξ xi
（读：克西）

O o omicron
（读：哦米可r安）

Π π pi
（读：派）

P ρ rho
（读：肉）

Σ σ Sigma
（读：西格玛）

希腊字母 4

greek letters

Τ τ tau

（读：涛）

Υ υ upsilon

（读：优普西拢）

Φ φ phi

（读：fai）

Χ χ chi

（读：铠）

Ψ ψ psi

（读：普赛）

Ω ω omega

（读：欧米伽）

Chris Albon

网格搜索

GridSearch

一种模型选择策略。该策略中，对最每组学习算法和/或者超参数的组合训练一个模型。然后选择其中最优模型。

ChrisAlbon

哈达马乘积

两个矩阵的元素之积

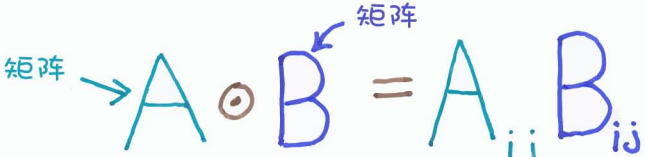

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \odot \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} a_{11}b_{11} & a_{12}b_{12} \\ a_{21}b_{21} & a_{22}b_{22} \end{bmatrix}$$

Chris Albon

汉明损失
hamming loss

预测类　　真实类

$$\text{Hamming} = \frac{1}{n}\sum_{i=1}^{n} I\left(\hat{y}_i \neq y_i\right)$$

n ← 观察点数

其中I(x)是indicator function，当预测结果与实际情况完全相符时，距离为0；
当预测结果与实际情况完全不符时，距离为1；当预测结果是实际情况的真子集或真超集时，距离介于0到1之间。

ChrisAlbon

在支持向量机下，处理不平衡类别的问题

handling Imbalanced Classes in suport vector machines

支持向量机中，超参数C决定了错误分类的惩罚值。为了处理不平衡类别问题（不同类的数据集大小差别很大），我们可以给C按类加权重

类别k的惩罚值 $C_K = C * w_K$ 权值和类别k出现的频率成反比

目标是防止数量较多的类别淹没了数量较小的类别的信息。

Chris Albon

异常处理

handling outliers

Title: 处理离群

1.如果是信息错误导致的离群点：丢掉它，把它标记为缺少有效值或者可能的错误

2.如果信息合法但是是极端值：看看它是否真的是我们尝试处理的点集中的一员

ChrisAlbon

黑塞矩阵

Hessian matrix

当我们有一个接受多个输入、返回一个输出的函数时，它的二阶偏导矩阵被称为它的黑塞矩阵。

Chris Albon

异方差

误差项的方差不为常数

*作者注：异方差会导致偏离标准误差。

Heteroskedasticity will bias standard errors.

BY CHRIS ALBON

隐含层
hidden layer

之所以叫作隐含层是因为这些值不在数据当中。

然而，这些值对建模关系仍然是有用的。

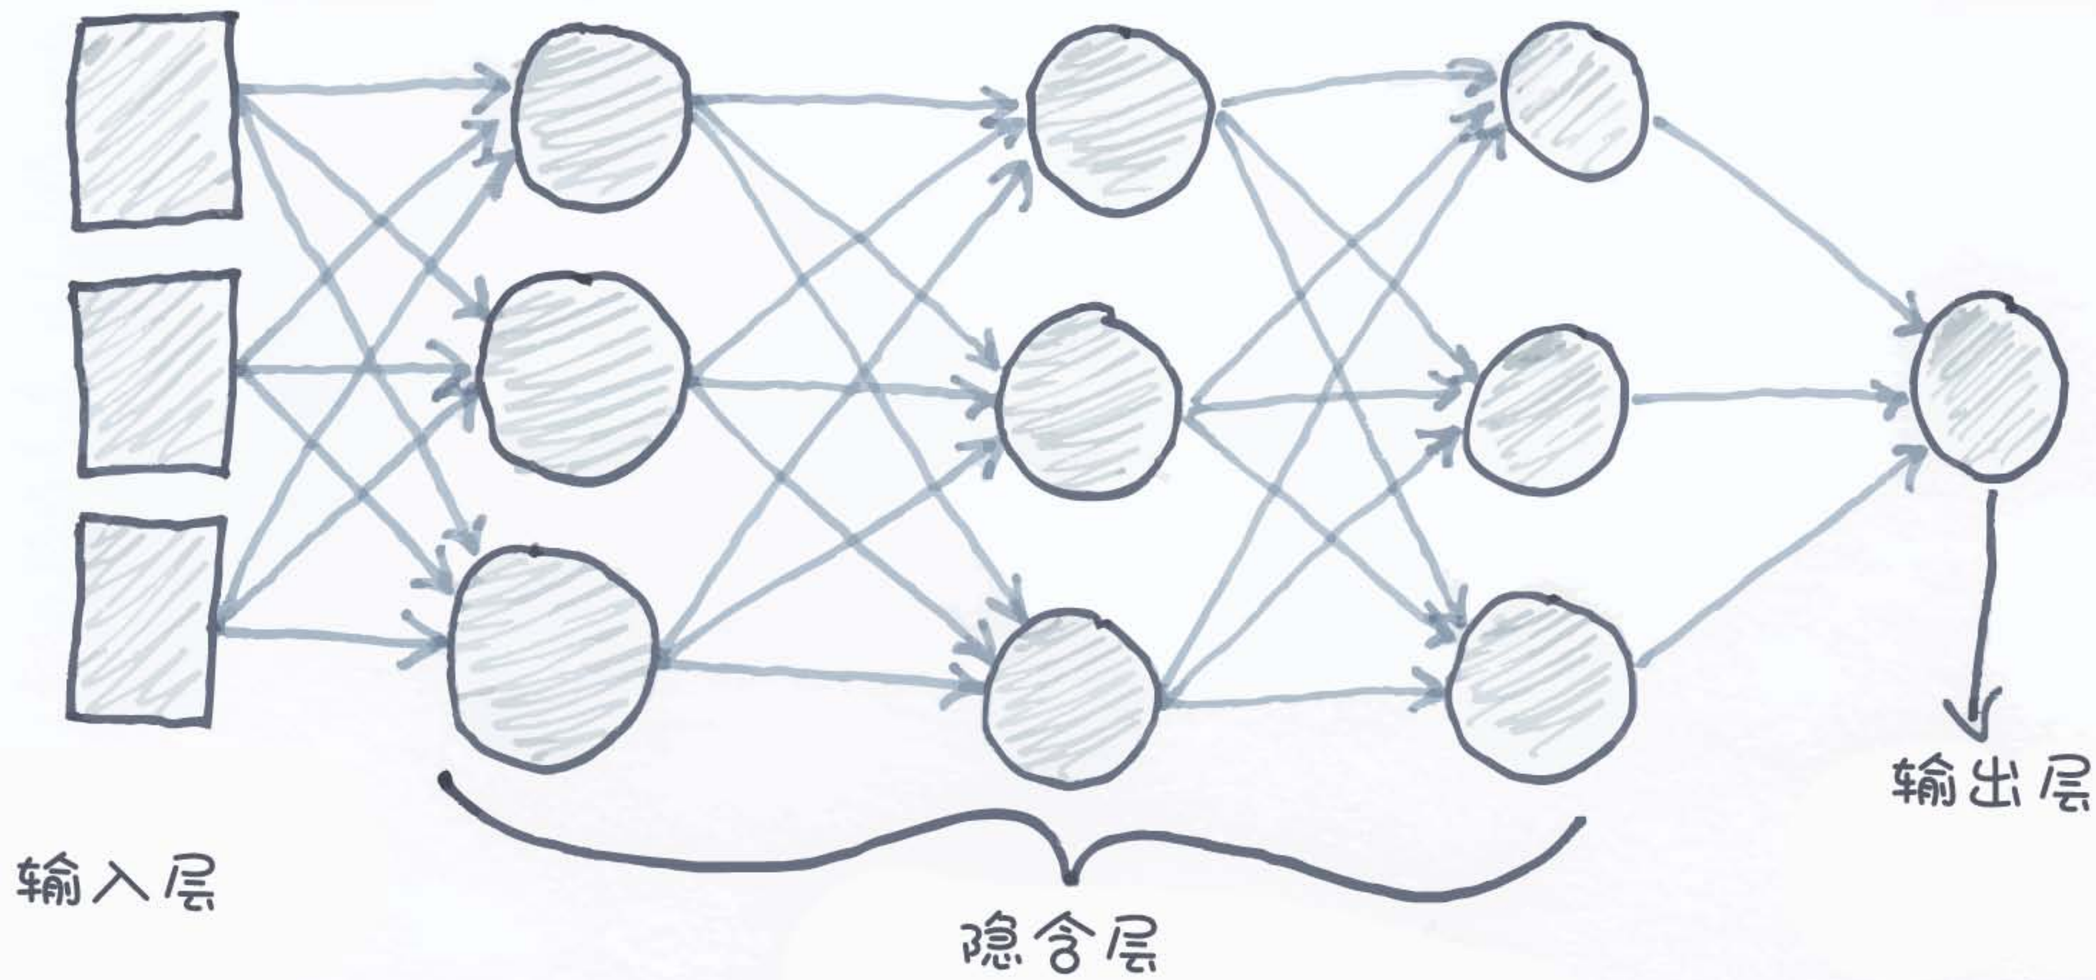

BY CHRIS ALBON

HINGE LOSS 损失函数

类别标签为+ 1和- 1

$$L_{Hinge}(y, w) = \max\{1 - wy, 0\}$$

True y　　分类器原始的输出　　True y

用于支持向量分类器，当y和w同符号，并且|w|≥1时，Hinge Loss为0。否则 Hinge Loss随着w的增加而增加

BY CHRIS ALBON

范数惩罚是如何起作用的

how norm penalties work

L1范数和L2范数惩罚向0缩减参数
好处来自参数值的方差较小，不一定是最小值。
0是一个典型的数值，因为它既不为正也不为负。

Chris Albon

如何选择隐藏单元激活函数

How To Choose Hidden Unit Activation Functions

—没有已经被证实的最好的选择。

—应当根据模型在验证集上的表现而定。

—Relu 激活函数是一个不错的第一选择。

Chris Albon

超参数调优

hyperparameter tuning

寻找可以产出最好的模型的算法中超参数的值。

Chris Albon

准确率
ACCURACY

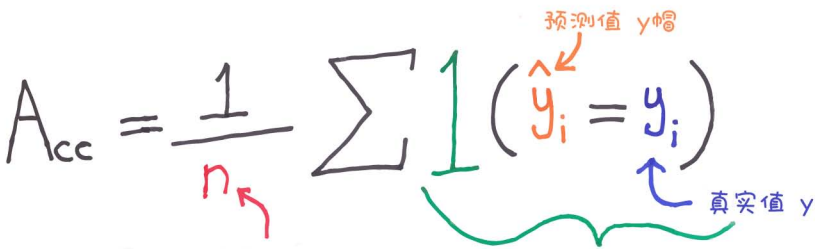

对于给定的一组数据的一系列测量，当y_i的预测值与真实值y相等时，指示函数取1，不相等时，指示函数取0。在类别严重不均衡时，F1 值更符合。

译者注：
准确率accuracy其定义：对于给定的测试数据集，分类器正确分类的样本数与总样本数之比，反映了分类系统对整个样本的判定能力——能将正的判定为正，负的判定为负。

测量理论

Almost Everywhere

一个几乎全场hold住的理论，但是总有那么几次打脸的时候。

*译者注：

测量理论是应用数学的一个分支，可用于测量和数据分析。测量理论的基本思想是测量与被测量属性不同。因此，如果你想得出关于属性的结论，你必须考虑属性和测量之间的对应关系的性质。

Chris Albon

岭回归（或脊回归）中的α值

alpha in ridge regression

ChrisAlbon

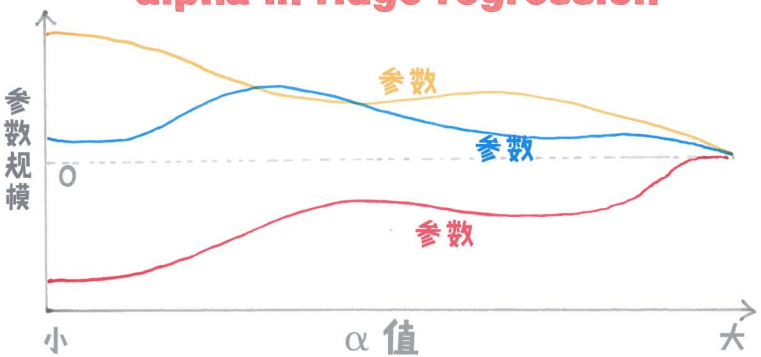

*译者注：

如果α为岭回归的岭参数，将回归估计参数与岭回归参数α之间的变化关系用一张图来表示，便是岭迹图，其中横坐标就是参数大小，纵坐标为回归估计的参数。

根据岭迹图，可以得到的结论有：

1）当不存在奇异值时，岭迹应该是稳定地逐渐趋于0。

2）当存在奇异值时，α不够大时，奇异值并没有得到太大的改变，随着α的变化，回归的估计参数震动很大，当α足够大时，奇异值的影响逐渐减少，从而估计参数的值变的逐渐稳定。

安斯库姆四重奏

Anscombe's quartet

BY CHRIS ALDON

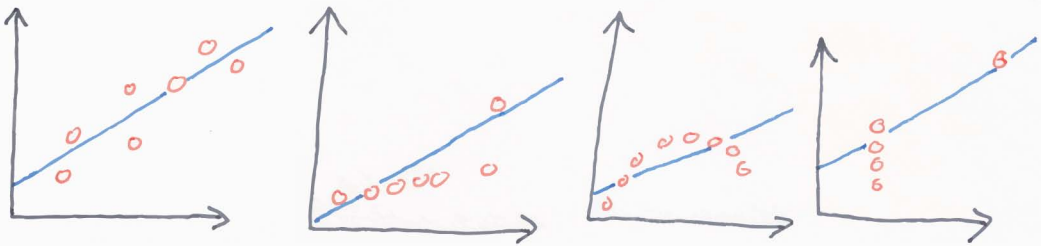

安斯库姆四重奏是具有相同汇总统计和回归线的四组不同数据集。这是一个关于汇总统计的警告。

偏差和方差的权衡

Bias-Variance Tradeoff

$$Error(x) = \left(E\left[\hat{f}(x)\right] - f(x)\right)^2 + E\left[\hat{f}(x) - E\left[\hat{f}(x)\right]\right]^2 + \sigma_e^2$$

- $\hat{f}(x)$：预测值
- $f(x)$：真实值
- $\hat{f}(x)$：预测值
- $E\left[\hat{f}(x)\right]$：预测值的均值
- σ_e^2：残差

偏差^2

预测值和真实值之间相差多少

方差

对于同一个值的预测是怎样因为模型的不同实现而变化的

BY CHRIS ALBON

自助采样法

自助采样法：通过不断重复进行有放回采样的方式来模拟得到许多新的训练数据集。

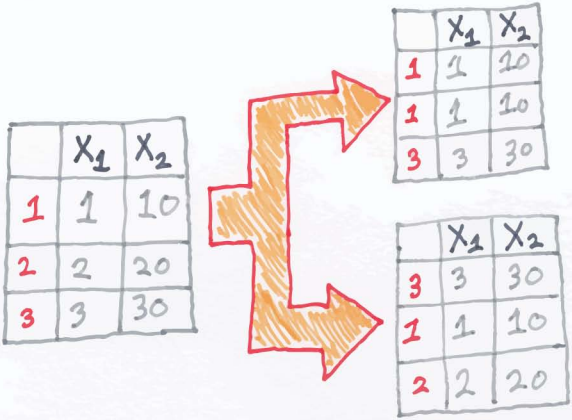

Chris Albon

能力
capacity

机器学习算法的能力是指它学习各种可能函数的能力。更多的能力，意味着一个在过拟合风险下更灵活的模型

ChrisAlbon

常见的神经网络最优化算法
Common Optimizers of Neural Nets

1.随机梯度下降
2.带动量的随机梯度下降
3.方均根传播算法
4.自适应矩估计

*译者注:
RMS Prop 为Geoff Hinton在其课oursera的课程中提到的未公开算法，译法待考。

Chris Albon

常见的输出层激活函数

Common Output Layer Activation Functions

二元分类：sigmoid函数

多分类：softmax函数

回归：没有激活函数

Chris Albon

凹函数&凸函数

concave & convex function

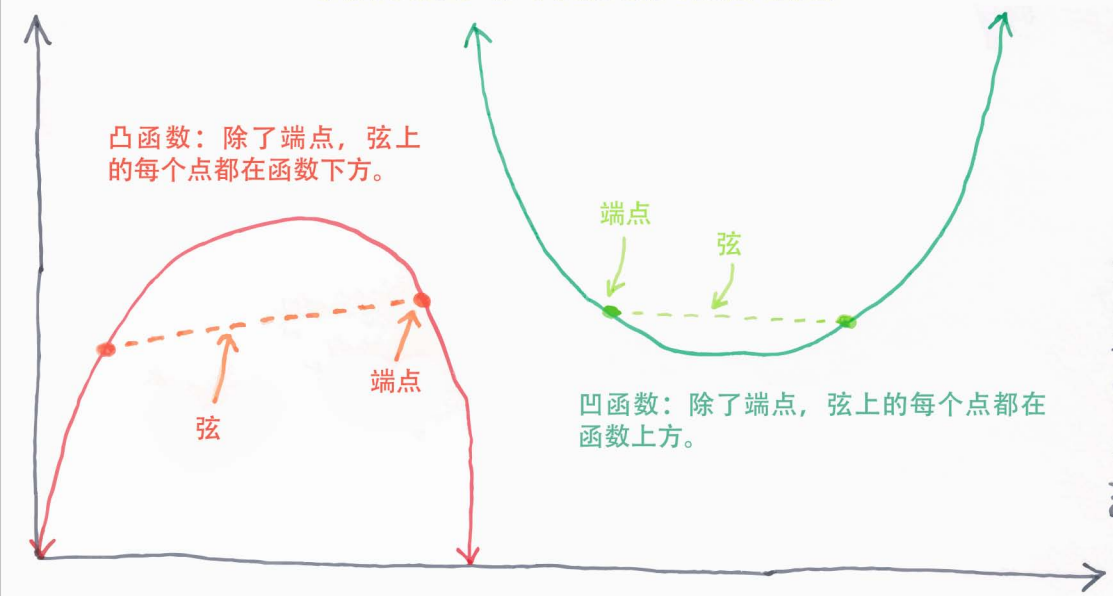

BY CHRIS ALBON

条件概率

conditional probability

$$P(A \text{ and } B) = P(A) \times P(B|A)$$

条件概率是指事件A在另外一个事件B已经发生条件下的发生概率。条件概率表示为：P（A|B）P(AB)表示A和B同时发生的概率

例如：$P(A \text{ and } B) = P(\text{DRAW ACE and DRAW KING}) = \left(\frac{4}{52}\right) \times \left(\frac{4}{51}\right)$

P(AandB)：从花色牌中同时拿到A和K的概率；

P(AandB)=P(A)*P(B|A)= 4/52 * 4/51

*译者注：ACE：扑克牌中的A King：扑克牌中的K

DRAW：扑克牌中的（梅、方片）花牌共52张，除去2张大小王。

学会的可以拉斯维加斯玩21点了。

BY CHRIS ALBON

置信区间

Confidence Intervals

95%级是自信意味着，如果我们进行了同样的实验100次，如那些100的置信区间包含真正的参数值（例如β1的真正价值）

BY CHRIS ALBON

模型的一致性

随着观测数量接近无穷大，预测目标与真实目标差值大于某个值的概率接近于零。

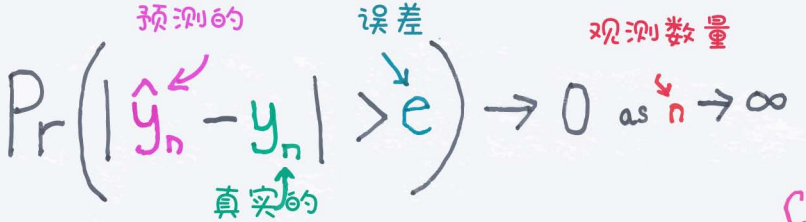

Chris Albon

代价函数和损失函数
Cost and loss functions

代价函数和损失函数是相同的。它们是我们训练模型时所要最小化的目标函数。

例如：交叉熵。

*译者注：

交叉熵是机器学习中一个常见的函数，最小化该函数将使待估计的模型更加有效。

Chris Albon

交叉熵

cross-entropy

样本在有k个取值的第m个分布区域的概率

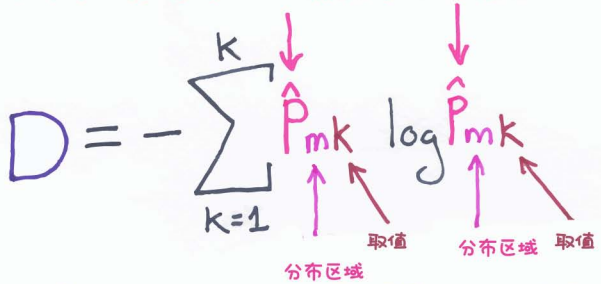

D越接近于0，变量取值越稳定，因此熵越大变量的取值越不稳定。

BY CHRIS ALBON

决策边界 DecisionBoundary

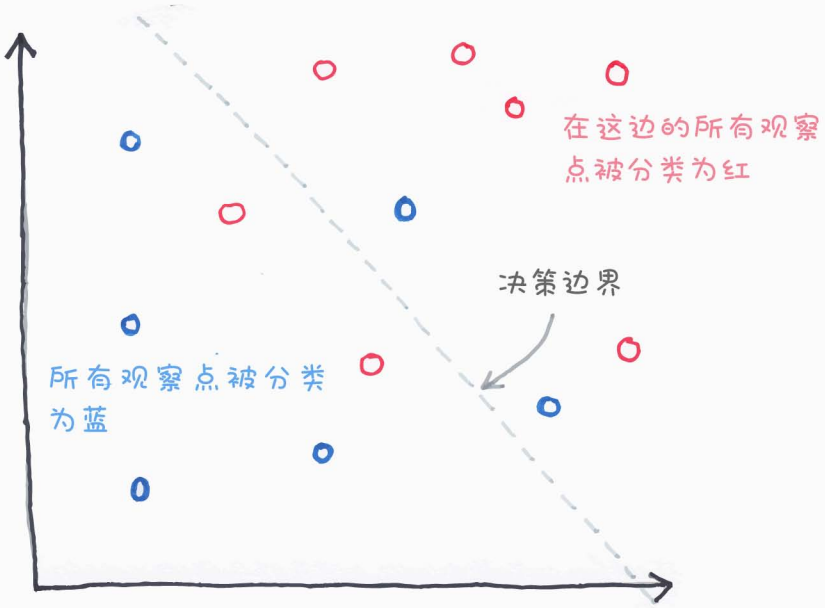

Chris Albon

特征选择策略

feature selection strategies

1. 移除高度相关的变量
2. 使用最小二乘法来选择高度显著的特征
3. 正向选择/反向选择/递归选择
4. 随机森林模型输出的特征重要性程度
5. Lasso回归（L1正则）

*译者注：
正向选择可以理解为每次加入一个新的特征，重新对模型进行评估，找出评估结果最佳的特征组合。反向选择是依次减少特征

BY CHRIS ALBON

核主成分分析

Kernel PCA

线性PCA能降维但不能使降维后的数据线性可分

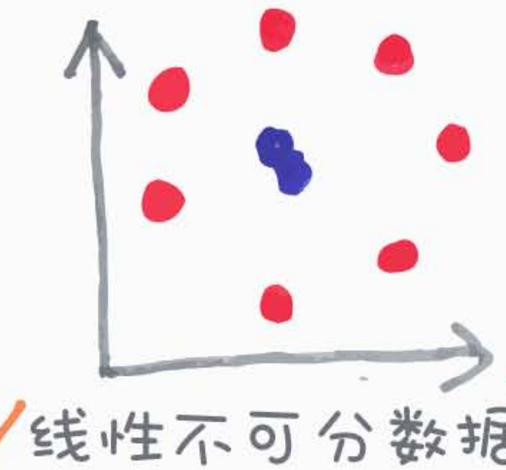

KPCA不仅能够数据降维，而且能使降维后的数据线性可分。

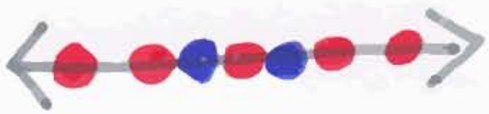

Chris Albon

核技巧

Kernel Trick

支持向量机可以简化为一个向量点积

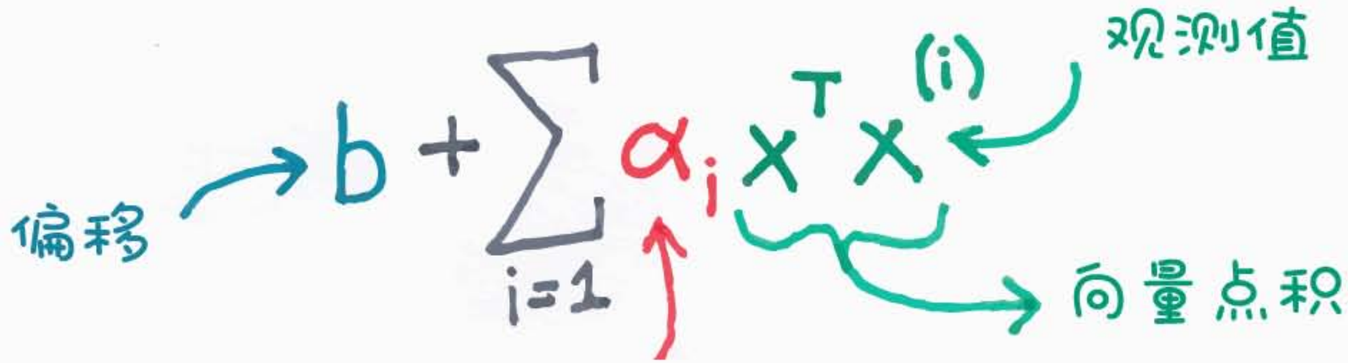

核技巧就是用核运算替代向量点积

$$b + \sum \alpha_i \, k(x, x^{(i)})$$ ← 核

这样适用于非线性的决策边界以及提升计算效率

*译者注:
在线性支持向量机的对偶问题中，无论目标函数还是决策函数都只涉及输入实例与实例之间的内积。
对偶问题中的目标函数中的内积(x_i·x_j)可以用核函数K(x_i·x_j)= ϕ(x_i)· ϕ(x_j)来代替

Chris Albon

L1 范数

L1 Norm

曼哈顿范数，也称为出租车范数

*译者注：L1范数就是简单的绝对值加总。在支持向量学习过程中，质是对损失函数的优化过程。通过向成本函数中添加L1范数，能够防止过拟合，增加模型的泛化能力。

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|$$

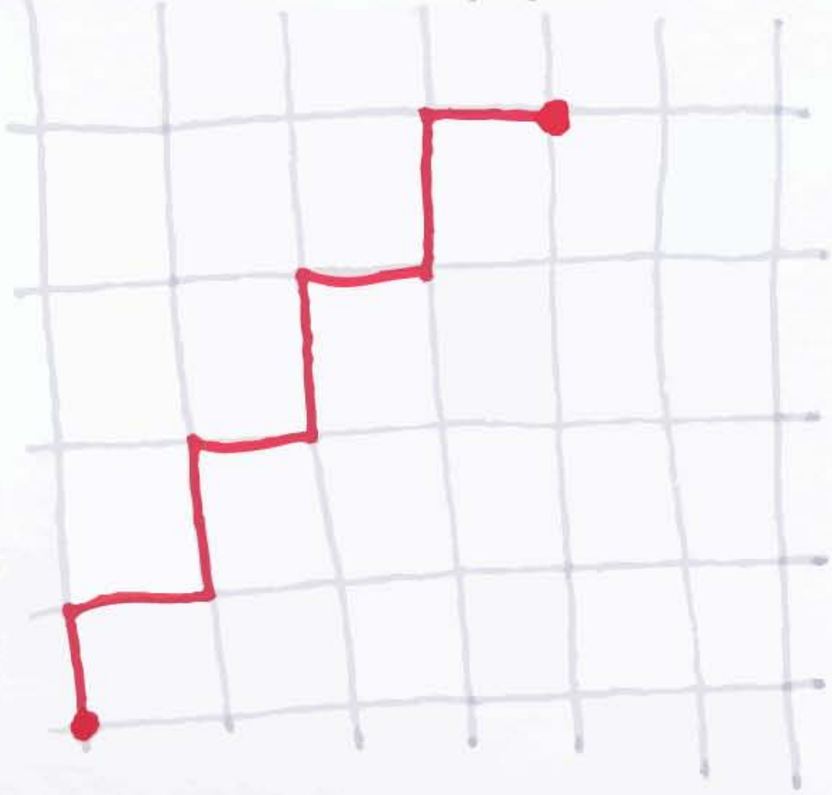

ChrisAlbon

L2范数

L2 Norm

欧几里得范数

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$

L2范数在机器学习中有很多用处，比如用于样本的标准化（比如自然语言处理）和正则化（比如：岭回归）

Chris Albon

特征选择法之Lasso

Lasso For Feature Selection

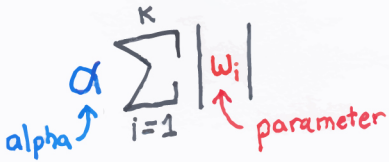

— Lasso回归使用L1范数作为正则化矩阵

— 不同于岭回归，Lasso的范数正则化驱使参数趋近于0

—阿尔法（alpha）的值越高，越少非零特征值

Chris Albon

带泄露线性整流函数

Leaky ReLU

类似于ReLU(线性整流函数)但永远非零，取而代之是返回一个极小正数：

$$\phi(z)=\begin{cases} z & \text{if } z>0 \\ 0.01z & \text{otherwise} \end{cases}$$

由于带泄露线性整流总是返回一个值，梯度永远非零。

ChrisAlbon

学习曲线
Learning Curve

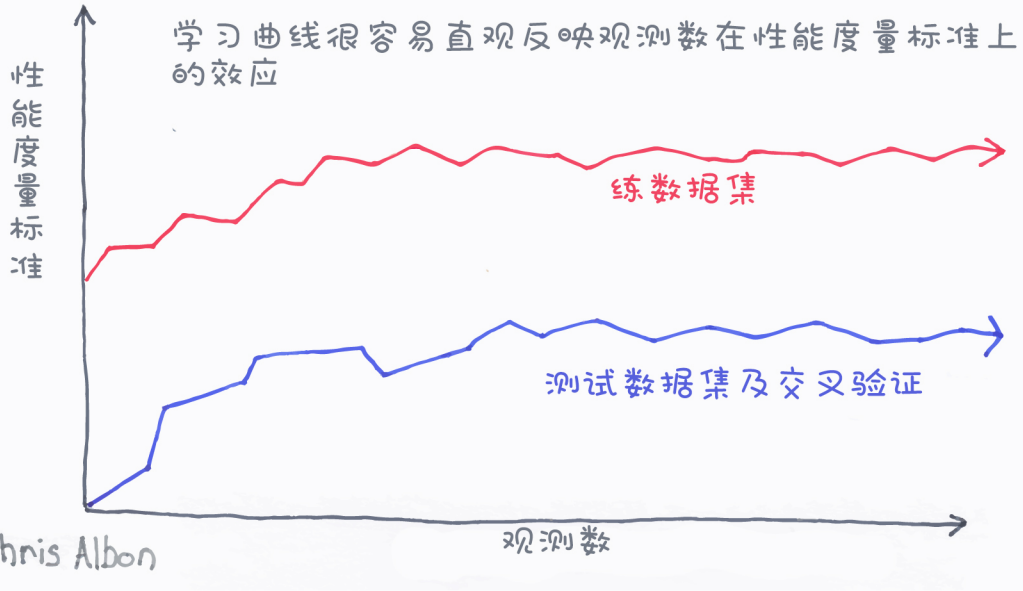

机器学习中的“学习“是指什么

Learning In Machine Learning

对于某给定的任务T，在合理的性能度量方案P的前提下，某计算机程序可以自主学习任务T的经验E;随着提供合适、优质、大量的经验E，该程序对于任务T的性能逐步提高。

——汤姆 米切尔（1997）

Chris Albon

学习速率
Learningrate

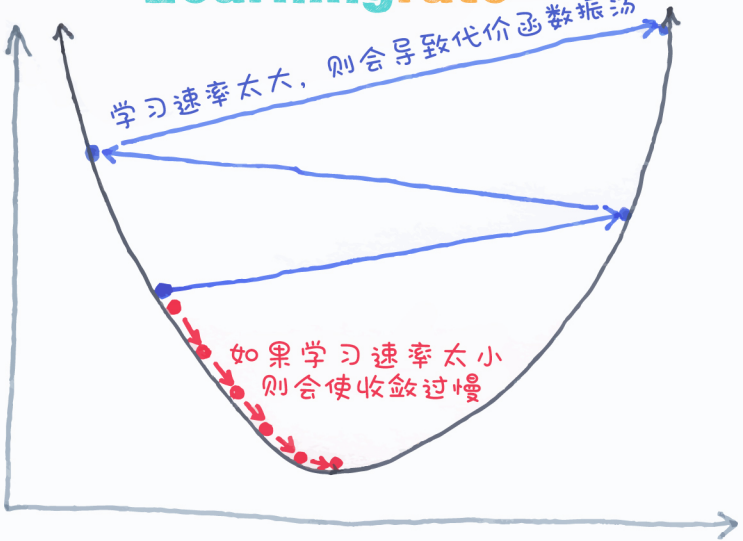

ChrisAlbon

线性激活函数

linear activation funtion

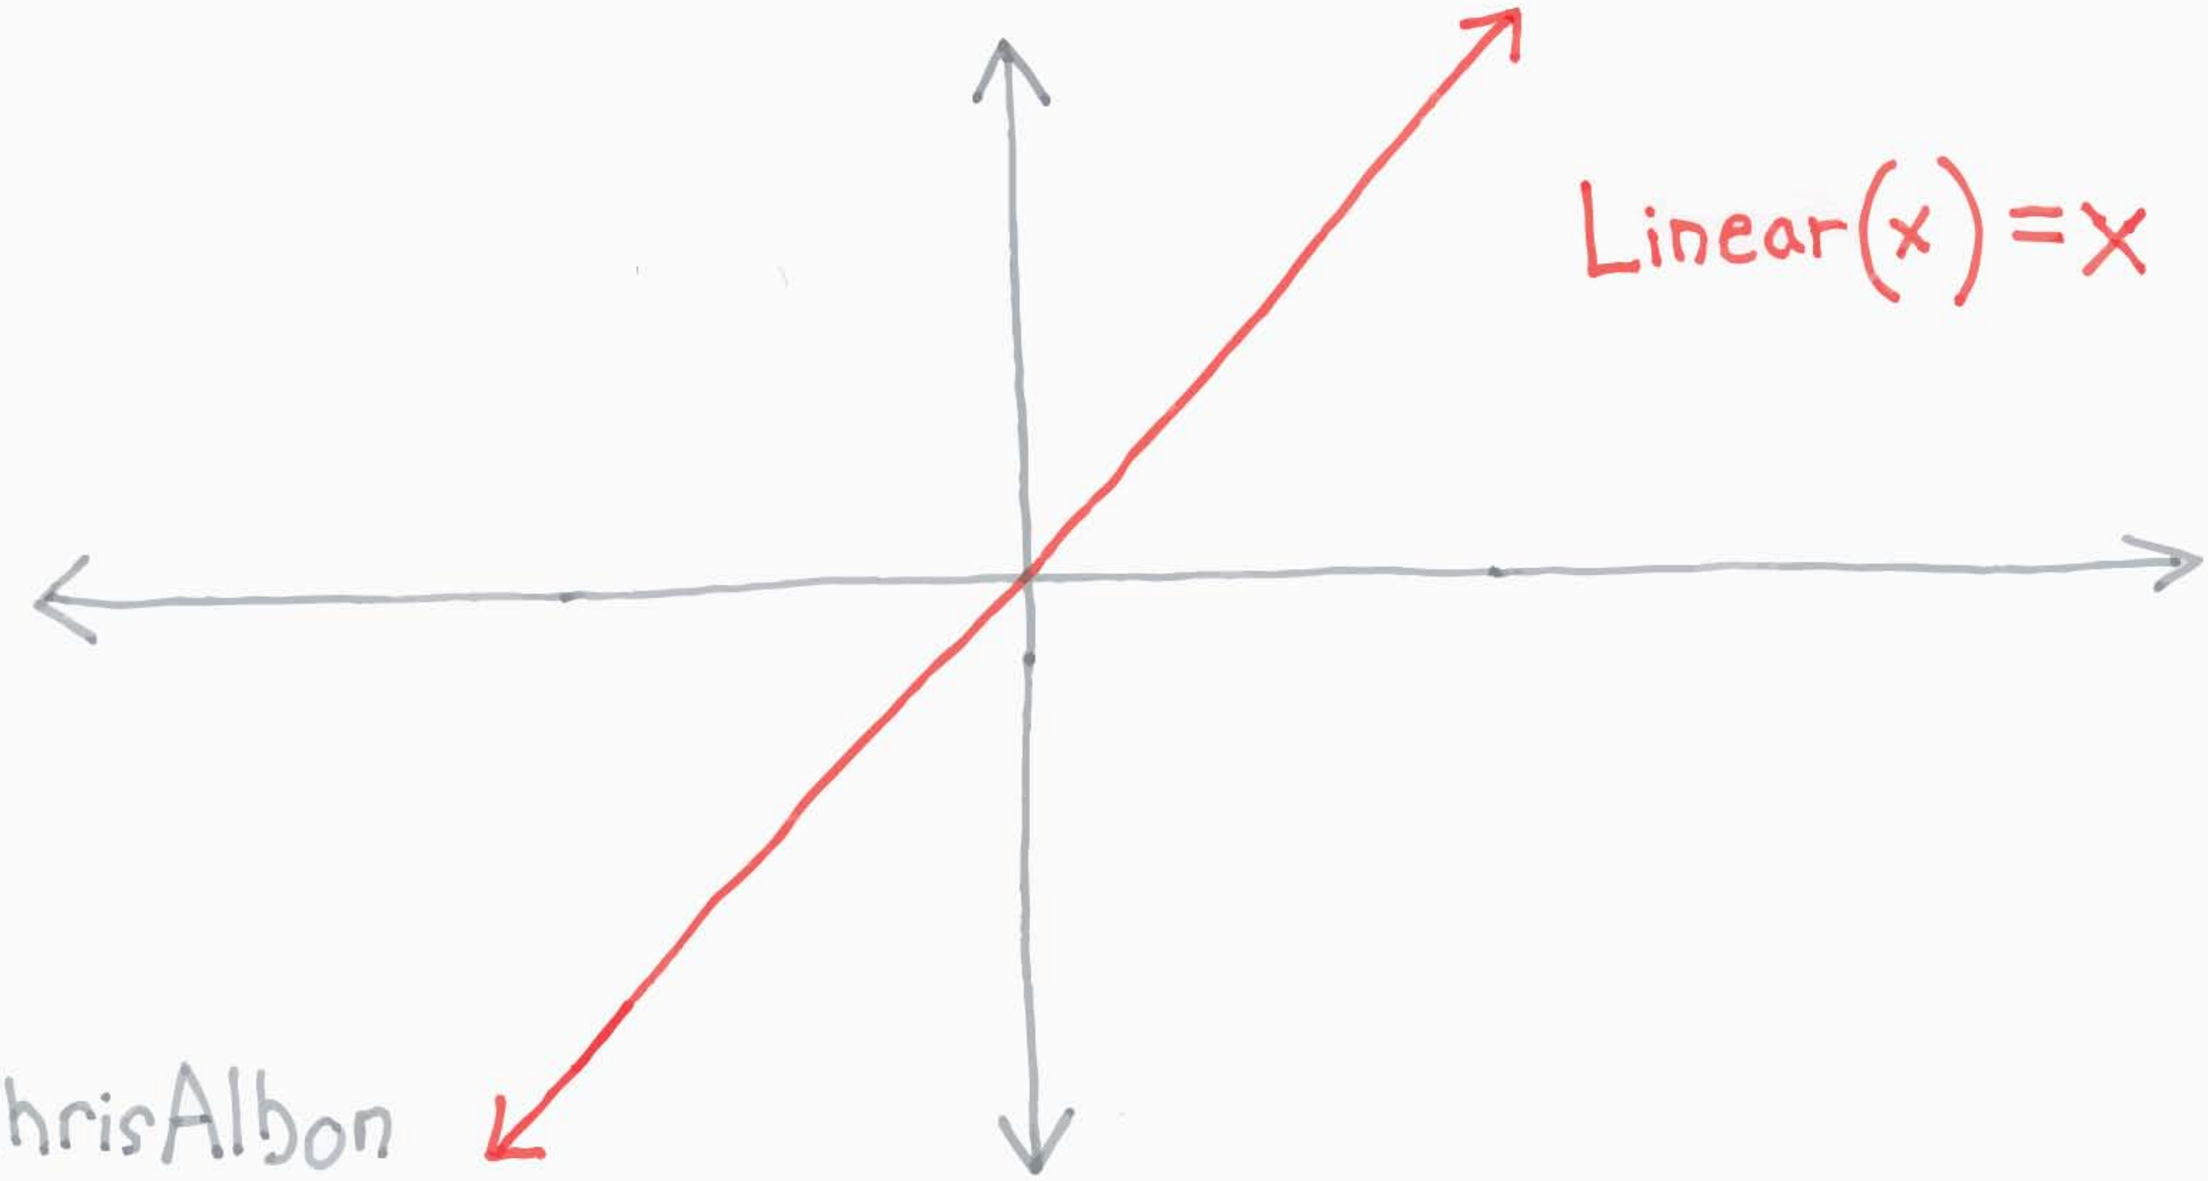

向量的线性组合
Linear Combination

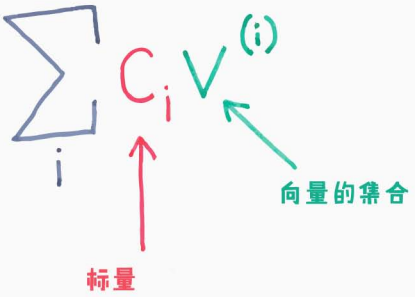

ChrisAlbon

线性判别分析

Linear discriminant analysis

降维

查找将类和项目数据之间最大可分性最大化的轴。

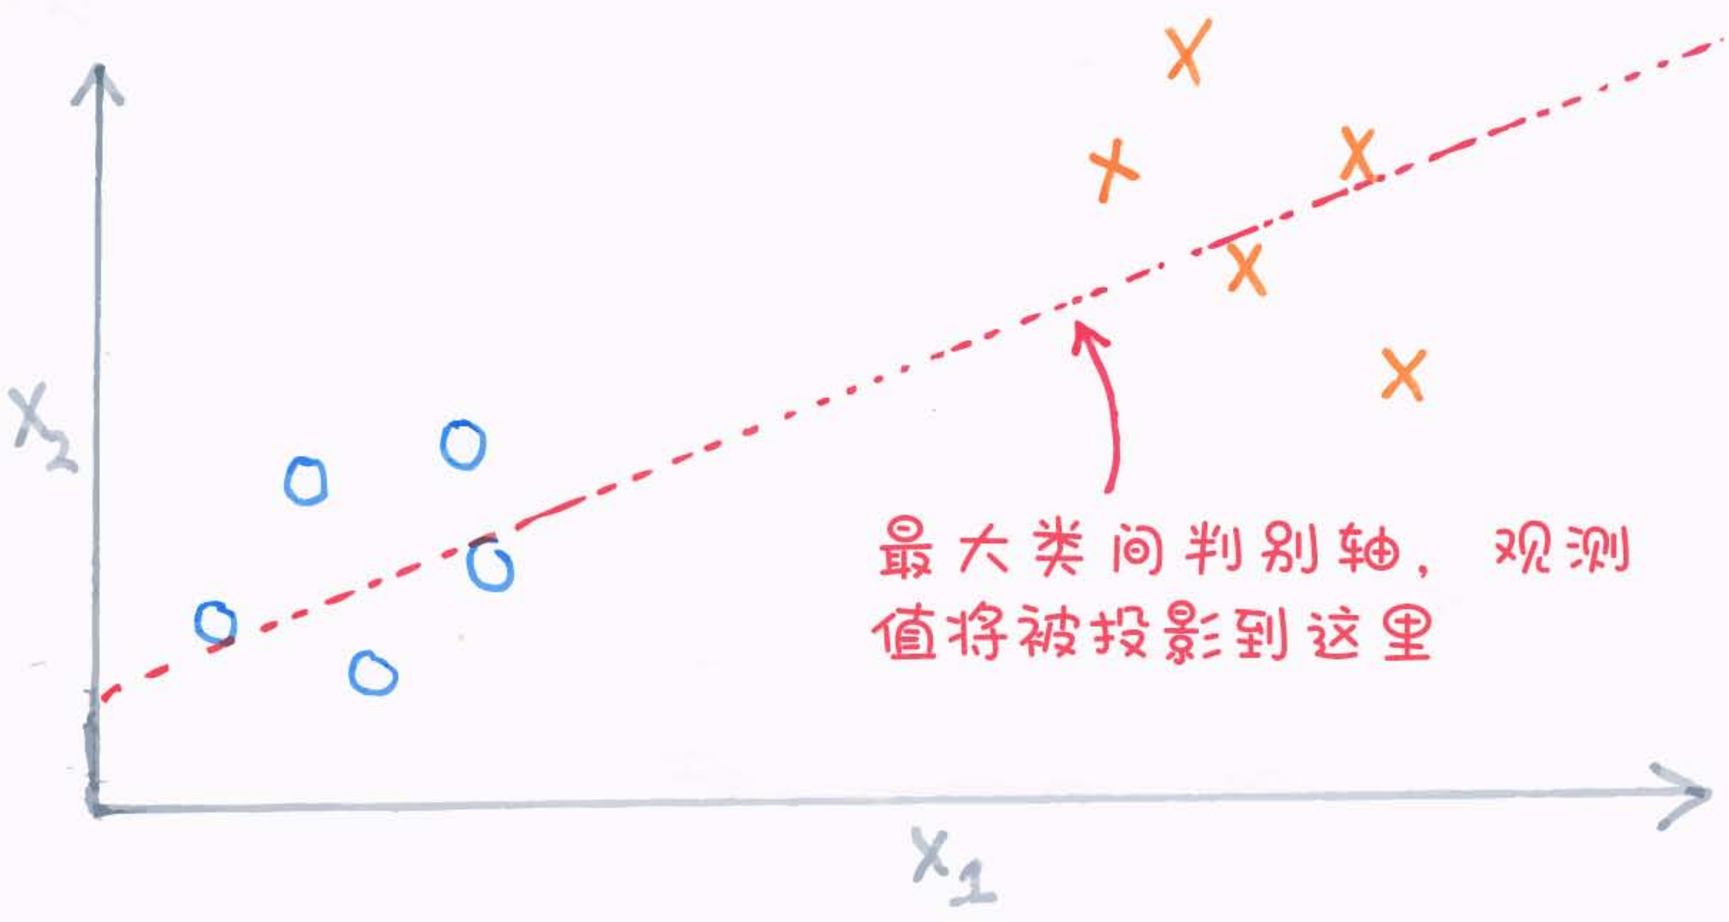

Chris Albon

线性无关
Linearly Independent

若矩阵中没有一个向量可以由其他向量线性表示，那么该矩阵线性无关。

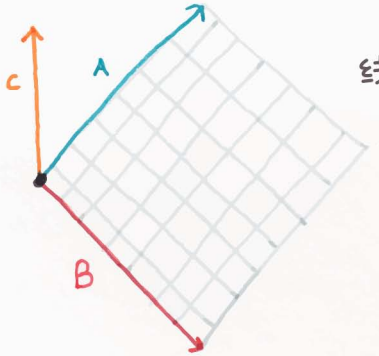

线性无关

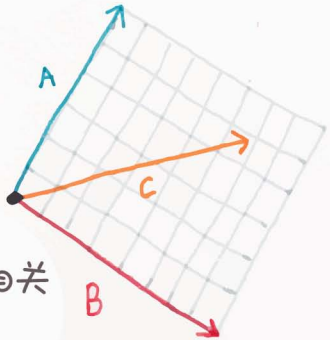

线性相关

BY CHRIS ALBON

线性可分

Linearly Separable

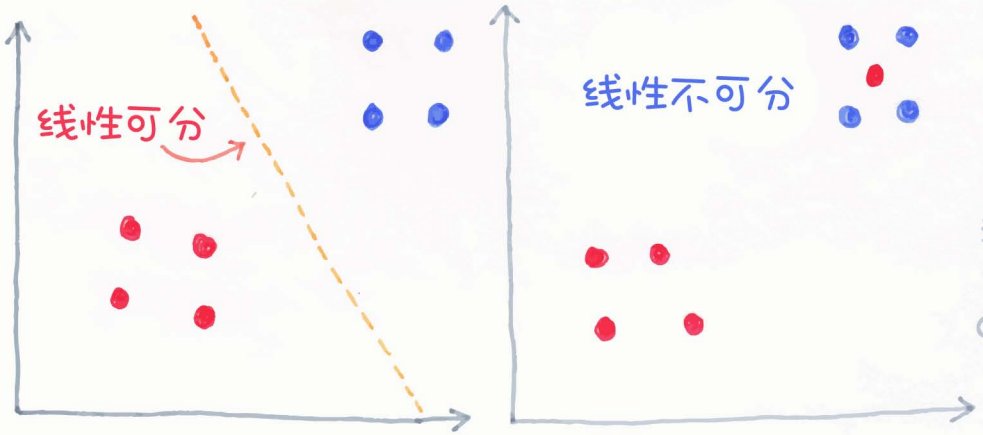

指数之和的对数

LOG-SUM-EXP

假设我们要计算下面这个式子：

$$c = \log \sum_{i=1}^{n} e^{x_i}$$

如果x的值很小或很大，将会导致c因为值太小或太大而无法在电脑上显示，这种情况称为下溢和上溢。

“指数之和的对数”这个技巧利用了这个事实：

$$\log \sum_{i=1}^{n} e^{x_i} = a + \log \sum e^{x_i - a} \qquad \text{其中，} a = \max(x)$$

这个事实变换了中心使得（xi -a）的最大值为0，避免了上溢和下溢的情况发生。

逻辑回归

LOGISTIC REGRESSION

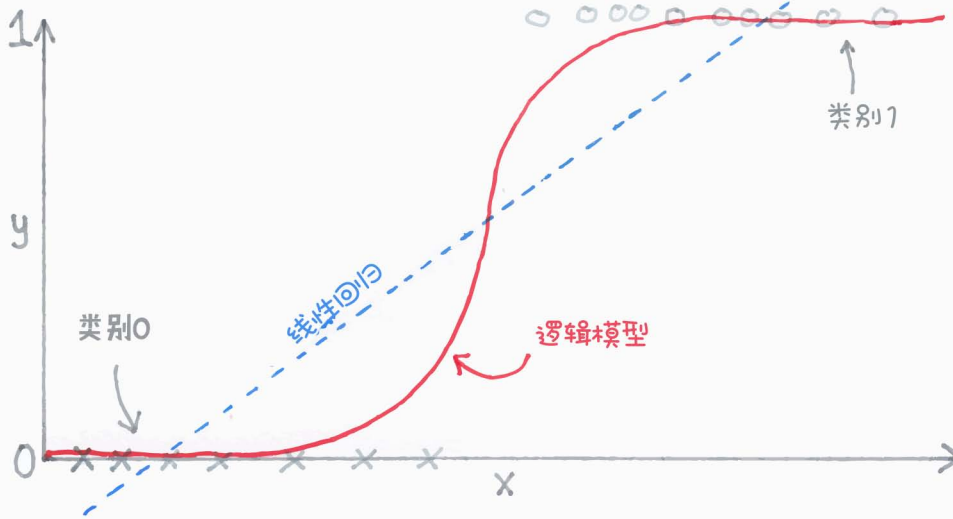

ChrisAlbon

逻辑模型 VS. 线性模型

LOGISTIC REGRESSION vs LINEAR REGRESSION

$$p = \frac{1}{1 + e^{-(b_0 + b_1 x_1 + \cdots b_k x_k)}}$$

逻辑模型

线性模型

Chris Albon

逻辑sigmoid 函数

$$\sigma(x) = \frac{1}{1 + e^{(-x)}}$$

输入

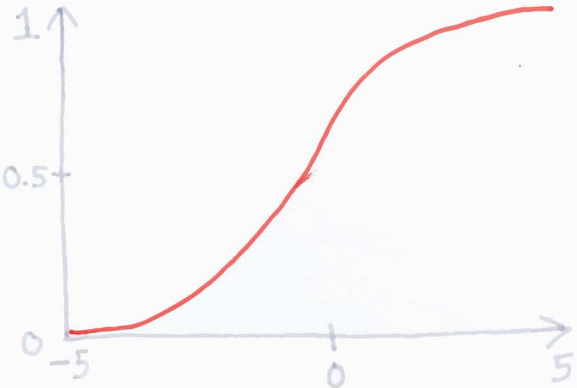

*译者注：Logistic回归曲线是“S”形，又称为Sigmoid回归

Chris Albon

曼哈顿距离

Manhattan distance

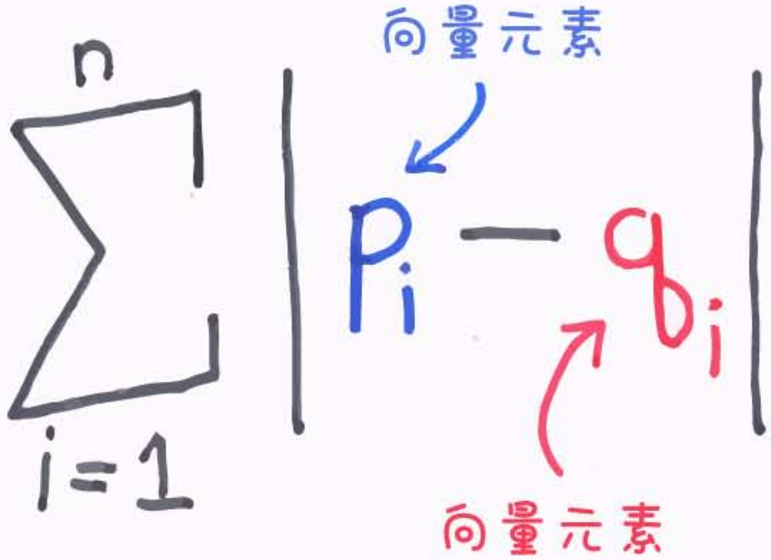

想象一下，你在曼哈顿，你只能向正东，正西，正南，正北四个方向行走。

*译者注：
对于一个具有正南正北、正东正西方向上的旅行距离，从一点到另一点的距离正是在南北方向上的旅行的距离加上在东西方向上旅行的距离。

ChrisAlbon

矩阵

matrices

两维的标量数组

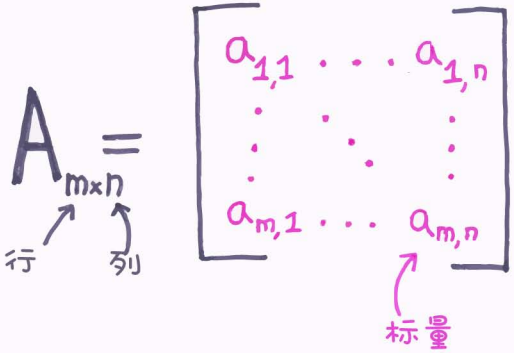

ChrisAlbon

马修斯相关系数

Matthews correlation coefficient

真阳性 真阴性 假阳性 假阴性

$$M = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

范围从负的最差分类器的准确率到最佳分类器的准确率

通过类比理解均值漂移

Meanshift Clustering By Analogy

想象一下，有100人站在一个有雾的足球场。因为有雾，人们只能看到很短的距离。每个人每隔一分钟都环顾四周，朝着他们所能看到的人最多的方向移动一步。随着时间推移，由于所有人都不断的移动，人们会开始聚集起来。最终会形成一个围在一起的人群。

ChrisAlbon

小批量随机梯度方法

从数据中提取的一组观察数据，而不需要替换。
用于随机梯度下降，采用一种高效的计算方式来估计梯度。
通常每一批的样本数设置为一个到数百个。

ChrisAlbon

参数化建模

parametric modeling

两步建模法：

1. 假设一个函数形式来表达x和y之间的关系

2. 估算这个函数的参数来拟合数据和函数

参数建模法把数据间关系的估算简化成了函数的n个参数的估算

Chris Alban

偏导数
partial deribative

表示，当函数有两个或多个变量且只有一个变量发生变化时输出将如何变化。

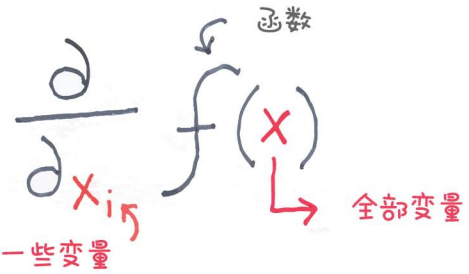

ChrisAlbon

相关系数
correlation

（皮尔逊相关系数）

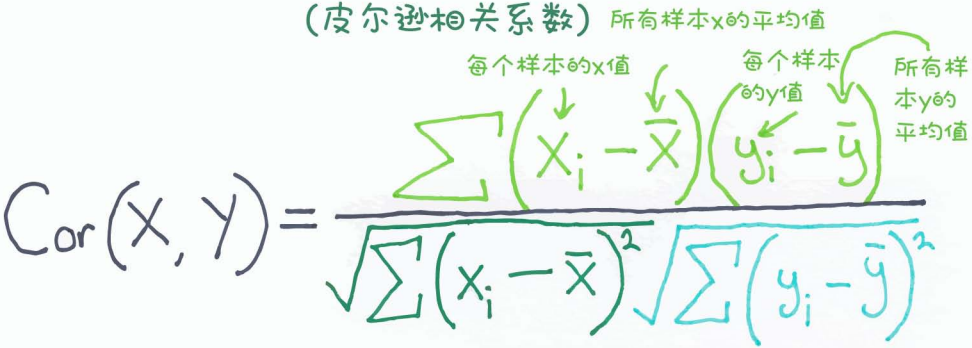

范围在-1到1之间。越接近于0的话，两个变量间的线性相关性越弱

BY CHRIS ALBON

感知机学习

perceptron learning

ChrisAlbon

被更新的参数　　当前的参数

$$w_j' \equiv w_j + \Delta w_j$$

$$\Delta w_j = \eta \left(y_i - \hat{y}_i \right) x_{ij}$$

学习率　　真实的y_i　　预测的y_i　　输入特征

*译者注：

感知机是二分类的线性分类模型，旨在求出将训练数据进行线性分类的分离超平面。

为此，导入基于误分类的损失函数，利用梯度下降法对损失函数进行极小化，是神经网络和SVM的基础（其中i是输出的编号，j是参数的编号）

感知机
perceptron

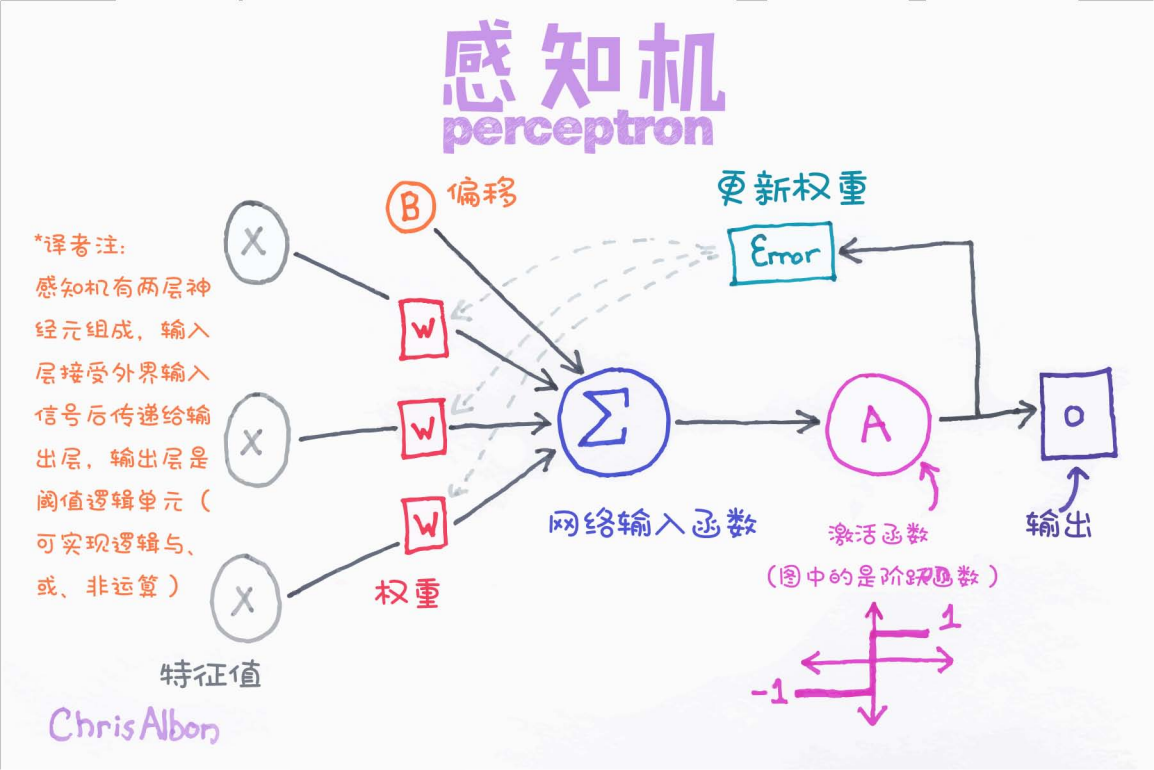

普拉托变换
Platt Scaling

为线性支持向量机输出概率值

线性支持向量机并不能直接输出预测地概率值。

普拉托变换被应用于二分类的SVC模型。

首先，在数据集上用SVC训练得到分类及得分， 然后对所得的分类及得分建立独立的交叉验证逻辑回归模型，训练找到sigmoid函数的参数A&B，把SVC分数f(x)映射为样本x是分类y的概率。

$$P(y=1|x)=\frac{1}{1+e^{(A\times f(x)+B)}}$$

欧拉数　特征向量 B　特征向量 A

ChrisAlbon

多项式回归

polynomial regression

*译者注：

多项式回归的最大优点就是可以通过增加x的高次项对实测点进行逼近，相当于非线性拟合

多项式项

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \ldots + \beta_d x_i^d + e_i$$

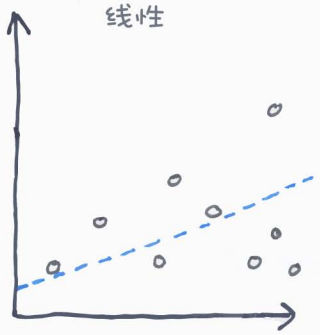

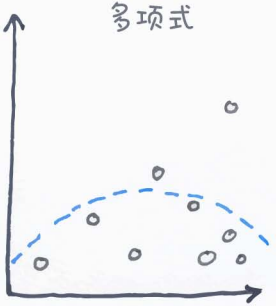

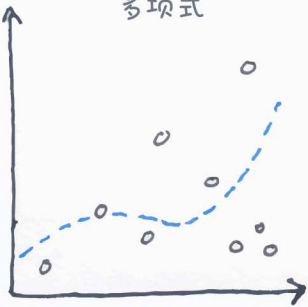

BY CHRIS ALBON

精确度

确度是指分类器不会把真阴性分类为阳性的能力

$$\frac{\text{真阳性}}{\text{（真阳性 + 假阳性）}} = \frac{\text{正确标记正值}}{\text{正确标记正值} + \text{误标记正值}}$$

ChrisAlbon

预处理之训练集与测试集

Preprocessing Training And Test Sets

1. 只将预处理操作（如，缩放）与训练集匹配

2.将其应用于训练集和测试集。

为何这么做：我们必须将训练集视为未知数据。

ChrisAlbon

主成分分析

Principal Component Analysis

主成分分析法将特征变量转换为主成分，目的是在对变量降维的同时保证仅损失一小部分信息

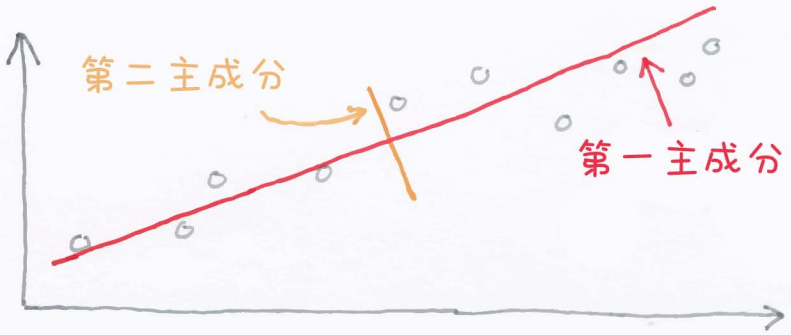

ChrisAlbon

主成分
principal components

主成分是指特征变量所有线性组合中方差最大的那组线性组合。
另一种解释：主成分是最接近观察值的低维线性表面。

ChrisAlbon

机率密度函数

probability density function

概率密度函数是一个连续随机变量的概率分布。概率密度函数可以计算一个无穷小区域的概率，我们可以通过对（概率密度函数）求积分得到这个概率。

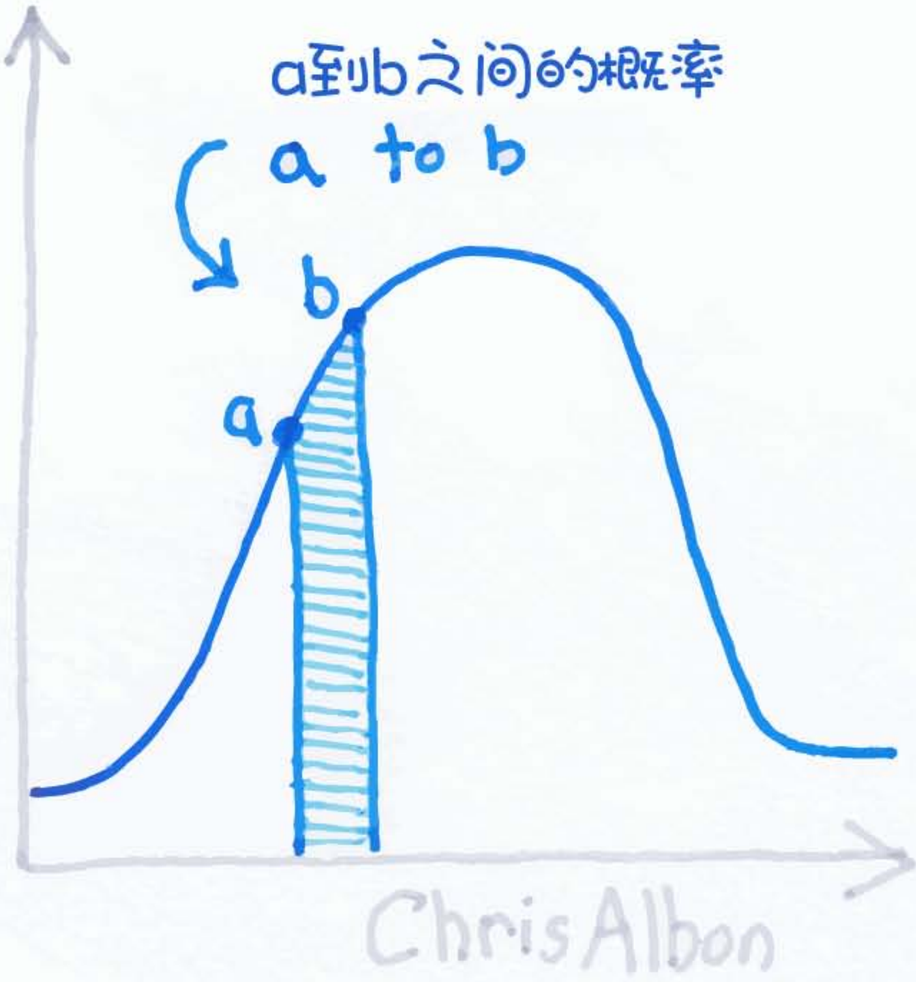

概率质量函数

probability mass function

离散随机变量的概率分布。

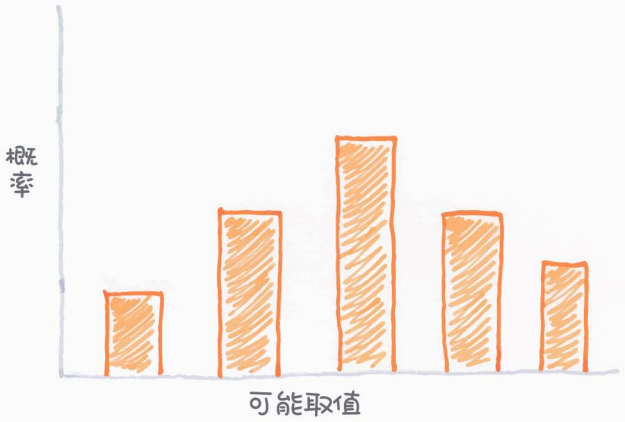

ChrisAlbon

R^2

R^2 观察目标向量中有多少方差由特征向量解释

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

TRUE y — PREDICTED y — 预测方差 VS. 真值y

TRUE y — MEAN TRUE y — 方差在目标向量

BY CHRIS ALBON

基于半径的最近邻分类器

radius-based nearest neighbor classifier

对k临近值的一种替代，其中最近邻是由超参半径决定的。

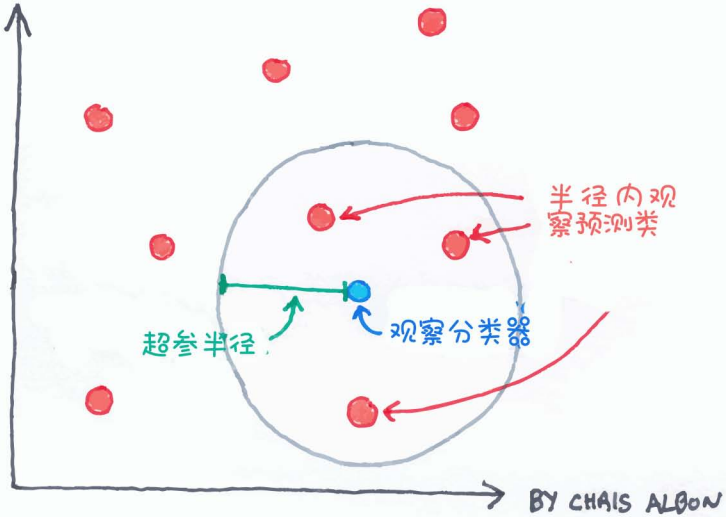

随机森林

random for forest

1.很多树是用特征变量和引导数据的随机子集创建的。

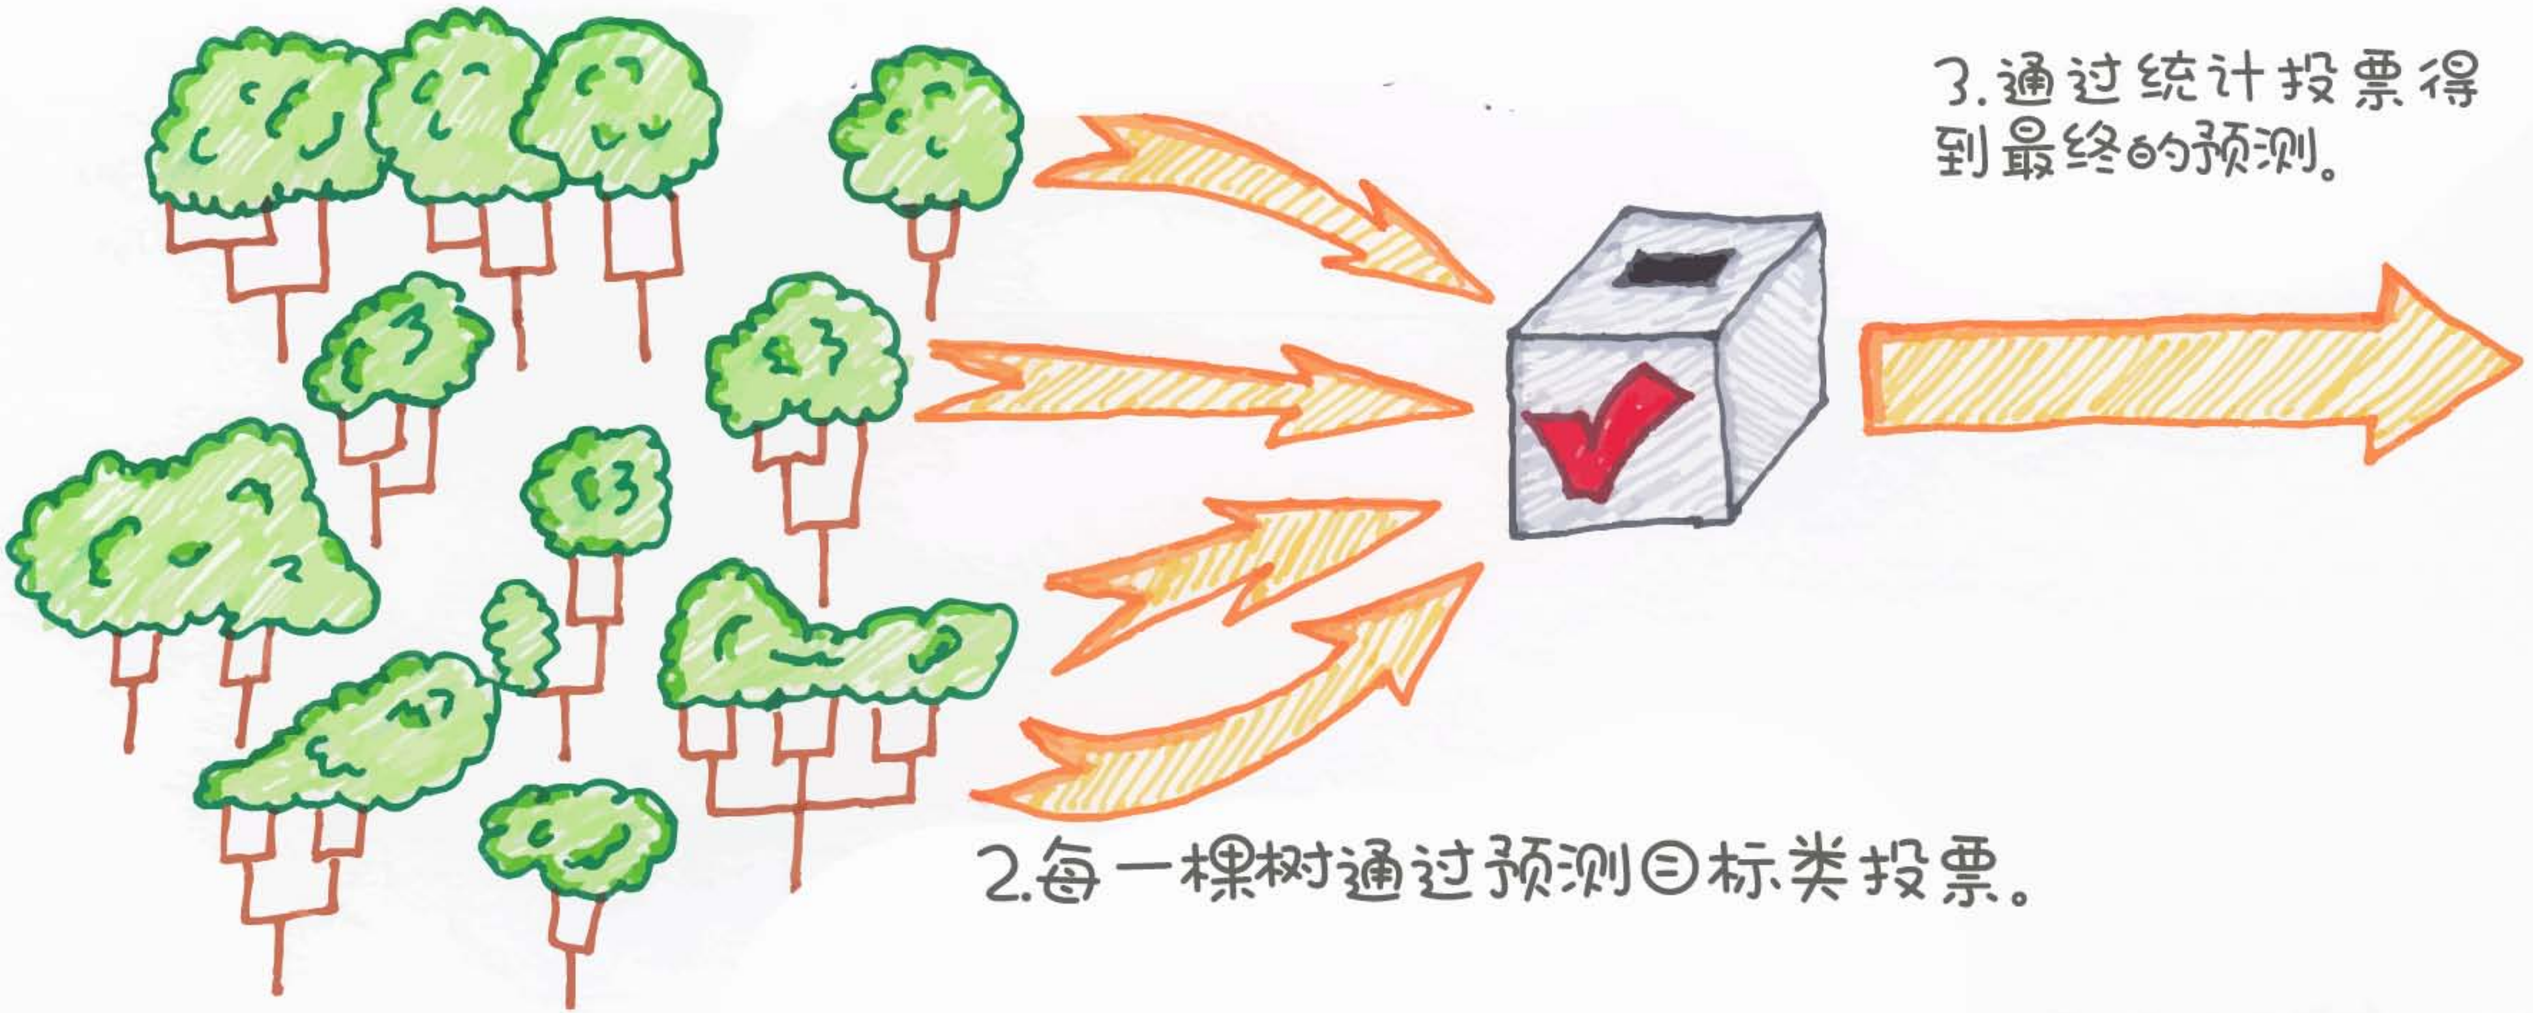

2.每一棵树通过预测目标类投票。

3.通过统计投票得到最终的预测。

CHRIS ALBON

随机变量

RANDOM VARIABLE

任意一个可随机取值的变量。

一个随机变量可取的值由一个概率分布决定。

例如，掷骰子的结果就是一个随机变量。

Chris Albon

随机搜索

RANDOMIZED SEARCH

在候选超参数数值分布（例如正态分布、均匀分布等）中随机选择的一种模型选择策略。和网格搜索相比，随机搜索的计算效率更高。我们可以指定组合的数目来进行测试。

ChrisAlbon

召回率

Recall

召回率是关于正类的。

$$\frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

TP/(TP+FN)

召回率是关于（预测为正确的实例中）真正正确（的实例比例）的

。

召回率是用于度量分类器发现真正正确实例的能力。如果我们想要确保发现所有真正正确的实例，我们需要最大化召回率。

Chris Albon

标量

scalars

单个数字例如”4”或者”4.02”。通常在数据符号中用小写变量名字表示。

Chris Albon

主成分分析（PCA）的成分选择

Selecting Number Of Components In PCA

投影误差平方和均值

$$\frac{\frac{1}{m}\sum_{i=1}^{m}\left\| x_i - x_{i\,approx} \right\|^2}{\frac{1}{m}\sum_{i=1}^{m}\left\| x_i \right\|^2} = 0.01$$

数据中的总变差

99%的方差存留

0.01至0.05属于正常值

BY CHRIS ALBON

灵敏度

sensitivity

也称为“召回率”

所有被正确预测为正例的样本 缩写TP 称为”真正例”。

$$\frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

所有实际为正例的样本 TP+FN（FN称为”假反例”）

Chris Albon

S型激活函数

sigmoid activation function

在二分类任务中经常被用作输出单元。

返回一个0到1的数值

$$\phi(x) = \frac{1}{1+e^{-x}}$$

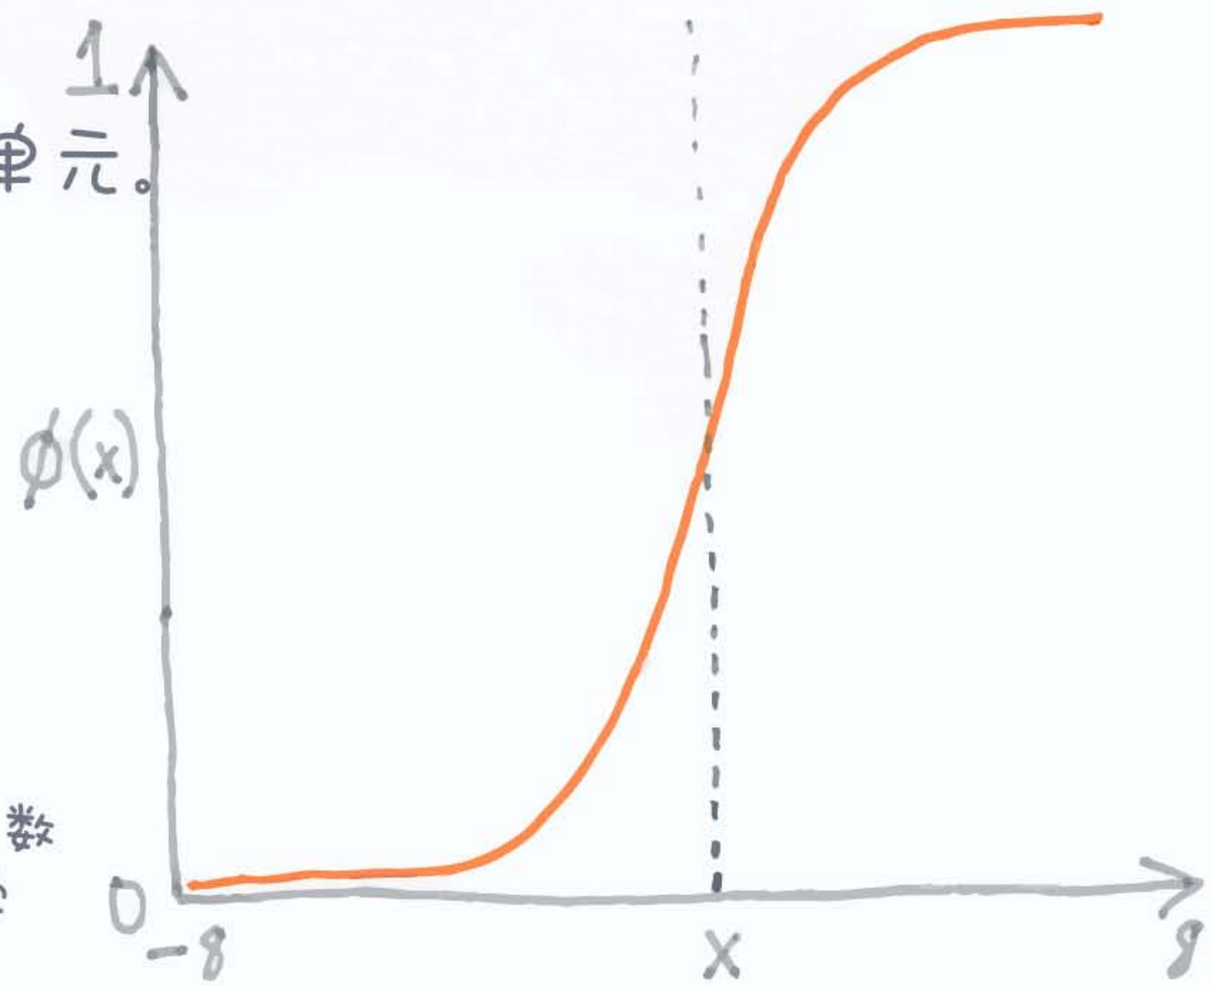

*译者注:

sigmoid函数存在易梯度消失的可能，它的导数在两端较大范围的定义域内梯度为0，造成学习停止。

轮廓系数

Silhouette Coefficient

样本到同簇其他样本的平均距离

$$S_c = \frac{1}{n}\sum_{i=1}^{n}\frac{b_i - a_i}{\max(a_i, b_i)}$$

样本数

样本到最近的某簇的所有样本的平均距离

系数值在-1到1之间，越接近1表示聚类的效果越好

Chris Albon

辛普森悖论

Simpson's Paradox

这个现象解释如下：当变量分组进行比较时，某一趋势被观察到，但当变量组合到一起时，另一种不同的趋势会被观察到。

*译者注：

在某个条件下的两组数据，分别讨论时都会满足某种性质，可是一旦合并考虑，却可能导致相反的结论。

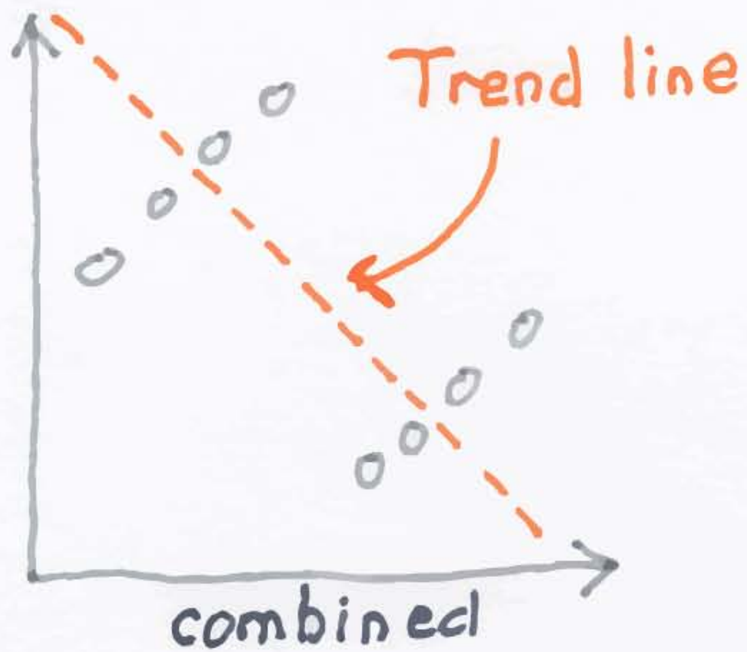

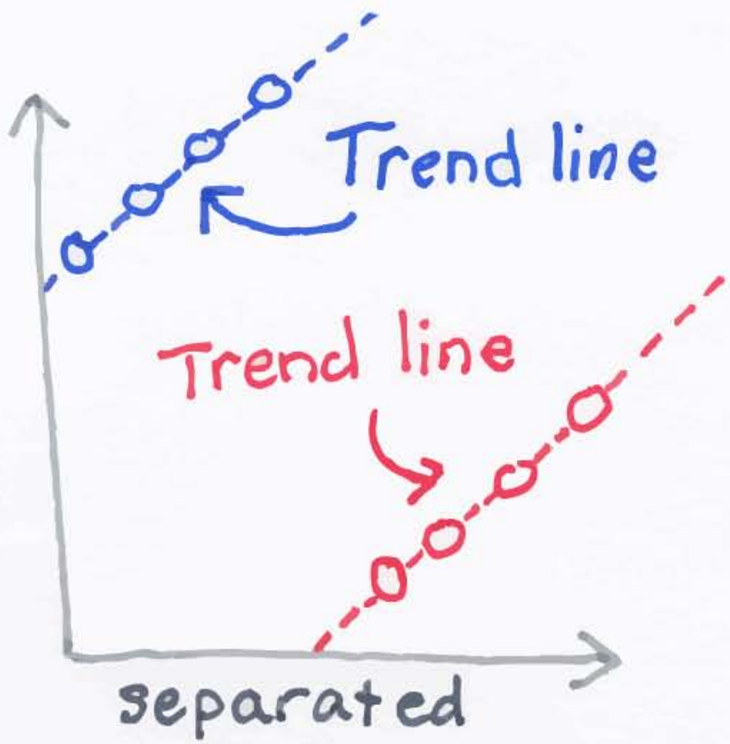

Chris Albon

软间隔SVM中的松弛变量

slack variable in soft-margin svm

$\xi_i = 0$, 被正确分类的样本

$0 < \xi_i < 1$, 在间隔边界中的样本

$\xi \geq 1$, 被误分类的样本

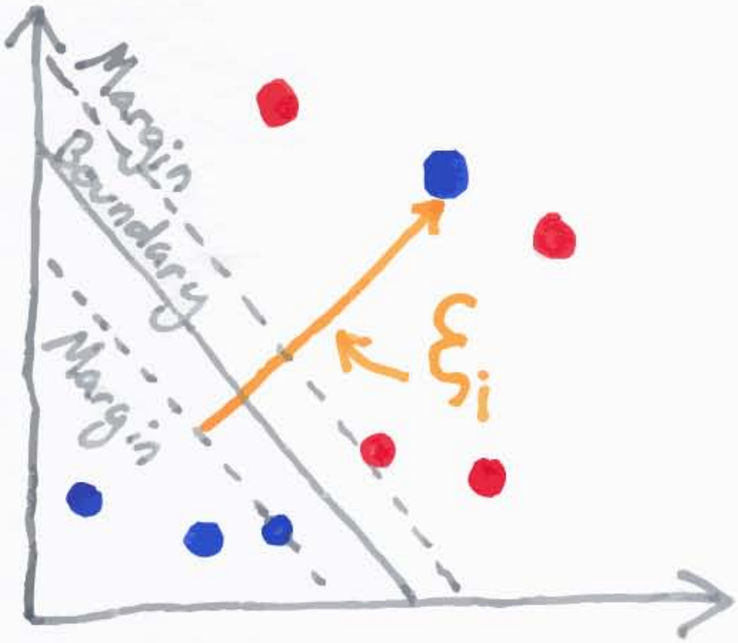

softmax激活函数

softmax normalization

在多分类任务中经常被用作输出单元。和sigmod一样，输出的值范围在0到1之间。应用范围更广，可对多标签的样本进行分类。

*译者注:

指数函数是一个急剧增加的函数，它会增加向量元素间的差异。它能很快地产生数值较大的值。接着，你标准化向量，最大的元素会逼近1，其他元素会趋向0。这也是为什么称为softmax而不是hardmax的原因了，并不是直接去取最大值。

$$\mathrm{Softmax}(z)_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

z_i：类i的输入

$\sum_j e^{z_j}$：对所有类别的输入和

Chris Albon

softmax归一化

softmax normalization

在不去除异常值的情况下减少它们的影响

$$X_i' = \frac{1}{1 + e^{-(x_i - \bar{x})/\sigma}}$$

归一化值

具体数值

欧拉数

平均值

标准差

BY CHRIS ALBON

softplus函数

输入

$$\log\left(1+e^{x}\right)$$

*译者注:
它的导数就是sigmoid函数。softplus的函数图像和ReLU有些类似。

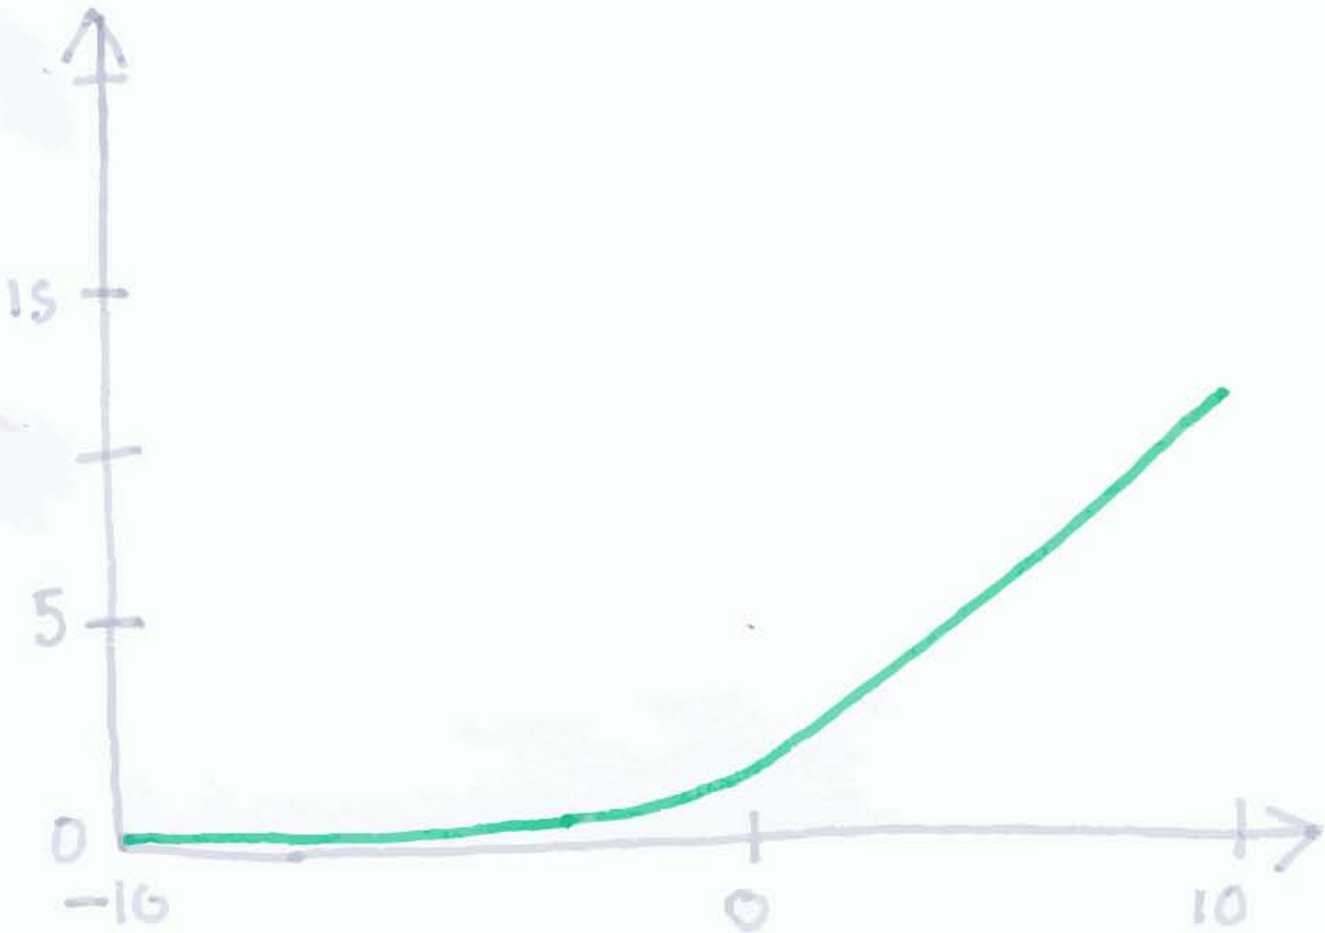

ChrisAlbon

ROC曲线

receiver operating characteristic

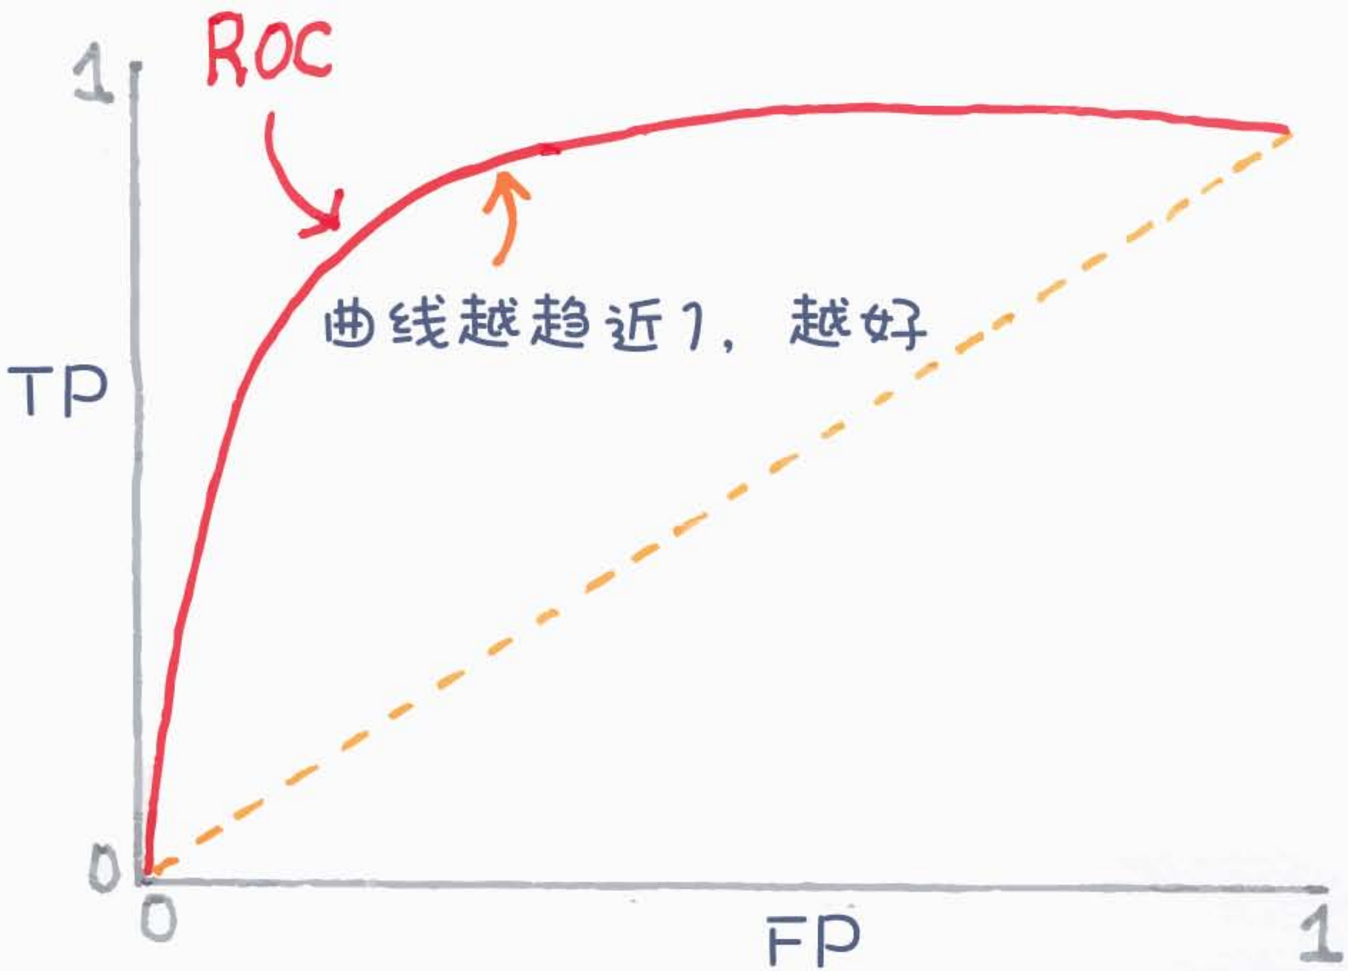

给出了一个二元分类器的每个概率阈值的真阳率和假阳率

Chris Albon

回归
Regression

回归通过训练模型来预测定量的目标。下图是关于房价的例子。

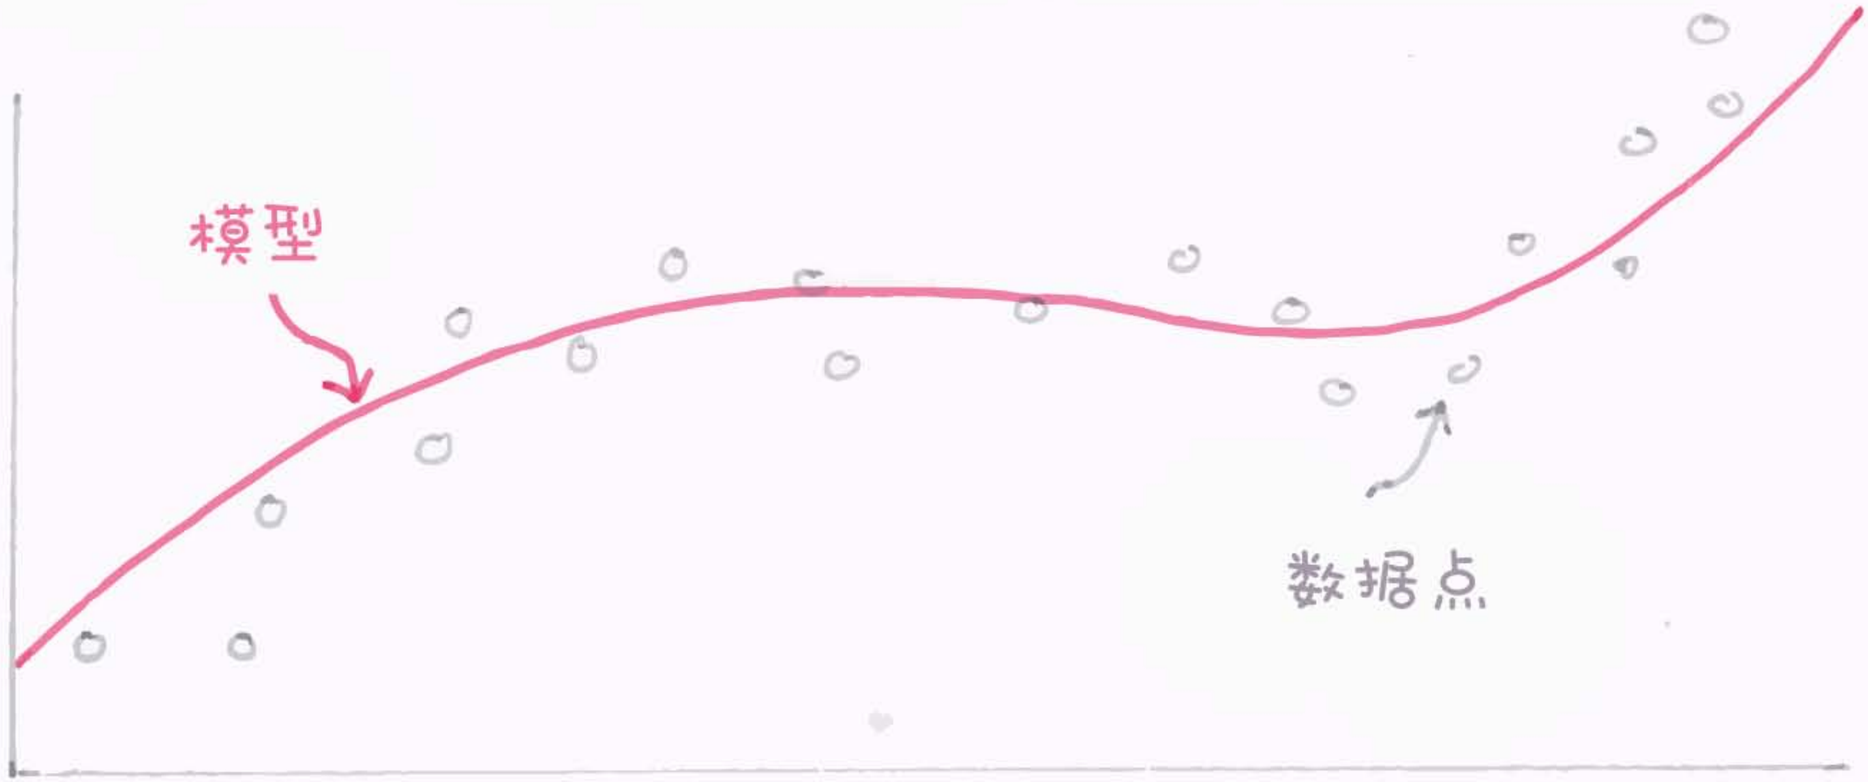

ChrisAlbon

正则化

Regularization

通过改变学习算法来提升泛化能力的一系列工具，也可以提升模型在测试集上的表现。

举个栗子

—权值衰减

—暂时丢弃

—岭回归

—拉索回归

Chris Albon

ReLU激活函数

ReLU Activation Function

修正线性单元

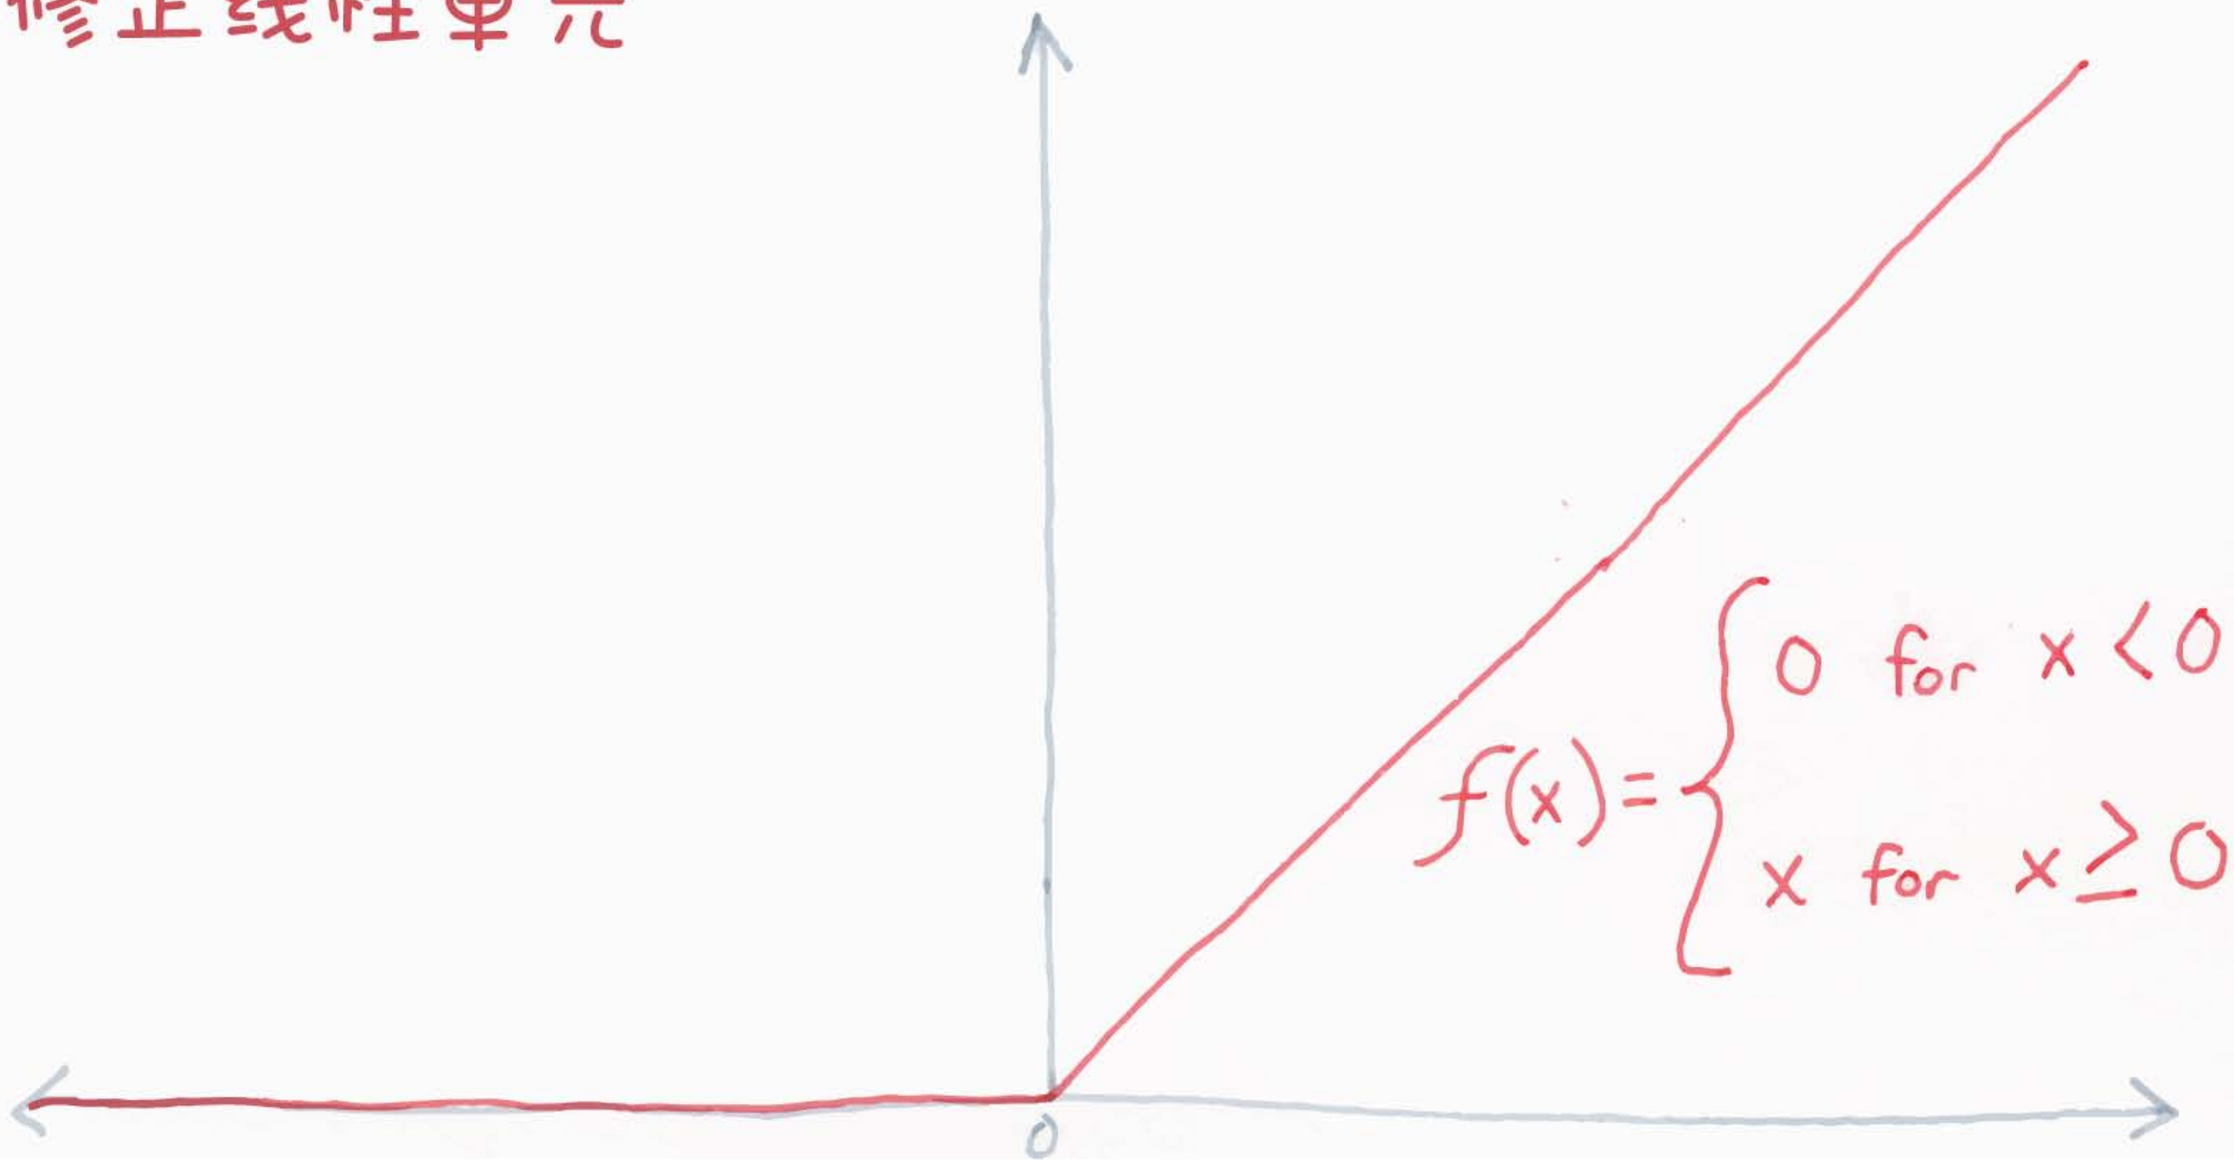

BY CHRIS ALBON

残差平方和

Residual Sum Of Squares

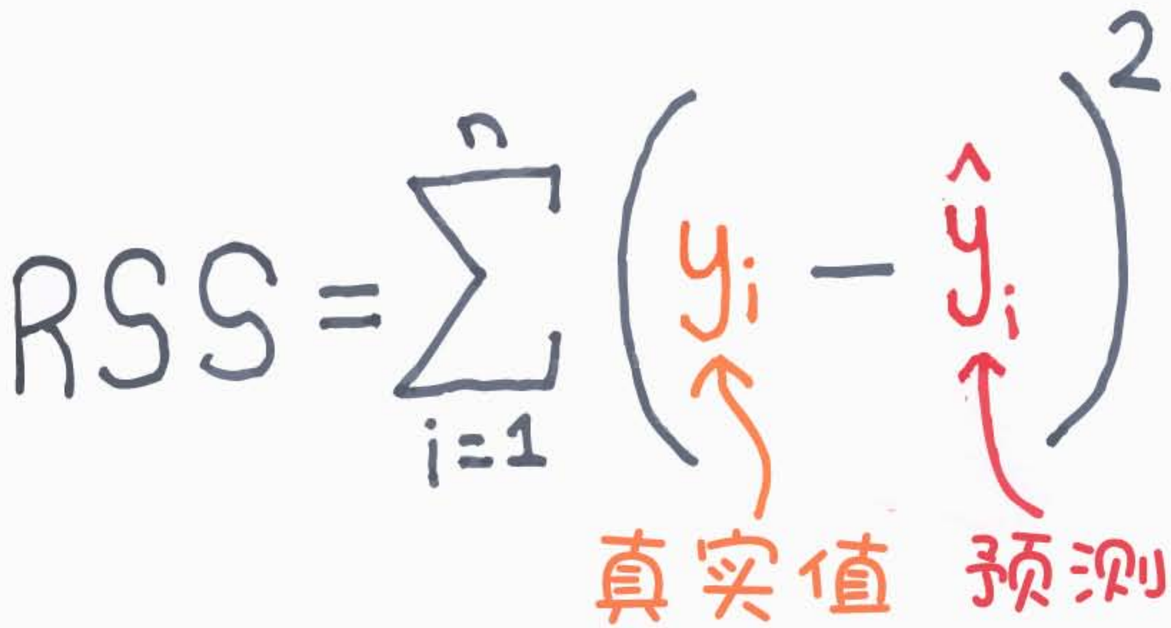

将误差进行平方将会赋予较大的误差以更大的权重，给小误差更小的权重，尽管误差加和是相等的。

Chris Albon

岭回归

Ridge Regression

残差平方和

$$RSS + \lambda \sum_{j=1}^{p} \hat{B}_j^2$$

λ：调节参数

$\hat{B}_j^2$：参数的平方

特征缩减

缺点：参数不能为0.（lasso回归参数可以压缩为0）

*作者注：

注：要记得先将数据标准化。

Chris Albon

鞍点
Saddle Point

在一个方向是极大值，另一个方向是极小值的点。

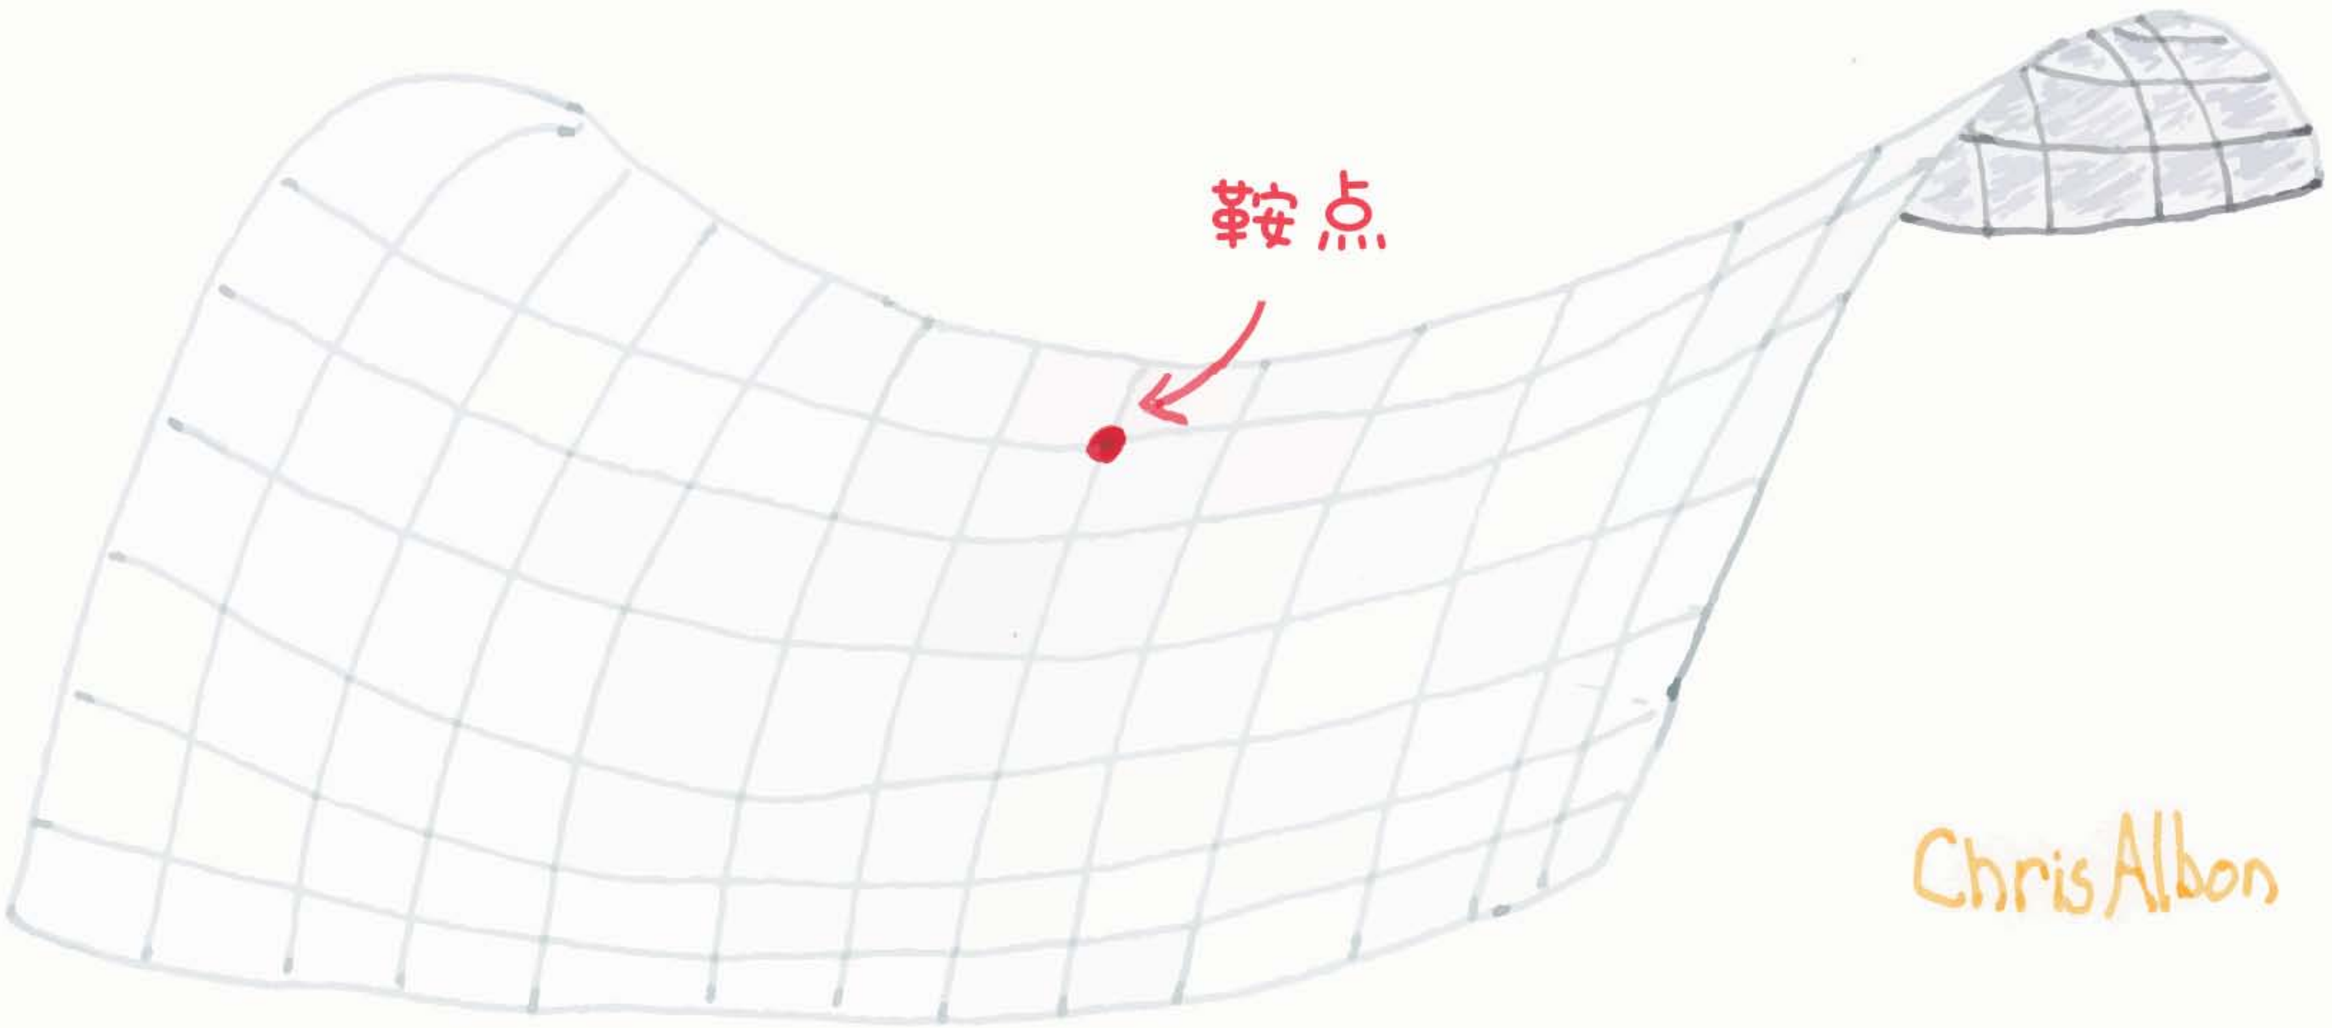

Chris Albon

损失函数的饱和

Saturation Of The Loss Function

饱和指的是一个函数的输出对输入已经非常不敏感的时候。

在处于高饱和度的阶段，损失函数的梯度很小并且在模型的训练过程中不再那么有用了。

Chris Albon

饱和
Saturation

当一个函数在输入之后的结果变化微乎其微的状态。例如：Sigmoid函数

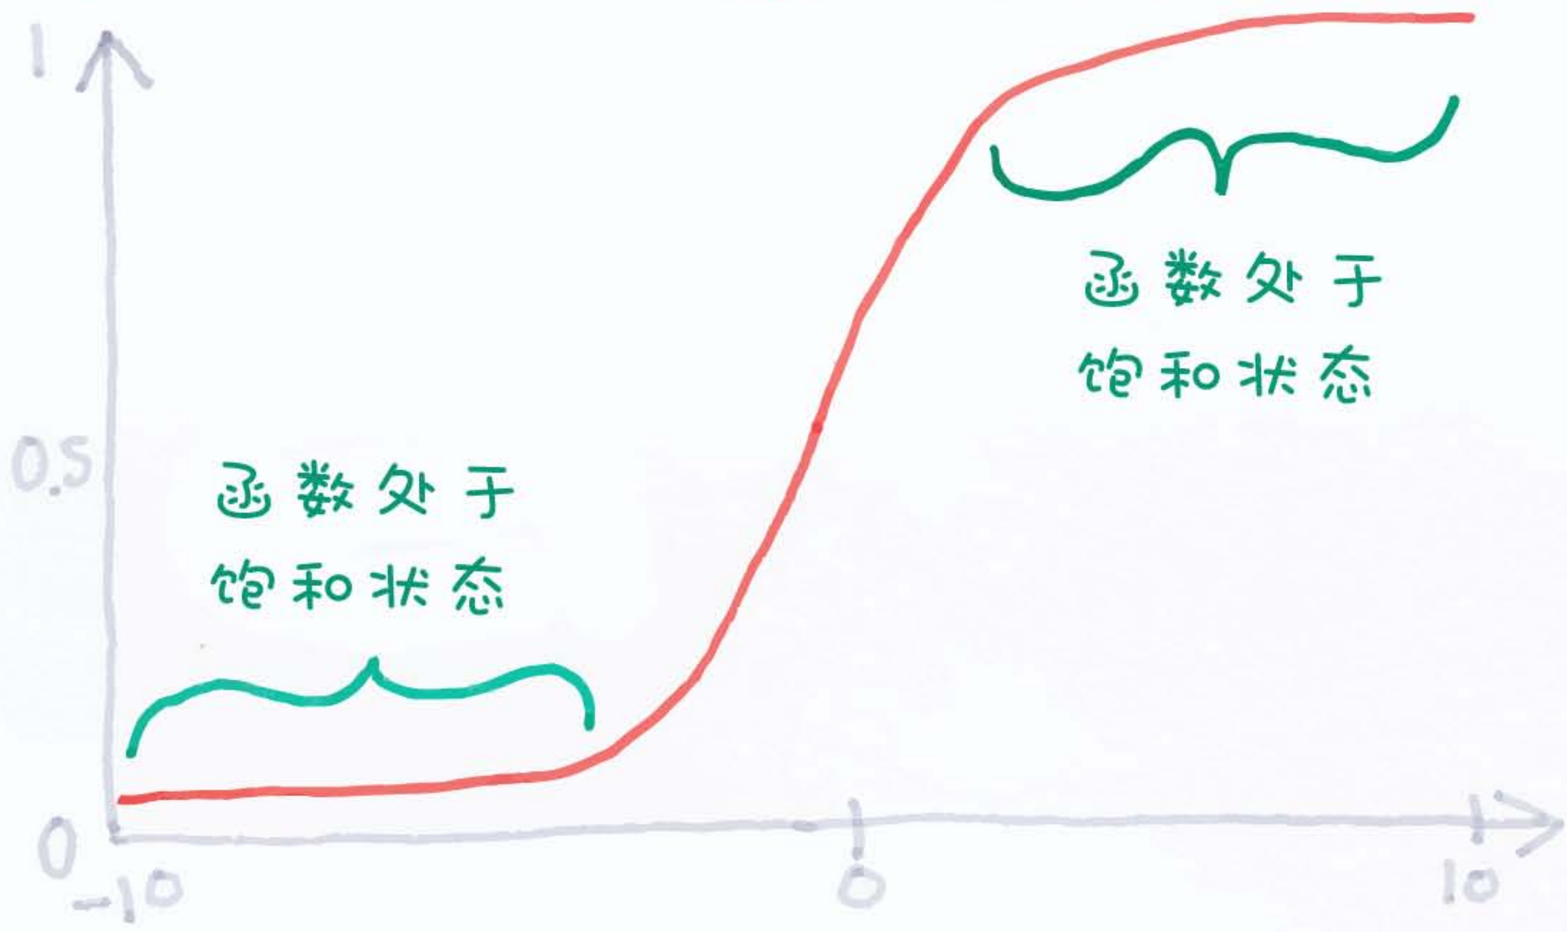

Chris Albon

均匀分布

uniform distribution

某个取值

$$Pr(x = x_i) = \frac{1}{n}$$

随机变量

随机变量可能取值的总个数

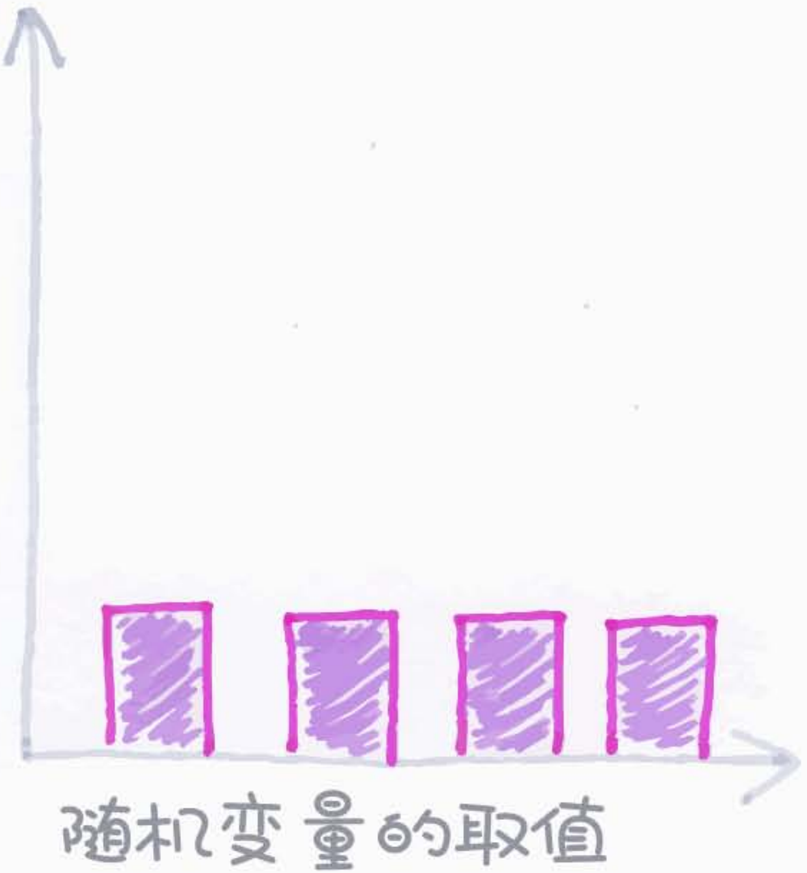

Chris Albon

单位阶跃激活函数

unit-step actication function

译者注：

单位阶跃函数目前有三种定义，共同之处是自变量取值大于0时，函数值为1；自变量取值小于0时，函数值为0，不同之处是，自变量为0时函数值各不相同。

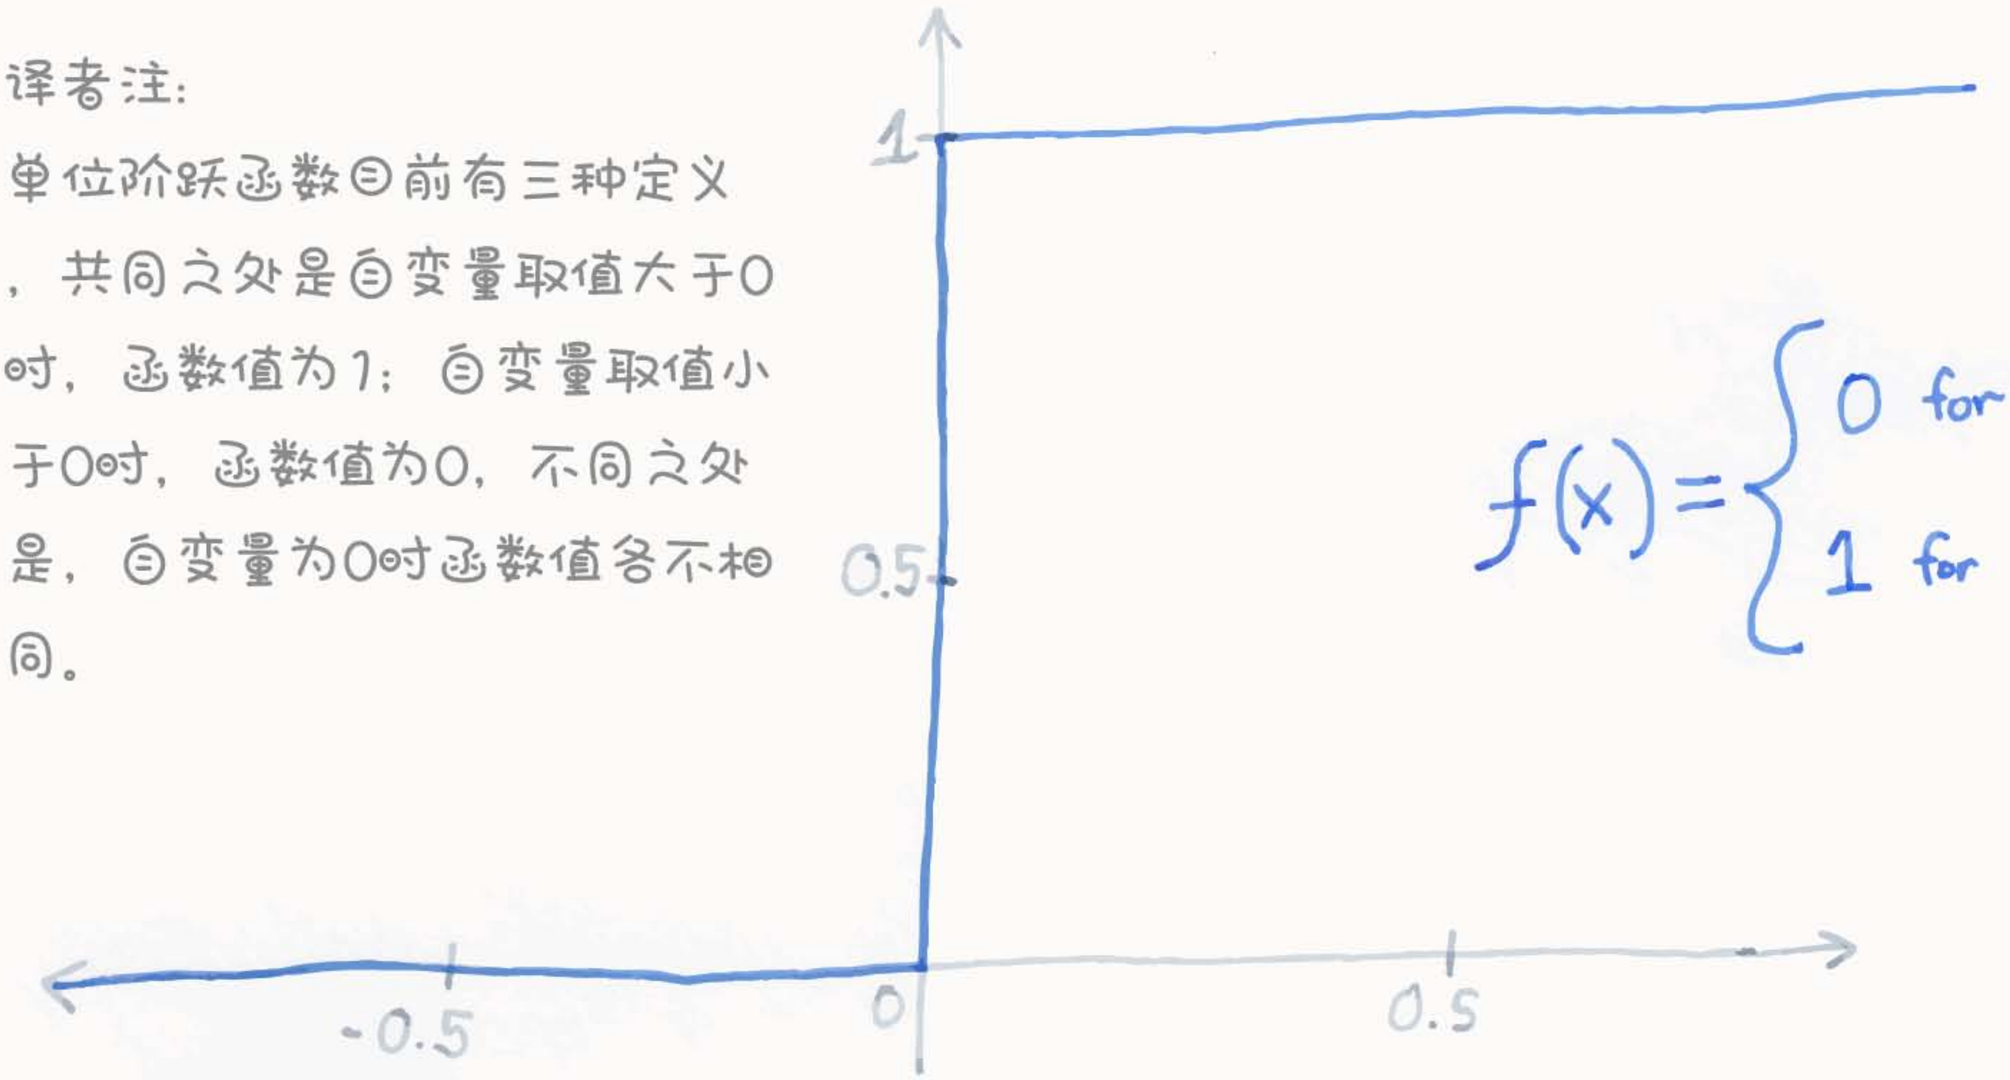

$$f(x)=\begin{cases}0 \text{ for } x<0\\ 1 \text{ for } x\geq 0\end{cases}$$

BY CHRIS ALBON

上采样

Upsampling

上采样是一种通过不断从小类中重复放回抽样，使之与大类样本大小一致，从而解决类不平衡的方法。

ChrisAlbon

验证曲线
Validation Curve

验证曲线将某超参数不同值下的模型性能度量可视化。

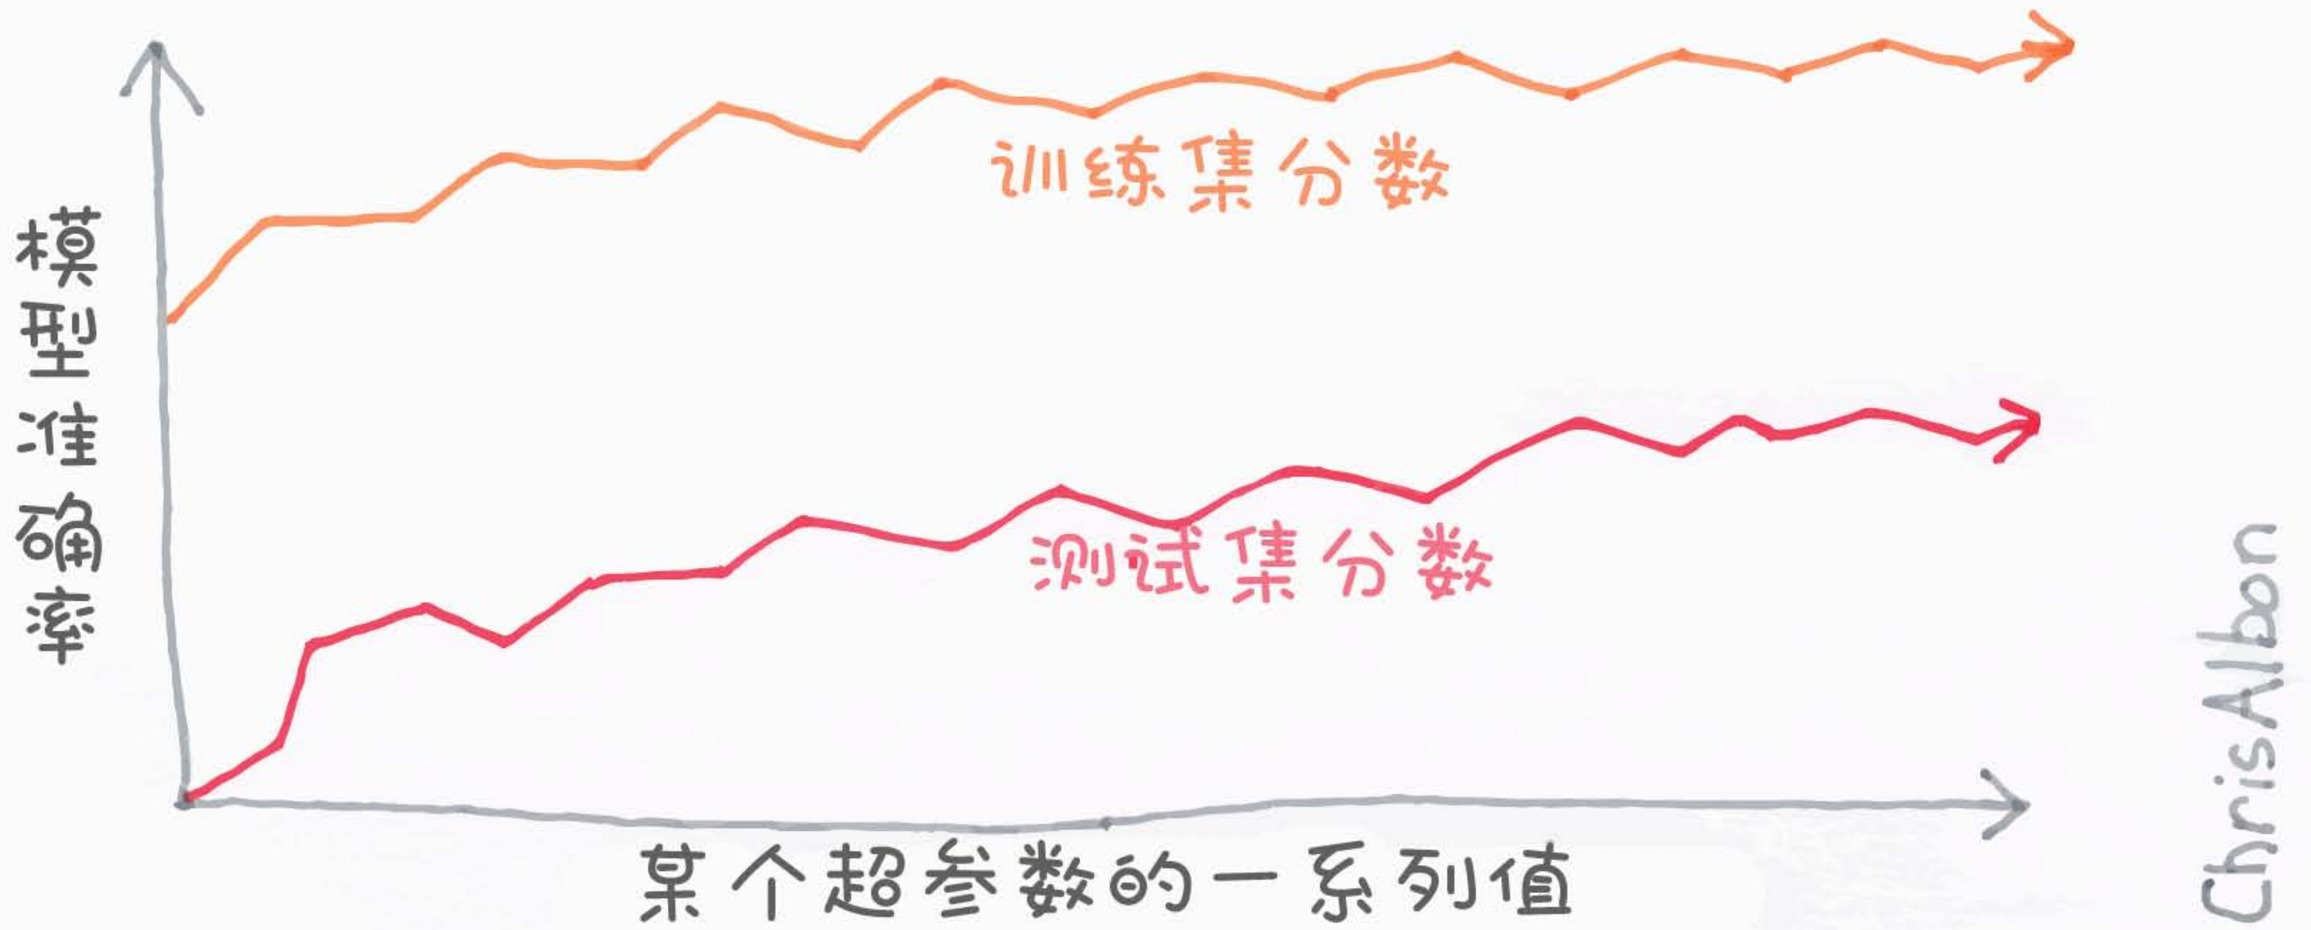

“消失”的梯度

Vanishing Gradient Problem

指损失函数中有关网络前几层的参数的梯度变得很小很小很小。这将使模型的学习速度变得很慢，而且很多梯度已经小到对模型学习没什么用了，故而最终导致模型表现不怎么好。

Chris Albon

方差膨胀因子

variance inflation factor

方差膨胀因子用于衡量特征之间的共线性所带来的影响，尤其是当特征相关时，模型参数方差的增量。

为了计算VIF，将特征视为模型目标，接着运行模型并计算R2。（注：Ri为自变量xi对其余自变量作回归分析的复相关系数。），则有：如果VIF=1，则无关；若VIF>3，则相关。

如果VIF=1，则变量无相互关系；若VIF大于3，则有相互关系。

$$R^2:\ VIF_i = \frac{1}{1-R_i^2}$$

ChrisAlbon

方差
Variance

$$Var\left[\hat{f}(x)\right] = E\left[\hat{f}(x)^2\right] - E\left[\hat{f}(x)\right]^2$$

方差表示的是当时用不同的训练数据集时，预测值将可能改变的量。它代表模型的“灵活度”，需要和偏差达到平衡。

BY CHRIS ALBON

特征选择的方差阈值法

Variance Thresholding For Feature Selection

— 受低方差特征包含较少信息的想法启发

— 计算每个特征的方差，然后去掉方差小于某一阈值的特征。

— 确保特征具有相同的尺度

Chris Albon

向量
vectors

向量是一组有序的数字（标量），可以被认为是同时具有数据意义和几何意义。

数据意义：

标量

$$X = [x_1\ x_2 \cdots\ x_n]$$

第N个元素

$$X = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

几何意义：

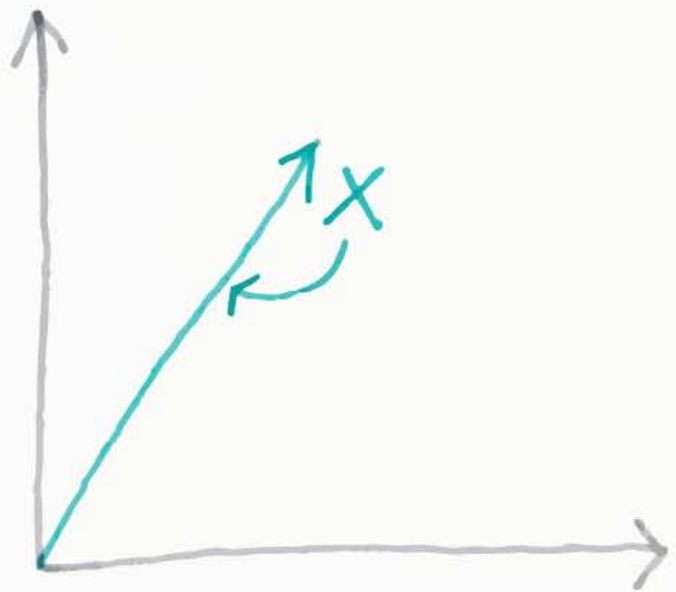

BY CHRIS ALBON

RSS 可视化

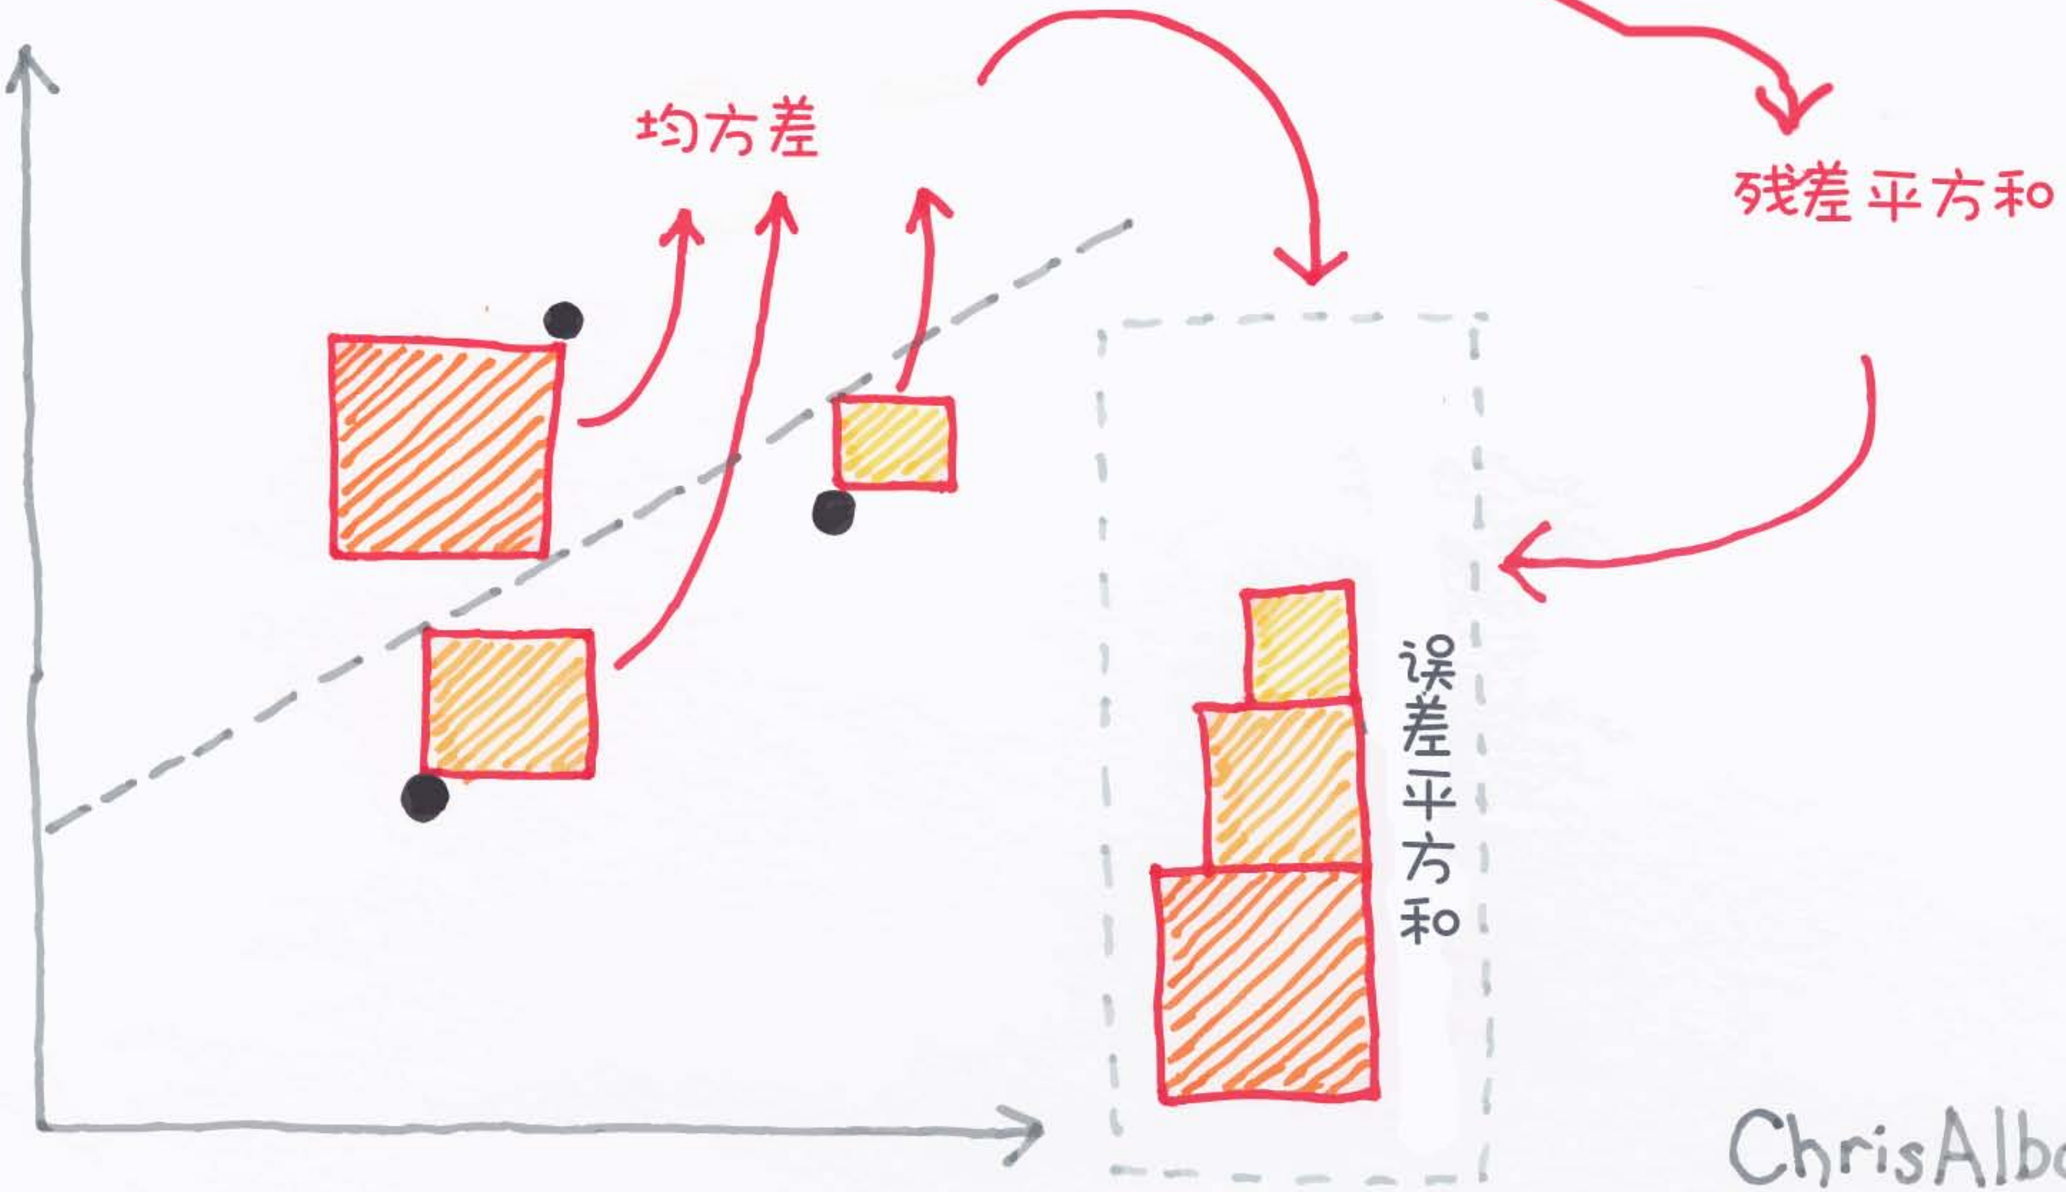

ChrisAlbon

最大最小值缩放

MIN MAX scaling

将特征值变换到区间[0,1]中

$$X_i' = \frac{X_i - \min(x)}{\max(x) - \min(x)}$$

变换后的值 X_i'

原数据 X_i

特征中的最小值 $\min(x)$

特征中的最大值 $\max(x)$

ChrisAlbon

随机缺失

MAR MISSING AT RANDOM

一类缺失值，这种缺失值的缺失概率不是完全随机的，而是依赖于在其他特征中获得的信息。

例如，男人在调查中不太会回答薪资问题，但是我们在其他问题中捕捉到了性别特征。

Chris Albon

完全随机迷失

Missing Completely At Random

一种缺失数据，这种缺失数据的概率是
独立于其他所有事物的

例如：缺失值是由掷骰决定的。

Chris Albon

不完全随机缺失

Missing Not At Random

一种缺失的数据类型，即缺失的概率不是随机的，依赖于没有在其他特征中获得的信息。

例如：男性不太可能在一项调查中回答薪资问题，但我们没有在另一项特征中捕捉性别认同。

Chris Albon

模型复杂度

model complexity

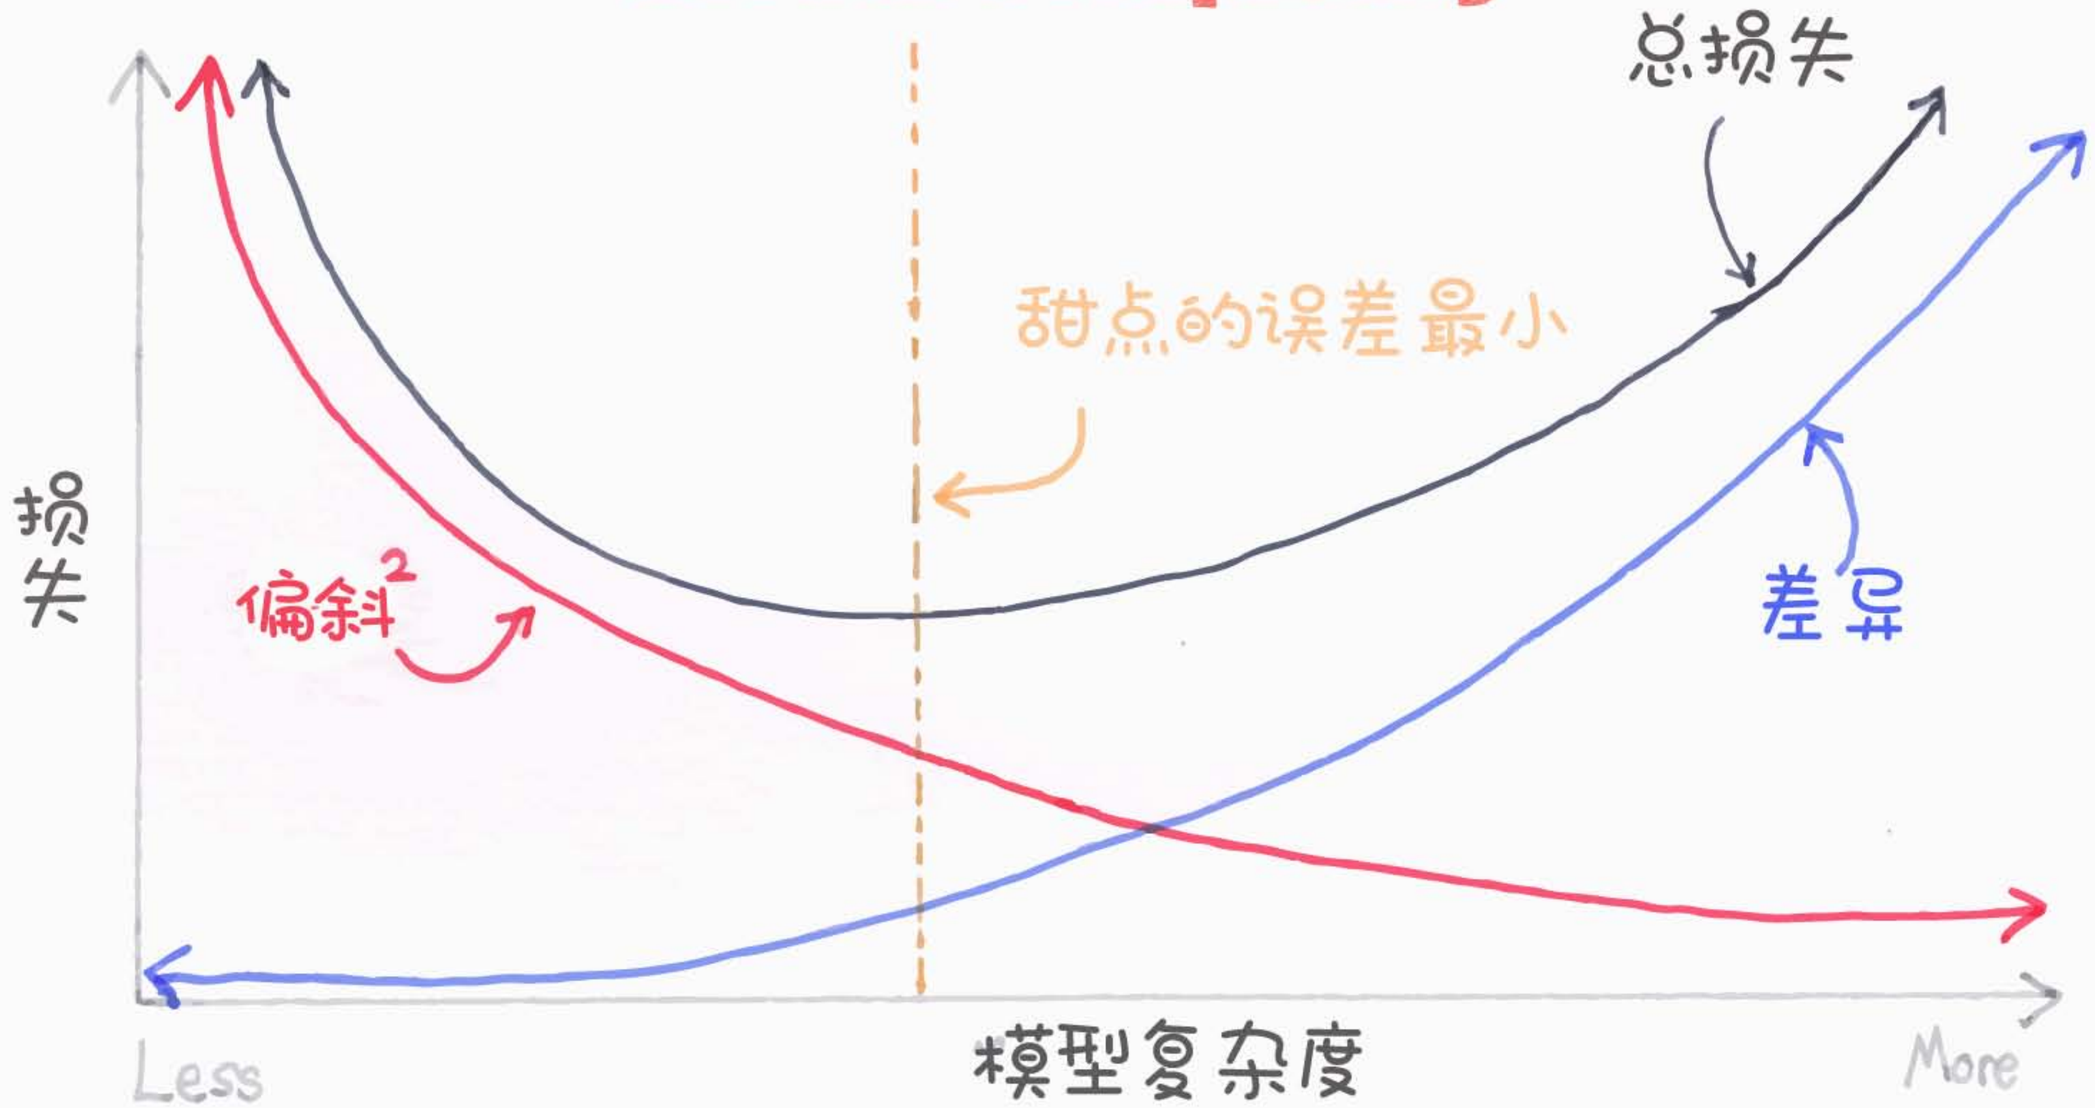

ChrisAlbon

模型可识别度

Model Identifiability

如果可以使用数据找到一组最佳的参数，啧该模型是可以识别的

Chris Albon

选择模型

Model Selection

寻找到了最优模型的机器学习算法及其超参数值。

Chris Albon

动量
Momentum

动量使用之前的梯度来影响优化器的运动，常用于随机梯度下降。

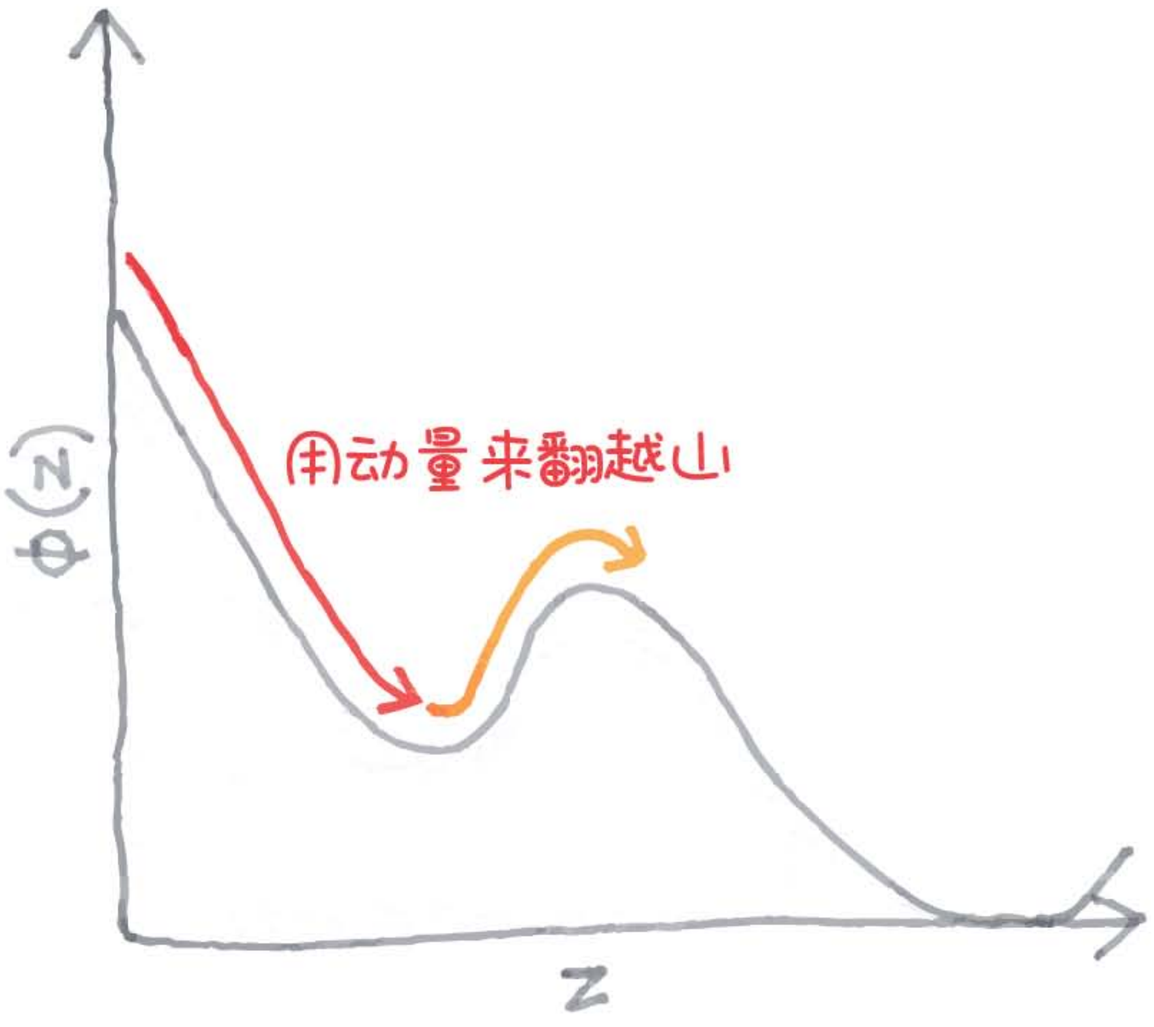

Chris Albon

深层网络的动机

motivation for deep layers

假设，有一层的前馈神经网络对任何事物都足够好，然而，这一层可能是非常大的，深层网络的动机是其可以使用可管理的单位数量来产生于浅层网络同样的效果

Chris Albon

深度学习的动机

Motivation for deep learning

浅层学习算法，如支持向量机，可以再有结构化特性数据时发挥作用。然而，他们在高维空间中经常表现不佳如发现在计算机视觉和机器翻译。

ChrisAlbon

多元逻辑回归

multinomial logistic regression

对逻辑回归的扩展，处理多分类问题

用一个softmax函数代替logistic函数

$$P(y_i = k \mid X) = \frac{e^{\beta_k x_i}}{\sum_{j=1}^{K} e^{\beta_j x_i}}$$

y_i：目标值　k：第K类　X：特征矩阵　e：欧拉数

ChrisAlbon

自然对数
natural log

$$\ln(e^{x}) = x$$

欧拉数

2.71828...

BY CHRIS ALBON

神经元

neuron

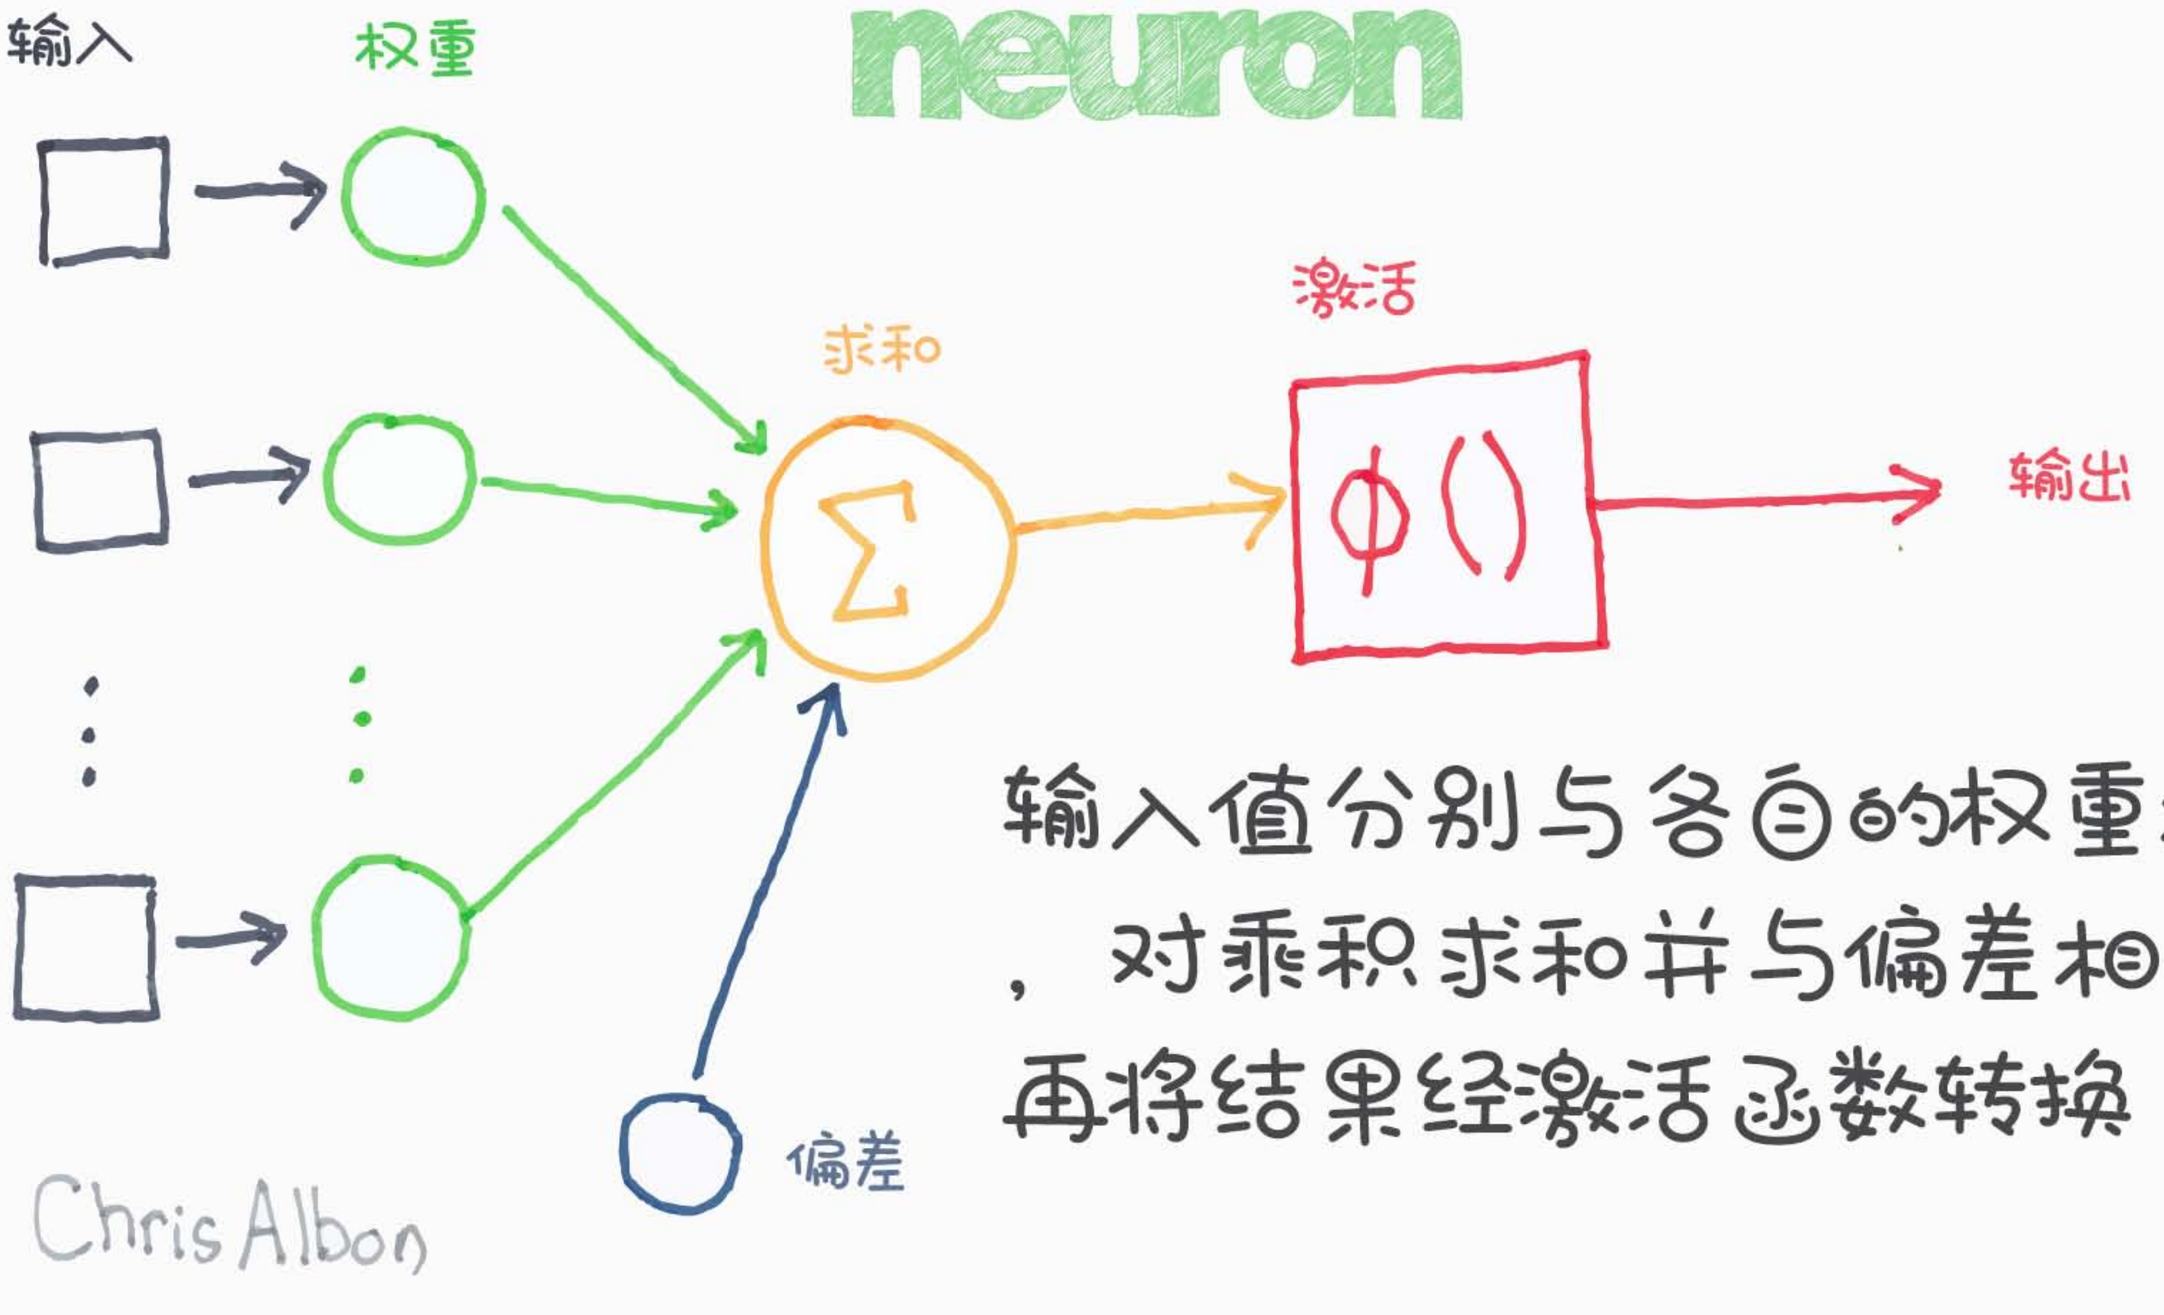

输入值分别与各自的权重相乘，对乘积求和并与偏差相加，再将结果经激活函数转换

没有免费的午餐定理（NFL）

想象一下，每一种可能的潜在的数据生成分布，

想象一下，我们在这些分布上训练所有机器学习算法，平均来说，每个算法都有相同的测试误差。

直观理解：不存在“最佳”的机器学习算法。

*译者注：
NFL定理表明没有一个学习算法可以在任何领域总是产生最准确的学习器。不管采用何种学习算法，至少存在一个目标函数，能够使得随机猜测算法是更好的算法。

Chris Albon

噪声修正线性单元

Noisy RELU

和修正线性单元（ReLU）相似，但添加了高斯噪声

输入

$$\phi(z) = \max(0, z + N)$$

正态分布中的取值

$$N(0, \sigma(z))$$

Chris Albon

非参数方法

Non-parametric Methods

非参数方法不假定特征值和目标值之间的关系的具体形式。

优点： 优点：对特征值和目标值之间可能存在的各种关系，非参数方法都能拟合

缺点： 缺点：通常需要大量的观测值来拟合模型

Chris Albon

正态分布

Normal Distribution

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

某个值 期望 方差

π 方差

欧拉数（自然对数的底）

样本 期望 方差

神经网络参数的标准初始化

Normalized Initialization Of Neural Network Parameters

均匀分布

$$W_{i,j} \sim U\left(-\sqrt{\frac{6}{m+n}}, \sqrt{\frac{6}{m+n}}\right)$$

全连接层的参数

输入的个数

输出的个数

Chris Albon

归一化观测值

Normalizing Observations

改变每个观测值的特征的尺度，使它们具有单位范数。

两个常用的范数是L1范数和L2范数。

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \ldots + x_n^2}$$

L2 范数

标记符号1

$\neg$ Not 非

$\exists$ Such that 使得

$a \in b$ a is an element of b

a属于b

$\therefore$ Therefore 所以

Chris Albon

标记符号2

Because
因为

If and only if
当且仅当

Then
则

There exists
存在

Chris Albon

标记符号3

$\forall$ For all

所有

$\perp$ Orthogonal

垂直

$\parallel$ Parallel

平行

$\propto$ Proportional

正比于

ChrisAlbon

标记符号4

$\sum$ Summation

连加求和

$\prod$ Product

连乘求和

ChrisAlbon

$\lfloor\ \rfloor$ Floor

向下取整

$\lceil\ \rceil$ Ceiling

向上取整

标记符号5

$x|y$

X, given y

$\arg\min f(x)$

在y发生的条件下，X发生

使目标函数f(x)取最小值时x的值

$\max()$

max value

求最大值

ChrisAlbon

概率相关概念

Notions Of Probability

频率：　重复试验中某事件发生的比率

贝叶斯定理：某事件为真的可信度

Chris Albon

奥卡姆剃刀原理

Occams Razor

如果多种假设都可以很好地解释某事，我们更偏好最简单的。

*作者注：这是一种凭直觉写出来的解释，不是奥卡姆剃刀原理的正规定义。

*译者注：原解释：如非必要，勿增实体；
《一拳超人》解释：我秃了，但更强了。

Chris Alban

比值

ODDS

事件发生

$$\frac{Pr(y)}{Pr(\sim y)}$$

事件未发生

比值是事件发生的概率与未发生的概率的比率。

ChrisAlbon

比值比
ODDS RATIO

$$\frac{Pr(X_1)/Pr(\sim X_1)}{Pr(X_2)/Pr(\sim X_2)}$$

事件X1的比值

事件X2的比值

ChrisAlbon

独热编码 One-Hot Encoding

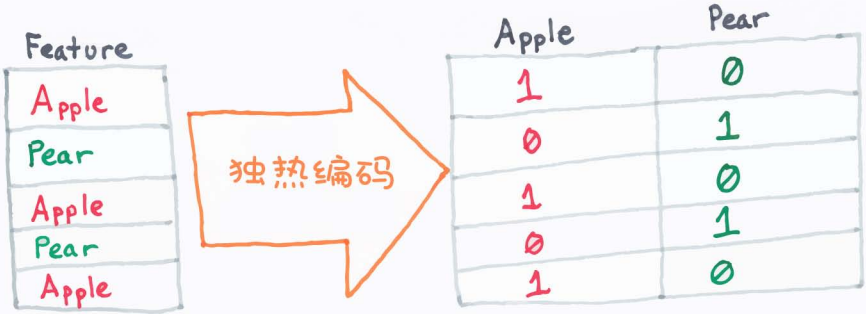

独热编码可以让我们将名义分类数据转化成用数值表示的特征，不过这并没有在数学上说明这些类别之间有次序关系。

ChrisAlbon

单边标签平滑

One-Sided Label Smoothing

—通常数据集是会存在错误的。

—标签平滑可以减少判别器的自信。

—将正例样本的标签从1替换为0.9

—将负例样本的标签从0替换为0.1

ChrisAlbon

“一对其余”逻辑回归

One-Vs-Rest Logistic Regression

· 二元逻辑回归的拓展版，用于解决将因变量分为多个类别的情况

· 对每一级建一个模型，来预测某观察项是否属于这一级。（把它看成一个二元分类器问题）

Chris Albon

最小二乘法

Ordinary Least Squares

- 拟合一个模型，使得残差的平方和最小。

- 最小二乘法是一个简单的方法，但是将其用作基准常常有效

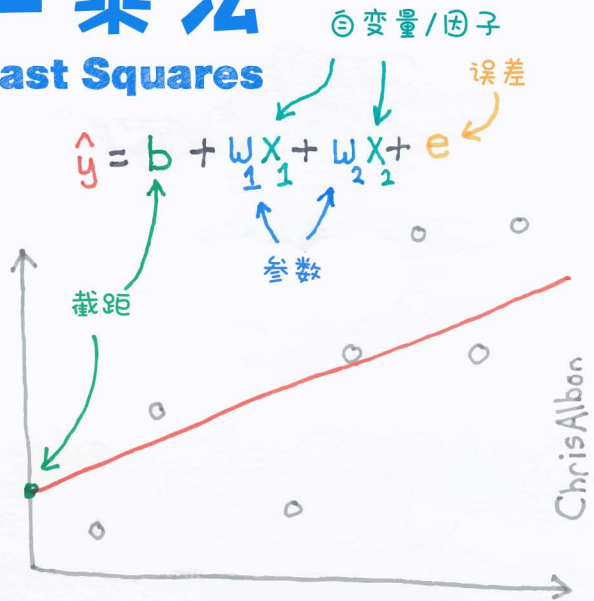

袋外数据误差

Out-of-Bag Error

袋外数据误差可在袋装模型中用于估计测试误差。OOB误差通过所有bootstrap数据集内不包含观测值Xi的树求出，它表示的是所有Xi的平均误差。OOB估计出的错误率和使用与训练集大小一致的测试集所得到的错误率一样精确(Breiman 1996)。

Chris Albon

外核

Out of Core

当数据规模太大，内存容量不足时可采用的一类处理方法。

举几个栗子：
分块预处理数据
按行读取并预处理数据
增量学习
随机学习（译者注：原文为Stocastic此处根据Stochastic翻译）
随即拟合学习法

Chris Albon

异常值
Outlier

Drop: 直接删除异常值不是一个好选择，因为有可能导致大量信息丢失。应当先确认该值是否为极值，并检查异常值检测算法是否合理

Mark: 进行标记是最安全的选择，可以帮助我们确认异常值是否有干扰。

Rescale: 重新调整，即进行取对数以减小异常值带来的干扰。

Chris Albon

过拟合 vs 欠拟合

Overfit vs Underfit

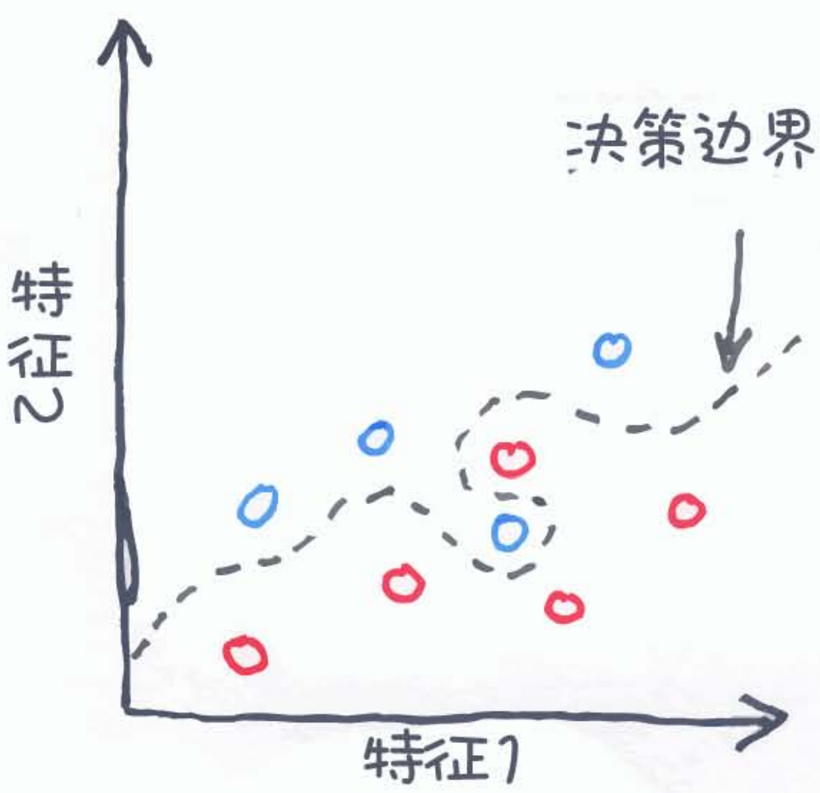

过拟合 方差过大

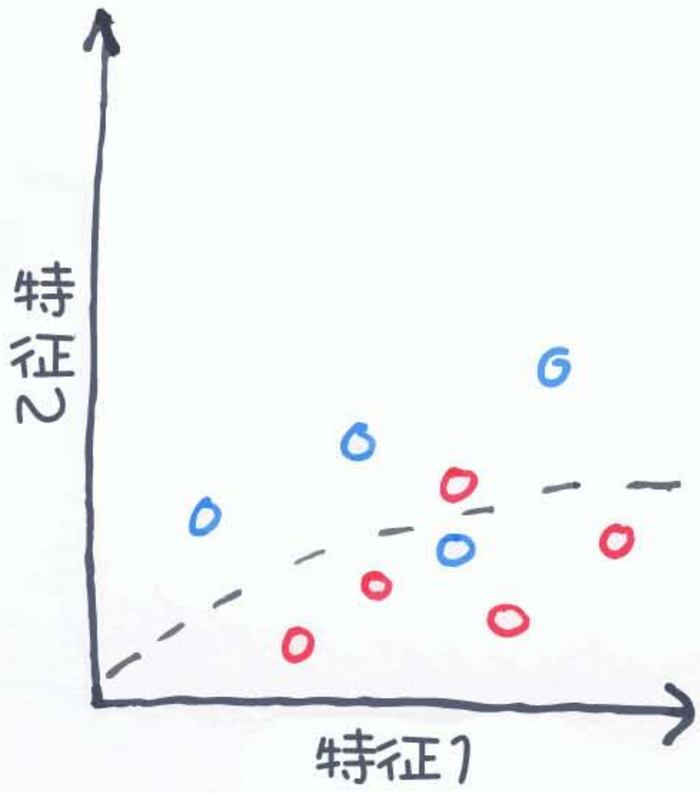

理想情况

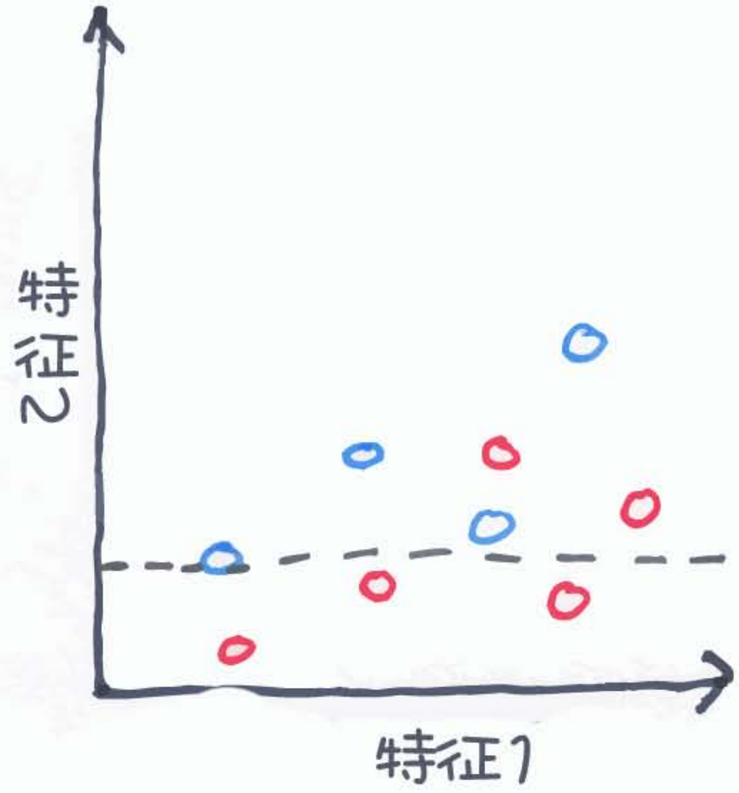

欠拟合 偏差过大

过度拟合 Overfitting

过度拟合是指模型过于彻底地学习训练数据，以致无法一般化推广的现象。

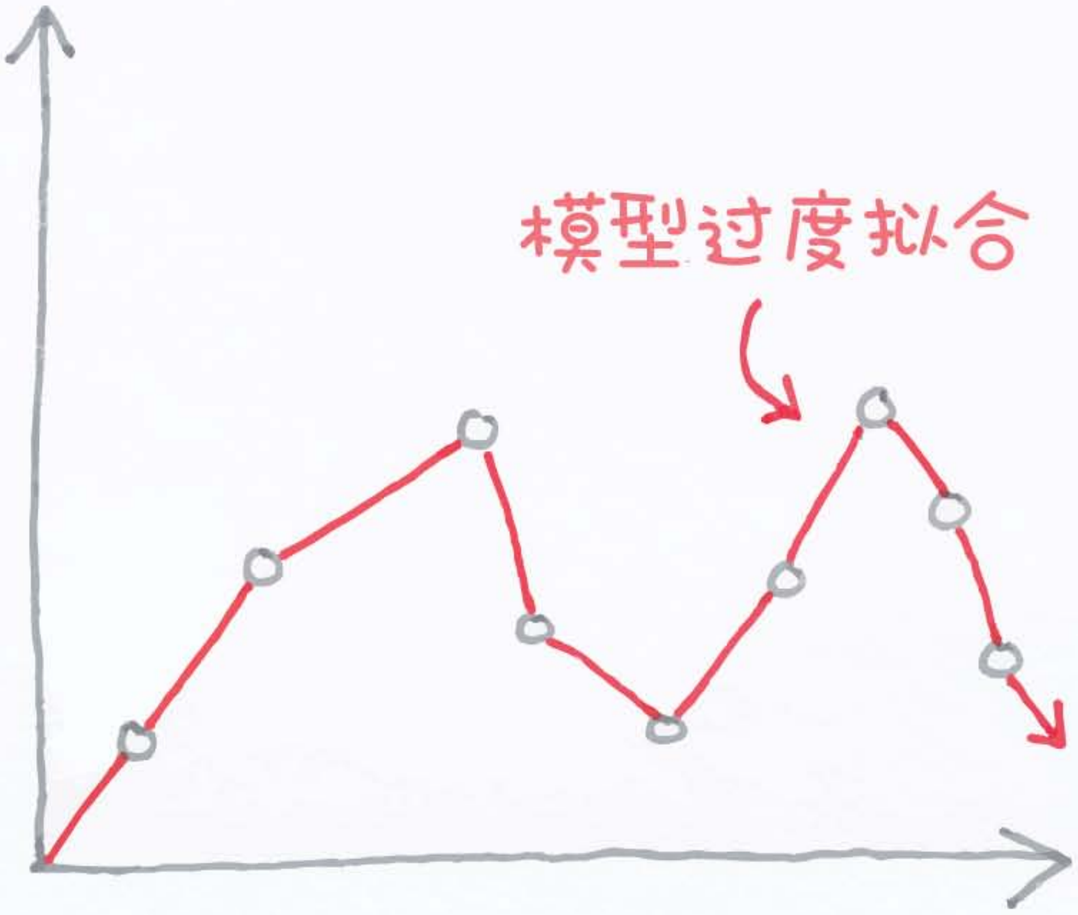

Chris Albon

正则化的参数范数惩罚

parameter norm penalties for regularization

为损失函数添加一个参数范数惩罚:

大多数情况下都不适用于偏置的参数
从技术上讲，每一层都有自己的超参数和/或规范惩罚

Chris Albon

参数共享

parameter sharing

参数共享是指参数在多个模型或者部分模型中被共享。例如，卷积神经网络在图像的不同部位中共享参数，这使得CNN在一个图像的任意位置都可以识别模式以及减少需要存储的参数数量

Chris Albon

参数 VS. 超参数

parameters VS hyperparameters

参数是在训练模型的过程中学习到的，
例如神经网络的权重

在训练开始前设置超参数，可以通过网络搜索以及其他方法进行优化调整。

ChrisAlbon

不确定性的来源

sources of uncertainty

1. 宇宙固有的随机性：例如，量子力学

2. 即使某个现象是确定发生，也没有能力完全观察到它：例如，监测犯罪

3. 没有能力用某一模型完全描述一个现象：例如，预测犯罪的模型都是简化过的

Chris Alban

度（夹角）

span

一个矩阵张成（的线性空间）是用该矩阵向量的线性组合能够表示的所有点的集合。

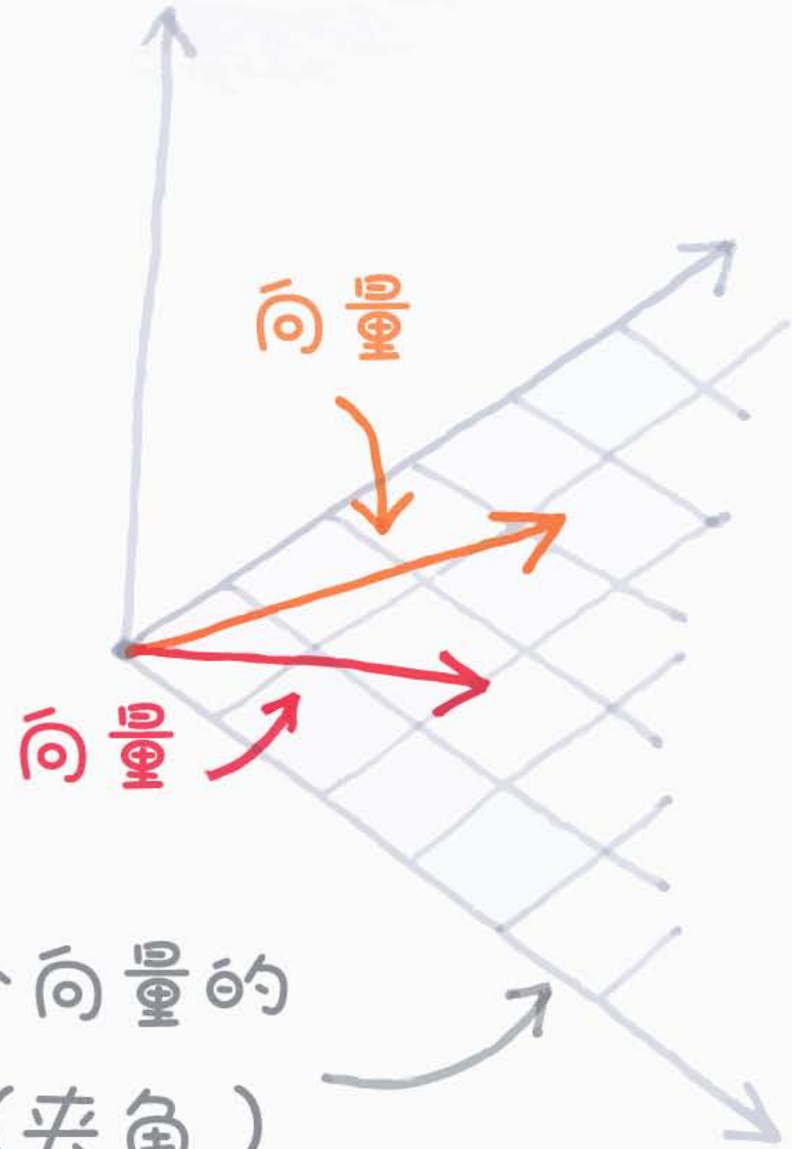

Chris Albon

稀疏性
SPARSITY

矩阵中零元素占的比例。

$$\text{稀疏性} = \frac{\text{零元素的个数}}{\text{矩阵元素的总数}}$$

ChrisAlbon

平方根

主（r次方）根　　平方根

$$\sqrt[r]{x} = x^{\frac{1}{r}}$$

$$\sqrt[2]{x} = x^{\frac{1}{2}}$$

标准差

STANDARD DEVIATION

标准差

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{N}(x_i - \mu)^2}$$

n：总体个数　x_i：观测值　μ：总体均值

样本标准差

$$S = \sqrt{\frac{1}{n-1}\sum_{i=1}^{N}\left(X_i - \bar{X}\right)^2}$$

$n-1$：贝塞尔修正　X_i：观测值　$\bar{X}$：样本均值

BY CHAIS ALBON

均值的标准误

STANDARD ERROR OF THE MEAN

均值的标准误差是样本均值的标准差，可用样本标准差除以观测值个数的平方根来估计。

$$SEM = \frac{S}{\sqrt{n}}$$

S：样本标准差

n：观测值个数

Chris Albon

标准化 STANDARDIZATION

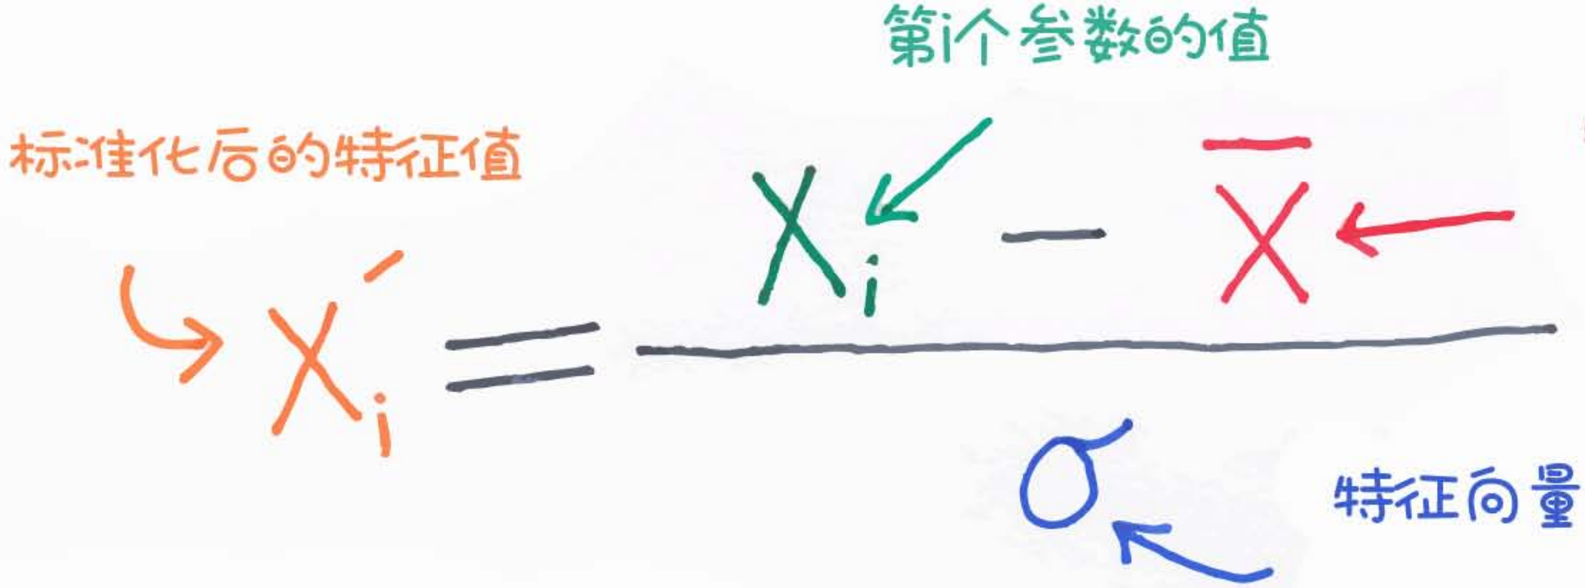

标准化是一种常见的缩放方法。X代表每个观察值偏离平均值的标准差的值。经过调整后的特征值均值为0，方差为1。

Chris Albon

驻点

Stationary Points

使函数导数为0的点

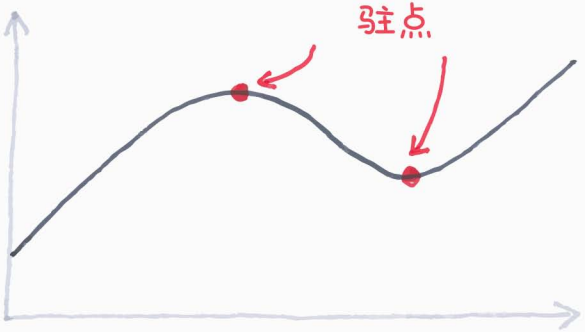

ChrisAlbon

词根

Stemming Words

词干提取是（通过）减少一个词（的字母）得到它的词根。其结果虽然对人类来说缺少了可读性，但可以令文本在观测中更具有可比性。

例如：“tradition”和“traditional”有相同的词根“tradit”

ChrisAlbon

随机梯度下降

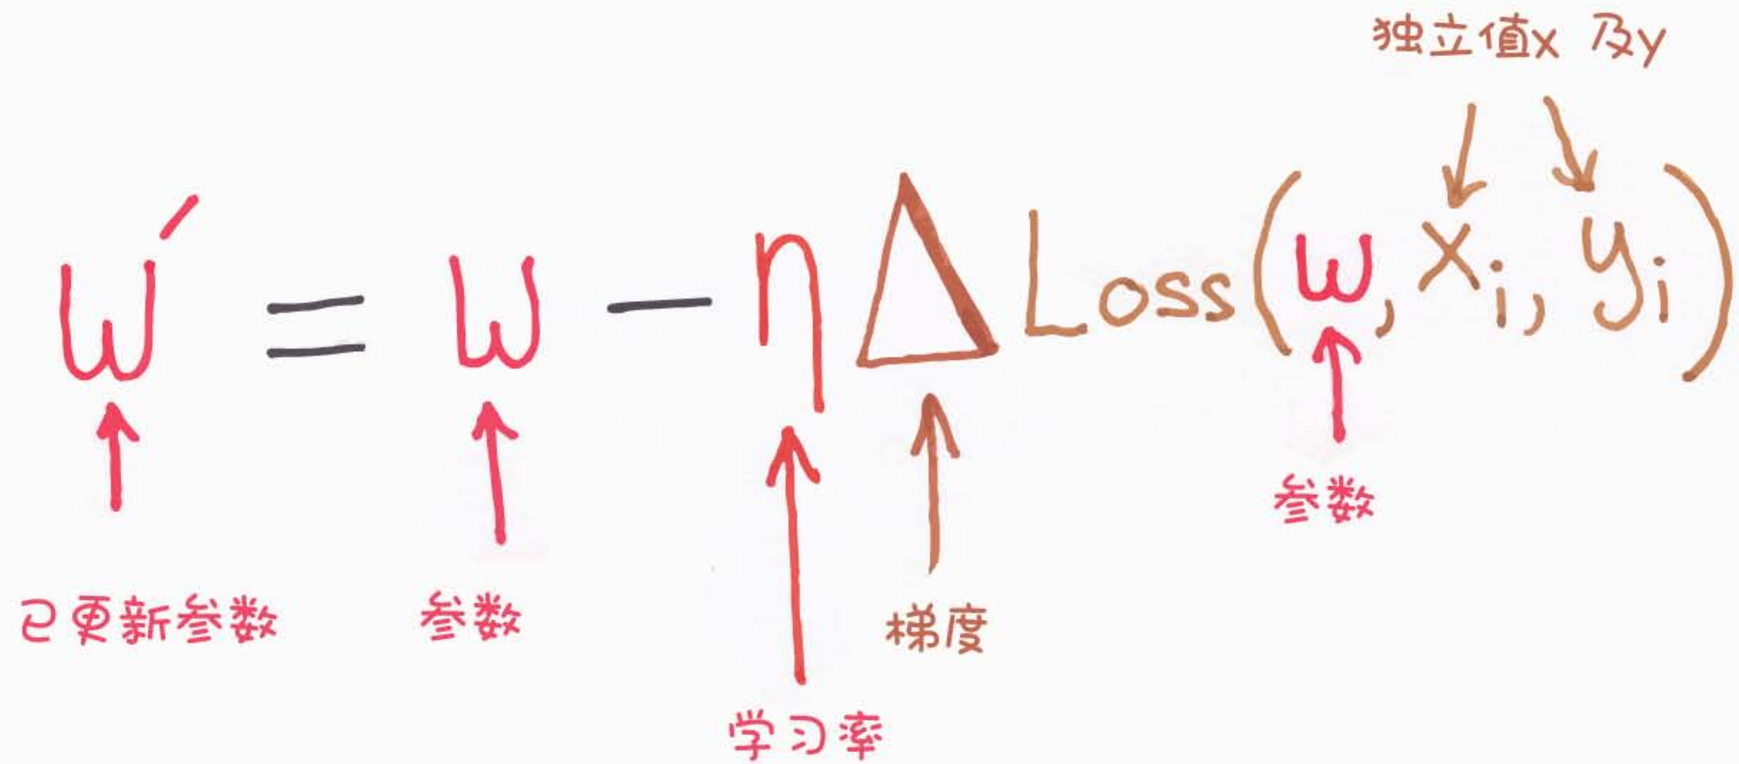

1. 随机重排整个观测集；
2. 对每一个观测值：
3. 重复（1，2）直到获得

BY CHRIS ALBON

停用词
stop words

处理自然语言数据（或文本）前需要移除的词。常用停用词都是含有极少信息价值的极其常用的单词。

例如：
- 它
- 我
- 我自己
- 我们
- 和

Chris Albon

处理高度不平衡数据策略

Strategies For Highly Imbalanced Classes

1. 收集更多数据
2. 选择一个适合类别不平衡数据的损失函数，比如查准率或者查全率
3. 加权
4. 降采样和升采样

Chris Albon

应对高方差（过拟合）时的策略

Strategies When You Have High Variance

权重衰减

添加dropout层或使用bagging的集成学习方法

降维

特征选择

*译者注：

过拟合另外的解决方法为：增加训练集数据大小，增加范数（L1，L2）等

ChrisAlbon

监督式深度学习的核心规则

supervised deep learning rule of thumb

如果想获得好的结果每个类别的样本数至少要达到：**5,000**

如果想达到人类水平的预测成绩，样本总数至少要达到

10,000,000

BY CHRIS ALBON

监督学习vs非监督学习
supervised vs unsupervised

在监督学习中，对于每个样本，我们有一些特征值和一些以向量或张量形式表示的标签。我们同时使用它们来训练模型，输入给它一些x值然后得到一个预测值。

在无监督学习中，我们只有特征并没有标签。这会使得预测结果变得困难，如果可以的话，尽可能使用有监督学习。

Chris Albon

支持向量机分类器

Support_Vector_Classifier

找到一个能够通过最大间隔来分割不同类别的样本的线性超平面

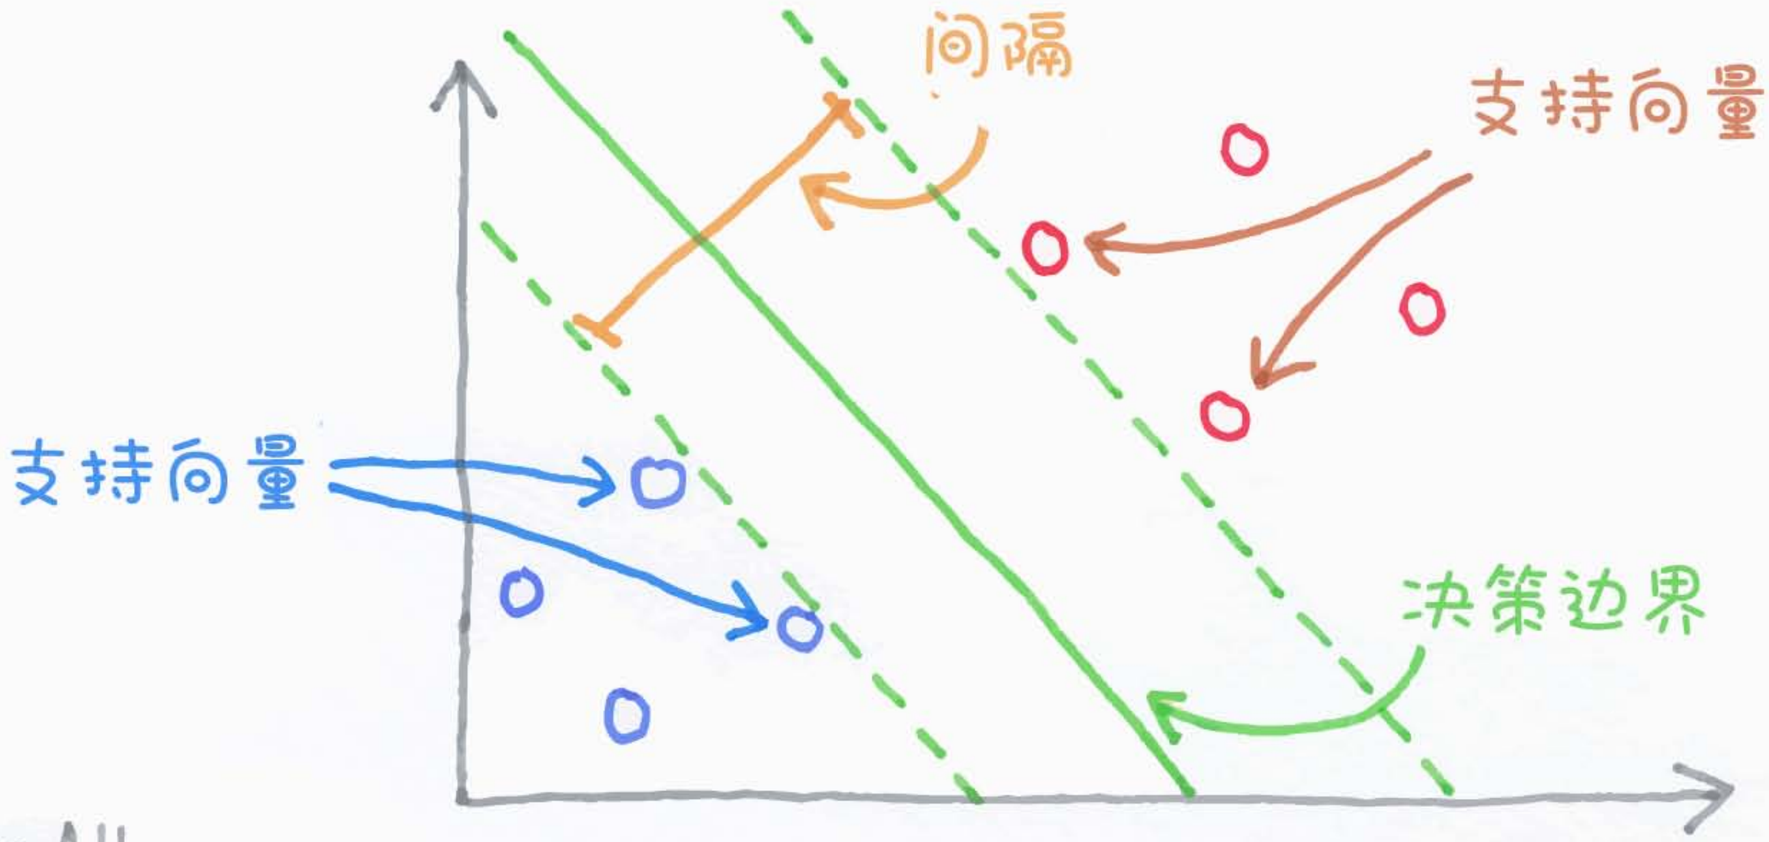

Chris Albon

支持向量机的软间隔分类

SVC soft-margin classification

参数

目标函数 $= \frac{1}{2}\|w\|^2 + C\left(\sum_i \xi_i\right)$

松弛变量：

超参数C用来控制误分类的惩罚程度

大于等于1，表示该样本被误分类；在0到1之间，表示该样本在间隔区间中浮动，但不是误分类的样本。

*译者注：

等于0时，表示该样本恰好落在间隔边界上

Chris Albon

支持向量
support veators

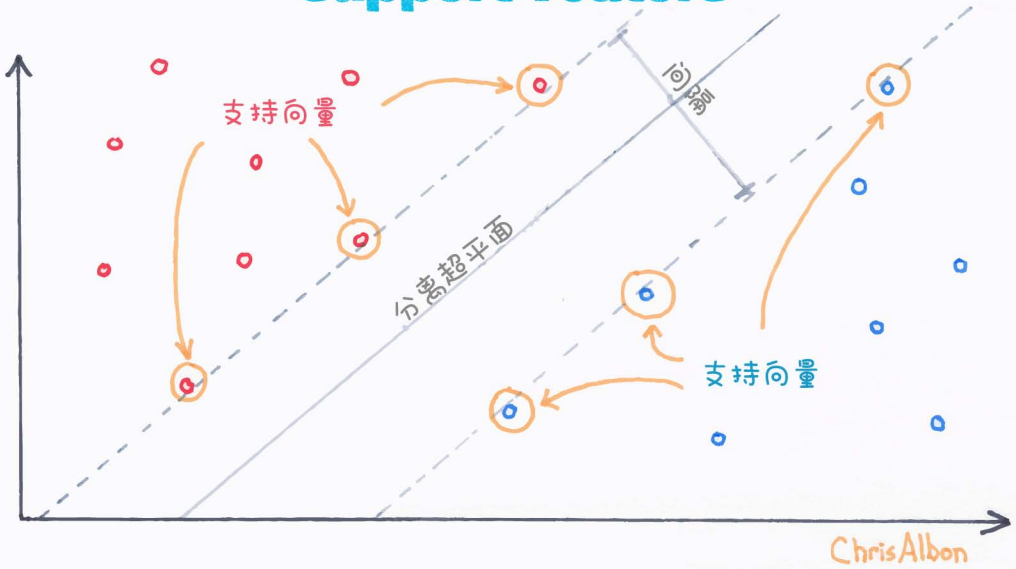

SVC的径向基函数核

svc radial basis function kernel

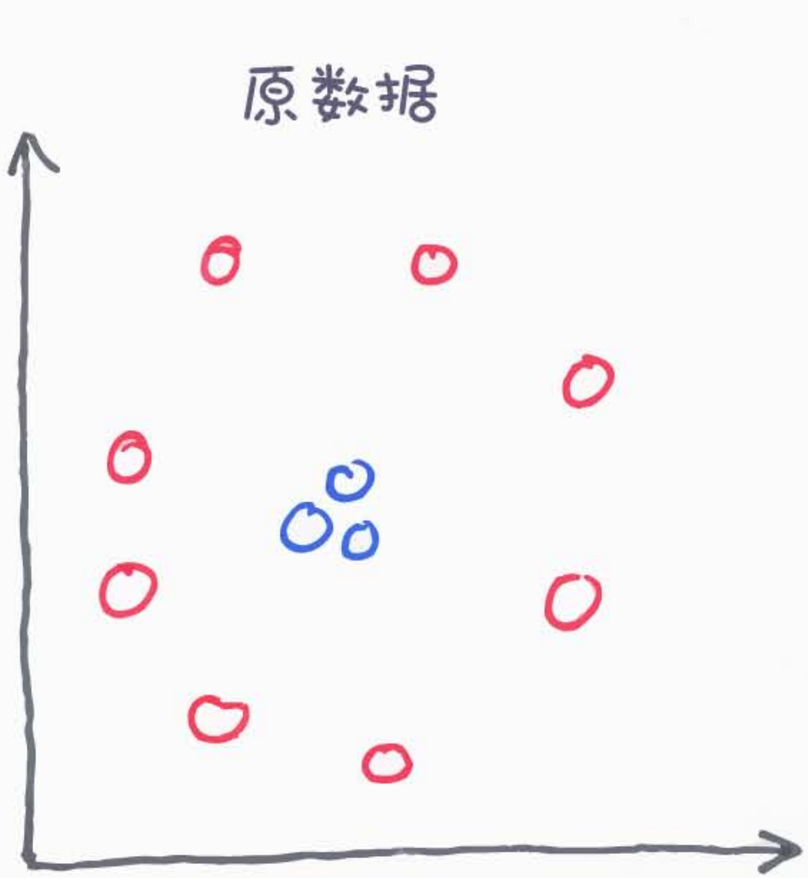

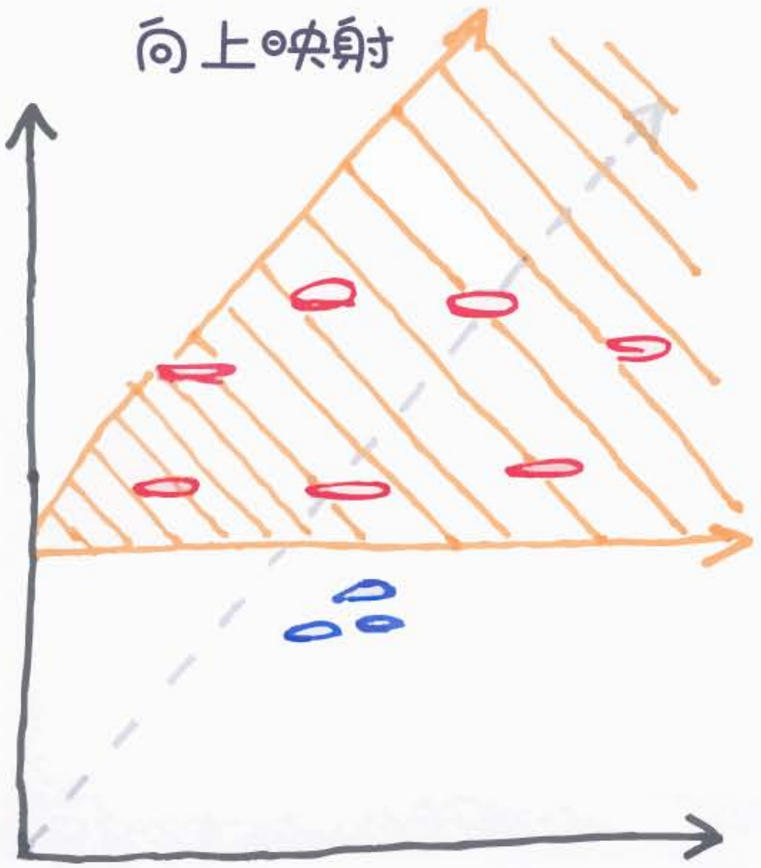

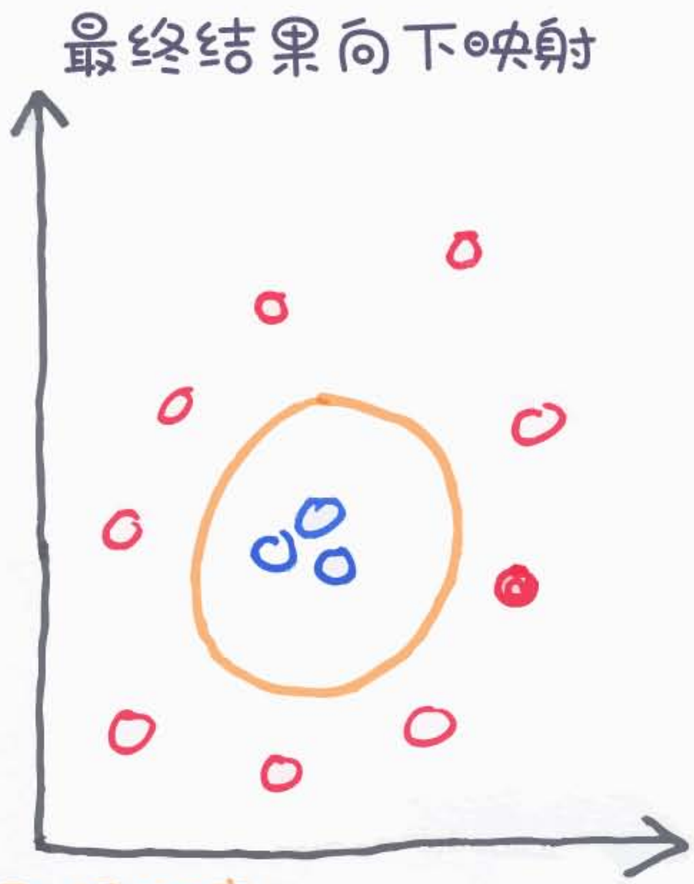

*译者注:

径向基函数是一个取值仅仅依赖于离中心点距离的实值函数，一般使用欧氏距。

$$\exp\left[\frac{\|x_i - x_j\|^2}{2\sigma^2}\right]$$

欧氏距离

BY CHRIS ALBON

T 统计量

t-statistics

某个参数偏离常数的标准差的数量

*译者注:
t统计量用来对模型中关于参数的单个假设进行检验的一种统计量。

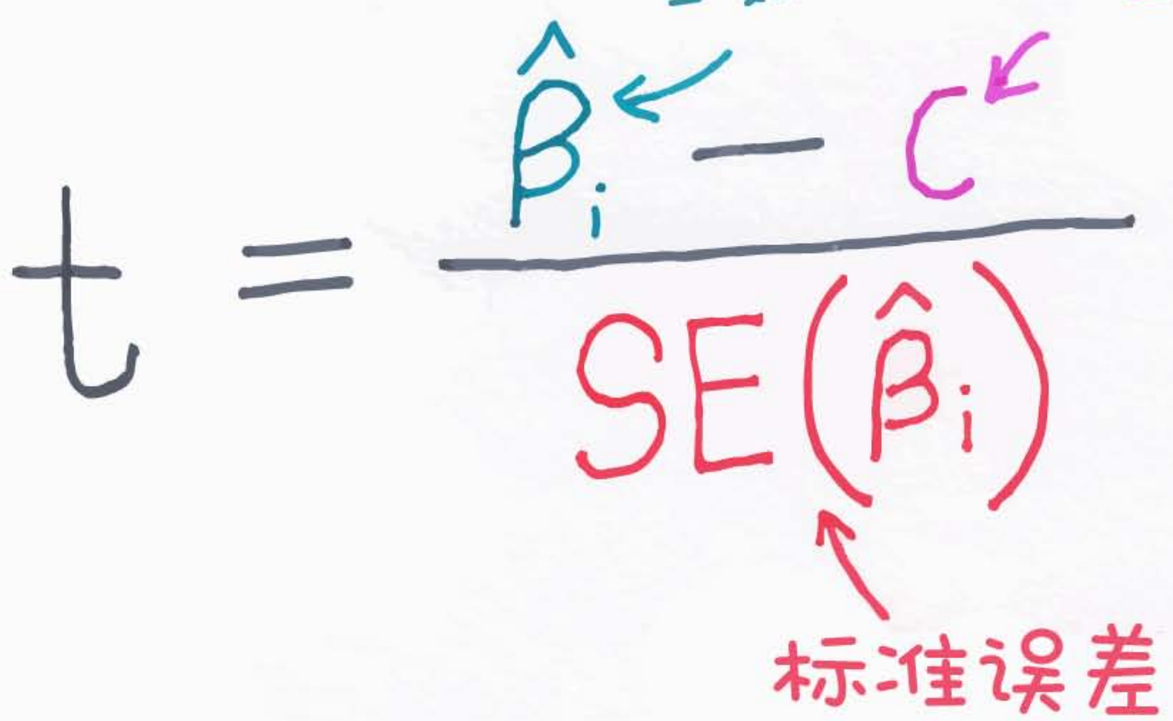

Chris Albon

双曲正切激活函数

hyperbolic tangent activation function

经常用来替代sigmoid激活函数

$$\phi(z) = \frac{\sinh(z)}{\cosh(z)}$$

由于tanh的值域范围在-1到1之间，所以相比较sigmoid梯度不容易变得很小

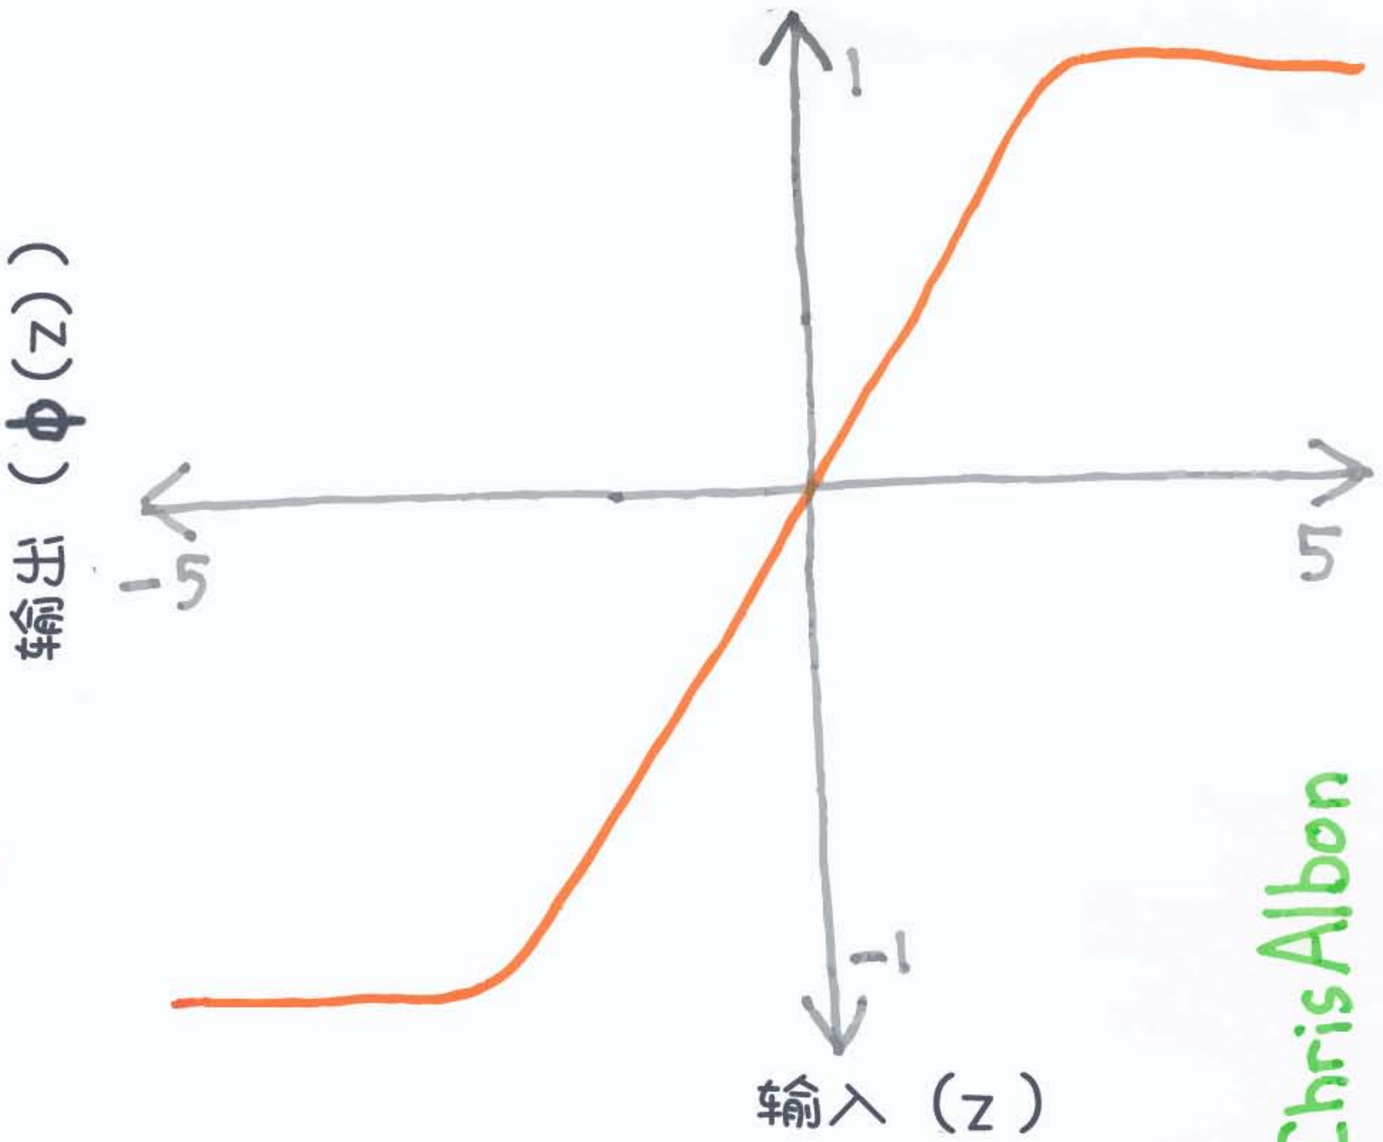

ChrisAlbon

张量
tensors

以“网格”坐标形式排列的n维数组

1维张量（向量）

2维张量（矩阵）

3为张量

ChrisAlbon

测试集、训练集、验证集
test,training,validation sets

训练集:用于寻找最小损失的权重的数据

验证集:用于调优学习算法的超参数的数据

测试集:用于评估模型普遍适用性的数据

Chris Albon

信息检索数据挖掘的常用加权技术

TD-IDF

是一种衡量词原创程度的评价方法，通过将一个词在一个文档中出现的次数和这个词出现过的文档数量进行比较。

$$TF\text{-}IDF = TF(t,d) \times IDF(t)$$

$TF(t,d)$：词的频率

$IDF(t)$：逆文本频率指数

次数+出现在文档中，d的文档

$$\log\frac{1+n}{1+df(d,t)}+1$$

术语t的文本频率

丢弃对于隐含单元的影响

the effect of dropout on hidden units

在丢弃过程中，要保证每个隐含单元必须学会在不受神经网络内其他单元的影响下表现良好。这种学习的稳健性可以帮助整个网络系统面对未见的测试数据时也能表现良好

Chris Albon

特征缩放对梯度下降的影响

the effect of feature scaling gradient descent

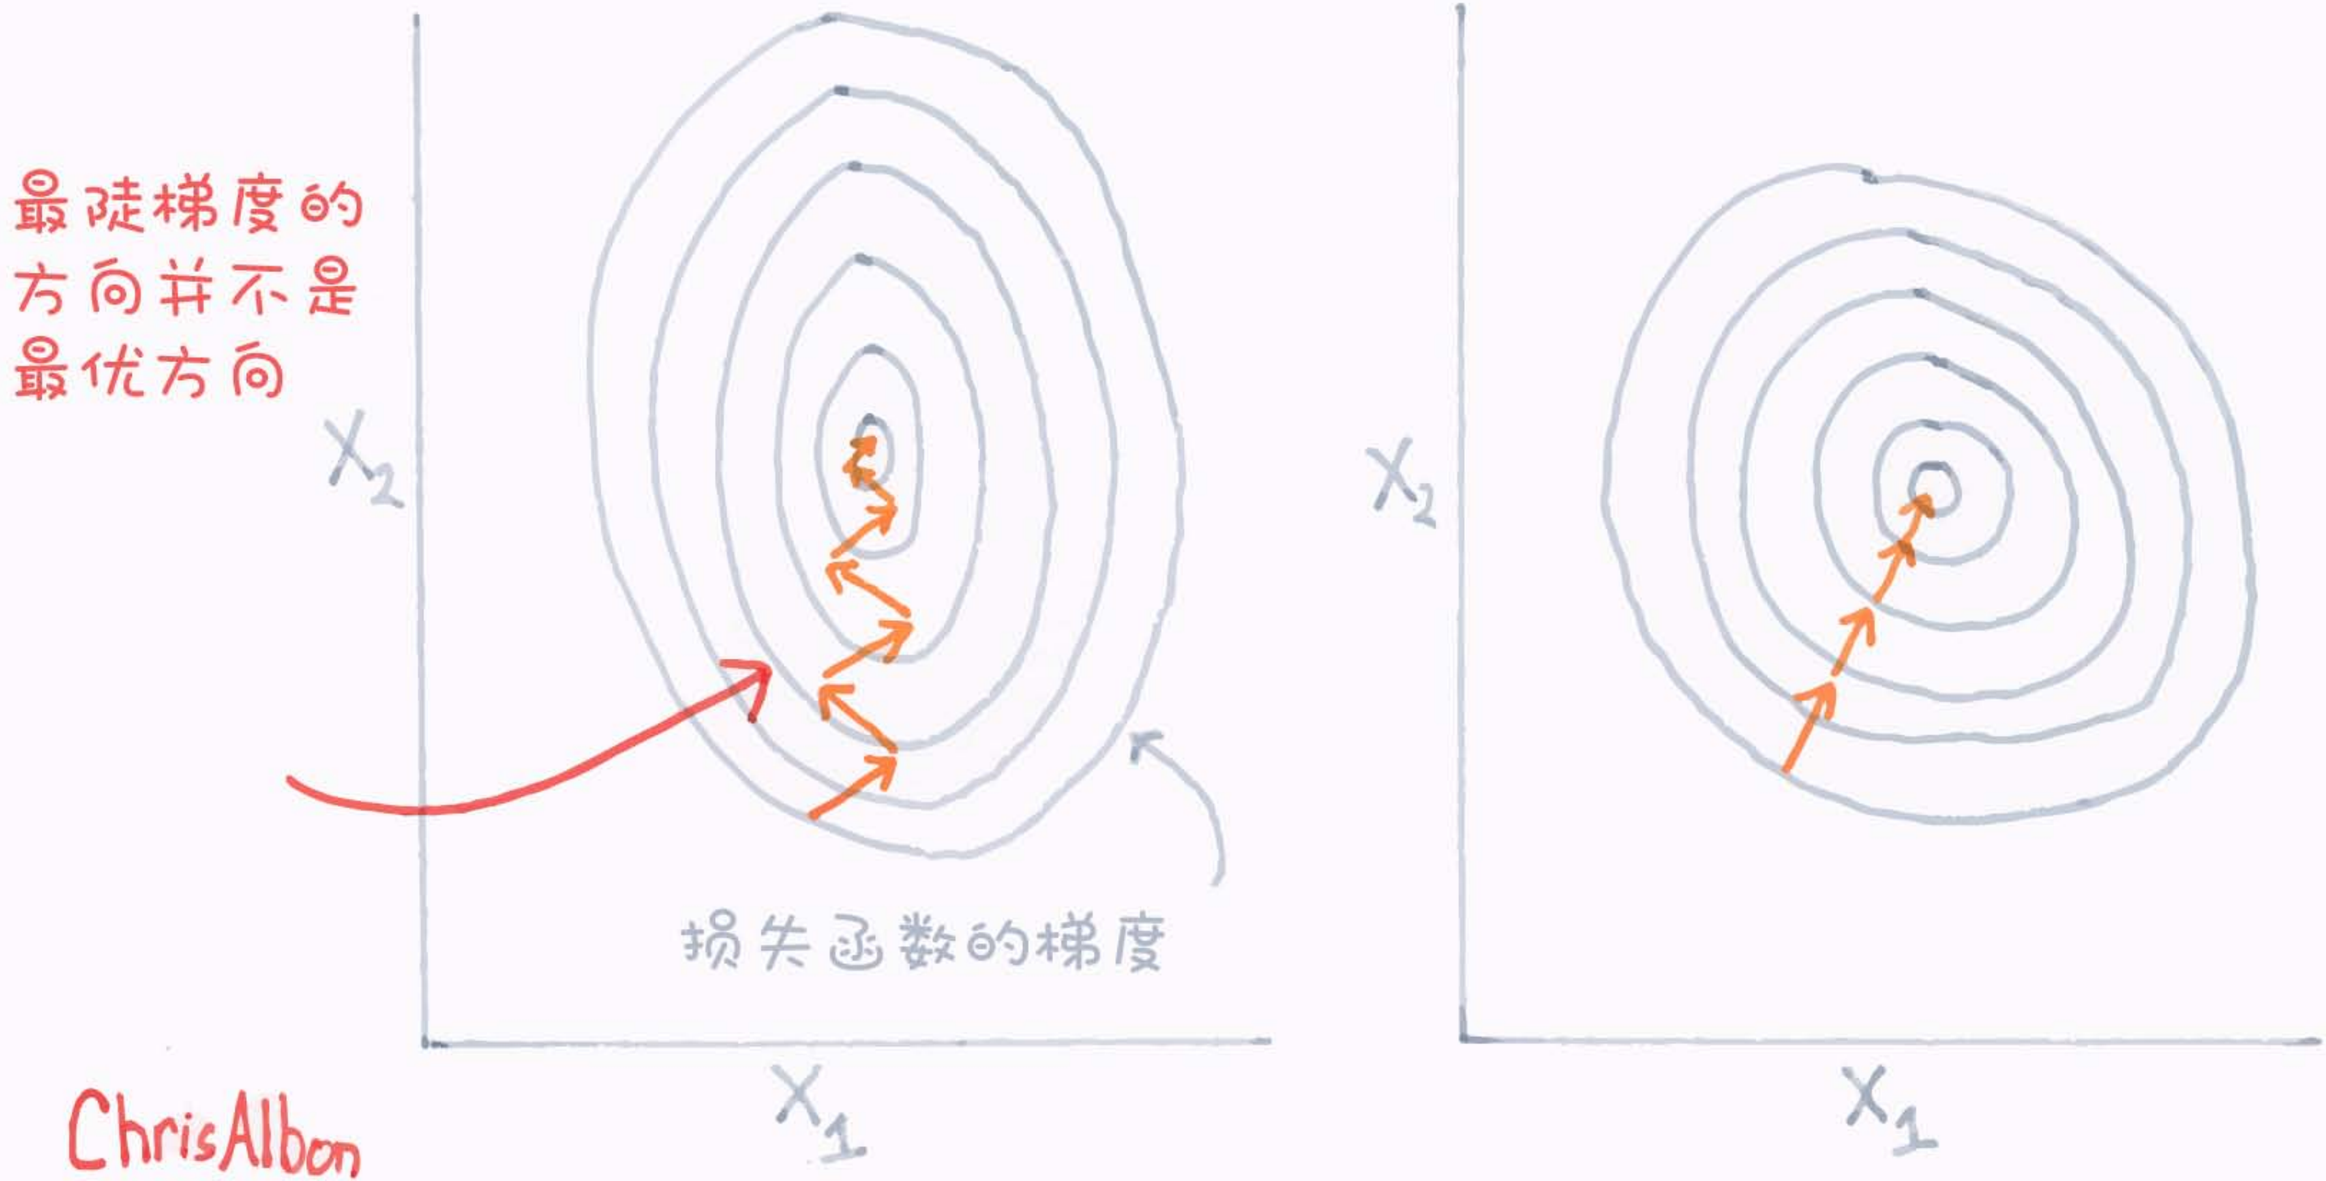

ChrisAlbon

模型的复杂度对训练和测试误差的影响

the effect of model complexity training and test error

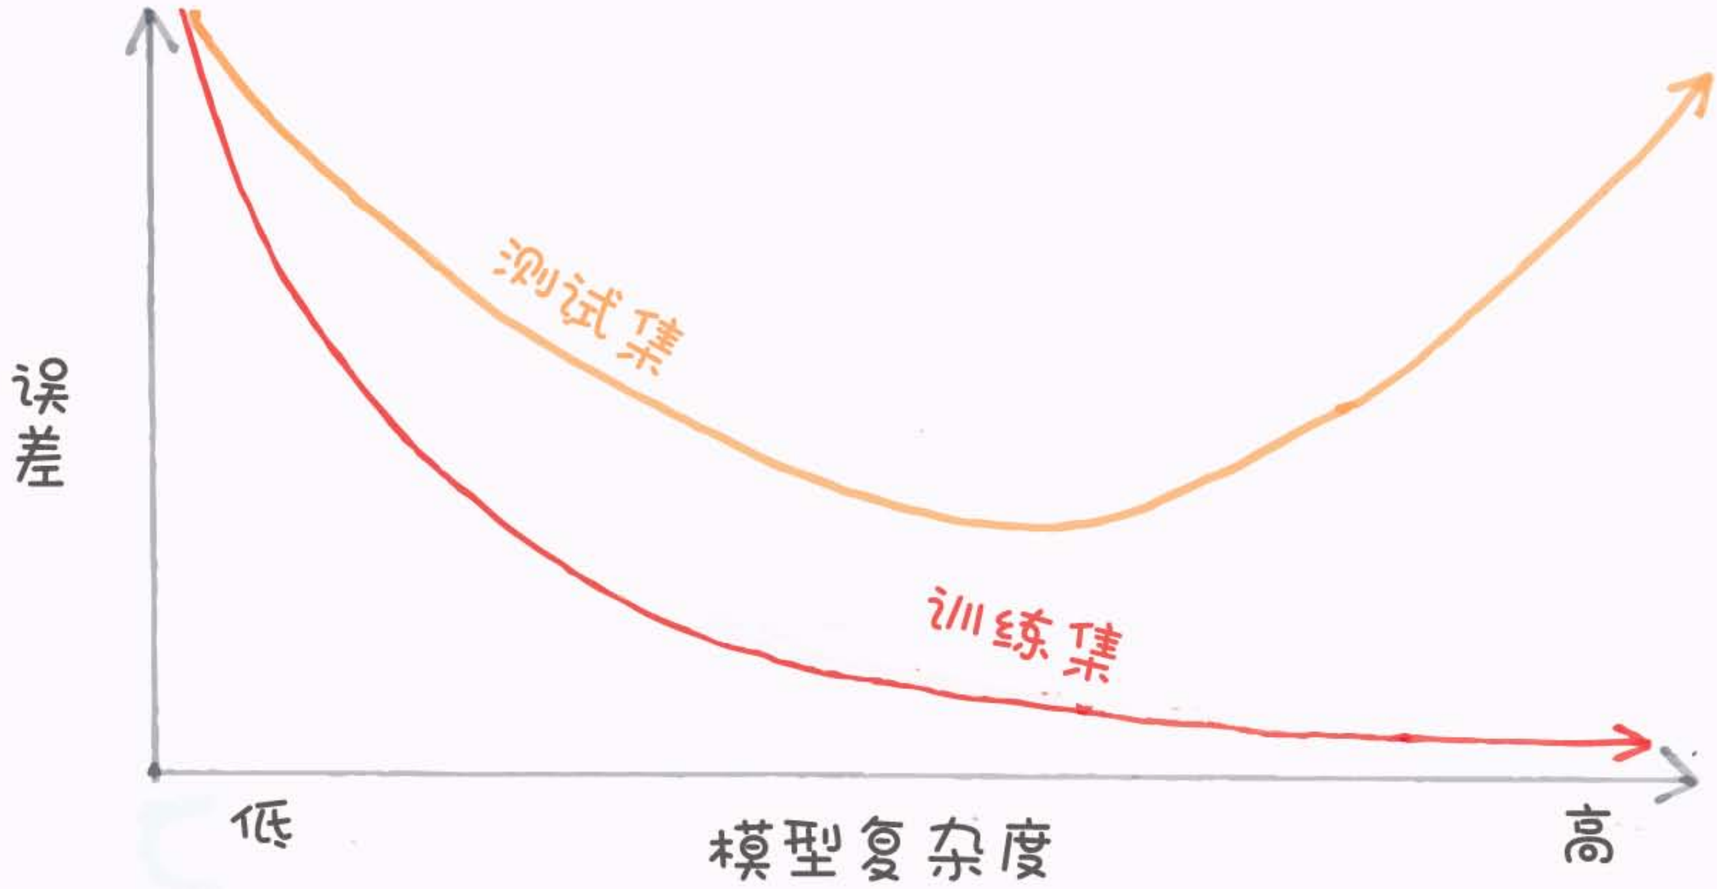

ChrisAlbon

随机森林中的随机性

the random in random forest

1. 每棵树都有一个随机的观测样本。

2.每棵树都得到一个从观测值中有放回地随机抽取的样本。

Chris Albon

所以/因为 的表示符号

therefore and because notation

所以

因为

BY CHRIS ALBON

激活阈

threshold activation

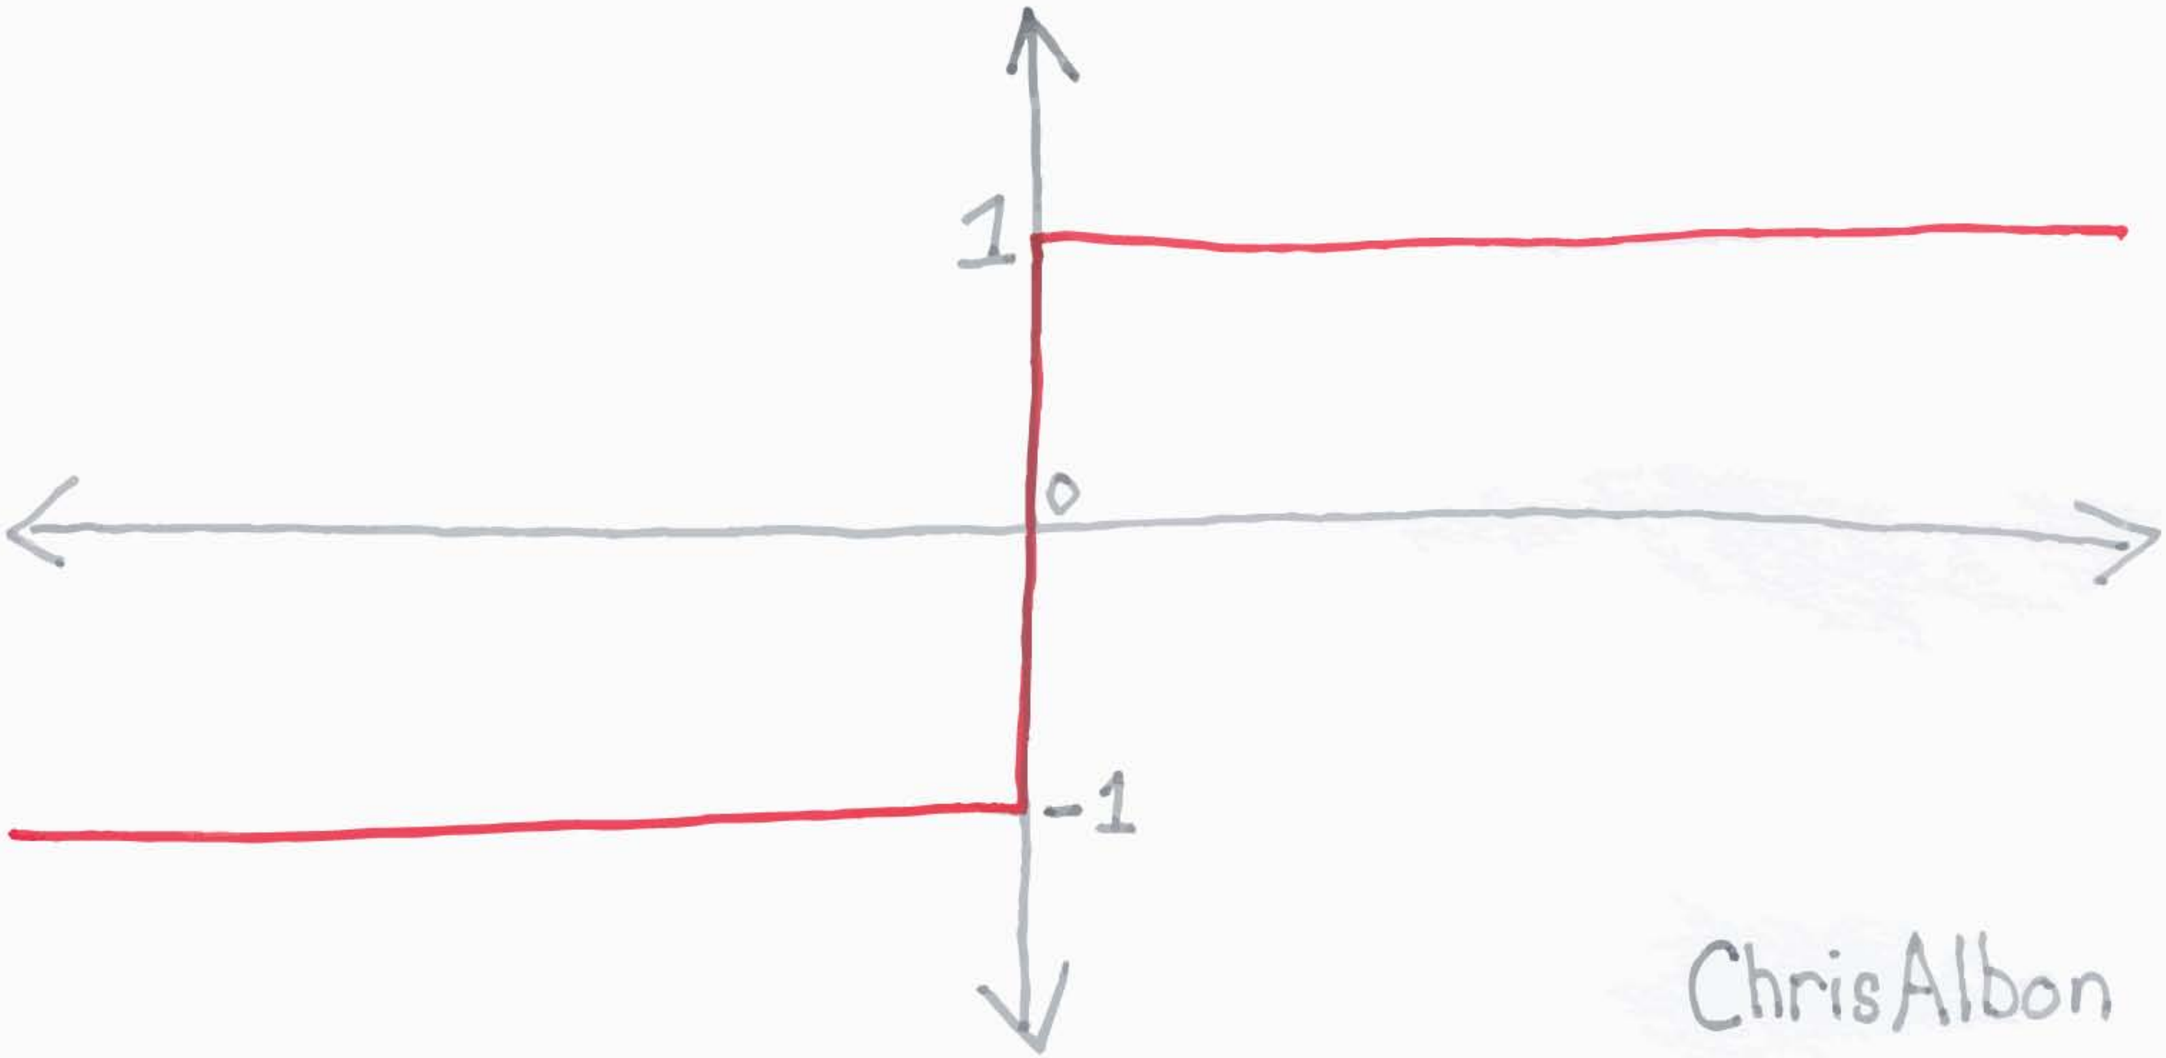

阈值类别特征的方差

thresholding categorical feature variance

受特征的方差越大包含更多信息的启发

在二分类变量中，方差是：

$$var(x) = p(1-p)$$

p：类别1样本的比例

方差比阈值小的特征将被丢弃

Chris Albon

切分文本

tokenize text

将文本分割为单独的语义单元，如段落，句子或者词

例如：

“我喜欢小鸟”————“我”，“喜欢”，“小鸟”

ChrisAlbon

邻域链接

TOMEK LINK

邻域链接：

1.x的最邻近单元是y；

2.y的最邻近单元是x；

3.x、y属于不同的类别。

删除邻域链接后可以提高模型性能，但当n数目很小或类不平衡时会问出现问题。

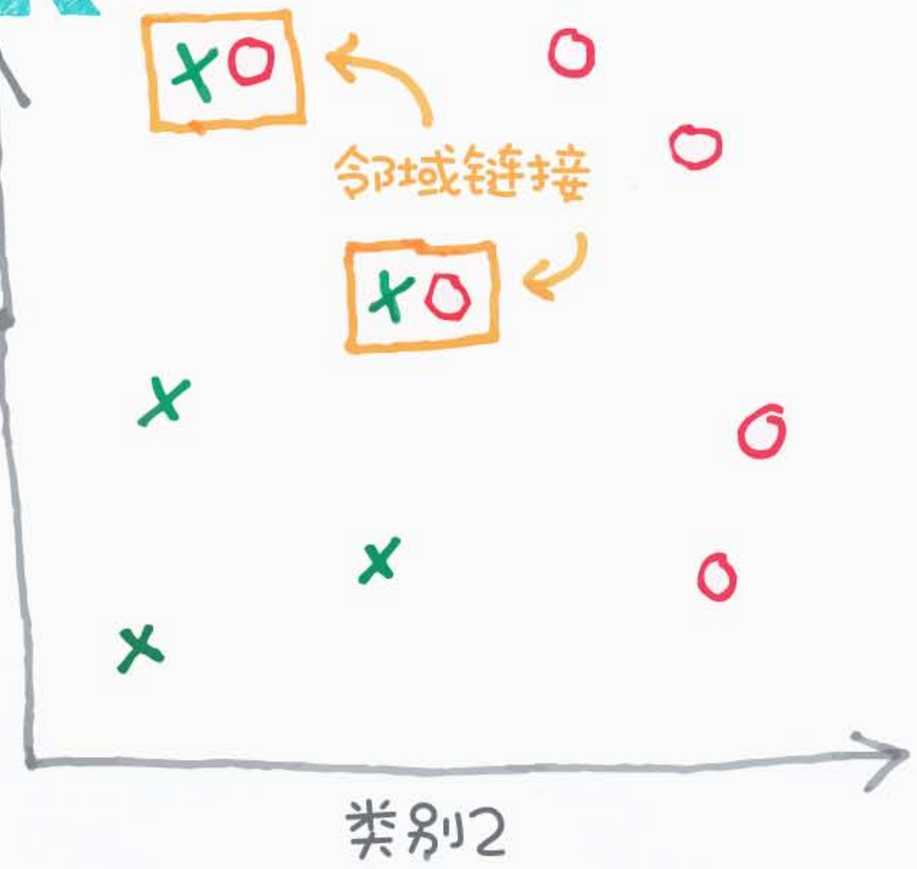

Chris Albon

TSS总平方和

$$TSS = \sum_{i=1}^{n} \left(y_i - \bar{y} \right)^2$$

y_i 真值

$\bar{y}$ yi平均值

ChrisAlbon

训练误差和测试误差

TRAINING AND TEST ERROR

训练误差度量模型在训练数据集上的表现

（注：训练数据集是指训练模型所用的数据集）

测试误差度量模型在未知数据集上的表现

ChrisAlbon

训练错误率

Training ERROR RATE

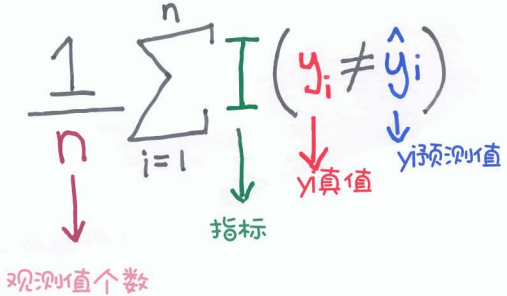

预测错误 / 所有预测

BY CHRIS ALBON

TPR 真正类率

$$TPR = \frac{\text{真正类}}{\text{真正类} + \text{假正类}}$$

ChrisAlbon

典型的丢弃概率

typical dropout probabilities

20% 的输入层神经元被丢弃。

50% 的隐藏层神经元被丢弃。

*译者注:

神经元多的层应该被设置更小的keep_prob，不同层的keep_prob应该设置的不一样

Chris Albon

来源：deep learning

欠拟合

underfitting

当模型尝试挖掘数据中的模式失败时我们称这个模型欠拟合。它受到高偏差的影响。

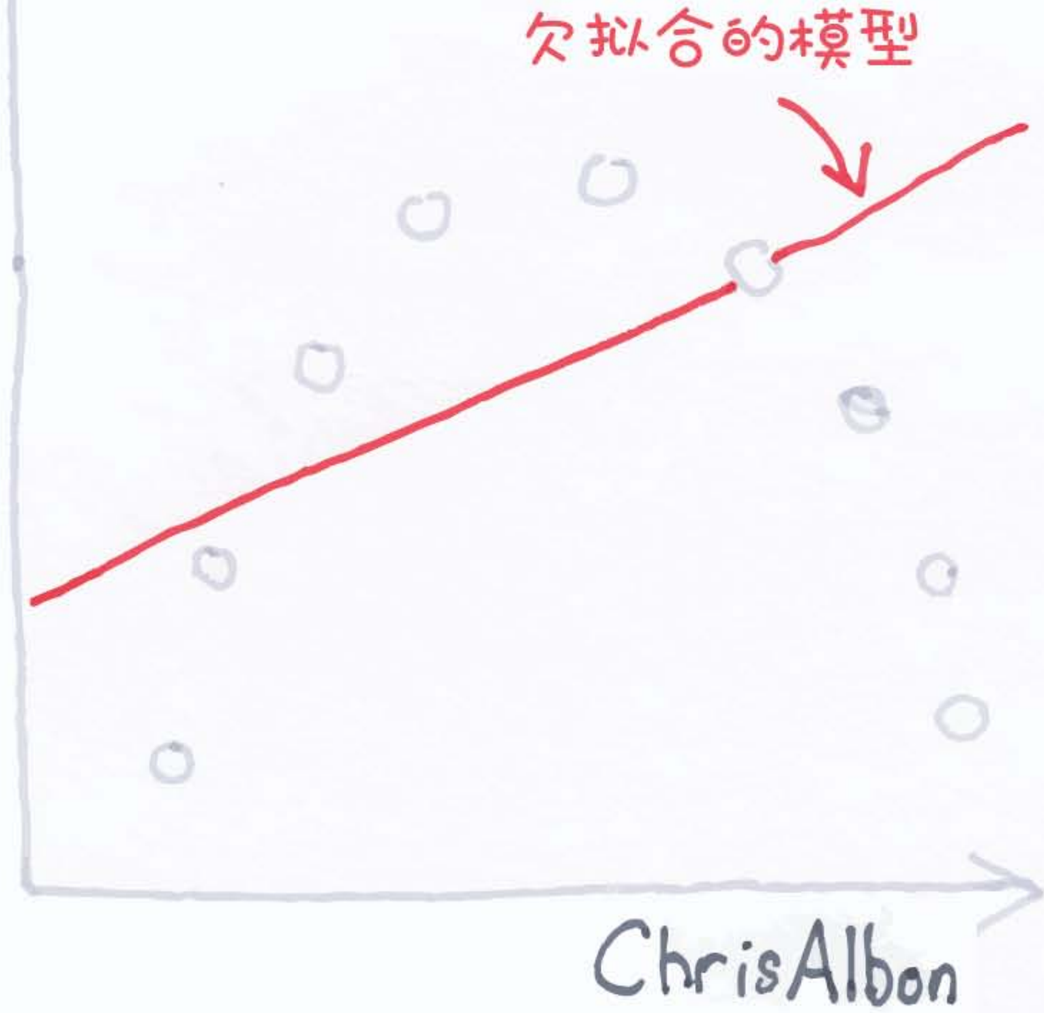

*译者注：
常见的解决方案为：
数据：
1. 清洗数据
特征：
1. 增加特征
2. 删除噪音特征
模型：
1. 调低正则项的惩罚系数
2. 换更复杂的模型（非线性模型）
3. 多个模型级联或组合

数值下溢
underflow

当这个数字太小了以至于计算机难以表示它时，下溢就会出现。计算机通常会把这些值四舍五入为0。

但这会造成问题（比如梯度消失问题），因为0通常和极小数的性质有很大差异。

Chris Albon

弱学习器

weak learners

弱学习器模型没比随机分类好多少

常用在boosting算法中

最大深度决策树，也被称为剪枝，
常被用作弱学习器

Chris Albon

权重衰减
weight decay

使用L2正则化的参数惩罚项：

L2的正则化惩罚项

$$Loss = Loss + \frac{1}{2}\|w\|_2^2$$

Loss：损失函数　Loss：损失函数　w：权重

在回归中，L2正则化惩罚项的使用称为岭回归

ChrisAlbon

何时有缺失值的样本才可删除？

When Can We Delete Observations With Missing Values

我们不情愿删除有缺失值的样本。不过，如果缺失是随机的或者出于某些原因缺失值可以在其它特征中体现，那么删除这样的样本是可以的。否则，某些值缺失本身就是某种信息的体现，而删除这样的样本会使数据产生偏差。

ChrisAlbon

当N=整个母体
WHEN N=POPULATION

问题：当我们的“样本”是全部内战时，为何还用统计来研究呢？

这是因为根本不确定性。我们可能拥有所有已观察到的内战的数据，但是我们没有未发生的内战的数据。

当一个理论涉及到一系列事件的发生的过程时，那些可能事件，除了事实事件，是相关的。
-Gailmard 2014

Chris Albon

什么是代价（损失）函数

WHY IT CALLED A COST FUNCTION

代价（或损失）函数是在训练过程中需要最小化的目标函数。这是使用模型，而不是事实，的“代价”

Chris Albon

WORD2VEC 自然语言训练模型

使用浅层神经网络将单词映射到向量空间，其中相似上下文的单词具有相近的向量。

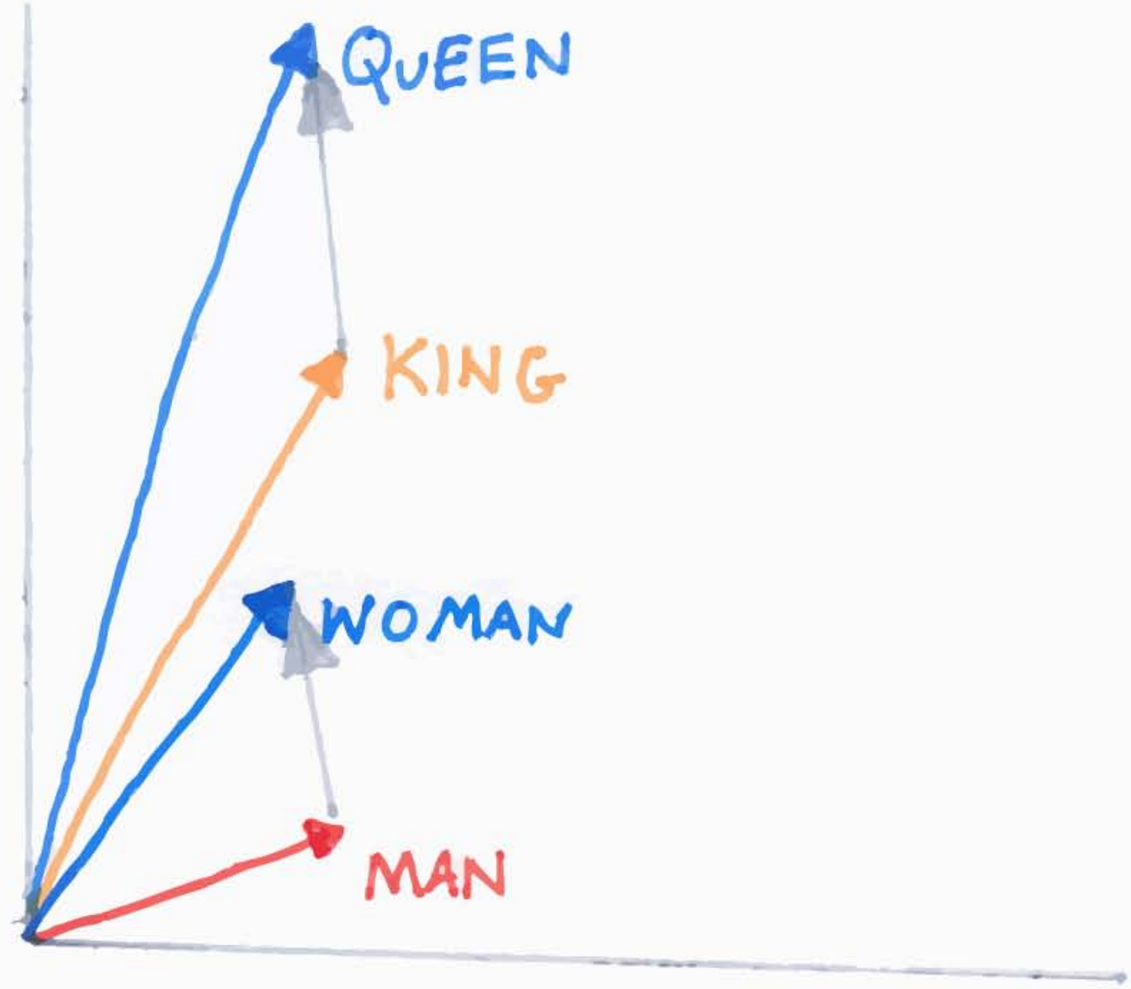

Chris Albon

异或函数

XOR FUNCTION

$f([1,0]) = 1$

$f([1,1]) = 0$

$f([0,1]) = 1$

$f([0,0]) = 0$

BY CHRIS ALBON

约登指数

模型预测正例样本的表现

模型预测负例样本的表现

$$J = \frac{TP}{TP + FN} + \frac{TN}{TN + FP} - 1$$

其值在-1和1之间。值为0时模型无用。通常用于选择ROC曲线的截止点。约登指数（J值）越大越好。

零损失

指示函数

$$L_{0-1}(y, \hat{y}_i) = \mathbb{1}(\hat{y}_i \neq y_i)$$

真正的类别

预测的类别

真正的类别

BY CHRIS ALBON

超平面
hyperplane

在一个n维空间中，超平面是一个分割该空间的n-1维的平面。

*译者注：

超平面是n维欧氏空间中n-1维的线性子空间

也就是说，如果空间是二维的，其超平面是一条直线

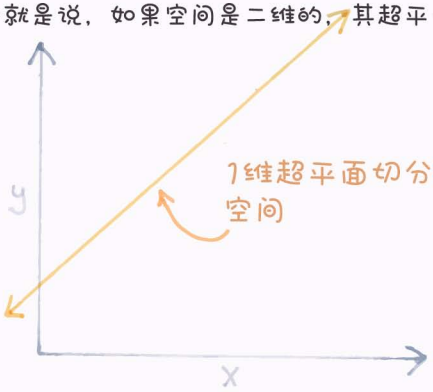

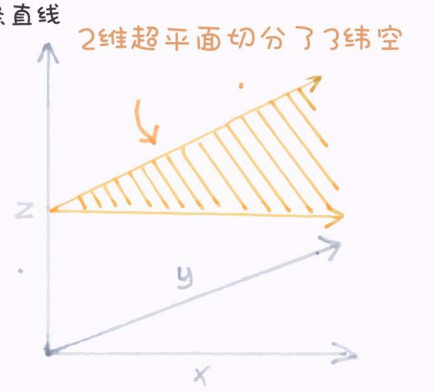

ChrisAlbon

假设空间
hypothesis space

假设空间是一个模型当中，用于减小损失的，合理的函数集合

例子：

带有线性核函数的支持向量机，只能用线性函数作为其决策边界

Chris Albon

独立同分布

Independent and identically distributed

独立性：

每个观测值都是一个独立事件

同分布：

每个观测值都服从同一个分布

*译者注：

原文中提到的观测值，观测的是随机变量

ChrisAlbon

用K-NN填补缺失值

*译者注：

寻找10个左右的相似样本（距离最近的），使用这10个特征的中位数或者加权均值的方式进行填补

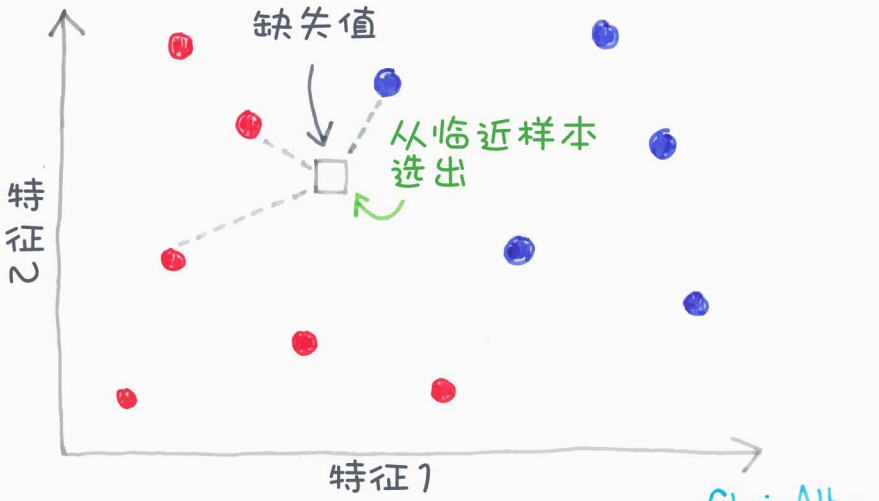

填补缺失值

Imputing missing value

1.如果是定量分析，就用平均值填补。

2.如果是定性分析，就用众数填补。

3.用模型来预测缺失值。比如用k临近值来建立模型预测。

ChrisAlbon

拐点 Inflection point

拐点是函数图像上由凸函数变成凹函数的点，或者是反过来由凹函数变成凸函数的点。

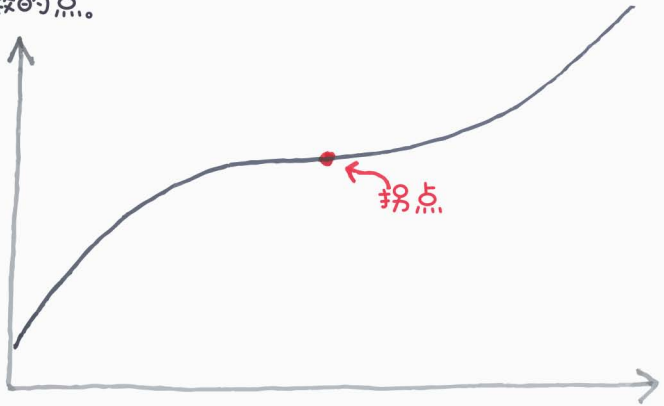

ChrisAlbon

神经网络参数的初始化

Initialization Of Neural Network Parameters

——参数通常从均匀分布或正态分布中随机提取，初始化成最小值。

——参数的初始化规模，太大或太小都不好

——标准初始化是的Scale的解决方案之一：

均匀分布

$$U\left(-\sqrt{\frac{6}{m+n}}, \sqrt{\frac{6}{m+n}}\right)$$

输入层数

输出层数

Chris Albon

在前向神经网络中初始权重

Initializing Weights In Feedforward Neural Networks

— 以小的随机数作为初始值

— 通常从正态分布中抽取初始权重值

— 偏差预置为0 或者小正数

Chris Albon

工具变量

Instrumental variables

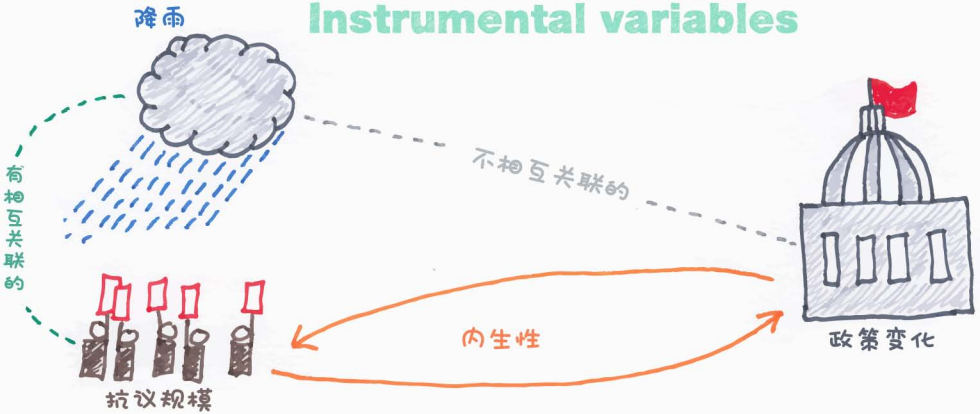

Chris Albon

我们用“抗议规模”代替“降雨”，来解决内生性问题。因为“降雨”与“政策变化”无关，却与“抗议规模”相关，所以“降雨”和“政策变化”的任何关系都必须来自“抗议规模”。

交叉项

Interaction term

当目标特征变化受到另一特征影响时，交叉项允许我们建立关系模型。

$$y=\beta_0+\beta_1 x_1+\beta_2 x_2+\beta_3 x_1 x_2+e$$

特征X1和X2的相互影响。

ChrisAlbon

线性插值
Interpolaton

在已知的数值间换一条线来填补缺失数值的一种策略。

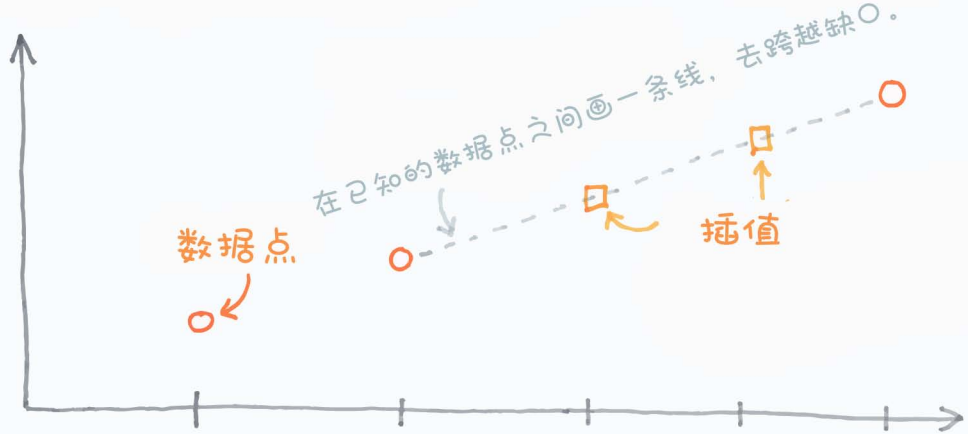

内距(又称四分位差)
Interquartile Range

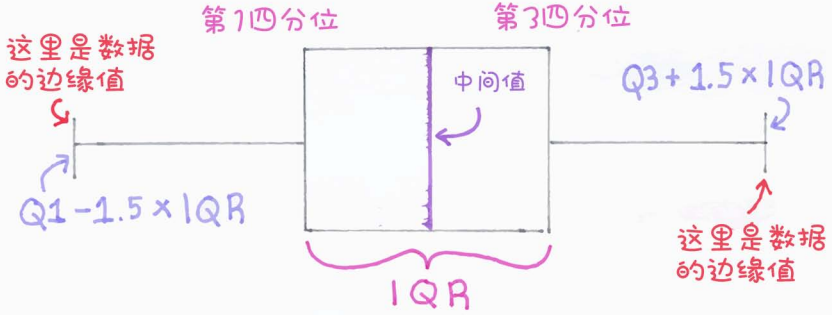

译者注:

IQR = Q3-Q1　　Q3+3IQR 和 Q1 - 3IQR处画两条线段，称其为外限

Q2 中位数　　Q3+1.5IQR 和 Q1 - 1.5IQR：异常值截断点

ChrisAlbon

普拉托变换的相关问题

Issues With Platt Scaling

1.由于我们训练了额外的交互验证模型，单位时间内的资源会有一个明显的增长

2.由于预测概率已知，因而可能会造成预测结果与预测概率不匹配

Chris Albon

雅可比矩阵

Jacobian Matrix

当一个函数的输入和输出都是向量的时候，包括了所有一阶偏导的矩阵叫做雅可比矩阵。

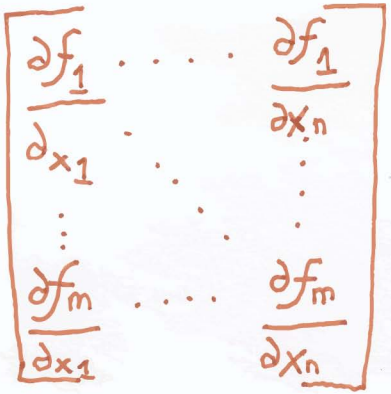

Chris Albon

JOINS

*译者注：此乃SQL的多表连接语句

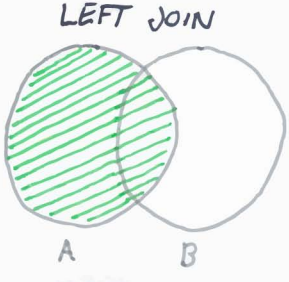

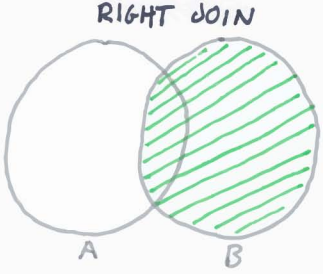

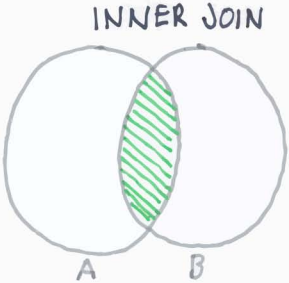

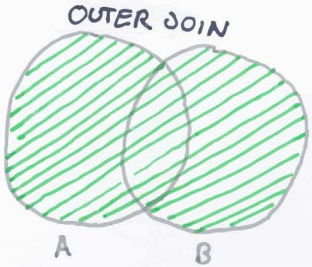

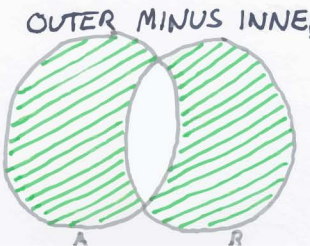

BY CHRIS ALBON

K折交叉验证
K-Fold Cross-Validation

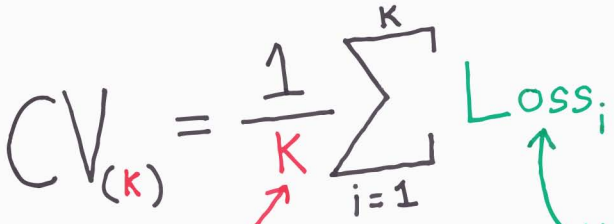

Chris Albon

K-means聚类算法
K-Means Clustering

1、随机地初始化k个中心点
2、样本被分配到最近的中心点
3、中心点移动到聚合后的样本中心
4、重复第2步和第3步，直到第2步没有样本再移动为止。

Chris Albon

kNN算法
k-nearest neighbors

-k代表参与计算的邻近单元数量；
-k的取值比较重要；
-k值一般为奇数；
-如果我们有二进制特征，可以利用海明距离计算；
-以待分类单元与邻近单元的距离为权重进行分类；
-不适合用于大量数据的分类。

假设k=3，那么灰色方块将被预测为绿色，这是因为与它最邻近的三个单元中，两个是绿色的，一个是红色的。

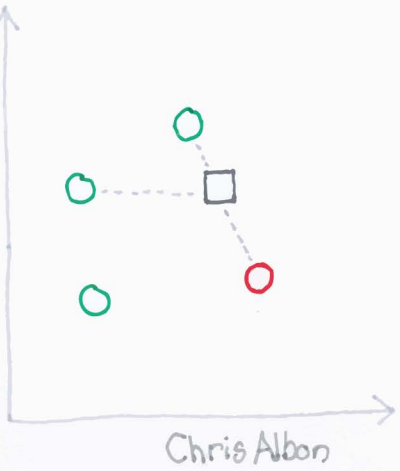

KNN算法的小技巧

k-nearest neighbors tips and tricks

1. 所有的特征应该被放缩到相同的量级

2. 为了避免平票的出现，K应该选择奇数

3. 投票的结果会被到近邻样本的距离归一化，这样更近的样本的投票价值更大

4. 尝试各种不同的距离度量方法

ChrisAlbon

K近邻中K的大小
K-NN Neighborhood Size

k值小时

K= 低偏移，高方差

K= 高偏移，低方差

k值大时

BY CHRIS ALBON

高斯朴素贝叶斯分类器
Gaussian Naive Bayes Classifier

称之为“高朴”是因为这是一个正态分布

这是我们的先验信念

$$P(\text{class} \mid \text{data}) = \frac{P(\text{data} \mid \text{class}) \times P(\text{class})}{P(\text{data})}$$

我们在朴素贝叶斯分类器中不用计算这个概率值

*译者注：

不需要计算P(data)是因为它与类标记无关。

高斯朴素贝叶斯是针对连续值特征的，离散特征的话直接计算出现的频率就ok。

ChrisAlbon

基尼指数
GINI INDEX

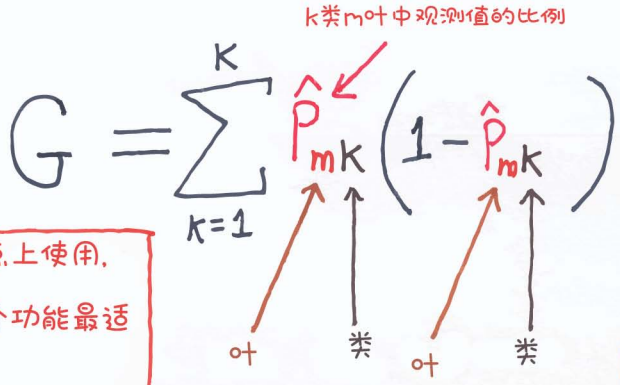

在每个节点上使用，以决定哪个功能最适合拆分。

G 的值越小，节点中的分布就越平均。

基于随机树方法的测量

BY CHRIS ALBON

Grabcut 算法——用于去除图片背景

grabcut for removing image backgrounds

1.用户在目标外面画一个框，把目标框住.

2.所有在框外部的部分被视为背景，所有在框内部的部分被视为未知的.

3.crabcut算法的原理是去除框内那些看起来像框外的内容。

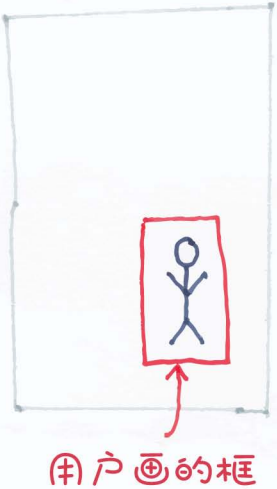

Chris Albon

梯度悬崖

gradient cliff

当损失函数急剧下降时会产生梯度悬崖。若陡坡导致优化算法的值超过最小值，会引起问题。

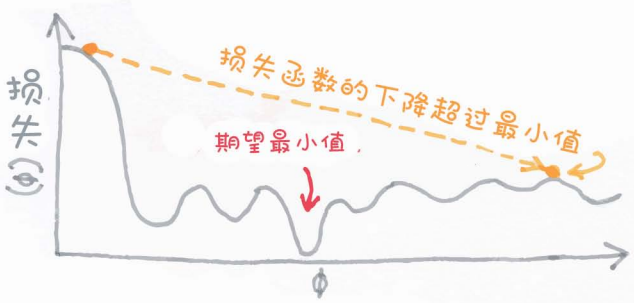

Chris Albon

梯度裁剪
gradient clipping

损失函数中的梯度悬崖会导致模型在学习过程中超出期望最小值。发生这种情况，是因为梯度悬崖坡度太陡。解决方法：阻止梯度选择极端值。

ChrisAlbon